

Clase pasada $\rightarrow$ V.A. $\rightarrow$ Disc / cont


$\left\{ \begin{array}{l} \text{pmf} \\ p(x) \end{array} \right.$	$\left\{ \begin{array}{l} \text{pdf} \\ f(x) \end{array} \right.$	$\left\{ \begin{array}{l} \text{cdf} \\ F(x) \end{array} \right.$
---	---	---

$\left\{ \begin{array}{l} \text{Momentos} \rightarrow \text{Absolutos } E(x^k) \\ \quad \quad \quad \rightarrow \text{Centrados } E[(x-\mu)^k] \end{array} \right.$

Nos caracterizan a las variables aleatorias

$\left\{ \begin{array}{l} \text{Esperanza} \\ \text{Varianza} \rightarrow \text{desviación estándar} \\ \text{Covarianza} \rightarrow \text{correlación} \end{array} \right.$

$\downarrow$
son los parámetros que nos interesa conocer.



Algunos modelos para variables aleatorias

- | | | | | |
|-----|---|----------------------|---|-----------|
| Ej: | - | BERNOULLI / BINOMIAL | } | discretas |
| | - | POISSON | | |
| | - | NORMAL | } | continuas |

1) BERNOULLI

$\hookrightarrow$ sirve para modelar eventos binarios

$\hookrightarrow$ un evento sucede o no sucede

Ej: tirar una moneda $X = \begin{cases} 1 & \text{cara} \\ 0 & \text{ceza} \end{cases}$

X v.a. con dist de Bernoulli

$$\Rightarrow X \sim \text{Bern}(p)$$

$p = \text{prob de éxito}$

$$p = P(X=1)$$

$$X = \begin{cases} 0 & 1-p \geq 0 \\ 1 & p \geq 0 \end{cases}$$

"VARIABLE BINARIA"

"VARIABLE DUMMY"

"VARIABLE INDICADORA"

pmf

$$p(x) = p^x (1-p)^{1-x}$$

momentos

$$E(X) = p$$

$$\text{Var}(X) = p \cdot (1-p)$$

Experimento: "tirar una moneda y anotar 1 si sale cara"

¿qué pasaría si...

Experimento: "tirar una moneda 3 veces y anotar la cantidad de caras"

■ **Ejemplo:** se lanzará una moneda tres veces, ¿cuál es la probabilidad de sacar exactamente una cara?

- a. 0.125
- b. 0.250
- c. 0.333
- d. 0.375
- e. 0.500

$X =$ cantidad de caras luego de haber tirado la moneda 3 veces.

X	P(X)
0	1/8
1	3/8 = 0,375
2	3/8
3	1/8

Pensamos en cuál es el espacio muestral

3 caras $\rightarrow X=3$ 2 caras $\rightarrow X=2$

$$\Omega = \{ (c, c, c), (c, c, x), (c, x, c), (x, c, c), (c, x, x), (x, c, x), (x, x, c), (x, x, x) \}$$

1 cara $\rightarrow X=1$ 0 caras $\rightarrow X=0$

$$P(X=0) = \frac{CF}{CD} = \frac{1}{8}$$

$$P(X=1) = \frac{CF}{CD} = \frac{3}{8}$$

¿Cuál es $P(X=1)$ si el experimento fuera tirar una moneda 100 veces?



Observamos el caso con $n=3$

$$P(\text{"1 cara"}) = P(X_1=1, X_2=0, X_3=0)$$

prob de que 3 ensayos de Bernoulli den esos resultados

$$= P(X_1=1) \cdot P(X_2=0) \cdot P(X_3=0)$$

$$= p^1 \cdot (1-p)^0 \cdot p^0 \cdot (1-p)^1 \cdot p^0 \cdot (1-p)^1$$

$$= p^1 (1-p)^2$$

DISTRIBUCIÓN BINOMIAL

$$P(\text{"obtener } x \text{ éxitos en } n \text{ intentos"}) = \binom{n}{x} p^x (1-p)^{n-x}$$

$$x = 0, 1, 2, \dots, n$$

↓
combinatorio

$$\binom{n}{x} = \frac{n!}{x! (n-x)!}$$

$$S! = 1 \cdot 2 \cdot 3 \cdot 4 \cdot 5$$

$$X \sim \text{Bin}(n, p)$$

n = cantidad de ensayos

p = prob. de éxito

Memoria:

$$E(X) = n \cdot p$$

$$\text{Var}(X) = n p (1-p)$$

DISTRIBUCIÓN POISSON

X discreta

X cuenta realizaciones en un periodo de tiempo

$$\text{Notación: } X \sim \text{Pois}(\lambda)$$

$$S_X = \{0, 1, 2, 3, \dots\}$$

$$p(x) = \begin{cases} \frac{e^{-\lambda} \cdot \lambda^x}{x!} & x \in \{0, 1, 2, \dots\} \\ 0 & x \notin \{0, 1, 2, \dots\} \end{cases}$$

$$E(x) = \lambda$$


$$\text{var}(x) = \lambda$$

- en muestras grandes se puede aproximar con Normal


- Relación entre Poisson y Exponencial

↓
cantidad de
llegadas u
en periodos de
tiempo



↓
tiempo hasta
el primer
suceso



lambda=2



lambda=5




Normal

↳ Variables continues

↳ $S_x = \mathbb{R}$


↳ Simétrica

↳ Se caracteriza con media y varianza.




Notación: $X \sim \mathcal{N}(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad x \in \mathbb{R}$$




$\mu = 0$
 $\mu = 1$ σ^2 constant



Para calcular probs:

$$F(x) = P(X \leq x)$$

$$P(a \leq X \leq b) = F(b) - F(a)$$



$$P(X \leq 1) = \text{green hatched area}$$

$$P(-1 \leq X \leq 1) = \text{green hatched area} - \text{purple hatched area} = \text{pink shaded area}$$

se usa la dist. normal estandar

$$X \sim N(\mu, \sigma^2)$$


$$Z \sim N(0, 1) \quad \text{"normal estandar"}$$

$$Z = \frac{X - \mu}{\sigma}$$

$$f(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}z^2}$$




Andrés



Una regla simple para pensar en la distribución normal es la siguiente:

- A ± 1 desvío estándar, se concentra el 68% de los datos
- A ± 2 desvíos estándar, se concentra el 95% de los datos
- A ± 3 desvíos estándar, se concentra el 99.7% de los datos



Ej: (slide 57)

$$X \sim N(\mu=80, \sigma=40)$$

X = cont. de personas que llegan a emergencia
por día

$$\begin{aligned} P(X > 120) &= 1 - P(X \leq 120) \\ &= 1 - F(120) \end{aligned}$$

estandarizamos:

$$= 1 - P(X \leq 120)$$

$$= 1 - P\left(\frac{X-80}{40} \leq \frac{120-80}{40}\right)$$


$$= 1 - P(Z \leq 1)$$

$$= 1 - \Phi(1) \quad \text{--- cdf normal estandar.}$$

$$= 1 - 0,84$$

$$= 0,16$$

→ calculamos la prob



- ¿Cuál es el valor que acumula cierta prob?

Tipo 2. ¿Y si me dicen que quieren saber cuál es lo máximo que puede llegar a vender un kiosko con 95% de probabilidad (es decir, el 95% de las veces)?

$$P(Y \leq y) = 0,95$$

¿Cuál es el valor que acumula 95%?

$$z_{0,95} = 1,64 \Rightarrow P(Z \leq 1,64) = 0,95$$

⇒ "desestandarizar" $\frac{x-\mu}{\sigma} = 1,64 \Rightarrow x = 1,64 \cdot \overset{=25}{\sigma} + \mu = 100$
 $x = 141$

el 95% de los casos el desvío
viene a los datos del registro.

ESTADÍSTICA DESCRIPTIVA

CONJUNTO DE DATOS → DESCRIBIRLO.

↓
MEDIDAS DE RESUMEN
GRÁFICOS
TABLAS / TABULADOS



¿qué datos tenemos?

¿Cómo se obtienen los datos?

- **Encuestas:** se elige un subgrupo (muestra) de la población de interés. Existen muchas técnicas de muestreo (veremos algunas brevemente en el curso).
- **Censos:** se recolecta la información de toda la población en cierto momento del tiempo.
- **Datos administrativos:** bases de datos de compañías, organismos nacionales o internacionales, etc.
- **Estudios experimentales:** se obtienen los datos de un experimento buscando establecer "relaciones causales" (e.g. grupo de tratamiento y control)
- **Internet:** websites, redes sociales → Web scraping, Data mining.

■ Saber cómo se obtuvieron los datos.

■ Entender sus limitaciones (en la forma en cómo se obtuvieron o cómo se miden las variables).



■ Evaluar si es consistente (¿faltan datos? ¿hay errores?).

→ 99% de las personas las personas no pueden evaluar
Fuente: encuesta.

■ Entender si podemos (o no) decir algo válido y fundamentado sobre el universo o población en base a una porción limitada de muestra.

Ojo, aún estamos lejos de poder hacer esto último.

• TIPOS DE DATOS



(Y_1, Y_2, Y_3, Y_4) muestra


$(Y_i)_{i=1}^n$ $Y_i, i=1, \dots, n$

$(Y_i, X_i)_{i=1}^n$

i	Y_i	X_i^1	X_i^2
1	Y_1	X_1^1	X_1^2
2	Y_2	X_2^1	X_2^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
i	Y_i	X_i^1	X_i^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	Y_n	X_n^1	X_n^2

muestra

- Series de tiempo



$$Y_t \quad t = 1, 2, \dots, T$$

modelo

$Y = \text{PIB Arg} \quad 2007 - 2022$


$X_1 = \text{tasa de pol. non} \quad "$

$X_2 = \text{inflación} \quad " \quad "$

t	Y	X^1	X^2
1	Y_1	X_1^1	X_1^2
2	Y_2	X_2^1	X_2^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
t	Y_t	X_t^1	X_t^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
T	Y_T	X_T^1	X_T^2

DADOS DE PANEL

(T clava fixo)



N=2 T=2

formato
"long"

i	τ	Y	X
1	1	Y_{11}	X_{11}
2	2	Y_{12}	X_{12}
2	1	Y_{21}	X_{21}
2	2	Y_{22}	X_{22}

Y_{it}

X_{it}

formato
"wide"

i	X_1	X_2	Y_1	Y_2
1	X_{11}	X_{12}	Y_{11}	Y_{12}
2	X_{21}	X_{22}	Y_{21}	Y_{22}

MEDIDAS DE TENDENCIA CENTRAL

1) Media

Simpos


→ ARITMÉTICA: $\bar{x} = \frac{\sum_{i=1}^N x_i}{N}$

→ GEOMÉTRICA: $\bar{x}_G = \left(\prod_{i=1}^N x_i \right)^{1/N}$

PONDERADO → ARITMÉTICA: $\bar{x}_w = \frac{\sum_{i=1}^N x_i \cdot w_i}{N}$

$$0 \leq w_i \leq 1$$
$$\sum_{i=1}^N w_i = 1$$

→ GEOMÉTRICA: $\left(\prod_{i=1}^N x_i^{w_i} \right)^{1/N}$



fácil de calcular
tiene buenas propiedades estadísticas
sensibles a valores extremos

$\bar{x}_G$ → menos sensible
→ $x > 0$

$$\prod_{i=1}^N (1 + r_i)$$

Media geométrica - Ejemplo

IPC: índice de precios al cons.

Según datos del Banco Central de Venezuela, la tasa de inflación fue del 56% en 2013, del 69% en 2014 y del 181% en 2015. ¿Cuál fue la **tasa promedio de inflación** durante esos 3 años?

■ **ERROR:** $(56\% + 69\% + 181\%)/3 = 102\%$

■ **CORRECTO:**

$$(1 + \pi)^3 = (1 + \pi_{13}) \times (1 + \pi_{14}) \times (1 + \pi_{15})$$

$$(1 + \pi)^3 = 1.56 \times 1.69 \times 2.81 = 7.408284$$

$$(1 + \pi) = \sqrt[3]{7.408284} = 1.949422$$

$$\pi = 1.949422 - 1 = 94.9422\%$$

$$(1 + \pi_t) = \frac{IPC_t}{IPC_{t-1}}$$

$$(1 + \pi_{13})(1 + \pi_{14})(1 + \pi_{15})$$

$$= \frac{IPC_{13}}{IPC_{12}} \cdot \frac{IPC_{14}}{IPC_{13}} \cdot \frac{IPC_{15}}{IPC_{14}} = \frac{IPC_{15}}{IPC_{12}}$$

MEIANA

Lo obs que acumula el 50% de la data

Año	2009	2010	2014	2012	2013	2008	2011
Beneficiarios	31	33	33	34	34	35	36

datos ordenados

Año	2009	2010	2014	2012	2013	2008
Beneficiarios	31	33	33	34	34	35

0.

$$\frac{33 + 34}{2} = 33,5$$

→ No se ve afectada por valores extremos

MODA $\rightarrow$ el valor más frecuente

$$\bar{X}_M = a_j \Leftrightarrow n_j = \max\{n_1, n_2, \dots, n_k\}$$

valor de la observación j

n_j = cantidad de obs de el valor j

x	n
1	40
2	20
3	15

Año	2009	2010	2014	2012	2013	2008	2011
Beneficiarios	31	33	33	34	33 33	35	36

x	n
31	1
33	3
34	2
35	1
36	1

MODA = 33.

Año	2009	2010	2014	2012	2013	2008	2011
Beneficiarios	31	33	33	34	34	35	36

"bimodal"
no hay único moda.

Pros y Contras

Medida	Pro	Contra
Moda	-Cálculo sencillo	-Sensible a n
	-Interpretación clara	-Puede haber más de una moda
	-Puede calcularse en variables cualitativas	-No siempre está en el centro -Poco sentido para var. continuas
Mediana	-Fácil de calcular	-Para var. numéricas ordenables
	-Robusto a outliers	-Sensible a n -Concepto no tan familiar
Media	-Fácil de entender	-Afectado por outliers
	-Poco sensible a n	-Puede caer fuera de los posibles
	-Usa todos los datos	-No es útil para variables discretas

MEDIDAS DE DISPERSIÓN

- La varianza
- El desvío estándar
- La desviación absoluta
- El coeficiente de variación
- El rango o recorrido

$$E[(x-\mu)^2]$$

VARIANZA MUESTRAL

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

le da más peso a las obs. "grandes" "outliers"

DESVIÓ : $\sqrt{s^2} = S$

DESVIACIÓN ABSOLUTA

$$DMA = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

x	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$ x_i - \bar{x} $
2	-5	25	5
8	1	1	1
11	4	16	4
		<u>42</u>	<u>10</u>
$\bar{x} = \frac{21}{3} = 7$		$S^2 = 14$	$\frac{10}{3} = 3.3$
		$S = 4.66$	

RANGO / Rango medio:

$$R = \max - \min$$

$$35 - 31 = 4$$

$$150 - 0 = 150$$

RANGO INTERCUANTIL

$$R_q = Q_3 - Q_1$$

CUANTILES


Q_1 : amplitud al 25%.

Q_2 : " " 50% (mediana)

Q_3 : " " 75%.



¿entre qué valores está el 50% central?



Hasta ahora, las medidas de dispersión están en la misma unidad que las variables

$$CV = \frac{S}{\bar{x}} \cdot 100$$


¿En qué caso hay más dispersión?

Semana	1	2	3	4	5	6	7	8	9	10	Media	Var.	Desvío
Temperatura (°C)	31	29	27	23	21	12	25	18	22	25	23.3	30.5	5.5
Cantidad de lluvia (mm)	12	11	6	6	6	14	6	3	3	2	6.9	16.8	4.1


$$CV = \frac{5.5}{23.3} \cdot 100 = 23.6$$

$$CV = \frac{4.1}{6.9} \cdot 100 = 60$$

Medidas de posición - Cuantiles



WARTIL



PERIL



PERCENTIL



PERCENTIL 80:

80% de los valores son menores a P_{80}

