

Última clase

↳ Aplicaciones de test de hipótesis

↳ Regresión lineal

Clase Pasada : Test de Hip.

No depende de
parámetros de
la dist
de los datos

1) Hipótesis (H_0 y H_1)

2) Estadístico de prueba (VA, tiene dist)

3) Regla de rechazo (nivel de significación)

$$\alpha = Pr(\text{Rech } H_0 | H_0 V)$$

Con (=) en H_0

Error de tipo 1 y 2

Potencia

$$\begin{aligned} & \hookrightarrow Pr(\text{Rech } H_0 | H_0 F) \\ & = 1 - Pr(\text{error de Tipo 2} | H_0 F) \end{aligned}$$

P-valor

$$\hookrightarrow P(RH_0 | H_0 V)$$

$$= P(\text{estadístico} > \text{estadístico calculado} | H_0 V)$$

1) Calculamos el estadístico con datos

5) $\Rightarrow$ Decisión (RH_0 / No RH_0).

Testear μ (con varianza conocida)

$$X \sim N(\mu, \sigma^2)$$

1) Planteamos hipótesis

$$\left\{ \begin{array}{l} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0 \end{array} \right\} \quad \left\{ \begin{array}{l} H_0: \mu \geq \mu_0 \\ H_1: \mu < \mu_0 \end{array} \right\} \quad \left\{ \begin{array}{l} H_0: \mu \leq \mu_0 \\ H_1: \mu > \mu_0 \end{array} \right\}$$

2) Estadístico

sabemos que $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$




$$\Rightarrow \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \underbrace{N(0,1)}_{\substack{\text{no depende ni de } \mu \\ \text{ni de } \sigma^2}}$$

3) $\alpha = 0,05$

Regla de rechazo:

si las hipótesis son...

$$\left\{ \begin{array}{l} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0 \end{array} \right\} \quad \left\{ \begin{array}{l} H_0: \mu \geq \mu_0 \\ H_1: \mu < \mu_0 \end{array} \right\} \quad \left\{ \begin{array}{l} H_0: \mu \leq \mu_0 \\ H_1: \mu > \mu_0 \end{array} \right\}$$



Rech si $z^{calc} < z^{crit}$

Rech si $z^{calc} > z^{crit}$

$\Rightarrow$ Regla de rechazo




Rech si $|z^{calc}| > z^{crit}$

datos $\leftarrow \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \rightarrow$ datos

$\nwarrow H_0 \nearrow$

$\nwarrow z_{1-\alpha/2} \nearrow$

Sino, decisión con p-valor



Ej:

$$X \sim N(\mu, \sigma^2)$$

$$\sigma^2 = 1$$

$$n = 25$$

Queremos testear

1) Hipótesis

$$\begin{cases} H_0: \mu \leq 3 \\ H_1: \mu > 3 \end{cases}$$

trabaja con $\mu = 3$

$\mu_0 = 3$

2) estadístico:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \text{ si } H_0 \text{ V}$$

3) Nivel de signif

$$\alpha = 0.05$$

$\alpha/2 = 0.025$
 $1 - \alpha/2 = 0.975$

Rechazo H_0 si $z^{\text{calc}} > z_{0.975}$

$$z^{\text{calc}} > 1.96$$

4) Supuestos: $\bar{X} = 3.5$
 (ma iid)

si H_0 es Verdadero,

$$X \sim N(3, 1)$$

$$\Rightarrow \bar{X} \sim N(3, 1/5)$$

$$\Rightarrow \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$$

$$\frac{\bar{X} - 3}{1/5} \sim N(0,1)$$

$$\Rightarrow z^{\text{calc}} = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}} = \frac{3,5 - 3}{1 / \sqrt{25}} = \frac{0,5}{1/5} = 2,5$$

$$5) \quad \left. \begin{array}{l} z^{\text{critic}} = 1,96 \\ z^{\text{calc}} = 2,5 \end{array} \right\} \rightarrow z^{\text{calc}} > z^{\text{critic}}$$

$\Rightarrow$ Rechazo H_0

Conclusión:

"Hay evidencia estadística para decir que μ es significativamente mayor a 3"

5') Calcular el p-valor

$$z^{\text{calc}} = 2,5$$

$$p\text{-valor} = \text{Prds}(\text{Rech } H_0 / H_0 V) \quad \text{"en nuestros"}$$

una VA
con la
misma dist
que la dist.
del estadístico
de prueba.

$$= P(Z > z^{\text{calculado}} / H_0 V) \quad (\mu=3)$$

$$= P(Z > 2,5 \mid \mu=3)$$

$$= 1 - P(Z \leq 2,5 \mid \mu=3)$$

$$= 1 - 0,99379$$

$$= 0,00621$$

$$\approx 0,006 = p\text{-valor} < \alpha = 0,05$$

$p\text{-valor} < \alpha$
 $\Rightarrow$ Rechazo H_0 .

$\Uparrow$

Test para μ con σ^2 desconocida.

$$X \sim N(\mu, \sigma^2)$$

$$s^2 = \hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$$

Hipótesis $\rightarrow$ igual que antes.

Estadístico:

Antes:

$$\frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

$\downarrow$ lo estimamos

$$\hat{\text{var}}(\bar{x}) = \frac{s^2}{n-1}$$

$$\frac{\bar{x} - \mu_0}{s / \sqrt{n-1}}$$

$\downarrow$
es V.A.
 $\Rightarrow$ tiene dist

$$t = \frac{\bar{x} - \mu_0}{s / \sqrt{n-1}} \sim t_{n-1} \quad \text{si } H_0 V.$$

$\downarrow$
dist t con $n-1$ gl.

$$\rightarrow \text{usar } \sqrt{s^2}, \sqrt{n-1}$$

$$\rightarrow P(t > t^{\text{calc}})$$

$\hookrightarrow$ usar dist t_{n-1}




Test para Varianza

$$\left. \begin{array}{l} H_0: \sigma^2 = \sigma_0^2 \\ H_1: \sigma^2 \neq \sigma_0^2 \end{array} \right\} \left. \begin{array}{l} H_0: \sigma^2 \geq \sigma_0^2 \\ H_1: \sigma^2 < \sigma_0^2 \end{array} \right\} \left. \begin{array}{l} H_0: \sigma^2 \leq \sigma_0^2 \\ H_1: \sigma^2 > \sigma_0^2 \end{array} \right\}$$

$$\chi^2 = \frac{(n-1) \cdot S^2}{\sigma_0^2} \sim \chi_{n-1}^2 \quad \text{si } H_0 \text{ V.}$$

χ_{n-1}^2

χ_{n-1}^2 χ_{n-1}^2



Ej:

Una empresa fabrica dispositivos eléctricos operados por un control termostático. El desvío estándar de la temperatura a la que estos controles operan no debe exceder los 2 grados. Dada una muestra aleatoria de 20 de estos controles, el desvío estándar de la muestra de la temperatura de funcionamiento es 2.36 grados. Testear, a un nivel de significación del 5% la hipótesis nula de que el desvío estándar de la población es 2.0 grados o menos frente a la alternativa de que sea más grande. Considere $\alpha = 0.05$.

$$H_0: \sigma \leq 2$$

$$H_1: \sigma > 2$$

$\Rightarrow$

$$H_0: \sigma^2 \leq 4$$

$$H_1: \sigma^2 > 4$$

$$n = 20.$$

Estadístico:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$$

$\alpha = 0.05$

$\therefore \alpha = 0,05$

Decido si $\chi_{calc}^2 > \chi_{crito}^2$.

Cálculos:

$$\chi_{calc}^2 = \frac{(20-1) \cdot (2.36)^2}{4}$$

$$= \frac{19 \cdot (5.57)}{4}$$

$$\chi_{calc}^2 = 24,46$$

$$\chi_{crito}^2 = \chi_{1-\alpha}^2 = \chi_{0,95}^2 \approx 30,1$$

~~$= 27,2$~~

Decisión:

$$24,46 < 30,1$$

$$\chi_{calc}^2 < \chi_{crito}^2$$

$$\chi_{0,10}^2 = 27,2$$

No Rechazamos la H_0 .

No hay evidencia estadística de que el dueño de la temperatura supere significativamente los 2 grados.

Test para proporción:

$$X \sim \text{Bern}(\bar{p})$$


$$\hat{p} = \bar{X}$$

$$\bar{X} \sim N\left(\bar{p}, \sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\right)$$

$$\frac{\bar{X} - \bar{p}}{\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}} \underset{N \rightarrow \infty}{\overset{a}{\sim}} N(0, 1)$$

Tests para 2 parámetros

↳ comparar medias
↳ comparar varianzas.



Test de diferencia de medias:

2 muestras

→ $(X_1^1, X_2^1, \dots, X_{n_1}^1)$ iid

~ "Grupo de tratamiento"

↓

$(X_1^0, X_2^0, \dots, X_{n_0}^0)$ iid

~ "Grupo de control"

$$X \sim N(\mu, \sigma^2)$$

↳ Tratamiento: "beneficiarios"

↳ Control: "no beneficiarios"

Estadísticos:

si X, Y son indep.

$$Var(X+Y) = Var(X) + Var(Y)$$

$$Var(X-Y) = Var(X) + Var(Y)$$

$$\bar{X}_1 \sim N(\mu_1, \sigma_1^2)$$

$$\bar{X}_0 \sim N(\mu_0, \sigma_0^2)$$

$$E(\bar{X}_1 - \bar{X}_0) = \mu_1 - \mu_0$$

$$Var(\bar{X}_1 - \bar{X}_0) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_0^2}{n_0}$$

iid

+ 0
↓
cov=0

Suponga σ_1^2 y σ_0^2 conocidas.

$$Z = \frac{(\bar{X}_1 - \bar{X}_0) - (\mu_1 - \mu_0)_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_0^2}{n_0}}} \sim N(0, 1)$$

Si las varianzas son desconocidas pero los

grupos iguales:

↓
"homocedastic"

$$t = \frac{(\bar{X}_1 - \bar{X}_0) - (\mu_1 - \mu_0)_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_0}}}$$

$$S_p = \sqrt{\frac{(n_1 - 1) \cdot S_1^2 + (n_0 - 1) \cdot S_0^2}{n_1 + n_0 - 2}}$$

↓
"pooled"
"agrupado"

$$\frac{\sum (x_i - \bar{x})^2}{n-1}$$

Si suponemos que las varianzas son distintas

$$t = \frac{(\bar{x}_1 - \bar{x}_0) - (\mu_1 - \mu_0)_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}}} \sim t_{\eta_0}$$

$\downarrow$
 gl

$$\eta_0 = \frac{\left(\frac{s_X^2}{n_X} + \frac{s_Y^2}{n_Y}\right)^2}{\frac{s_X^4}{n_X^2(n_X-1)} + \frac{s_Y^4}{n_Y^2(n_Y-1)}}$$

→ grados de libertad



"test de Welch"

Test de cociente de Varianzas.

"test F"

$$\begin{cases} H_0: & \sigma_1^2 \leq \sigma_0^2 \\ H_1: & \sigma_1^2 > \sigma_0^2 \end{cases} \Rightarrow \begin{cases} \frac{\sigma_1^2}{\sigma_0^2} \leq 1 \\ \frac{\sigma_1^2}{\sigma_0^2} > 1 \end{cases}$$

$$F = \frac{s_1^2}{s_0^2} \sim F_{n_1-1, n_0-1}$$



Regresión Lineal

Antes:

(X) (X,Y)

POB

$(x_1, \dots, x_n) = (x_i)_{i=1}^n$

MUESTRA

$(x_i, y_i)_{i=1}^n$

PARAM

ESTADÍSTICOS

θ

inferencia

$\hat{\theta} = f(x_1, \dots, x_n)$

$\hat{\beta} = f(x_1, \dots, x_n, y_1, \dots, y_n)$

"correlación"

$$\rho_{xy} = \frac{\text{cov}(x,y)}{\sigma_x \cdot \sigma_y}$$

$$\Gamma_{xy} = \frac{s_{xy}}{s_x \cdot s_y}$$

Hasta acá, tenemos la correlación

Queremos:

- Quantificar (¿x en una ciudad, ¿y?)
- inferencia.

Se quiere modelar:

$$E(\text{Ingreso} | \text{Educ}) = \beta_0 + \beta_1 \text{Educ}$$

Esperanza Condicional


$$E(a) = a \Rightarrow E(a|X) = a$$

$$E(X|X) = X$$

$$W \text{ es VA} \Rightarrow E(a + bX + cW|X) = a + bX + E(W|X)$$

$$E(W \cdot X|X) = X \cdot E(W|X)$$

$$E(E(W|X)) = E(W) \text{ ley de Esperanza Iterada.}$$



$$\text{Ingreso} = \left(\text{Ingreso explicado por educ} \right) + \left(\text{Ingreso no explicado por educ} \right)$$

$$\downarrow$$

$$E(\text{Ingreso} | \text{Educ})$$

↓
otros factores
no correlacionados
con educación.

$$\varepsilon \quad (\text{epsilon}),$$

$$E(\varepsilon | \text{Educ}) = 0$$

$$\downarrow$$

$$\text{cov}(\varepsilon, \text{Educ}) = 0$$

$$\text{Ingreso} = E(\text{Ingreso} | \text{educ}) + \varepsilon$$

$$\text{Ingreso} = \beta_0 + \beta_1 \text{Educ} + \varepsilon$$

$$\frac{\partial E(\text{Ingreso} | \text{Educ})}{\partial \text{Educ}} = \beta_1$$

"Efecto/Cambio marginal"
de la educ en el ingreso.

Si Educ sube 1 unidad $\Rightarrow E(\text{Ingreso})$ cambia β_1 unidades.

$$E[\text{Ingreso} | \text{Educ} = 0] = \beta_0.$$

Lo ingreso esperado si hay cero años de educ.

$$\Rightarrow Y = \beta_0 + \beta_1 X + \varepsilon \quad \text{CVA}.$$

Escribimos el modelo a t mulo de una observaci n

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Donde

- Y : variable dependiente o explicada
- X : variable explicativa o regresor
- β_0 y β_1 : par metros desconocidos
- ε : error aleatorio

Extensiones:

- t rminos cuadr ticos: $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$

$$\frac{\partial E(Y|X)}{\partial X} = \beta_1 + \underbrace{2 X_i}_{\text{orange}} \beta_2$$

- interacciones: Y, X, W

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + \beta_3 X_i W_i$$

$$\frac{\partial E(Y_i | X_i)}{\partial X_i} = \beta_1 + \beta_3 W_i$$

• Logaritmos: $\ln Y = \beta + \beta_1 \ln x_i$
 diferenciando

$$\frac{1}{y_i} \cdot dy = \beta_1 \cdot \frac{1}{x_i} dx_i$$

$$\boxed{\frac{dy}{dx} \cdot \frac{x_i}{y_i} = \beta_1} \quad \text{Elasticidad.}$$

Si x sube 1%, y cambia β_1 %.


• x binaria ($x = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$) ($x \sim \text{ber}(p)$)

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$L \rightarrow \boxed{\hat{\beta}_1 = \bar{x}_1 - \bar{x}_0}$$


diferencia de medias.

POBLACIÓN



$E(Y|X)$



MUESTRA




$\beta_1 = 0$

(5)

ordenado
al origen β_0 β_1 pendiente.



MUESTRA



↳ Queremos sistematizar este criterio:

Definimos: $e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$

muestra $(x_i, y_i)_{i=1}^n$ distancia de y_i a la recta estimada


Queremos:

minimizar $\sum_{i=1}^n e_i^2$ cuadrado. $= \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2$

$\min_{\{\hat{\beta}_0, \hat{\beta}_1\}} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$

CPD:

$(\hat{\beta}_0): -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$
 $\sum_{i=1}^n e_i = 0$



$(\hat{\beta}_1): -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0$
 $\sum_{i=1}^n e_i x_i = 0$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

ESTIMADORES
DE
MÍNIMOS
CUADRADOS
CLÁSICOS

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$


$$\hat{\beta}_1 = \frac{\text{cov}(x, y)}{\text{VAR}(x)}$$

Bondad de Ajuste

R^2 = % de variabilidad en y
explicada por la recta.

$$STC = SEC + SRC$$

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$



$$R^2 = 1 - \frac{SRC}{STC}$$

$$0 \leq R^2 \leq 1$$

↳ medida de asociación lineal

con una constante y una exponencial

$$\hat{\rho}_{yx}^2 = R^2$$

Estimadores de MCC

- ↳ insesgados
- ↳ consistentes
- ↳ Eficientes.

Si vale:

EXOGENEIDAD: $E(\varepsilon|X) = 0$ ($\text{cov}(\varepsilon, X) = 0$).

$$E(\varepsilon^2|X) = \sigma^2$$

$$E(\varepsilon_i \varepsilon_j|X) = 0$$

$$(\varepsilon \sim N(0, \sigma^2))$$

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} \quad \rightarrow y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

⋮

$$\hat{\beta}_1 = \beta_1 + \frac{\sum (x_i - \bar{x}) \varepsilon_i}{\sum (x_i - \bar{x})^2}$$

Aplicando $E(\cdot | X)$:

$$E(\hat{\beta}_1 | X) = \beta_1 + \frac{\sum (x_i - \bar{x})}{\sum (x_i - \bar{x})^2} \cdot \overbrace{E(\varepsilon_i | X)}^{=0}$$

$E(\cdot)$

$$E(\hat{\beta}_1) = \hat{\beta}_1$$

EXACTO $\rightarrow \hat{\beta}_1$ INSECCADO.

$\searrow$
 $\hat{\beta}_1$ CONSISTENTE

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right) \quad \begin{array}{l} \nearrow \text{exacto si } \varepsilon_i \sim N(0, \sigma^2) \\ \downarrow \text{asintótico.} \end{array}$$

Inferencia:

$$IC: \hat{\beta}_1 \pm t_{n-k, 1-\alpha/2}^{n-k} \cdot se(\hat{\beta}_1)$$

$$se(\hat{\beta}_1) = \sqrt{\widehat{var}(\hat{\beta}_1)}$$

tests :

$$\begin{cases} H_0: \beta_1 = \beta_1^{H_0} \\ H_1: \beta_1 \neq \beta_1^{H_0} \end{cases}$$

$$t = \frac{\hat{\beta}_1 - \beta_1^{H_0}}{se(\hat{\beta}_1)} \sim t_{n-k}$$