

# Probabilidad

Convergencias

12/05/2023

Lara Sánchez Peña<sup>1</sup>

UTDT 2023 - MEC

---

<sup>1</sup>Basado en las notas de Andrea Rotnitzky

- Ley débil de grandes números
- Convergencia en probabilidad
- Convergencia en media cuadrática
- Teorema central del límite
- Convergencia en distribución
- Método Delta

En estas slides vamos a ver distintas nociones de convergencias de sucesiones de variables aleatorias y cómo se relacionan éstas diferentes nociones de convergencia entre sí.

# Sucesiones de números $(a_n)_{n \in \mathbb{N}}$

- Una sucesión de números  $(a_n)_{n \in \mathbb{N}}$  es una lista de números indexados por  $n \in \mathbb{N}$ .
- Decimos que  $(a_n)_{n \in \mathbb{N}}$  es **convergente** si existe  $\lim_{n \rightarrow \infty} a_n = a$ . Es decir, existe un número  $a$  tal que para cualquier  $\varepsilon > 0$  que se considere, existe  $n(\varepsilon)$  de manera que si  $n > n(\varepsilon)$  entonces

$$|a_n - a| < \varepsilon$$

- Una sucesión de variables aleatorias  $(V_n)_{n \in \mathbb{N}}$  es una lista de variables aleatorias indexadas por  $n \in \mathbb{N}$ .
- Vamos a considerar sucesiones de variables aleatorias  $(V_n)_{n \in \mathbb{N}}$  y vamos a estudiar **de qué tipos de manera** pueden converger cuando  $n \rightarrow \infty$ .

# Muestra aleatoria y media muestral $\bar{X}_n$

Antes de empezar, definimos las siguientes variables aleatorias:

- Llamamos una **muestra aleatoria** de v.a.  $X_1, \dots, X_n$  si las variables  $\{X_i\}_{i=1}^n$  son variables aleatorias independientes e idénticamente distribuidas.
- Definimos a la variable aleatoria  $\bar{X}_n$  la **media muestral** definida por

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} (X_1 + \dots + X_n)$$

- Definimos a la variable aleatoria  $S_n^2$  la **varianza muestral** definida por

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n-1} \sum_{i=1}^n X_i^2 - \frac{n}{n-1} (\bar{X}_n)^2$$

Para los resultados teóricos LGN y TCL vamos a estudiar de qué maneras converge la sucesión de variables aleatorias  $V_n = \bar{X}_n$  entre otras.

# Propiedades de $\bar{X}_n$ y $S^2$

- $E(\bar{X}_n) = E(X)$

$$E(\bar{X}_n) = \frac{1}{n} E(X_1 + \dots + X_n) = \frac{1}{n} (E(X_1) + \dots + E(X_n)) \underbrace{=}_{X_i \text{ id}} E(X)$$

- $Var(\bar{X}_n) = \frac{Var(X)}{n}$

$$Var(\bar{X}_n) = \frac{1}{n^2} Var(X_1 + \dots + X_n) \underbrace{=}_{X_i \text{ indep}} \frac{1}{n^2} (Var(X_1) + \dots + Var(X_n)) \underbrace{=}_{X_i \text{ id}} \frac{Var(X)}{n}$$

- $E(S_n^2) = Var(X)$

$$\begin{aligned} E(S_n^2) &= \frac{1}{n-1} \sum_{i=1}^n E(X_i^2) - \frac{n}{n-1} E[(\bar{X}_n)^2] \\ &= \frac{1}{n-1} \sum_{i=1}^n \left[ (E(X))^2 + Var(X) \right] - \frac{n}{n-1} \left[ (E(X))^2 + \frac{Var(X)}{n} \right] \\ &= Var(X) \end{aligned}$$

# Ley débil de los grandes números para $X_i \stackrel{iid}{\sim}$

Sea  $X_1, \dots, X_n$  una muestra aleatoria tal que  $E(X) = \mu$ . Entonces para todo  $\varepsilon > 0$

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

Notacionalmente escribimos  $\bar{X}_n \xrightarrow{P} \mu$  o plím  $\bar{X}_n = \mu$ .

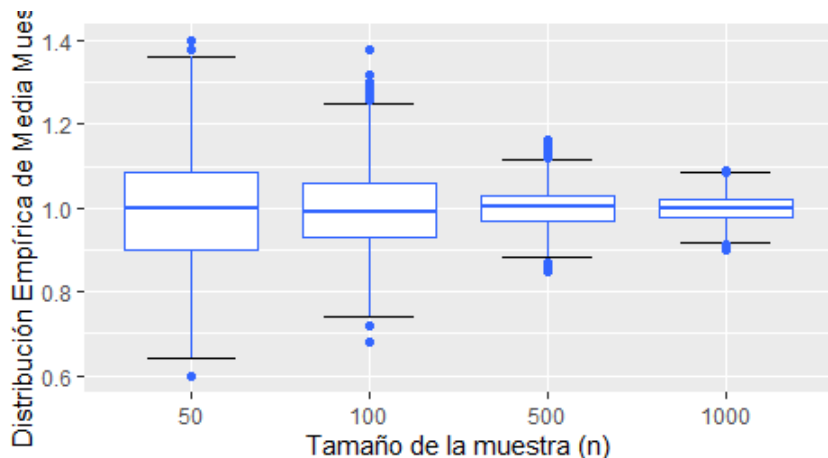
**Interpretación frecuentista:** Si  $n$  es grande con probabilidad alta el estimador  $\bar{X}_n$  tomará valores 'cerca' de  $E(X)$ . Notemos que es una propiedad deseable de  $\bar{X}_n$  como estimador de  $\mu$ .

Notemos que la conclusión es más general y débil que la que obtuvimos antes usando Chebyshev, pero también que las hipótesis son más débiles ya para que valga la LGN que no requerimos que exista  $\text{Var}(X)$ . Con Cheby al pedir que exista  $\text{Var}(X)$  sabemos que la probabilidad se achica con velocidad  $\frac{1}{n}$ .

La demostración está fuera del alcanza del curso. Es fácil probar que el resultado vale si asumimos que  $\text{Var}(X)$  es finita. En este caso, por Chebyshev, para todo  $\varepsilon > 0$  vale que

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(X)}{n} \frac{1}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

# Distribución empírica de $\bar{X}_n$ para $X_i \stackrel{iid}{\sim} Poi(1)$



# LGN visto gráficamente $X_i \stackrel{iid}{\sim} Poi(\lambda)$ si $\lambda = 1$




Figura: Distribución de  $\bar{X}_n$  para distintos tamaños de muestra



# LGN débil - ejercicios

Es importante que noten que si:

- $g$  es una función continua, si  $X_i = g(Y_i)$  entonces vale que

$$\frac{1}{n} \sum_{i=1}^n g(Y_i) \xrightarrow{P} E(g(Y))$$

- $X_i = Y_i^2$  entonces vale que  $\frac{1}{n} \sum_{i=1}^n Y_i^2 \xrightarrow{P} E(Y^2)$

- $X_i = \ln(W_i)$  entonces vale que  $\frac{1}{n} \sum_{i=1}^n \ln(W_i) \xrightarrow{P} E(\ln(W))$

## Ejercicios

1. Si  $T_i \sim iid$ ,  $E(T) = 5$  y  $Var(T) = 144$  calculá  $\theta$  si  $\frac{1}{n} \sum_{i=1}^n T_i^2 \xrightarrow{P} \theta$

2. Si  $S_i \sim iid$ ,  $E(S) = 1$  y  $E(\ln(S)) = -1$  calculá  $\theta$  si  $\ln \left[ \left( \prod_{i=1}^n S_i \right)^{\frac{1}{n}} \right] \xrightarrow{P} \theta$

# Convergencia en probabilidad

Sea  $V_1, \dots, V_n, \dots$  una sucesión de variables aleatorias. Decimos que la sucesión  $(V_n)_{n \in \mathbb{N}}$  **converge en probabilidad** a  $a \in \mathbb{R}$  si

$$\lim_{n \rightarrow \infty} P(\{\omega \in \Omega : |V_n(\omega) - a| > \varepsilon\}) = 0$$

Escribimos  $V_n \xrightarrow{P} a$  para denotar convergencia en probabilidad. En la LGN débil  $V_n = \bar{X}_n$  y  $a = E(X)$ .

Más en general, decimos que la sucesión  $(V_n)_{n \in \mathbb{N}}$  **converge en probabilidad** a  $V$  (una v.a.) si

$$\lim_{n \rightarrow \infty} P(\{\omega \in \Omega : |V_n(\omega) - V(\omega)| > \varepsilon\}) = 0$$

En ese caso escribimos  $V_n \xrightarrow{P} V$ . Note que en cierta bibliografía se escribe también  $\text{plim} V_n = V$ .

Notemos que si  $V_n \xrightarrow{P} V$  y  $V_n \xrightarrow{P} W$  entonces  $P(V = W) = 1$ .

## Ejemplo 1: convergencia en probabilidad

Sean  $X_1, \dots, X_n$  v.a.i.i.d. de manera que  $X_i \sim U(0, 1)$ ,  $i = 1, \dots, n$ . Definimos  $V_n = \min \{X_1, \dots, X_n\}$ . Muestre que  $V_n$  converge en probabilidad a  $a = 0$ . Sea  $\varepsilon > 0$ , entonces<sup>2</sup>

$$\begin{aligned} P(|V_n - 0| \geq \varepsilon) &= P(\min \{X_1, \dots, X_n\} \geq \varepsilon), \quad \text{porque } X_i \geq 0 \\ &= P(X_1 \geq \varepsilon \text{ y } \dots \text{ y } X_n \geq \varepsilon) \\ &= \underbrace{P(X_1 \geq \varepsilon) \cdots P(X_n \geq \varepsilon)}_{X_i \text{ indep}} = \underbrace{(1 - \varepsilon)^n}_{X_i \text{ id}} \end{aligned}$$

Tomando límite de  $n \rightarrow \infty$ , concluimos que

$$\lim_{n \rightarrow \infty} P(|V_n - 0| \geq \varepsilon) = \lim_{n \rightarrow \infty} (1 - \varepsilon)^n = 0.$$

Por lo tanto,  $V_n \xrightarrow{P} 0$ .

---

<sup>2</sup>Notemos que como  $X_i \sim U(0, 1)$ , entonces  $P(X_i < \varepsilon) = \varepsilon$  y  $P(X_i \geq \varepsilon) = 1 - \varepsilon$ .

## Ejemplo 2: convergencia en probabilidad

Sea  $X \sim \text{Exponencial}(1)$ .

Podemos calcular que  $P(X \geq x) = e^{-x}$ . Sea  $V_n = \frac{X}{n}$ . Muestre que  $V_n$  converge en probabilidad a  $a = 0$ . Sea  $\varepsilon > 0$ , entonces

$$\begin{aligned}P(|V_n - 0| \geq \varepsilon) &= P(V_n \geq \varepsilon) \\&= P(X \geq n\varepsilon) \\&= e^{-n\varepsilon}\end{aligned}$$

Tomando  $n \rightarrow \infty$

$$\lim_{n \rightarrow \infty} P(|V_n - 0| \geq \varepsilon) = \lim_{n \rightarrow \infty} e^{-n\varepsilon} = 0$$

Por lo tanto,  $V_n \xrightarrow{p} 0$ .

## $V_n \xrightarrow{P} V$ no implica que $E(V_n) \xrightarrow{n \rightarrow \infty} E(V)$ : Ejemplo 1

Para el siguiente ejemplo tomamos  $V = a = 0$ , una variable aleatoria degenerada. Sea  $U \sim U(0, 1)$  y sean

$$V_n(u) = \begin{cases} 0 & \text{si } u > \frac{1}{n}, \text{ con prob. } 1 - \frac{1}{n} \\ n & \text{si } u \leq \frac{1}{n}, \text{ con prob. } \frac{1}{n} \end{cases}$$

Notamos que:

- $E(V_n) = 0 \cdot \left(1 - \frac{1}{n}\right) + n \cdot \frac{1}{n} = 1$  para cualquier valor de  $n$ . O sea,

$$\lim_{n \rightarrow \infty} E(V_n) = 1$$

- Sin embargo,  $V_n \xrightarrow{P} 0$  porque

$$P(|V_n - 0| \geq \varepsilon) = P(V_n = n) = \frac{1}{n}$$


Entonces

$$\lim_{n \rightarrow \infty} P(|V_n - 0| \geq \varepsilon) = \lim_{n \rightarrow \infty} \frac{1}{n} = 0 \text{ pero } \lim_{n \rightarrow \infty} E(V_n) = 1 \not\rightarrow E(V) = 0.$$

## $V_n \xrightarrow{P} V$ no implica que $E(V_n) \xrightarrow{n \rightarrow \infty} E(V)$ : Ejemplo 2

Para el siguiente ejemplo tomamos  $V = a = 0$ , una variable aleatoria degenerada. Sea  $U \sim U(0, 1)$  y sean

$$V_n(u) = \begin{cases} 0 & \text{si } u > \frac{1}{n}, \text{ con prob. } 1 - \frac{1}{n} \\ n^2 & \text{si } u \leq \frac{1}{n}, \text{ con prob. } \frac{1}{n} \end{cases}$$



Notamos que:

- $E(V_n) = 0 \cdot \left(1 - \frac{1}{n}\right) + n^2 \cdot \frac{1}{n} = n$ . O sea,

$$\lim_{n \rightarrow \infty} E(V_n) = +\infty$$

- Sin embargo,  $V_n \xrightarrow{P} 0$  porque

$$P(|V_n - 0| \geq \varepsilon) = P(V_n = n) = \frac{1}{n}$$

$V_n \xrightarrow{p} V$  **no implica** que  $E(V_n) \xrightarrow{n \rightarrow \infty} E(V)$ : ¿por qué?

Lo importante para llevarse de estos ejemplos “patológicos” es que las variables que estamos considerando  $V_n$  toman con probabilidad cada vez menor  $\frac{1}{n}$  un valor cada vez más grande, ( $n$  o  $n^2$ ) de manera que la relación entre esa probabilidad  $\frac{1}{n}$  y el valor extremo ( $n$  o  $n^2$ ) hace que la media no sea cero o aumente indefinidamente, pero no modifica el límite en probabilidad que sigue siendo  $a = 0$ .

Esto es porque la probabilidad de que la variable aleatoria tome ese valor extremo es cada vez menor, de manera que tiende a cero.

# Propiedades de la convergencia en probabilidad

Sea  $a_n$  es una sucesión de números reales tal que  $a_n \xrightarrow[n \rightarrow \infty]{} a$ . Sean  $V_n$  y  $W_n$  dos variables aleatorias tales que  $V_n \xrightarrow{P} V$  y  $W_n \xrightarrow{P} W$ . Entonces:

1.  $a_n + V_n \xrightarrow{P} a + V$ .
2.  $a_n V_n \xrightarrow{P} aV$ .
3.  $V_n + W_n \xrightarrow{P} V + W$ .
4.  $V_n W_n \xrightarrow{P} VW$ .
5. Si  $P(W = 0) = 0$ ,  $V_n / W_n \xrightarrow{P} V / W$ .
6. Si  $f : \mathbb{R} \rightarrow \mathbb{R}$  es continua luego  $f(V_n) \xrightarrow{P} f(V)$ .
7. Si  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  es continua luego  $g(V_n, W_n) \xrightarrow{P} g(V, W)$ .



## Convergencia en probabilidad de $S_n^2$ y $\widehat{\sigma}^2$ a $a = \text{Var}(X)$

Sean  $X_1, \dots, X_n, \dots$  variables aleatorias independientes e idénticamente distribuidas. Muestre que:

1. ambas formas de escribir a  $\widehat{\sigma}_n^2$  son equivalentes.
2.  $S_n^2 = a_n \widehat{\sigma}_n^2$ , donde  $a_n = \frac{n}{n-1}$ .
3.  $\widehat{\sigma}_n^2$  y  $S_n^2$  convergen en probabilidad a  $\text{Var}(X)$  usando propiedades de convergencia y LGN apropiadamente.

donde:

$$\begin{aligned} \widehat{\sigma}_n^2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 - (\overline{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2 \\ S_n^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X}_n)^2 \end{aligned}$$

A partir de  $\widehat{\sigma}_n^2$  y  $S_n^2$ , ¿qué v.a. convergen en probabilidad a  $\sqrt{\text{Var}(X)}$ ?  
Llámelas  $\widehat{\sigma}_n$  y  $S_n$  respectivamente.

# Ejercicios/ Ejemplos

## Ejemplo 1

Sean  $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, 1)$ , hallar el límite en probabilidad de<sup>a</sup>

$$Y_n = (X_1 X_2 \dots X_n)^{1/n} = \left( \prod_{i=1}^n X_i \right)^{1/n}$$

---

<sup>a</sup>Tenga en cuenta que si  $X \sim U(0, 1)$  entonces  $E(\ln(X)) = -1$ . ¿Por qué vale?

## Ejemplo 2

Sean  $X_1, \dots, X_n \stackrel{iid}{\sim} X$  con  $E(X) = \text{Var}(X) = 1$ , mostrar que

$$\frac{\sum_{i=1}^n X_i}{\left( n \sum_{i=1}^n X_i^2 \right)^{1/2}} \xrightarrow{P} \frac{1}{\sqrt{2}}$$

# Convergencia en media cuadrática

Hasta ahora vimos que se puede demostrar que  $V_n \xrightarrow{P} V$  usando la ley débil de los grandes números y por definición. Veamos otra definición que nos permitirá ver convergencia en probabilidad.

- **Definición:** Decimos que las variables  $V_n$  convergen en media cuadrática al número  $a$ ,  $V_n \xrightarrow{m.c.} a$ , si:
  1.  $E(V_n) \xrightarrow{n \rightarrow \infty} a$
  2.  $Var(V_n) \xrightarrow{n \rightarrow \infty} 0$
- **Aplicación:** Si  $V_n \xrightarrow{m.c.} a$  entonces vale  $V_n \xrightarrow{P} a$ .
- **Intuición:** Si el centro del histograma (densidad) de  $V_n$  se está acercando a  $a$  y la variabilidad de  $V_n$  se está acercando a cero cuando  $n$  crece, entonces toda la distribución de probabilidad de  $V_n$  se está concentrando sobre  $a$  cuando  $n$  crece (por tanto lo tanto,  $V_n \xrightarrow{P} a$ ).

# Demostración de que $V_n \xrightarrow{m.c.} a$ implica que $V_n \xrightarrow{P} a$

**Caso 1:** Suponemos que  $E(V_n) = a$  para todo  $n$ . Sea  $\varepsilon > 0$ . Por Markov

$$P(|V_n - a| \geq \varepsilon) = P(|V_n - a|^2 \geq \varepsilon^2) \leq \frac{E((V_n - a)^2)}{\varepsilon^2} = \frac{Var(V_n)}{\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

**Caso 2, caso general:** Sea  $\varepsilon > 0$ . Por Markov

$$\begin{aligned} P(|V_n - a| \geq \varepsilon) &= P(|V_n - a|^2 \geq \varepsilon^2) \leq \frac{E((V_n - a)^2)}{\varepsilon^2} \\ &\leq \frac{1}{\varepsilon^2} E((V_n - E(V_n) + E(V_n) - a)^2) \\ &= \frac{1}{\varepsilon^2} \left( E[V_n - E(V_n)]^2 - 2E[(V_n - E(V_n))(E(V_n) - a)] + E[(E(V_n) - a)^2] \right) \\ &= \frac{1}{\varepsilon^2} \left( Var(V_n) - 2(E(V_n) - a) \cdot \underbrace{E[V_n - E(V_n)]}_{=0} + (E(V_n) - a)^2 \right) \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

## Ejemplo para ver que $V_n \xrightarrow{m.c.} \theta$

Si  $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$ , definimos

$$V_n = \max \{X_1, \dots, X_n\}.$$

Queremos ver que  $V_n \xrightarrow{m.c.} \theta$  y por lo tanto  $V_n \xrightarrow{P} \theta$ . Calculemos  $E(V_n)$  y  $Var(V_n)$ . Para poder hacer esto, necesitamos conocer la distribución de  $V_n$ . Calculemos primero la función de distribución acumulada de  $V_n$

$$\begin{aligned} P(V_n \leq x) &= P(X_1 \leq x, X_2 \leq x, \dots, X_n \leq x) \\ &= P(X_1 \leq x) \dots P(X_n \leq x) = P(X \leq x)^n. \end{aligned}$$

Como  $X \sim U(0, 1)$

Luego, se tiene que

$$P(X \leq x) = \begin{cases} 0 & x \leq 0 \\ \frac{x}{\theta} & 0 \leq x \leq \theta \\ 1 & x \geq \theta \end{cases}$$

$$P(V_n \leq x) = \begin{cases} 0 & x \leq 0 \\ \left(\frac{x}{\theta}\right)^n & 0 \leq x \leq \theta \\ 1 & x \geq \theta. \end{cases}$$

## Ejemplo para ver que $V_n \xrightarrow{m.c.} \theta$

Derivando, obtenemos la densidad de  $V_n$  es

$$f_{V_n}(x) = nx^{n-1} \frac{1}{\theta^n} I_{(0,\theta)}(x).$$

Entonces

$$E(V_n) = \int_0^\theta nx^n \frac{1}{\theta^n} dx = \frac{n}{n+1} \theta,$$

$$E(V_n^2) = \int_0^\theta nx^{n+1} \frac{1}{\theta^n} dx = \frac{n}{n+2} \theta^2$$

y

$$Var(V_n) = \frac{n}{n+2} \theta^2 - \left( \frac{n}{n+1} \theta \right)^2.$$

Como

$$E(V_n) \xrightarrow{n \rightarrow \infty} \theta \text{ y } Var(V_n) \xrightarrow{n \rightarrow \infty} 0,$$

por la proposición que vimos antes

$$V_n \xrightarrow{P} \theta$$

# Teorema Central del Límite

Theorem (Teorema central de límite para  $X_i \stackrel{iid}{\sim}$ )

Sea  $X_1, \dots, X_n \stackrel{iid}{\sim} X$  con  $E(X)$  y  $Var(X)$ , para todo  $z \in \mathbb{R}$

$$P\left(\sqrt{n} \frac{(\bar{X}_n - E(X))}{\sqrt{Var(X)}} \leq z\right) \xrightarrow{n \rightarrow \infty} P(Z \leq z)$$

donde  $P(Z \leq z)$  con  $Z \sim N(0, 1)$ . A veces se escribe  $\Phi(z) = P(Z \leq z)$ .

Escribimos

$$\sqrt{n} \frac{(\bar{X}_n - E(X))}{\sqrt{Var(X)}} \xrightarrow{d} N(0, 1)$$

# Observaciones sobre el TCL

- El TCL implica que, si  $X_i \sim_{iid}$ , entonces para cualesquiera  $z_1, z_2 \in \mathbb{R}$  que cumplen que  $z_1 \leq z_2$ , vale

$$P\left(z_1 \leq \frac{\sqrt{n}(\bar{X}_n - E(X))}{\sqrt{\text{Var}(X)}} \leq z_2\right) \xrightarrow{n \rightarrow \infty} P(Z \leq z_2) - P(Z \leq z_1)$$

- El TCL nos va a permitir (más adelante en la materia) *cuantificar la incertidumbre* (dar un **margen de error**) que tenemos sobre nuestra estimación de  $E(X)$  usando la media muestral  $\bar{X}_n$ .
- El teorema se refiere a la distribución de  $\bar{X}_n$ , **no** a la de  $X_1, \dots, X_n$ .
- Si  $X_i \sim_{iid} N(\mu, \sigma^2)$ , **no es necesario usar TCL** porque vale que, para cualquier  $n$  que:  $\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ .



# Notación correcta sobre el TCL

## Notación correcta:

- **Distribución asintótica** (versión estandarizada)

$$\frac{\sqrt{n}(\bar{X}_n - E(X))}{\sqrt{\text{Var}(X)}} \xrightarrow{D} N(0, 1)$$

- **Distribución aproximada** para **tamaños de muestra grande** ( $n \gg 0$ ), la distribución de  $\bar{X}_n$  es **aproximadamente normal**:
  - **Versión estandarizada:**

$$\frac{\sqrt{n}(\bar{X}_n - E(X))}{\sqrt{\text{Var}(X)}} \sim_a N(0, 1) \text{ si } n \gg 0$$

- **Versión no estandarizada:**

$$\bar{X}_n \sim_a N\left(E(X), \frac{\text{Var}(X)}{n}\right) \text{ si } n \gg 0.$$

Vale TCL para  $g(X_i) \stackrel{iid}{\sim}$  porque  $X_i \stackrel{iid}{\sim}$

- Si  $X_i = g(Y_i)$  entonces  $\sqrt{n} \left[ \frac{1}{n} \sum_{i=1}^n g(Y_i) - E(g(Y)) \right] \xrightarrow{d} N(0, \text{Var}(g(Y)))$

## Ejercicio

1. Si  $T_i \sim_{iid}$ ,  $E(T) = 8$  y  $\text{Var}(T) = 225$ ,  $g(T) = T^2$  y

$$\sqrt{n} \left[ \frac{1}{n} \sum_{i=1}^n T_i^2 - \theta \right] \xrightarrow{d} N(0, \text{Var}(T^2))$$

¿cuánto vale  $\theta$ ?

# Teorema Central del Límite

## ¿Qué tan grande debe ser el tamaño de muestra $n$ ?

- Si la distribución de  $X$  es simétrica, es decir, si existe algún punto  $c$  tal que el histograma o la función de densidad de  $X$  es simétrica respecto de  $c$ , típicamente con  $n > 20$  la aproximación normal del TCL es adecuada.
- Si la distribución de  $X$  no es simétrica, no hay una “receta” para decir qué tan grande debe ser  $n$  para que la distribución de  $\bar{X}_n$  se “parezca” a una distribución normal. Mientras más grande sea el  $n$ , mejor.
- Para el caso donde  $X_i \sim_{iid} Be(p)$  se suele decir que para que la aproximación de la distribución de  $\bar{X}_n$  por una distribución normal sea adecuada, debería ocurrir que  $np(1 - p) > 5$ . Notar que esta regla es una **heurística** y no tiene sustento teórico alguno.

# Convergencia en distribución

Sea  $V_1, \dots, V_n, \dots$  una sucesión de variables aleatorias y sea  $V$  una variable aleatoria. **Decimos que  $V_n$  converge en distribución a  $V$**  si, para todo  $v$  tal que la función de distribución acumulada de  $V$ ,  $F_V$  es continua en  $v$ , vale que

$$F_{V_n}(v) = P(V_n \leq v) \xrightarrow{n \rightarrow \infty} P(V \leq v) = F_V(v).$$

La convergencia en distribución, más que una convergencia de variables aleatorias, **es una convergencia de funciones de distribución.**

Si  $V_n \xrightarrow{d} V$ , la función de distribución acumulada de  $V_n$  está “cerca” de la distribución de  $V$  para valores de  $n$  grandes.

**Esto no quiere decir que  $V_n$  esté cerca de  $V$ !**

De hecho,  $V_1, \dots, V_n$  y  $V$  pueden estar definidas todas sobre espacios muestrales distintos!

**Notación:** Notamos  $V_n \xrightarrow{d} V$ . También haremos el siguiente abuso de notación. Por ejemplo, si  $V \sim \mathcal{N}(0, 1)$ , escribiremos  $V_n \xrightarrow{d} \mathcal{N}(0, 1)$ ,

## Convergencia en dist. vs. convergencia en prob.

Si  $V_n \xrightarrow{P} V$ , entonces  $V_n \xrightarrow{d} V$ .

En general no es necesariamente cierto que si  $V_n \xrightarrow{d} V$  entonces  $V_n \xrightarrow{P} V$ .

En otras palabras, la convergencia en distribución es más **débil** que la convergencia en probabilidad.

Consideremos una v.a. continua  $X$  con una función de probabilidad puntual  $f_X(x)$  que cumpla ser una función par, es decir,  $f_X(x) = f_X(-x)$ . Se sigue que  $-X$  tiene la misma PDF. Definimos la sucesión  $V_n = X$  si  $n$  es impar y  $V_n = -X$  si  $n$  es par, y sea  $V = X$ , entonces  $F_{V_n}(z) = F_V(z)$  para todo  $z$  porque la PDF de  $X$  y  $-X$  son iguales. Entonces,  $V_n \xrightarrow{d} V$ . Sin embargo,  $V_n \not\xrightarrow{P} V$  porque  $V_n$  oscila entre  $X$  y  $-X$ . Son v.a. diferentes, aunque tengan la misma CDF, porque

$$P(X = -X) = P(\{\omega : X(\omega) = -X(\omega)\}) = P(\{\omega : X(\omega) = 0\}) = 0$$

# Propiedades de la convergencia en distribución

## ■ Lema de Slutsky

Sea  $c \in \mathbb{R}$  una constante. Si  $W_n \xrightarrow{P} c$  y  $V_n \xrightarrow{d} V$  entonces

$$W_n V_n \xrightarrow{d} cV \quad \text{y} \quad V_n + W_n \xrightarrow{d} V + c$$

## ■ Teorema de la función continua

Las funciones continuas conservan los límites aún cuando sus argumentos son (sucesiones de) variables aleatorias. En otras palabras, si  $g : \mathbb{R} \rightarrow \mathbb{R}$  es una función continua y:

- $V_n \xrightarrow{P} c$  entonces  $g(V_n) \xrightarrow{P} g(c)$ .
- $V_n \xrightarrow{d} V$  entonces  $g(V_n) \xrightarrow{d} g(V)$ .

- **Ojo!** No es cierto que si  $V_n \xrightarrow{d} V$  y  $W_n \xrightarrow{d} W$  entonces  $V_n \cdot W_n \xrightarrow{d} V \cdot W$  o  $V_n + W_n \xrightarrow{d} V + W$ . Por ejemplo si  $V_n = W_n = V \sim N(0, 1)$  y  $W = -V \sim N(0, 1)$  se tiene que  $V_n \xrightarrow{d} V$ ,  $W_n \xrightarrow{d} W$ , pero  $V_n + W_n \sim N(0, 4)$  mientras que  $V + W = 0$ .

# Aplicación del lema de Slutsky

Volvamos al ejemplo de antes. Por TCL

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1).$$

Vimos en la slide §36 que  $\hat{\sigma}_n \xrightarrow{P} \sigma$  lo que implica, por las propiedades de convergencia en probabilidad

$$\frac{\sigma}{\hat{\sigma}_n} \xrightarrow{P} 1.$$

Ahora

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}_n} = \underbrace{\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}}_{\xrightarrow{d} \mathcal{N}(0,1)} \underbrace{\frac{\sigma}{\hat{\sigma}_n}}_{\xrightarrow{P} 1} \xrightarrow{d} \mathcal{N}(0, 1),$$

por el lema de Slutsky. Luego,

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}_n} \xrightarrow{d} \mathcal{N}(0, 1)$$

# Implicaciones de las convergencias

$$V_n \xrightarrow{m.c.} V \underbrace{\Rightarrow}_{(1)} V_n \xrightarrow{p} V \underbrace{\Rightarrow}_{(2)} V_n \xrightarrow{D} V$$

La implicación (1) vale por la desigualdad de Chebyshev. La demostración de (2) queda fuera del nivel del curso.



# Convergencia en distribución: Ejercicio

Ejercicio 1: Sea  $X_1, \dots, X_n$  una muestra aleatoria tal que  $E(X_1) = 0$  y  $E(X_1^2) = 2$ . Calcule el límite en distribución de

$$Y_n = \frac{\sqrt{n} \sum_{i=1}^n X_i}{\sum_{i=1}^n X_i^2} \text{ y de } W_n = e^{Y_n}.$$

# Método delta univariado

## Theorem (Método delta)

Supongamos que  $V_n$  cumple que

$$\sqrt{n}(V_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

donde  $\mu$  y  $\sigma^2$  son constantes. Supongamos que  $g(x)$  es una función con derivada continua y que  $g'(\mu) \neq 0$ . Entonces

$$\sqrt{n}(g(V_n) - g(\mu)) \xrightarrow{d} N(0, \sigma^2 g'(\mu)^2)$$

# Ejemplos de método delta univariado

- Sean  $X_i \sim_{iid} Be(p)$ . Muestre que  $\sqrt{n}(\bar{X}_n - p) \xrightarrow{d} N(0, p(1-p))$ . Calcule la distribución asintótica de  $\sqrt{n}(g(\bar{X}_n) - g(p))$ , donde  $g(x) = \frac{x}{1-x}$ .
- Repita el ejercicio anterior con  $g(x) = \ln\left(\frac{x}{1-x}\right)$ .
- Sean  $X_i \sim_{iid} Exp(\lambda)$ . Muestre que  $\sqrt{n}(\bar{X}_n - \frac{1}{\lambda}) \xrightarrow{d} N(0, \frac{1}{\lambda^2})$ . Vea entonces adónde converge en distribución  $\sqrt{n}(g(\bar{X}_n) - g(\frac{1}{\lambda}))$ , donde  $g(x) = \ln(x)$ .
- Repita el ejercicio anterior con  $g(x) = e^x$ .
- Repita el ejercicio anterior con  $g(x) = \frac{1}{x}$ .

# Método delta multivariado

Sea  $(\underline{Z}_n)_{\{n \in \mathbb{N}\}}$  una sucesión de vectores columna con  $p$ -coordenadas de manera que para  $\underline{a} \in \mathbb{R}^p$  y  $\Sigma \in \mathbb{R}^{p \times p}$  vale

$$\sqrt{n}(\underline{Z} - \underline{a}) \xrightarrow{d} N_p(\underline{0}, \Sigma)$$

donde  $\underline{0} = (0, \dots, 0)^T \in \mathbb{R}^p$ .

Sea  $g : \mathbb{R}^p \rightarrow \mathbb{R}^k$  una función continuamente diferenciable de  $\underline{z} = (z_1, \dots, z_p)$  Sea

$$\nabla(\underline{a}) = \begin{pmatrix} \frac{\partial}{\partial z_1} g_1(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \frac{\partial}{\partial z_1} g_2(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \cdots & \frac{\partial}{\partial z_1} g_k(\underline{z}) \Big|_{\underline{z}=\underline{a}} \\ \frac{\partial}{\partial z_2} g_1(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \frac{\partial}{\partial z_2} g_2(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \cdots & \frac{\partial}{\partial z_2} g_k(\underline{z}) \Big|_{\underline{z}=\underline{a}} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial}{\partial z_p} g_1(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \frac{\partial}{\partial z_p} g_2(\underline{z}) \Big|_{\underline{z}=\underline{a}} & \cdots & \frac{\partial}{\partial z_p} g_k(\underline{z}) \Big|_{\underline{z}=\underline{a}} \end{pmatrix}$$

# Método delta multivariado

Entonces si  $\nabla(\underline{a})^T \Sigma \nabla(\underline{a})$  es definido positivo, vale que

$$\sqrt{n}(g(\underline{Z}_n) - g(\underline{a}))^T \xrightarrow{d} N_k(\underline{0}, \nabla(\underline{a})^T \Sigma \nabla(\underline{a}))$$

**Ejercicio:** Consideremos  $X_i \sim_{iid} Be(p)$  e  $Y_i \sim_{iid} Be(q)$ . Suponga adicionalmente que las variables  $X_i$  e  $Y_j$  son independientes para cualquier  $i, j \in \{1, \dots, n\}$ .

Consideremos el vector  $\underline{Z}_n = (\bar{X}_n, \bar{Y}_n)$  Veamos cuál es el límite en distribución de:

1.  $g(a, b) = b - a$
2.  $g(a, b) = (a - b, a + b)$

Notemos que en ambos casos  $\underline{a} = (p, q)^T$  y  $\Sigma = \begin{pmatrix} p(1-p) & 0 \\ 0 & q(1-q) \end{pmatrix}$  y que,

por TCL

$$\sqrt{n}(\underline{Z}_n - \underline{a})^T \xrightarrow{d} N\left((0, 0)^T, \Sigma\right)$$

# Método delta multivariado: ejemplos

**Ejemplo 1:** Para  $g(a, b) = b - a$ , evaluado en  $\underline{Z}_n$  queda

$$g(\underline{Z}_n) = \bar{Y}_n - \bar{X}_n.$$

$$\text{Calculamos } \nabla(\underline{a}) = (-1 \quad 1)^T$$

**Ejemplo 2:** Para  $g(a, b) = (a - b, a + b)$ , evaluado en  $\underline{Z}_n$  queda

$$g(\underline{Z}_n) = (\bar{Y}_n - \bar{X}_n, \bar{Y}_n + \bar{X}_n)$$

$$\text{Calculamos } \nabla(\underline{a}) = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$$

Por lo tanto, por método delta multivariado vale que

$$\sqrt{n}(g(\underline{Z}_n) - g(\underline{a}))^T \xrightarrow{d} N_k(\underline{0}, \nabla(\underline{a})^T \Sigma \nabla(\underline{a}))$$

donde, para el **ejemplo 1**,  $\nabla(\underline{a})^T \Sigma \nabla(\underline{a}) = p(1 - p) + q(1 - q)$  donde,

para el **ejemplo 2**,  $\nabla(\underline{a})^T \Sigma \nabla(\underline{a}) = \begin{pmatrix} r+s & r-s \\ r-s & r+s \end{pmatrix}$  donde  $r = p(1 - p)$  y

$$s = q(1 - q)$$

## Apéndice

A partir de aquí las slides son optativas

## Demostración de las propiedades 2 y 3 en §16

2. Si  $a = 0$  es trivial. Si  $a \neq 0$   $P(|aV_n - aV| > \varepsilon) = P\left(|V_n - V| > \frac{\varepsilon}{|a|}\right) \xrightarrow{n \rightarrow \infty} 0$

3. Sea  $\varepsilon > 0$ . Tenemos que ver que

$$P(|V_n + W_n - (V + W)| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0.$$

Notemos que

$$\{|V_n + W_n - (V + W)| \geq \varepsilon\} \subset \{|V_n - V| \geq \varepsilon/2\} \cup \{|W_n - W| \geq \varepsilon/2\}.$$

Entonces

$$P(|V_n + W_n - (V + W)| \geq \varepsilon) \leq P(|V_n - V| \geq \varepsilon/2) + P(|W_n - W| \geq \varepsilon/2).$$

Como  $V_n \xrightarrow{P} V$  y  $W_n \xrightarrow{P} W$

$$P(|V_n - V| \geq \varepsilon/2) + P(|W_n - W| \geq \varepsilon/2) \xrightarrow{n \rightarrow \infty} 0.$$



## Ejemplo de variables que no son asintóticamente normales

Consideremos que  $X_i \sim_{iid} U(0, \theta]$  y las variables  $Y_n = \max\{X_1, \dots, X_n\}$ . Vimos anteriormente que  $F_{Y_n}(x) = \frac{x^n}{\theta^n}$  si  $0 \leq x \leq \theta$ .

Afirmamos que

$$n(\theta - Y_n) \xrightarrow{d} \text{Exp}\left(\frac{1}{\theta}\right)$$

Veamos que  $P(n(\theta - Y_n) \leq x) \xrightarrow{n \rightarrow \infty} 1 - e^{-x/\theta}$

$$\begin{aligned} P(n(\theta - Y_n) \leq x) &= P\left(\theta - Y_n \leq \frac{x}{n}\right) = P\left(\theta - \frac{x}{n} \leq Y_n\right) \\ &= P\left(Y_n \geq \theta - \frac{x}{n}\right) = 1 - P\left(Y_n < \theta - \frac{x}{n}\right) \\ &= 1 - P\left(X_1 < \theta - \frac{x}{n}, X_2 < \theta - \frac{x}{n}, \dots, X_n < \theta - \frac{x}{n}\right) \\ &\stackrel{X_i \text{ indep}}{=} 1 - P\left(X_1 < \theta - \frac{x}{n}\right) \cdots P\left(X_n < \theta - \frac{x}{n}\right) \\ &\stackrel{X_i \text{ i.d.}}{=} 1 - \left(P\left(X_1 < \theta - \frac{x}{n}\right)\right)^n = 1 - \left(1 - \frac{x}{n\theta}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-x/\theta}. \end{aligned}$$

# Demostración de TCL

Para hacer la demostración de TCL estamos asumiendo que las variables  $X_i$ ,  $i = 1, \dots, n$  son i.i.d., que la FGM de  $X_i$  está definida en un entorno de  $t = 0$ .

Sin pérdida de generalidad hacemos la demostración para  $\mu = 0$ .

La función generatriz de momentos de  $X$  es  $M_X(t) = E(e^{Xt})$ . Como las variables  $X_i$  son independientes si  $i = 1, \dots, n$ , entonces vale que:

$$M_{\sum_{i=1}^n X_i}(t) \underset{X_i \text{ indep}}{=} \prod_{i=1}^n M_{X_i}(t) = [M_X(t)]^n$$

Por lo tanto, considerando la variable aleatoria

$$Y_n = \frac{\bar{X}_n}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i/n}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^n X_i}{\sqrt{n} \cdot \sigma}$$

vale que, como  $Y_n = \sum_{i=1}^n a_i X_i$  con  $a_i = \frac{1}{\sqrt{n} \cdot \sigma}$ :

$$M_{Y_n}(t) = \left[ M_X \left( \frac{t}{\sqrt{n} \cdot \sigma} \right) \right]^n$$

## Demostración de TCL (cont)

Consideremos ahora el desarrollo de Taylor de la función generatriz de momentos  $M_X(t)$  en un entorno de  $s = 0$ :

$$M_X(s) = \sum_{k=0}^{\infty} \frac{s^k}{k!} M_X^{(k)}(0)$$

donde  $M_X^{(k)}$  es la  $k$ -ésima derivada de  $M$ . Remplazando<sup>3</sup>  $s = \frac{t}{\sqrt{n}} \cdot \sigma$

$$M_X\left(\frac{t}{\sqrt{n} \cdot \sigma}\right) = M(0) + \frac{t}{\sqrt{n} \cdot \sigma} M'(0) + \left(\frac{t}{\sqrt{n} \cdot \sigma}\right)^2 \frac{1}{2} M''(0) + \varepsilon$$

donde los términos representados por  $\varepsilon$  son:<sup>4</sup>

$$\varepsilon = \sum_{k=3}^{\infty} \left(\frac{t}{\sqrt{n} \cdot \sigma}\right)^k \frac{1}{k!} M^{(k)}(0) = o\left(\frac{1}{n}\right)$$

---

<sup>3</sup> Notemos que si  $s \approx 0$  entonces  $t \approx 0$ .

<sup>4</sup>  $o\left(\frac{1}{n}\right)$  es una función que cumple que  $\lim_{n \rightarrow +\infty} \frac{o\left(\frac{1}{n}\right)}{\frac{1}{n}} = 0$ .

## Demostración de TCL (cont)

Como  $M(0) = 1$ ,  $M'(0) = E(X) = 0$  y  $M''(0) = E(X^2) = \sigma^2$ :

$$M_X\left(\frac{t}{\sqrt{n} \cdot \sigma}\right) = 1 + \frac{t}{\sqrt{n} \cdot \sigma} \cdot 0 + \left(\frac{t}{\sqrt{n} \cdot \sigma}\right)^2 \frac{1}{2} \sigma^2 + \varepsilon = 1 + \frac{t^2/2}{n} + \varepsilon$$

En base a lo anterior, resulta que:

$$M_{Y_n}(t) = \left[ M_X\left(\frac{t}{\sqrt{n} \cdot \sigma}\right) \right]^n = \left( 1 + \frac{t^2/2}{n} + \varepsilon \right)^n$$

Tomando límite  $n \rightarrow \infty$ , resulta:

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = \lim_{n \rightarrow \infty} \left( 1 + \frac{t^2/2}{n} + \varepsilon \right)^n = e^{t^2/2} = M_Z(t)$$

donde  $e^{t^2/2}$  es la función generatriz de momentos de la distribución normal estándar. Entonces

$$F_{Y_n}(x) \xrightarrow{n \rightarrow \infty} F_Z(x) \text{ y por lo tanto } Y_n \xrightarrow{d} Z, \text{ donde } Z \sim N(0, 1).$$