

Trabajo Práctico N° 1**Ejercicio 1.**

El archivo “eurosec.dta” es una base de datos que contiene los porcentajes de empleo de los distintos sectores económicos para un grupo de países europeos. Los sectores son: S1 (Agricultura), S2 (Minería), S3 (Industria), S4 (Energía), S5 (Construcción), S6 (Servicios Industriales), S7 (Finanzas), S8 (Servicios), S9 (Transporte y Telecomunicaciones).

(a) Obtener la media, varianza y el coeficiente de variación asociados a cada una de las variables.

Stats	s1	s2	s3	s4	s5	s6	s7	s8	s9
Mean	19.13077	1.253846	27.00769	.9076923	8.165385	12.95769	4	20.02308	6.546154
Variance	241.6958	.9409846	49.10874	.1415385	2.707954	20.93294	7.8768	46.64265	1.936185
CV	.8126474	.7736544	.2594728	.4144752	.201532	.3530916	.7016409	.3410836	.2125628

(b) Obtener la matriz de varianzas y covarianzas.

	s1	s2	s3	s4	s5	s6	s7	s8	s9
s1	241.696								
s2	.539877	.940985							
s3	-73.1138	3.02637	49.1087						
s4	-2.33985	.147969	1.01594	.141538					
s5	-13.7721	-.040862	5.70228	.037077	2.70795				
s6	-52.421	-1.76003	6.53514	.347538	2.68048	20.9329			
s7	-9.592	-1.2052	-3.0648	.116	.0752	4.694	7.8768		
s8	-79.2911	-1.86169	7.37861	.340215	1.77843	17.8786	2.0632	46.6426	
s9	-12.2207	.211415	3.41963	.196431	.887662	1.19403	-.9604	5.39649	1.93618

(c) Obtener las medidas globales de variabilidad.

Varianza total= 371,98362.

Varianza media= 41,331513.

Varianza generalizada= 151,86262.

Varianza efectiva= 1,7473642.

(d) Obtener la matriz de correlaciones.

	s1	s2	s3	s4	s5	s6	s7	s8	s9
s1	1.0000								
s2	0.0358	1.0000							
s3	-0.6711	0.4452	1.0000						
s4	-0.4001	0.4055	0.3853	1.0000					
s5	-0.5383	-0.0256	0.4945	0.0599	1.0000				
s6	-0.7370	-0.3966	0.2038	0.2019	0.3560	1.0000			
s7	-0.2198	-0.4427	-0.1558	0.1099	0.0163	0.3656	1.0000		
s8	-0.7468	-0.2810	0.1542	0.1324	0.1582	0.5722	0.1076	1.0000	
s9	-0.5649	0.1566	0.3507	0.3752	0.3877	0.1876	-0.2459	0.5679	1.0000

(e) Regresar el porcentaje de empleo en el sector Minería, respecto de las variables restantes. Obtener la varianza de los residuos y el coeficiente de determinación. ¿Es posible obtener las estimaciones a partir de la matriz de varianzas y covarianzas?

Varianza de los residuos= 0,01730513.

Coeficiente de determinación= 0,98160955.

Sí, es posible obtener las estimaciones a partir de la matriz de varianzas y covarianzas y la matriz de precisión.

(f) Obtener el coeficiente de correlación parcial entre los porcentajes de empleo en el sector agrícola respecto del sector minero. ¿Cómo efectuaría el cómputo a partir de la matriz de varianzas y covarianzas?

El coeficiente de correlación parcial entre los porcentajes de empleo en el sector agrícola respecto del sector minero es -0,97480157.

(g) Obtener los autovalores asociados a la matriz de correlaciones. ¿Existe alguna relación entre el número de variables y los mismos?

	e1	e2	e3	e4	e5	e6	e7	e8	e9
r1	3.4871512	2.1301732	1.0989576	.99448297	.54321777	.38342764	.22575405	.13678988	.00004563

Sí, existe una relación entre el número de variables y los autovalores, siendo la suma de estos últimos igual al número de variables.

(h) Obtener el coeficiente de dependencia efectiva.

Coeficiente de dependencia efectiva= 0,80178941.

(i) Comentar, brevemente, la información que brinda la matriz de precisión.

La matriz de precisión brinda información sobre la relación multivariada entre cada una de las variables y el resto. Contiene información sobre:

- por filas y por fuera de la diagonal principal, los coeficientes de regresión múltiple de la variable correspondiente a esa fila, explicada por todas las demás;
- en la diagonal, las inversas de las varianzas residuales de la regresión de cada variable con el resto;
- estandarizando los elementos de esta matriz, los elementos fuera de la diagonal principal son los coeficientes de correlación parcial entre estas variables.

Por lo tanto, S^{-1} contiene toda la información sobre las regresiones de cada variable sobre las restantes.

Ejercicio 2.

En el archivo “individual_t410.dta”, se encontrará el corte por personas de la Encuesta Permanente de Hogares correspondiente al cuarto trimestre del año 2010. Se propone la construcción de una base para analizar la estructura de la muestra ocupada mayor de 15 años de edad, por aglomerado y por rama de actividad, de acuerdo con la clasificación CAES-Mercosur, considerando las grandes ramas: Agricultura, Ganadería, Caza y Pesca; Minería; Industria; Energía; Construcción; Comercio; Correo y Telecomunicaciones; Ss. Financieros; Otros Ss.; y Administración Pública.

(a) Analizar la variabilidad de la proporción de ocupados por grandes ramas de actividad.

	media
Agricultur~a	.05130951
Minería	.02980964
Industria	.34399797
Energía	.01516862
Construcción	.31695826
Comercio	.61320805
Correo_Tel~s	.03139245
SS._Financ~s	.04629727
Otros Ss.	1.3059524
Administra~a	.37090579

	var
Agricultur~a	.00222073
Minería	.00701461
Industria	.11365215
Energía	.00013202
Construcción	.01454471
Comercio	.11632129
Correo_Tel~s	.00062979
SS._Financ~s	.00216025
Otros Ss.	.49536335
Administra~a	.0216334

	cv
Agricultur~a	.91843911
Minería	2.8096042
Industria	.98001552
Energía	.75747711
Construcción	.3804963
Comercio	.5561882
Correo_Tel~s	.79941574
SS._Financ~s	1.0039137
Otros Ss.	.53893275
Administra~a	.39655079

(b) Analizar la estructura de correlaciones entre las proporciones de ocupados de las ramas de actividad consideradas.

Varianza total= 0,77367232.
 Varianza media= 0,07736723.
 Varianza generalizada= 5,414e-25.
 Varianza efectiva= 0,00374413.

(c) Regresar la proporción de ocupados de la rama servicios, respecto de las proporciones observadas en las ramas restantes. Obtener la varianza de los residuos y el coeficiente de determinación. ¿De qué otra forma se hubiera podido obtener estas estimaciones?

Varianza de los residuos= 0,01650179.
 Coeficiente de determinación= 0,96668751.

Estas estimaciones se podrían haber obtenido mediante la matriz de varianzas y covarianzas y la matriz de precisión.

(d) Obtener el coeficiente de correlación parcial entre los porcentajes de ocupados en el sector comercial respecto del sector Otros Ss.

El coeficiente de correlación parcial entre los porcentajes de ocupados en el sector Comercio respecto del sector Otros Ss. es 0,53293597.

(e) Obtener los autovalores asociados a la matriz de correlaciones.

	e1	e2	e3	e4	e5	e6	e7	e8	e9	e10
r1	5.1644303	1.5298711	.97845644	.87863852	.54266892	.41764761	.26798865	.12086755	.07397417	.0254568

(f) Proponer una métrica que resuma la dependencia entre las proporciones de ocupados entre los distintos sectores.

Coeficiente de dependencia efectiva= 0,64312145.

Ejercicio 3.

El archivo “records.dta” contiene información sobre récords obtenidos por atletas de diferentes nacionalidades en varias especialidades. La siguiente tabla muestra la descripción del contenido de cada variable:

<i>m_100</i>	100 metros
<i>m_200</i>	200 metros
<i>m_400</i>	400 metros
<i>m_800</i>	800 metros
<i>m_1000</i>	1000 metros
<i>m_1500</i>	1500 metros
<i>km_5</i>	5 kilómetros
<i>km_10</i>	10 kilómetros
<i>maratón</i>	42 kilómetros

(a) Realizar un análisis descriptivo de los datos. Señalar si, en el caso de querer efectuar un análisis de componentes principales, se recomendaría la estandarización de las variables.

Variable	Obs	Mean	Std. dev.	Min	Max
m_100	55	10.47109	.3514292	9.93	12.18
m_200	55	20.94036	.6446476	19.72	23.2
m_400	55	46.43873	1.457018	43.86	52.94
m_800	55	1.793273	.0636848	1.7	2.02
m_1500	55	3.698182	.1559094	3.51	4.24
km_5	55	13.84582	.8011605	13.01	16.7
km_10	55	28.98964	1.80785	27.38	35.38
maratón	55	136.624	9.227033	128.22	164.7

Stats	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
Mean	10.47109	20.94036	46.43873	1.793273	3.698182	13.84582	28.98964	136.624
Variance	.1235025	.4155705	2.1229	.0040558	.0243077	.6418582	3.268322	85.13814
CV	.0335618	.0307849	.0313751	.0355132	.0421584	.057863	.0623619	.067536

	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
m_100	1.0000							
m_200	0.9226	1.0000						
m_400	0.8411	0.8507	1.0000					
m_800	0.7560	0.8066	0.8702	1.0000				
m_1500	0.7002	0.7750	0.8353	0.9180	1.0000			
km_5	0.6195	0.6954	0.7786	0.8636	0.9281	1.0000		
km_10	0.6324	0.6964	0.7872	0.8691	0.9346	0.9746	1.0000	
maraton	0.5199	0.5962	0.7050	0.8065	0.8655	0.9322	0.9432	1.0000

	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
m_100	.123502							
m_200	.209022	.41557						
m_400	.4307	.799056	2.1229					
m_800	.01692	.033115	.080743	.004056				
m_1500	.038367	.077888	.189742	.009115	.024308			
km_5	.17441	.359139	.90888	.044062	.115929	.641858		
km_10	.4018	.811639	2.07364	.100059	.263438	1.41166	3.26832	
maraton	1.68601	3.54621	9.47786	.473903	1.24516	6.89105	15.7328	85.1381

En el caso de querer realizar un análisis de componentes principales, se recomendaría la estandarización de las variables, ya que, de lo contrario, se estarían considerando varianzas de unidades de medida diferentes.

Basado en matriz de correlaciones:

```

Number of obs      =          55
Number of comp.    =           8
Trace              =           8
Rho                 =        1.0000

```

Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Unexplained
m_100	0.3176	0.5669	0.3322	0.1277	0.2626	-0.5937	0.1367	0.1051	0
m_200	0.3370	0.4616	0.3607	-0.2591	-0.1541	0.6559	-0.1133	-0.0962	0
m_400	0.3557	0.2482	-0.5605	0.6523	-0.2182	0.1568	-0.0028	0.0004	0
m_800	0.3687	0.0124	-0.5324	-0.4800	0.5401	-0.0147	-0.2382	-0.0375	0
m_1500	0.3728	-0.1398	-0.1534	-0.4046	-0.4876	-0.1575	0.6105	0.1380	0
km_5	0.3644	-0.3120	0.1900	0.0296	-0.2541	-0.1417	-0.5900	0.5478	0
km_10	0.3668	-0.3069	0.1812	0.0804	-0.1332	-0.2192	-0.1784	-0.7965	0
maraton	0.3419	-0.4389	0.2635	0.2993	0.4980	0.3156	0.3989	0.1573	0

Principal components/covariance	Number of obs	=	55
	Number of comp.	=	8
	Trace	=	91.73866
Rotation: (unrotated = principal)	Rho	=	1.0000


Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	89.9139	88.5012	0.9801	0.9801
Comp2	1.4127	1.15277	0.0154	0.9955
Comp3	.25993	.150462	0.0028	0.9983
Comp4	.109468	.0821851	0.0012	0.9995
Comp5	.0272831	.0145485	0.0003	0.9998
Comp6	.0127347	.0104898	0.0001	1.0000
Comp7	.00224482	.00179918	0.0000	1.0000
Comp8	.000445635	.	0.0000	1.0000

Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Unexplained
m_100	0.0199	0.2107	-0.0295	0.3588	-0.1902	0.8869	0.0523	-0.0139	0
m_200	0.0416	0.3589	-0.0193	0.8335	0.0479	-0.4101	-0.0623	-0.0038	0
m_400	0.1106	0.8278	-0.3773	-0.3964	0.0123	-0.0476	-0.0204	-0.0095	0
m_800	0.0055	0.0232	0.0053	0.0096	0.0110	-0.0072	0.2610	0.9649	0
m_1500	0.0144	0.0446	0.0499	0.0162	0.0434	-0.0672	0.9592	-0.2620	0
km_5	0.0793	0.1300	0.3365	-0.0178	0.9092	0.1839	-0.0527	-0.0000	0
km_10	0.1811	0.2990	0.8488	-0.1340	-0.3642	-0.0680	-0.0456	0.0044	0
maraton	0.9728	-0.1808	-0.1419	0.0283	-0.0066	0.0035	0.0010	-0.0009	0

(c) *Efectuar la selección de los componentes principales de acuerdo con los siguientes modos:*


(i) *Búsqueda del “codo”.*




Mediante este modo, se seleccionarían los dos primeros componentes principales.

(ii) *Graficando el porcentaje de varianza explicada por cada componente.*

Porcentaje de varianza explicada por cada componente
(basado en matriz de correlaciones)



Porcentaje acumulado de varianza explicada por cada componente
(basado en matriz de correlaciones)



Mediante este modo, se seleccionarían los dos primeros componentes principales.

(d) Graficar las componentes en pares, en función de lo determinado en el inciso anterior. Interpretar.

