

Análisis Estadístico Multivariado

Problem Set 0

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Resuelva los siguientes ejercicios en R y en Stata.

Ejercicio 1

Abra el archivo Hogar_t403_0.dta, el cual contiene la base de microdatos correspondiente al relevamiento realizado en Argentina en el marco de la Encuesta Permanente de Hogares durante el cuarto trimestre de 2003.

- (a) ¿Qué tipo de variable identifica la vivienda?
- (b) ¿Cuántos hogares fueron relevados en total?
- (c) Genere una nueva base de datos (Hogar_t403_1.dta) que reúna únicamente los códigos para distinguir viviendas, hogares, año, semestre, region y las variables que reflejan la representatividad de] hogar, la cantidad de miembros en el hogar, el monto total del ingreso familiar, y el monto de ingreso per cápita familiar.
- (d) Ayudándose por el archivo Hogar_t403_2.raw obtenga el monto promedio de ingreso total familiar de los hogares correspondientes al aglomerado Gran Resistencia, que componen la muestra.

Ejercicio 2

A partir de la base obtenida en el inciso (d) del ejercicio anterior, construya la matriz $X_{n \times p}$ (con $(n > p)$), cuyas columnas estarán dadas por las variables que representan la cantidad de miembros del hogar, el monto total del ingreso familiar, y el monto de ingreso per cápita familiar, y sus filas por las primeras 600 observaciones.

- (a) Obtener las matrices X' , $X'X$, XX' , $(X'X)^{-1}$. Antes de hacer cuentas considere de qué tamaño deben ser las matrices resultantes.

(b) Verifique que, dada la matriz,

$$B = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

vale la siguiente igualdad:

$$(X'X + B)' = (X'X)' + B'.$$

(c) Obtener la traza y el determinante de la matriz $X'X$.

(d) Sea $\lambda = 1/1000$. Verifique que

$$|\lambda X'X| = \lambda^n |X'X|.$$

Ejercicio 3

Dadas las matrices

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}, \quad B = \begin{bmatrix} 23 & 2 \\ 22 & 15 \\ 3 & 7 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 3 \\ 2 & 13 \end{bmatrix}, \quad D = \begin{bmatrix} 34 & 25 & 2 \\ 3 & 14 & 32 \end{bmatrix},$$

(a) Verificar que

$$(A + BCD)^{-1} = A^{-1} - A^{-1}B(DA^{-1}B + C^{-1})^{-1}DA^{-1}$$

(b) Sea $A_{11} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ una partición de la matriz A . Verifique que

$$(A_{11} + C)^{-1} = C^{-1}(A_{11}^{-1} + C^{-1})^{-1}A_{11}^{-1}$$

Ejercicio 4

Dada la matriz

$$B = \begin{bmatrix} 1 & 1 & 2 & 3 & 2 & 5 & 5 & 2 \\ 1 & 2 & 1 & 2 & 1 & 3 & 3 & 6 \\ 1 & 2 & 3 & 2 & 3 & 1 & 5 & 10 \\ 2 & 4 & 4 & 57 & 5 & 7 & 9 & 1 \\ 2 & 5 & 5 & 5 & 5 & 4 & 4 & 2 \\ 3 & 6 & 5 & 5 & 5 & 6 & 5 & 6 \\ 1 & 7 & 4 & 5 & 6 & 7 & 7 & 8 \\ 3 & 8 & 5 & 6 & 3 & 1 & 1 & 8 \end{bmatrix}$$

obtenga el determinante y la inversa de la matriz, considerando sus particiones:

$$B_{11} = \begin{bmatrix} 1 & 1 & 2 & 3 \\ 1 & 2 & 1 & 2 \\ 1 & 2 & 3 & 2 \\ 2 & 4 & 4 & 57 \end{bmatrix}, \quad B_{12} = \begin{bmatrix} 2 & 5 & 5 & 2 \\ 1 & 3 & 3 & 6 \\ 3 & 1 & 5 & 10 \\ 5 & 7 & 9 & 1 \end{bmatrix}, \quad B_{12} = \begin{bmatrix} 2 & 5 & 5 & 5 \\ 3 & 6 & 5 & 5 \\ 1 & 7 & 4 & 5 \\ 3 & 8 & 5 & 6 \end{bmatrix}, \quad B_{22} = \begin{bmatrix} 5 & 4 & 4 & 2 \\ 5 & 6 & 5 & 6 \\ 6 & 7 & 7 & 8 \\ 3 & 1 & 1 & 8 \end{bmatrix}$$

Trabajo Práctico N° 0

Ejercicio 1.

Abrir el archivo Hogar_t403_0.dta, el cual contiene la base de microdatos correspondiente al relevamiento realizado en Argentina en el marco de la Encuesta Permanente de Hogares durante el cuarto trimestre de 2003.

(a) *¿Qué tipo de variable identifica la vivienda?*

La variable vivienda la identifica *CODUSU*, de tipo str8.

(b) *¿Cuántos hogares fueron relevados en total?*

En total, fueron relevados 12.693 hogares.

(c) *Generar una nueva base de datos (“Hogar_t403_1.dta”) que reúna, únicamente, los códigos para distinguir viviendas, hogares, año, semestre, región y las variables que reflejan la representatividad del hogar, la cantidad de miembros en el hogar, el monto total del ingreso familiar y el monto de ingreso per cápita familiar.*

Stata.

(d) *Ayudándose por el archivo Hogar_t403_2.raw, obtener el monto promedio de ingreso total familiar de los hogares correspondientes al aglomerado Gran Resistencia que componen la muestra.*

El monto promedio de ingreso total familiar de los hogares correspondientes al aglomerado Gran Resistencia que componen la muestra es \$752,3237.

Ejercicio 2.

A partir de la base obtenida en el inciso (d) del ejercicio anterior, construir la matriz $X_{n \times p}$ (con $n > p$), cuyas columnas estarán dadas por las variables que representan la cantidad de miembros del hogar, el monto total del ingreso familiar y el monto de ingreso per cápita familiar, y sus filas por las primeras 600 observaciones.

(a) Obtener las matrices X' , $X'X$, XX' , $(X'X)^{-1}$. Antes de hacer cuentas, considerar de qué tamaño deben ser las matrices resultantes.

Las matrices resultantes deben ser del siguiente tamaño: $(X')_{p \times n}$, $(X'X)_{p \times p}$, $(XX')_{n \times n}$, $((X'X)^{-1})_{p \times p}$.

(b) Verificar que, dada la matriz $B = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$, vale la igualdad: $(X'X + B)' = (X'X)' + B'$.

LHS [3, 3]

	r1	r2	r3
c1	9359	2044257	570667
c2	2044255	1.118e+09	4.124e+08
c3	570663	4.124e+08	2.201e+08

RHS [3, 3]

	r1	r2	r3
c1	9359	2044257	570667
c2	2044255	1.118e+09	4.124e+08
c3	570663	4.124e+08	2.201e+08

(c) Obtener la traza y el determinante de la matriz $X'X$.

La traza y el determinante de la matriz $X'X$ son 1,338e+09 y 3,896e+20, respectivamente.

(d) Sea $\lambda = \frac{1}{1000}$. Verificar que $|\lambda X'X| = \lambda^n |X'X|$.

symmetric LHS [1, 1]

	c1
r1	3.896e+11

symmetric RHS [1, 1]

	c1
r1	3.896e+11

Ejercicio 3.

Dadas las matrices $A = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{pmatrix}$, $B = \begin{pmatrix} 23 & 2 \\ 22 & 15 \\ 3 & 7 \end{pmatrix}$, $C = \begin{pmatrix} 1 & 3 \\ 2 & 13 \end{pmatrix}$, $D = \begin{pmatrix} 34 & 25 & 2 \\ 3 & 14 & 32 \end{pmatrix}$.

(a) Verificar que $(A + BCD)^{-1} = A^{-1} - A^{-1}B(DA^{-1}B + C^{-1})^{-1}DA^{-1}$.

LHS [3, 3]

	r1	r2	r3
c1	.02075734	-.02242204	.03839231
c2	-.02526137	.03133874	-.05725218
c3	.00854573	-.01150987	.02203451

RHS [3, 3]

	r1	r2	r3
c1	.02075734	-.02242204	.03839231
c2	-.02526137	.03133874	-.05725218
c3	.00854573	-.01150987	.02203451

(b) Sea $A_{11} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$ una partición de la matriz A . Verificar que $(A_{11} + C)^{-1} = C^{-1} - (A_{11}^{-1} + C^{-1})^{-1} + A_{11}^{-1}$.

LHS [2, 2]

	r1	r2
c1	.25641026	-.07692308
c2	-.21474359	.07692308

RHS [2, 2]

	r1	r2
c1	.25641026	-.07692308
c2	-.21474359	.07692308

Ejercicio 4.

Dada la matriz $B = \begin{pmatrix} 1 & 1 & 2 & 3 & 2 & 5 & 5 & 2 \\ 1 & 2 & 1 & 2 & 1 & 3 & 3 & 6 \\ 1 & 2 & 3 & 2 & 3 & 1 & 5 & 10 \\ 2 & 4 & 4 & 57 & 5 & 7 & 9 & 1 \\ 2 & 5 & 5 & 5 & 5 & 4 & 4 & 2 \\ 3 & 6 & 5 & 5 & 5 & 6 & 5 & 6 \\ 1 & 7 & 4 & 5 & 6 & 7 & 7 & 8 \\ 3 & 8 & 5 & 6 & 3 & 1 & 1 & 8 \end{pmatrix}$, obtener el determinante y la

inversa de la matriz, considerando sus particiones: $B_{11} = \begin{pmatrix} 1 & 1 & 2 & 3 \\ 1 & 2 & 1 & 2 \\ 1 & 2 & 3 & 2 \\ 2 & 4 & 4 & 57 \end{pmatrix}$,

$$B_{12} = \begin{pmatrix} 2 & 5 & 5 & 2 \\ 1 & 3 & 3 & 6 \\ 3 & 1 & 5 & 10 \\ 5 & 7 & 9 & 1 \end{pmatrix}, B_{21} = \begin{pmatrix} 2 & 5 & 5 & 5 \\ 3 & 6 & 5 & 5 \\ 1 & 7 & 4 & 5 \\ 3 & 8 & 5 & 6 \end{pmatrix}, B_{22} = \begin{pmatrix} 5 & 4 & 4 & 2 \\ 5 & 6 & 5 & 6 \\ 6 & 7 & 7 & 8 \\ 3 & 1 & 1 & 8 \end{pmatrix}.$$

El determinante de la matriz B es 5.648.

Análisis Estadístico Multivariado | UTDT

Problem Set 1

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

1. En el archivo *eurosec.dta* es una base de datos que contiene los porcentajes de empleo de los distintos sectores económicos para un grupo de países europeos. Los sectores son: S1 (Agricultura), S2 (Minería), S3 (Industria), S4 (Energía), S5 (Construcción), S6 (Servicios Industriales), S7 (Finanzas), S8 (Servicios), S9 (Transporte y Telecomunicaciones).
 - (a) Obtenga la media, varianza y el coeficiente de variación asociados a cada una de las variables.
 - (b) Obtenga la matriz de varianzas y covarianzas.
 - (c) Obtenga las medidas globales de variabilidad.
 - (d) Obtenga la matriz de correlaciones.
 - (e) Regrese el porcentaje de empleo en el sector Minería, respecto de las variables restantes. Obtenga la varianza de los residuos y el coeficiente de determinación. ¿Es posible obtener las estimaciones a partir de la matriz de varianzas y covarianzas?
 - (f) Obtenga el coeficiente de correlación parcial entre los porcentajes de empleo en el sector agrícola respecto del sector minero. ¿Cómo efectuaría el cómputo a partir de la matriz de varianzas y covarianzas?
 - (g) Obtenga los autovalores asociados a la matriz de correlaciones. ¿Existe alguna relación entre el número de variables y los mismos?
 - (h) Obtenga el coeficiente de dependencia efectiva.
 - (i) Comente brevemente la información que brinda la matriz de precisión.

Ejercicio 2

2. En el archivo *individual_t410.dta* encontrará el corte por personas de la Encuesta Permanente de Hogares correspondiente al cuarto trimestre del año 2010. Se propone la construcción de una base para analizar la estructura de la muestra ocupada mayor de 15 años de edad, por aglomerado y por rama de actividad, de acuerdo con la clasificación CAES-Mercosur, considerando las grandes ramas: Agricultura, Ganadería, Caza y Pesca; Minería; Industria; Energía; Construcción; Comercio; Correo y Telecomunicaciones; Ss. Financieros; Otros Ss.; y Administración Pública.
- (a) Analice la variabilidad de la proporción de ocupados por grandes de ramas de actividad.
 - (b) Analice la estructura de correlaciones entre las proporciones de ocupados de las ramas de actividad consideradas.
 - (c) Regrese la proporción de ocupados de la rama servicios, respecto de las proporciones observadas en las ramas restantes. Obtenga la varianza de los residuos y el coeficiente de determinación. ¿De qué otra forma hubiera podido obtener estas estimaciones?
 - (d) Obtenga el coeficiente de correlación parcial entre los porcentajes de ocupados en el sector comercial respecto del sector Otros Ss.
 - (e) Obtenga los autovalores asociados a la matriz de correlaciones.
 - (f) Proponga una métrica que resuma la dependencia entre las proporciones de ocupados entre los distintos sectores.

Ejercicio 3

El archivo *records.dta* contiene información sobre records obtenidos por atletas de diferentes nacionalidades en varias especialidades. La siguiente tabla muestra la descripción del contenido de cada variable.

m_100	100 metros
m_200	200 metros
m_400	400 metros
m_800	800 metros
m_1000	1000 metros
m_1500	1500 metros
km_5	5 kilómetros
km_10	10 kilómetros
maraton	42 kilómetros

- (a) Realice un análisis descriptivo de los datos. Señale si en el caso de querer efectuar un análisis de componentes principales, recomendaría la estandarización de las variables.
- (b) Realice un análisis de componentes principales.
- (c) Efectue la selección de los componentes principales de acuerdo con los siguientes modos:
 - i. Búsqueda del “codo”.
 - ii. Graficando el porcentaje de varianza explicada por cada componente.
- (d) Grafique las componentes en pares, en función de lo determinado en el punto anterior. Interprete.

Trabajo Práctico N° 1**Ejercicio 1.**

El archivo “eurosec.dta” es una base de datos que contiene los porcentajes de empleo de los distintos sectores económicos para un grupo de países europeos. Los sectores son: S1 (Agricultura), S2 (Minería), S3 (Industria), S4 (Energía), S5 (Construcción), S6 (Servicios Industriales), S7 (Finanzas), S8 (Servicios), S9 (Transporte y Telecomunicaciones).

(a) Obtener la media, varianza y el coeficiente de variación asociados a cada una de las variables.

Stats	s1	s2	s3	s4	s5	s6	s7	s8	s9
Mean	19.13077	1.253846	27.00769	.9076923	8.165385	12.95769	4	20.02308	6.546154
Variance	241.6958	.9409846	49.10874	.1415385	2.707954	20.93294	7.8768	46.64265	1.936185
CV	.8126474	.7736544	.2594728	.4144752	.201532	.3530916	.7016409	.3410836	.2125628

(b) Obtener la matriz de varianzas y covarianzas.

	s1	s2	s3	s4	s5	s6	s7	s8	s9
s1	241.696								
s2	.539877	.940985							
s3	-73.1138	3.02637	49.1087						
s4	-2.33985	.147969	1.01594	.141538					
s5	-13.7721	-.040862	5.70228	.037077	2.70795				
s6	-52.421	-1.76003	6.53514	.347538	2.68048	20.9329			
s7	-9.592	-1.2052	-3.0648	.116	.0752	4.694	7.8768		
s8	-79.2911	-1.86169	7.37861	.340215	1.77843	17.8786	2.0632	46.6426	
s9	-12.2207	.211415	3.41963	.196431	.887662	1.19403	-.9604	5.39649	1.93618

(c) Obtener las medidas globales de variabilidad.

Varianza total= 371,98362.

Varianza media= 41,331513.

Varianza generalizada= 151,86262.

Varianza efectiva= 1,7473642.

(d) Obtener la matriz de correlaciones.

	s1	s2	s3	s4	s5	s6	s7	s8	s9
s1	1.0000								
s2	0.0358	1.0000							
s3	-0.6711	0.4452	1.0000						
s4	-0.4001	0.4055	0.3853	1.0000					
s5	-0.5383	-0.0256	0.4945	0.0599	1.0000				
s6	-0.7370	-0.3966	0.2038	0.2019	0.3560	1.0000			
s7	-0.2198	-0.4427	-0.1558	0.1099	0.0163	0.3656	1.0000		
s8	-0.7468	-0.2810	0.1542	0.1324	0.1582	0.5722	0.1076	1.0000	
s9	-0.5649	0.1566	0.3507	0.3752	0.3877	0.1876	-0.2459	0.5679	1.0000

(e) Regresar el porcentaje de empleo en el sector Minería, respecto de las variables restantes. Obtener la varianza de los residuos y el coeficiente de determinación. ¿Es posible obtener las estimaciones a partir de la matriz de varianzas y covarianzas?

Varianza de los residuos= 0,01730513.

Coeficiente de determinación= 0,98160955.

Sí, es posible obtener las estimaciones a partir de la matriz de varianzas y covarianzas y la matriz de precisión.

(f) Obtener el coeficiente de correlación parcial entre los porcentajes de empleo en el sector agrícola respecto del sector minero. ¿Cómo efectuaría el cómputo a partir de la matriz de varianzas y covarianzas?

El coeficiente de correlación parcial entre los porcentajes de empleo en el sector agrícola respecto del sector minero es -0,97480157.

(g) Obtener los autovalores asociados a la matriz de correlaciones. ¿Existe alguna relación entre el número de variables y los mismos?

	e1	e2	e3	e4	e5	e6	e7	e8	e9
r1	3.4871512	2.1301732	1.0989576	.99448297	.54321777	.38342764	.22575405	.13678988	.00004563

Sí, existe una relación entre el número de variables y los autovalores, siendo la suma de estos últimos igual al número de variables.

(h) Obtener el coeficiente de dependencia efectiva.

Coeficiente de dependencia efectiva= 0,80178941.

(i) Comentar, brevemente, la información que brinda la matriz de precisión.

La matriz de precisión brinda información sobre la relación multivariada entre cada una de las variables y el resto. Contiene información sobre:

- por filas y por fuera de la diagonal principal, los coeficientes de regresión múltiple de la variable correspondiente a esa fila, explicada por todas las demás;
- en la diagonal, las inversas de las varianzas residuales de la regresión de cada variable con el resto;
- estandarizando los elementos de esta matriz, los elementos fuera de la diagonal principal son los coeficientes de correlación parcial entre estas variables.

Por lo tanto, S^{-1} contiene toda la información sobre las regresiones de cada variable sobre las restantes.

Ejercicio 2.

En el archivo “individual_t410.dta”, se encontrará el corte por personas de la Encuesta Permanente de Hogares correspondiente al cuarto trimestre del año 2010. Se propone la construcción de una base para analizar la estructura de la muestra ocupada mayor de 15 años de edad, por aglomerado y por rama de actividad, de acuerdo con la clasificación CAES-Mercosur, considerando las grandes ramas: Agricultura, Ganadería, Caza y Pesca; Minería; Industria; Energía; Construcción; Comercio; Correo y Telecomunicaciones; Ss. Financieros; Otros Ss.; y Administración Pública.

(a) Analizar la variabilidad de la proporción de ocupados por grandes ramas de actividad.

	media
Agricultur~a	.05130951
Minería	.02980964
Industria	.34399797
Energía	.01516862
Construcción	.31695826
Comercio	.61320805
Correo_Tel~s	.03139245
SS._Financ~s	.04629727
Otros Ss.	1.3059524
Administra~a	.37090579

	var
Agricultur~a	.00222073
Minería	.00701461
Industria	.11365215
Energía	.00013202
Construcción	.01454471
Comercio	.11632129
Correo_Tel~s	.00062979
SS._Financ~s	.00216025
Otros Ss.	.49536335
Administra~a	.0216334

	cv
Agricultur~a	.91843911
Minería	2.8096042
Industria	.98001552
Energía	.75747711
Construcción	.3804963
Comercio	.5561882
Correo_Tel~s	.79941574
SS._Financ~s	1.0039137
Otros Ss.	.53893275
Administra~a	.39655079

(b) Analizar la estructura de correlaciones entre las proporciones de ocupados de las ramas de actividad consideradas.

Varianza total= 0,77367232.
 Varianza media= 0,07736723.
 Varianza generalizada= 5,414e-25.
 Varianza efectiva= 0,00374413.

(c) Regresar la proporción de ocupados de la rama servicios, respecto de las proporciones observadas en las ramas restantes. Obtener la varianza de los residuos y el coeficiente de determinación. ¿De qué otra forma se hubiera podido obtener estas estimaciones?

Varianza de los residuos= 0,01650179.
 Coeficiente de determinación= 0,96668751.

Estas estimaciones se podrían haber obtenido mediante la matriz de varianzas y covarianzas y la matriz de precisión.

(d) Obtener el coeficiente de correlación parcial entre los porcentajes de ocupados en el sector comercial respecto del sector Otros Ss.

El coeficiente de correlación parcial entre los porcentajes de ocupados en el sector Comercio respecto del sector Otros Ss. es 0,53293597.

(e) Obtener los autovalores asociados a la matriz de correlaciones.

	e1	e2	e3	e4	e5	e6	e7	e8	e9	e10
r1	5.1644303	1.5298711	.97845644	.87863852	.54266892	.41764761	.26798865	.12086755	.07397417	.0254568

(f) Proponer una métrica que resuma la dependencia entre las proporciones de ocupados entre los distintos sectores.

Coeficiente de dependencia efectiva= 0,64312145.

Ejercicio 3.

El archivo “records.dta” contiene información sobre récords obtenidos por atletas de diferentes nacionalidades en varias especialidades. La siguiente tabla muestra la descripción del contenido de cada variable:

<i>m_100</i>	100 metros
<i>m_200</i>	200 metros
<i>m_400</i>	400 metros
<i>m_800</i>	800 metros
<i>m_1000</i>	1000 metros
<i>m_1500</i>	1500 metros
<i>km_5</i>	5 kilómetros
<i>km_10</i>	10 kilómetros
<i>maratón</i>	42 kilómetros

(a) Realizar un análisis descriptivo de los datos. Señalar si, en el caso de querer efectuar un análisis de componentes principales, se recomendaría la estandarización de las variables.

Variable	Obs	Mean	Std. dev.	Min	Max
m_100	55	10.47109	.3514292	9.93	12.18
m_200	55	20.94036	.6446476	19.72	23.2
m_400	55	46.43873	1.457018	43.86	52.94
m_800	55	1.793273	.0636848	1.7	2.02
m_1500	55	3.698182	.1559094	3.51	4.24
km_5	55	13.84582	.8011605	13.01	16.7
km_10	55	28.98964	1.80785	27.38	35.38
maratón	55	136.624	9.227033	128.22	164.7

Stats	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
Mean	10.47109	20.94036	46.43873	1.793273	3.698182	13.84582	28.98964	136.624
Variance	.1235025	.4155705	2.1229	.0040558	.0243077	.6418582	3.268322	85.13814
CV	.0335618	.0307849	.0313751	.0355132	.0421584	.057863	.0623619	.067536

	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
m_100	1.0000							
m_200	0.9226	1.0000						
m_400	0.8411	0.8507	1.0000					
m_800	0.7560	0.8066	0.8702	1.0000				
m_1500	0.7002	0.7750	0.8353	0.9180	1.0000			
km_5	0.6195	0.6954	0.7786	0.8636	0.9281	1.0000		
km_10	0.6324	0.6964	0.7872	0.8691	0.9346	0.9746	1.0000	
maraton	0.5199	0.5962	0.7050	0.8065	0.8655	0.9322	0.9432	1.0000

	m_100	m_200	m_400	m_800	m_1500	km_5	km_10	maraton
m_100	.123502							
m_200	.209022	.41557						
m_400	.4307	.799056	2.1229					
m_800	.01692	.033115	.080743	.004056				
m_1500	.038367	.077888	.189742	.009115	.024308			
km_5	.17441	.359139	.90888	.044062	.115929	.641858		
km_10	.4018	.811639	2.07364	.100059	.263438	1.41166	3.26832	
maraton	1.68601	3.54621	9.47786	.473903	1.24516	6.89105	15.7328	85.1381

En el caso de querer realizar un análisis de componentes principales, se recomendaría la estandarización de las variables, ya que, de lo contrario, se estarían considerando varianzas de unidades de medida diferentes.

Basado en matriz de correlaciones:

```

Number of obs      =          55
Number of comp.    =           8
Trace              =           8
Rho                 =        1.0000

```

Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Unexplained
m_100	0.3176	0.5669	0.3322	0.1277	0.2626	-0.5937	0.1367	0.1051	0
m_200	0.3370	0.4616	0.3607	-0.2591	-0.1541	0.6559	-0.1133	-0.0962	0
m_400	0.3557	0.2482	-0.5605	0.6523	-0.2182	0.1568	-0.0028	0.0004	0
m_800	0.3687	0.0124	-0.5324	-0.4800	0.5401	-0.0147	-0.2382	-0.0375	0
m_1500	0.3728	-0.1398	-0.1534	-0.4046	-0.4876	-0.1575	0.6105	0.1380	0
km_5	0.3644	-0.3120	0.1900	0.0296	-0.2541	-0.1417	-0.5900	0.5478	0
km_10	0.3668	-0.3069	0.1812	0.0804	-0.1332	-0.2192	-0.1784	-0.7965	0
maraton	0.3419	-0.4389	0.2635	0.2993	0.4980	0.3156	0.3989	0.1573	0

Principal components/covariance	Number of obs	=	55
	Number of comp.	=	8
	Trace	=	91.73866
Rotation: (unrotated = principal)	Rho	=	1.0000


Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	89.9139	88.5012	0.9801	0.9801
Comp2	1.4127	1.15277	0.0154	0.9955
Comp3	.25993	.150462	0.0028	0.9983
Comp4	.109468	.0821851	0.0012	0.9995
Comp5	.0272831	.0145485	0.0003	0.9998
Comp6	.0127347	.0104898	0.0001	1.0000
Comp7	.00224482	.00179918	0.0000	1.0000
Comp8	.000445635	.	0.0000	1.0000

Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Unexplained
m_100	0.0199	0.2107	-0.0295	0.3588	-0.1902	0.8869	0.0523	-0.0139	0
m_200	0.0416	0.3589	-0.0193	0.8335	0.0479	-0.4101	-0.0623	-0.0038	0
m_400	0.1106	0.8278	-0.3773	-0.3964	0.0123	-0.0476	-0.0204	-0.0095	0
m_800	0.0055	0.0232	0.0053	0.0096	0.0110	-0.0072	0.2610	0.9649	0
m_1500	0.0144	0.0446	0.0499	0.0162	0.0434	-0.0672	0.9592	-0.2620	0
km_5	0.0793	0.1300	0.3365	-0.0178	0.9092	0.1839	-0.0527	-0.0000	0
km_10	0.1811	0.2990	0.8488	-0.1340	-0.3642	-0.0680	-0.0456	0.0044	0
maraton	0.9728	-0.1808	-0.1419	0.0283	-0.0066	0.0035	0.0010	-0.0009	0



(c) *Efectuar la selección de los componentes principales de acuerdo con los siguientes modos:*

(i) *Búsqueda del “codo”.*




Mediante este modo, se seleccionarían los dos primeros componentes principales.

(ii) *Graficando el porcentaje de varianza explicada por cada componente.*



Mediante este modo, se seleccionarían los dos primeros componentes principales.

(d) Graficar las componentes en pares, en función de lo determinado en el inciso anterior. Interpretar.



Análisis Estadístico Multivariado | UTDT

Problem Set 2

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

El archivo *ine_dta* es una base de datos que contiene los gastos promedio, en euros, de los hogares españoles, por grandes rubros y comunidad autónoma, correspondientes a los relevamientos de la encuesta de presupuestos familiares del año 2005 realizada por el Instituto Nacional de Estadísticas de España (INE). La descripción de las variables y de la base puede consultarse en las etiquetas asociadas a cada una.

- (a) Realice un análisis descriptivo de los datos.
- (b) Realice un análisis de componentes principales.
- (c) Efectúe la selección de los componentes principales de acuerdo con los siguientes modos:
 - i. Búsqueda del “codo”.
 - ii. Búsqueda por umbral de varianza a explicar, considerando un 80%.
 - iii. Búsqueda por tope mínimo al valor de los eigenvalores, considerando la varianza media.
- (d) Interprete los componentes seleccionados. Para ello, puede emplear el archivo *renta.csv*.

Aclaración: el archivo *mmta_csv* contiene información referida al ingreso promedio por hogar, por comunidad; relevado por el INE para el año 2005.

Ejercicio 2

En relación al ejercicio anterior, realice el *biplot* asociado a las dos dimensiones principales, considerando un parámetro $c = 0.5$.

Ejercicio 3

Teniendo en cuenta la misma base de datos del primer punto, efectúe los *biplots* correspondientes a las dos dimensiones principales y a la primera y tercera, considerando en ambos casos, un parámetro $c = 0$. Comente brevemente el resultado en relación a lo obtenido mediante el análisis de componentes principales efectuado en el primer ejercicio.

Ejercicio 4

La base *wb.dta* contiene información relevada por el Banco Mundial en 77 países durante el año 2007 (los detalles de las variables relevadas se pueden observar en las etiquetas asignadas a las mismas). A partir de estos datos, se pide:

- (a) Realice un análisis normado de componentes principales a partir de los datos.
- (b) ¿Cuántos componentes sugiere extraer?
- (c) ¿Cuál es el porcentaje de variabilidad total explicado por las componentes seleccionadas?
- (d) ¿Qué interpretación sugiere de las componentes, con arreglo a las correlaciones existentes con las variables originales? Para este punto puede ayudarse con la estructura de análisis presente en el libro *P2.xls*.
- (e) Clasifique a los países de acuerdo con las dos componentes principales.
- (f) Realice un biplot considerando las dos dimensiones principales de análisis para un parámetro $c = 0.5$. ¿Qué puede decir sobre la posición de los Estados Unidos y China, y su influencia en el análisis, a la luz de los resultados obtenidos?

Ejercicio 5

La base *hspendusa2009.dta* contiene información relevada durante los años 2008-2009 por el Instituto de Estadísticas de los Estados Unidos, correspondiente a los gastos medios de los hogares por capítulos y por área metropolitana (los detalles de las variables se pueden observar en el archivo *usa.xls*). Efectúe un análisis de componentes principales.

Trabajo Práctico N° 2**Ejercicio 1.**

El archivo “ine.dta” es una base de datos que contiene los gastos promedio, en euros, de los hogares españoles, por grandes rubros y comunidad autónoma, correspondientes a los relevamientos de la encuesta de presupuestos familiares del año 2005 realizada por el Instituto Nacional de Estadísticas de España (INE). La descripción de las variables y de la base puede consultarse en las etiquetas asociadas a cada una.

(a) Realizar un análisis descriptivo de los datos.

Variable	Obs	Mean	Std. dev.	Min	Max
alybnh	18	4200.572	712.644	3406.59	6561.27
vestcal	18	1751.38	389.5767	1244.85	2792.25
vivagelo	18	7863.757	1846.833	4833.29	12291.94
mobyment	18	1131.067	205.8	724.82	1500.56
salud	18	570.0333	151.5053	302.85	942.22
transp	18	2561.397	411.2195	1680.61	3148.5
comu	18	678.1139	97.78773	496.75	897.13
ocio	18	1485.072	352.4416	746.21	2080.19
educ	18	231.9739	98.86097	87.76	438.92
esparc	18	2178.802	349.0546	1670.36	2840.56
otros	18	1510.961	263.4181	898.3	1925.89

Stats	alybnh	vestcal	vivagelo	mobyment	salud	transp	comu	ocio	educ	esparc	otros
Mean	4200.572	1751.38	7863.757	1131.067	570.0333	2561.397	678.1139	1485.072	231.9739	2178.802	1510.961
Variance	507861.5	151770	3410793	42353.62	22953.85	169101.5	9562.441	124215.1	9773.491	121839.1	69389.08
CV	.1696541	.2224399	.2348538	.181952	.2657832	.160545	.1442055	.2373228	.4261728	.1602049	.1743381

	alybnh	vestcal	vivagelo	mobyment	salud	transp	comu	ocio	educ	esparc	otros
alybnh	1.0000										
vestcal	0.8303	1.0000									
vivagelo	0.1151	0.2817	1.0000								
mobyment	0.4255	0.5484	0.6729	1.0000							
salud	0.5876	0.5515	0.3730	0.4359	1.0000						
transp	0.1807	-0.0512	0.2390	0.3747	0.2431	1.0000					
comu	0.4905	0.4005	0.6784	0.7074	0.6655	0.5336	1.0000				
ocio	0.3118	0.4689	0.8845	0.7746	0.5416	0.2545	0.7954	1.0000			
educ	0.1116	0.3366	0.8761	0.6143	0.3818	0.1906	0.6814	0.8939	1.0000		
esparc	0.3450	0.4988	0.8082	0.7159	0.5586	0.2354	0.7587	0.8548	0.7795	1.0000	
otros	0.2994	0.3766	0.5744	0.6579	0.2632	0.4942	0.6145	0.6348	0.5729	0.4650	1.0000

	alybnh	vestcal	vivagelo	mobyment	salud	transp	comu	ocio	educ	esparc	otros
alybnh	507862										
vestcal	230526	151770									
vivagelo	151455	202659	3.4e+06								
mobyment	62406.2	43970.8	255737	42353.6							
salud	63440.3	32552.6	104375	13591.6	22953.8						
transp	52953.1	-8196.36	181481	31707.6	15144.9	169101					
comu	34183.7	15255.9	122513	14235.9	9859.84	21457.3	9562.44				
ocio	78308.8	64381.6	575741	56184.1	28917.1	36890.3	27411.5	124215			
educ	7865.77	12962.6	159964	12497.5	5719.04	7749.14	6587.29	31144.4	9773.49		
esparc	85819.1	67823.8	520992	51425.6	29541.2	33783.9	25895.3	105165	26897.8	121839	
otros	56211	38643.3	279426	35665.3	10505	53537.4	15828.2	58937.5	14920	42757.5	69389.1

Variable	Partial corr.	Semipartial corr.	Partial corr.^2	Semipartial corr.^2	Significance value
vestcal	0.8688	0.5915	0.7549	0.3498	0.0024
vivagelo	0.1226	0.0416	0.0150	0.0017	0.7534
mobymant	-0.2715	-0.0951	0.0737	0.0090	0.4798
salud	-0.1229	-0.0417	0.0151	0.0017	0.7528
transp	0.2801	0.0983	0.0785	0.0097	0.4654
comu	0.6013	0.2536	0.3615	0.0643	0.0868
ocio	0.0837	0.0283	0.0070	0.0008	0.8305
educ	-0.4532	-0.1714	0.2054	0.0294	0.2205
esparc	-0.2692	-0.0942	0.0725	0.0089	0.4837
otros	-0.2278	-0.0788	0.0519	0.0062	0.5556

(b) Realizar un análisis de componentes principales.

Basado en matriz de correlaciones:

Principal components/correlation	Number of obs	=	18
	Number of comp.	=	11
	Trace	=	11
Rotation: (unrotated = principal)	Rho	=	1.0000

Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	6.31799	4.63452	0.5744	0.5744
Comp2	1.68348	.518886	0.1530	0.7274
Comp3	1.16459	.4527	0.1059	0.8333
Comp4	.711894	.376163	0.0647	0.8980
Comp5	.33573	.0888713	0.0305	0.9285
Comp6	.246859	.0686718	0.0224	0.9510
Comp7	.178187	.0371071	0.0162	0.9672
Comp8	.14108	.0155581	0.0128	0.9800
Comp9	.125522	.0650827	0.0114	0.9914
Comp10	.0604393	.0262194	0.0055	0.9969
Comp11	.0342199	.	0.0031	1.0000

Principal components (eigenvectors)


Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Comp9	Comp10	Comp11	Unexplained
alybnh	0.2073	0.6146	0.1074	0.0974	-0.0291	0.4075	-0.2469	0.1482	0.2589	-0.1293	0.4740	0
vestcal	0.2441	0.5185	-0.2140	0.3225	0.0077	0.1046	0.3670	0.0381	-0.1907	0.1589	-0.5595	0
vivagelo	0.3315	-0.3155	-0.2008	-0.0142	-0.0053	0.1415	0.1154	0.1745	0.7708	0.2617	-0.1536	0
mobybamt	0.3387	-0.0037	0.0613	0.2925	-0.5949	-0.5657	-0.1077	0.2229	-0.0724	0.1447	0.1859	0
salud	0.2635	0.3311	0.0166	-0.6080	0.3392	-0.5052	0.2374	0.0221	0.0754	0.0557	0.1226	0
transp	0.1628	-0.1258	0.7924	-0.1381	-0.1746	0.2416	0.4188	0.1691	-0.0608	-0.0674	-0.0976	0
comu	0.3549	-0.0061	0.2045	-0.2695	0.0288	0.1126	-0.6905	-0.1208	-0.1672	0.0743	-0.3892	0
ocio	0.3716	-0.1529	-0.1714	-0.0178	0.0565	-0.0395	-0.0991	0.2073	-0.0471	-0.8409	-0.2046	0
educ	0.3285	-0.2921	-0.2482	-0.0056	0.2639	0.2693	0.1127	0.3735	-0.4946	0.2721	0.3634	0
esparc	0.3507	-0.0735	-0.2080	-0.1840	-0.3619	0.2056	0.2194	-0.7228	-0.0861	-0.0665	0.1970	0
otros	0.2863	-0.1195	0.3072	0.5524	0.5432	-0.2004	-0.0105	-0.3845	0.0748	-0.0081	0.1241	0

Principal components/covariance	Number of obs	=	18
	Number of comp.	=	11
	Trace	=	4639612
Rotation: (unrotated = principal)	Rho	=	1.0000

Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	3687478	3054180	0.7948	0.7948
Comp2	633298	456210	0.1365	0.9313
Comp3	177088	130083	0.0382	0.9694
Comp4	47004.7	5090.15	0.0101	0.9796
Comp5	41914.5	23807.5	0.0090	0.9886
Comp6	18107	5406.33	0.0039	0.9925
Comp7	12700.7	510.343	0.0027	0.9953
Comp8	12190.3	4652.97	0.0026	0.9979
Comp9	7537.36	6015.16	0.0016	0.9995
Comp10	1522.2	750.196	0.0003	0.9998
Comp11	772.001	.	0.0002	1.0000

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Comp9	Comp10	Comp11	Unexplained
alybnh	0.0638	0.8748	0.0036	-0.3835	-0.0667	0.1843	-0.1913	-0.0431	-0.0210	-0.0181	0.0771	0
vestcal	0.0674	0.4068	-0.2632	0.4366	-0.1017	-0.5842	0.4014	0.1016	-0.1445	0.0458	-0.1550	0
vivagelo	0.9596	-0.1403	-0.0612	-0.1929	-0.1053	-0.0776	0.0174	0.0039	0.0315	-0.0062	-0.0122	0
mobyant	0.0756	0.0907	0.0793	0.3368	0.0122	-0.0716	-0.1282	-0.8100	0.4121	0.0663	0.1192	0
salud	0.0325	0.1034	0.0181	-0.0021	0.2610	0.2465	0.5642	0.2636	0.6688	-0.0669	0.1393	0
transp	0.0559	0.0724	0.9261	-0.0395	0.1198	-0.2521	0.1785	0.0056	-0.1481	-0.0271	-0.0018	0
comu	0.0363	0.0463	0.0764	0.0249	0.0980	0.2043	-0.0221	0.0149	0.1007	0.6585	-0.7031	0
ocio	0.1662	0.0812	0.0016	0.3749	0.1859	0.6086	0.2876	-0.1949	-0.4906	-0.2321	-0.0707	0
educ	0.0455	-0.0020	-0.0093	0.0953	0.0272	0.0785	0.0867	0.0706	-0.2086	0.7023	0.6578	0
esparc	0.1514	0.1031	-0.0276	0.3115	0.7140	-0.1199	-0.5073	0.2790	0.0444	-0.0676	0.0522	0
otros	0.0823	0.0777	0.2368	0.5126	-0.5803	0.2381	-0.2953	0.3757	0.2055	-0.0525	0.0391	0


(i) *Búsqueda del “codo”.*




Mediante este modo, se seleccionarían los tres primeros componentes principales.

(ii) *Búsqueda por umbral de varianza a explicar, considerando un 80%.*

Porcentaje de varianza explicada por cada componente
(basado en matriz de correlaciones)



Porcentaje acumulado de varianza explicada por cada componente
(basado en matriz de correlaciones)



Mediante este modo, se seleccionarían los tres primeros componentes principales.

(iii) *Búsqueda por tope mínimo al valor de los eigenvalores, considerando la varianza media.*

Mediante este modo, se seleccionarían los tres primeros componentes principales, ya que estos tienen un autovalor mayor a 1, correspondiente a la varianza media.

(d) *Interpretar los componentes seleccionados. Para ello, se puede emplear el archivo “renta.csv”. Aclaración: El archivo “renta.csv” contiene información referida al ingreso promedio por hogar, por comunidad; relevado por el INE para el año 2005.*

```
Principal components/correlation      Number of obs      =      18
                                     Number of comp.    =      3
                                     Trace                =     11
Rotation: (unrotated = principal)    Rho                =     0.8333
```

Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	6.31799	4.63452	0.5744	0.5744
Comp2	1.68348	.518886	0.1530	0.7274
Comp3	1.16459	.4527	0.1059	0.8333
Comp4	.711894	.376163	0.0647	0.8980
Comp5	.33573	.0888713	0.0305	0.9285
Comp6	.246859	.0686718	0.0224	0.9510
Comp7	.178187	.0371071	0.0162	0.9672
Comp8	.14108	.0155581	0.0128	0.9800
Comp9	.125522	.0650827	0.0114	0.9914
Comp10	.0604393	.0262194	0.0055	0.9969
Comp11	.0342199	.	0.0031	1.0000

Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Unexplained
alybnh	0.2073	0.6146	0.1074	.07912
vestcal	0.2441	0.5185	-0.2140	.1178
vivagelo	0.3315	-0.3155	-0.2008	.0913
mobymant	0.3387	-0.0037	0.0613	.2709
salud	0.2635	0.3311	0.0166	.3763
transp	0.1628	-0.1258	0.7924	.07458
comu	0.3549	-0.0061	0.2045	.1554
ocio	0.3716	-0.1529	-0.1714	.05395
educ	0.3285	-0.2921	-0.2482	.103
esparc	0.3507	-0.0735	-0.2080	.1633
otros	0.2863	-0.1195	0.3072	.3483

El primer autovector pondera con signo positivo a todas las variables, por lo que el primer componente puede ser interpretado como una medida global de gasto.


El segundo autovector pondera con un signo positivo a la primera, segunda y quinta variable y con signo negativo a las restantes, por lo que el segundo componente tomará

valores altos en aquellas comunidades cuyos gastos de necesidad primaria (alimentos y bebidas no alcohólicas, artículos de vestir y calzado, y salud) resulten más importantes, en términos relativos, a los restantes.

El tercer autovector pondera con un signo negativo a la segunda, tercera, octava, novena y décima variable y con signo positivo a las restantes, por lo que el tercer componente tomará valores altos en aquellas comunidades cuyos gastos en transporte, en comunicaciones y otros resulten más importantes, en términos relativos, a los restantes.


Ejercicio 2.

En relación al ejercicio anterior, realizar el biplot asociado a las dos dimensiones principales, considerando un parámetro $c = 0,5$.



Ejercicio 3.

Teniendo en cuenta la misma base de datos del primer punto, efectuar los biplots correspondientes a las dos dimensiones principales y a la primera y tercera, considerando, en ambos casos, un parámetro $c = 0$. Comentar, brevemente, el resultado en relación a lo obtenido mediante el análisis de componentes principales efectuado en el primer ejercicio.






Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	3.37471e+16	3.32396e+16	0.9837	0.9837
Comp2	5.07523e+14	4.75686e+14	0.0148	0.9985
Comp3	3.18369e+13	1.13473e+13	0.0009	0.9994
Comp4	2.04896e+13	2.04896e+13	0.0006	1.0000
Comp5	0	0	0.0000	1.0000
Comp6	0	0	0.0000	1.0000
Comp7	0	0	0.0000	1.0000
Comp8	0	0	0.0000	1.0000
Comp9	0	.	0.0000	1.0000


Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Unexplained
var4	-0.0000	0.0003	-0.0005	0.0001	199727543
var5	0.0625	0.1785	0.5969	0.7797	6.625
var6	-0.0000	0.0000	-0.0000	-0.0000	45.19
var7	0.0000	0.0000	-0.0000	-0.0000	88.41
var8	0.8535	-0.1211	0.3820	-0.3331	-4
var9	-0.0000	-0.0000	0.0000	-0.0000	1.515
var10	0.1607	0.9679	-0.1538	-0.1167	27.25
var11	0.4917	-0.1287	-0.6886	0.5172	35
var12	-0.0000	-0.0000	0.0000	-0.0000	15.35


(b) ¿Cuántos componentes se sugiere extraer?



Porcentaje de varianza explicada por cada componente
(basado en matriz de correlaciones)



Porcentaje acumulado de varianza explicada por cada componente
(basado en matriz de correlaciones)



Por lo tanto, se sugiere extraer los tres primeros componentes principales.

(c) *¿Cuál es el porcentaje de variabilidad total explicado por las componentes seleccionadas?*

El porcentaje de variabilidad total explicado por las componentes seleccionadas es 80,85%.


(d) *¿Qué interpretación se sugiere de las componentes, con arreglo a las correlaciones existentes con las variables originales? Para este punto, se puede ayudar con la estructura de análisis presente en el libro “P2.xlsx”.*

El primer autovector pondera con signo positivo a todas las variables excepto a “Real Interest Rate”, “Life Expectancy at Birth” y “MFN Tariff Rate”, por lo que el primer componente principal tomará valores bajos en aquellos países cuyos valores en estas variables resulten más importantes, en términos relativos, a los restantes.


El segundo autovector pondera con signo positivo a todas las variables excepto a “GNI per cápita” y “Life Expectancy at Birth”, por lo que el segundo componente principal tomará valores bajos en aquellos países cuyos valores en estas variables resulten más importantes, en términos relativos, a los restantes.

El tercer autovector pondera con signo positivo a todas las variables excepto a “Population”, “Labor Force” y “MFN Tariff Rate”, por lo que el tercer componente principal tomará valores bajos en aquellos países cuyos valores en estas variables resulten más importantes, en términos relativos, a los restantes.

(e) *Clasificar a los países de acuerdo con las dos componentes principales.*



(f) Realice un biplot considerando las dos dimensiones principales de análisis para un parámetro $c = 0.5$. ¿Qué se puede decir sobre la posición de los Estados Unidos y China y su influencia en el análisis, a la luz de los resultados obtenidos?



A la luz de los resultados obtenidos, lo que se puede decir sobre la posición de los Estados Unidos y China es que ambos tienen, respecto al resto de los países, un alto valor del componente 1 y China, además, del componente 2, reflejando, por ejemplo, en el primer caso, el alto nivel de GNI per cápita y, en el segundo caso, el alto nivel de población.

La base “hspendusa2009.csv” contiene información relevada durante los años 2008-2009 por el Instituto de Estadísticas de los Estados Unidos, correspondiente a los gastos medios de los hogares por capítulos y por área metropolitana (los detalles de las variables se pueden observar en el archivo “usa.xlsx”). Efectuar un análisis de componentes principales.

Principal components/correlation	Number of obs	=	18
	Number of comp.	=	12
	Trace	=	12
Rotation: (unrotated = principal)	Rho	=	1.0000

Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	5.75656	3.47503	0.4797	0.4797
Comp2	2.28152	.811626	0.1901	0.6698
Comp3	1.4699	.560801	0.1225	0.7923
Comp4	.909096	.345173	0.0758	0.8681
Comp5	.563923	.185157	0.0470	0.9151
Comp6	.378766	.0882703	0.0316	0.9466
Comp7	.290495	.154762	0.0242	0.9709
Comp8	.135733	.0151273	0.0113	0.9822
Comp9	.120606	.065335	0.0101	0.9922
Comp10	.0552706	.0325018	0.0046	0.9968
Comp11	.0227689	.00740786	0.0019	0.9987
Comp12	.015361	.	0.0013	1.0000

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Comp9	Comp10	Comp11	Comp12	Unexplained
a1	0.3249	0.1082	0.1179	0.4039	-0.0847	-0.4483	-0.5954	-0.2547	-0.1863	-0.0399	0.0672	-0.1932	
a2	0.3622	-0.1079	-0.0891	-0.0526	-0.4197	-0.2630	0.2928	0.5530	0.2384	0.2614	0.2057	-0.2054	
a3	0.2664	-0.3628	0.4079	0.0860	0.0321	0.2124	-0.1371	0.0835	-0.2400	0.1808	0.0173	0.6790	
a4	0.3125	-0.3461	0.0866	0.0318	0.0199	-0.3517	0.4060	-0.0445	0.5343	-0.0914	0.1525	0.0702	
a5	0.2889	0.0334	-0.3934	0.1789	0.6302	-0.0234	0.1522	-0.1939	-0.1494	-0.0157	-0.4413	0.0545	
a6	0.2949	-0.3189	0.0667	-0.4400	0.0120	-0.0027	0.2830	-0.4110	-0.5335	-0.2671	0.0680	0.0592	
a7	0.3543	0.0996	-0.1814	-0.3747	-0.0746	0.2392	-0.2605	-0.2149	0.2105	0.6132	-0.2872	-0.1083	
a8	0.3040	-0.3184	-0.0560	-0.3259	0.3305	0.2489	-0.3263	0.2117	0.1111	-0.3629	0.3941	-0.2739	
a9	0.3469	0.2693	0.1281	0.0110	-0.3529	0.1077	-0.0393	0.2257	0.3488	-0.5086	-0.4322	0.1427	
a10	0.1669	-0.6064	-0.2782	0.3044	0.2879	0.4422	0.2633	0.4422	-0.2711	-0.2711	-0.2711	-0.2711	
a11	0.0943	0.6215	-0.0666	0.0189	0.2171	-0.0972	-0.0393	0.1823	0.2712	0.1527	0.5103	0.3828	
a12	0.2291	-0.0810	-0.4962	0.5255	-0.1972	0.5408	0.1506	-0.2244	-0.0736	-0.0668	0.2111	0.0002	

Basado en matriz de varianzas y covarianzas:

Principal components/covariance

Number of obs = 18

Number of comp. = 12

Trace = 1.11e+07

Rotation: (unrotated = principal)


Rho = 1.0000

Component	Eigenvalue	Difference	Proportion	Cumulative
Comp1	8841316	7450143	0.7964	0.7964
Comp2	1391172	974398	0.1253	0.9217
Comp3	416774	174838	0.0375	0.9592
Comp4	241937	132052	0.0218	0.9810
Comp5	109885	63204.4	0.0099	0.9909
Comp6	46680.9	18101.4	0.0042	0.9951
Comp7	28579.5	9397.67	0.0026	0.9977
Comp8	19181.8	14531.8	0.0017	0.9994
Comp9	4649.94	3549.22	0.0004	0.9998
Comp10	1100.72	486.454	0.0001	0.9999
Comp11	614.268	497.431	0.0001	1.0000
Comp12	116.837	.	0.0000	1.0000


Principal components (eigenvectors)

Variable	Comp1	Comp2	Comp3	Comp4	Comp5	Comp6	Comp7	Comp8	Comp9	Comp10	Comp11	Comp12	Unexplained
a1	0.0895	0.1877	0.2331	0.2551	0.8776	0.1399	-0.1722	-0.0759	-0.0775	0.0351	-0.0675	-0.0189	0
a2	0.0307	0.0633	0.0374	-0.0893	0.0850	0.1349	0.1400	0.2168	0.9142	0.1149	-0.1600	-0.1380	0
a3	0.9757	-0.1659	-0.0750	-0.0449	-0.0350	-0.0301	-0.0827	0.0402	-0.0012	-0.0254	0.0396	0.0031	0
a4	0.0937	0.0965	-0.0638	-0.1080	0.0360	0.6025	0.7225	-0.2176	-0.1596	0.0199	0.0802	-0.0133	0
a5	0.1136	0.8667	-0.3679	0.2253	-0.1831	-0.0134	-0.1095	-0.0283	0.0228	-0.0464	-0.0121	0.0228	0
a6	0.0416	0.2246	0.6171	-0.1579	-0.2815	0.4613	-0.2943	0.3776	-0.1441	0.0060	0.0067	-0.0029	0
a7	0.0808	0.3266	0.4250	-0.5521	0.0605	-0.4759	0.2103	-0.3278	0.0190	-0.1254	-0.0589	0.0006	0
a8	0.0295	0.0420	-0.0183	-0.0950	-0.0621	-0.0456	-0.0656	-0.1416	-0.1266	0.9443	-0.1625	-0.1535	0
a9	0.0064	0.0158	0.0464	0.0006	0.0301	-0.0110	0.0434	0.0328	0.1234	0.2046	0.1325	0.9586	0
a10	0.0882	-0.0240	0.4695	0.7197	-0.2626	-0.2078	0.3131	-0.1359	0.0570	0.0338	-0.1403	-0.0222	0
a11	-0.0145	0.0486	0.1118	0.0748	0.0156	-0.0693	-0.0264	-0.0671	0.1476	0.1460	0.9444	-0.1846	0
a12	0.0131	0.1035	-0.0491	-0.0110	0.1724	-0.3295	0.4173	0.7767	-0.2341	0.1027	0.0518	-0.0530	0


PCA
(basado en matriz de correlaciones)





Porcentaje de varianza explicada por cada componente
(basado en matriz de correlaciones)



Porcentaje acumulado de varianza explicada por cada componente
(basado en matriz de correlaciones)



Por lo tanto, se sugiere extraer los cuatro primeros componentes principales.



Análisis Estadístico Multivariado | UTDT

Problem Set 3

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

Utilizando la base de datos *firmas.dta*, la cual contiene información financiera referida a dos tipos de firmas: 12 firmas consideradas de buena performance, y 12 firmas no tan buenas en ese sentido; y dispone de dos características relevada: EBITASS (gcias. despues de impuestos e intereses sobre activos; y ROTC (retorno sobre el capital), se pide:

- (a) Realizar un análisis de clusters empleando el algoritmo de las k -medias. Determinar el número de grupos a partir de un test F de reducción de variabilidad.
- (b) Realizar un análisis de conglomerados empleando métodos jerárquicos. Trabajar con distintas medidas de distancias entre clusters, comentando los pros y las contras de cada una de ellas.

Ejercicio 2

Utilice la base de datos *iris* para realizar un análisis de conglomerados. La base contiene datos de especies de flores de iris con registros de las medidas del sépalo y pétalo de cada una. Originalmente los datos ya están agrupados por especie, pero en este ejercicio se propone utilizar *k-means clustering* para aplicar el método y ver cómo se compara con las categorías verdaderas.

Nota: la base *iris* ya está precargada en R, porque podemos acceder a ella directamente.

Ejercicio 3

El archivo “govt_bond_returns.xlsx” contiene los rendimientos anuales para los inversores (a partir de septiembre de 2010) de bonos del gobierno, enumerados por duración y emisor. Estos retornos están influenciados por las respectivas tasas de inflación y fortalezas de las diversas monedas, así como las percepciones del mercado para estas tasas en el futuro. Realizar un agrupamiento jerárquico (*hierarchical clustering*) de estos retornos a identificar países con situaciones financieras similares. Comente como el dendrograma agrupa países en regiones geográficas similares.


Trabajo Práctico N° 3

Ejercicio 1.

Utilizando la base de datos “firmas.dta”, la cual contiene información financiera referida a dos tipos de firmas: 12 firmas consideradas de buena performance y 12 firmas no tan buenas en ese sentido; y dispone de dos características relevadas: EBITASS (ganancias después de impuestos e intereses sobre activos) y ROTC (retorno sobre el capital), se pide:


(a) Realizar un análisis de clusters empleando el algoritmo de las *k*-medias. Determinar el número de grupos a partir de un test *F* de reducción de variabilidad.

El número de grupos, a partir de un test *F* de reducción de variabilidad, es 2.




(b) Realizar un análisis de conglomerados empleando métodos jerárquicos. Trabajar con distintas medidas de distancias entre clusters, comentando los pros y las contras de cada una de ellas.


Dendrograma para análisis de clusters con método jerárquico singlelinkage




Dendrograma para análisis de clusters con método jerárquico averagelinkage




Dendrograma para análisis de clusters con método jerárquico completelinkage




Dendrograma para análisis de clusters con método jerárquico waveragelinkage




Dendrograma para análisis de clusters con método jerárquico medianlinkage



Dendrograma para análisis de clusters con método jerárquico centroidlinkag






Ejercicio 2.


Utilizar la base de datos iris para realizar un análisis de conglomerados. La base contiene datos de especies de flores de iris con registros de las medidas del sépalos y pétalo de cada una. Originalmente, los datos ya están agrupados por especie, pero, en este ejercicio, se propone utilizar k-means clustering para aplicar el método y ver cómo se compara con las categorías verdaderas. Nota: La base iris ya está precargada en R, por lo que se puede acceder a ella directamente.

Ejercicio 3.


El archivo “govt_bond_returns.xlsx” contiene los rendimientos anuales para los inversores (a partir de septiembre de 2010) de bonos del gobierno, enumerados por duración y emisor. Estos retornos están influenciados por las respectivas tasas de inflación y fortalezas de las diversas monedas, así como las percepciones del mercado para estas tasas en el futuro. Realizar un agrupamiento jerárquico (hierarchical clustering) de estos retornos para identificar países con situaciones financieras similares. Comentar cómo el dendrograma agrupa países en regiones geográficas similares.




Dendrograma para análisis de clusters con método jerárquico averagelinkage




Dendrograma para análisis de clusters con método jerárquico completelinkage




Dendrograma para análisis de clusters con método jerárquico waveragelinkage



Dendrograma para análisis de clusters con método jerárquico centroidlinkage





Por lo tanto, se puede observar que, cualquiera sea el método jerárquico utilizado, USGovt-Canada y Eurozone-Switzerland son agrupados como regiones geográficas con situaciones financieras similares.

Análisis Estadístico Multivariado | UTDT

Problem Set 4

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

Construya un test de normalidad multivariada, y aplíquelo sobre los datos correspondientes al primer ejercicio de la práctica 2. ¿Puede concluir que el vector de medias de los datos es distinto del vector nulo?

Recordemos del ejercicio 1 de la práctica 2 que el archivo *ine_dta* es una base de datos que contiene los gastos promedio, en euros, de los hogares españoles, por grandes rubros y comunidad autónoma, correspondientes a los relevamientos de la encuesta de presupuestos familiares del año 2005 realizada por el Instituto Nacional de Estadísticas de España (INE).

```
ine <- haven::read_dta("C:/Users/fiona/Dropbox/Materias MAECO/Análisis Estadístico Multivariado/Practica
mardia(ine[,2:ncol(ine)])
```

```
## $mv.test
##           Test Statistic p-value Result
## 1      Skewness    302.0658  0.2459   YES
## 2      Kurtosis     0.2887  0.7728   YES
## 3  MV Normality      <NA>    <NA>   YES
##
```

```
## $uv.shapiro
##           W      p-value UV.Normality
## alybnh    0.7665 5e-04    No
## vestcal   0.9284 0.1819   Yes
## vivagelo  0.9725 0.8428   Yes
## mobymant  0.982  0.9682   Yes
## salud     0.9499 0.4232   Yes
## transp    0.9292 0.1881   Yes
## comu      0.9715 0.8249   Yes
## ocio      0.9851 0.9872   Yes
## educ      0.9489 0.4083   Yes
## esparc    0.9473 0.3837   Yes
## otros     0.9468 0.3765   Yes
```

```
k <- 11
N <- 18
(6*((k+1)*(N+1)-6))*302.0658/(k+1)*(N+1)*(N+3)
```

```
## [1] 13378192
```

```
0.2887*sqrt(8*k*(k+2)/N)+k*(k+2)*(N-1)/(N+1) #para la igualdad con STATA
```

```
## [1] 130.2489
```

```
qchisq((1-0.2459),(11*12*13)/6)
```

```
## [1] 302.0691
```

Ahora realizamos un test de significatividad sobre el vector de medias:

```
ICSNP::HotellingsT2(ine[,2:ncol(ine)])
```

```
##  
## Hotelling's one sample T2-test  
##  
## data: ine[, 2:ncol(ine)]  
## T.2 = 70.918, df1 = 11, df2 = 7, p-value = 4.258e-06  
## alternative hypothesis: true location is not equal to c(0,0,0,0,0,0,0,0,0,0,0)
```

Rechazo la hipotesis nula de que el vector de medias sea el vector nulo.

Ejercicio 2

Generar una muestra de 100 observaciones de una población normal multivariada teniendo en cuenta los siguientes vectores de parámetros:

$$\mu = \begin{bmatrix} 2 \\ 0.45 \\ 0.23 \\ 0.54 \\ 0.12 \\ 0.63 \\ 0.66 \\ 0.32 \end{bmatrix}, \quad \sigma = \begin{bmatrix} 0.67 \\ 0.89 \\ 0.56 \\ 0.90 \\ 0.56 \\ 0.34 \\ 0.76 \\ 0.13 \end{bmatrix}$$

- Efectúe un test para verificar la normalidad de la base de datos construída.
- ¿Existe evidencia empírica suficiente que permita concluir que el vector de medias es estadísticamente distinto del vector nulo?
- Efectúe un test para contrastar la hipótesis acerca de la igualdad de las medias de las variables que componen la matriz de datos.
- Contraste la esfericidad de la distribución de los datos.
- ¿Se verifica estadísticamente la diagonalidad de la matriz de varianzas y covarianzas en los datos?

Ejercicio 3

Repetir el ejercicio anterior, considerando en este caso la siguiente estructura:

$$X = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}, \quad X_1 \sim N(\mu_1, \Sigma_1), \quad X_2 \sim N(\mu_2, \Sigma_2), \quad X_3 \sim N(\mu_3, \Sigma_3).$$

siendo

$$\mu_1 = \begin{bmatrix} 2 \\ 0.45 \\ 0.23 \\ 0.54 \\ 0.12 \\ 0.63 \\ 0.66 \\ 0.32 \end{bmatrix}, \quad \sigma_1 = \begin{bmatrix} 0.67 \\ 0.89 \\ 0.56 \\ 0.90 \\ 0.56 \\ 0.34 \\ 0.76 \\ 0.13 \end{bmatrix}, \quad \pi_1 = 40\%$$

$$\mu_2 = \begin{bmatrix} 3 \\ 1.45 \\ 1.23 \\ 1.54 \\ 1.12 \\ 1.63 \\ 1.66 \\ 1.32 \end{bmatrix}, \quad \sigma_2 = \begin{bmatrix} 1.67 \\ 1.89 \\ 1.56 \\ 1.90 \\ 1.56 \\ 1.34 \\ 1.76 \\ 1.13 \end{bmatrix}, \quad \pi_2 = 50\%$$

$$\mu_3 = \begin{bmatrix} 4 \\ 2.45 \\ 2.23 \\ 2.54 \\ 2.12 \\ 2.63 \\ 2.66 \\ 2.32 \end{bmatrix}, \quad \sigma_3 = \begin{bmatrix} 2.67 \\ 2.89 \\ 2.56 \\ 2.90 \\ 2.56 \\ 2.34 \\ 2.76 \\ 2.13 \end{bmatrix}, \quad \pi_3 = 10\%$$

- Comente lo observado en contraste con el ejercicio anterior.
- Efectúe similares contrastes pero considerando cada partición de X por separado.
- Proponga soluciones al problema observado, incluso considerando la eventualidad de que existan valores atípicos en la muestra que conlleven al mismo. Aplica la/s soluciones sufridas y comentar brevemente el resultado encontrado.

Trabajo Práctico N° 4

Ejercicio 1.

Construir un test de normalidad multivariada y aplicarlo sobre los datos correspondientes al primer ejercicio de la práctica 2. ¿Se puede concluir que el vector de medias de los datos es distinto del vector nulo? Recordemos del Ejercicio 1 de la Práctica 2 que el archivo “ine.dta” es una base de datos que contiene los gastos promedio, en euros, de los hogares españoles, por grandes rubros y comunidad autónoma, correspondientes a los relevamientos de la encuesta de presupuestos familiares del año 2005 realizada por el Instituto Nacional de Estadísticas de España (INE).

Test for multivariate normality

Mardia mSkewness =	84.03333	chi2(286) =	302.066	Prob>chi2 =	0.2459
Mardia mKurtosis =	130.2492	chi2(1) =	2.558	Prob>chi2 =	0.1097
Henze-Zirkler =	.9871703	chi2(1) =	3.025	Prob>chi2 =	0.0820
Doornik-Hansen		chi2(22) =	18.126	Prob>chi2 =	0.6985

Por lo tanto, con un nivel de significancia del 10% (excepto con el test Henze-Zirkler), estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

Hotelling T2 =	1894.51
Hotelling F(11,7) =	70.92
Prob > F =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias de los datos es distinto del vector nulo.

Ejercicio 2.

Generar una muestra de 100 observaciones de una población normal multivariada teniendo en cuenta los siguientes vectores de parámetros:

$$\mu = \begin{pmatrix} 2 \\ 0,45 \\ 0,23 \\ 0,54 \\ 0,12 \\ 0,63 \\ 0,66 \\ 0,32 \end{pmatrix}, \sigma = \begin{pmatrix} 0,67 \\ 0,89 \\ 0,56 \\ 0,9 \\ 0,56 \\ 0,34 \\ 0,76 \\ 0,13 \end{pmatrix}.$$

(a) Efectuar un test para verificar la normalidad de la base de datos construida.

Test for multivariate normality

Mardia mSkewness =	8.975172	chi2(120) =	155.098	Prob>chi2 =	0.0171
Mardia mKurtosis =	81.19782	chi2(1) =	0.224	Prob>chi2 =	0.6359
Henze-Zirkler =	.9600012	chi2(1) =	0.093	Prob>chi2 =	0.7601
Doornik-Hansen		chi2(16) =	16.982	Prob>chi2 =	0.3867

Por lo tanto, con un nivel de significancia del 10% (excepto con el test de Mardia mSkewness), estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

(b) ¿Existe evidencia empírica suficiente que permita concluir que el vector de medias es, estadísticamente, distinto del vector nulo?

Test that all means are 0

Hotelling T2 =	2798.76
Hotelling F(8,92) =	325.11
Prob > F =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias no es igual al vector nulo.

(c) Efectuar un test para contrastar la hipótesis acerca de la igualdad de las medias de las variables que componen la matriz de datos.

Test that all means are the same

Hotelling T2 =	907.75
Hotelling F(7,93) =	121.82
Prob > F =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

(d) *Contrastar la esfericidad de la distribución de los datos.*

Test that covariance matrix is spherical

Adjusted LR chi2(35) =	412.74
Prob > chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

(e) *¿Se verifica, estadísticamente, la diagonalidad de la matriz de varianzas y covarianzas en los datos?*

Test that covariance matrix is diagonal

Adjusted LR chi2(28) =	21.96
Prob > chi2 =	0.7833

Por lo tanto, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

Ejercicio 3.

Repetir el ejercicio anterior, considerando, en este caso, la siguiente estructura:

$$X = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}, X_1 \sim \mathcal{N}(\mu_1, \Sigma_1), X_2 \sim \mathcal{N}(\mu_2, \Sigma_2), X_3 \sim \mathcal{N}(\mu_3, \Sigma_3),$$

siendo:

$$\begin{aligned} \mu_1 &= \begin{pmatrix} 2 \\ 0,45 \\ 0,23 \\ 0,54 \\ 0,12 \\ 0,63 \\ 0,66 \\ 0,32 \end{pmatrix}, \sigma_1 = \begin{pmatrix} 0,67 \\ 0,89 \\ 0,56 \\ 0,9 \\ 0,56 \\ 0,34 \\ 0,76 \\ 0,13 \end{pmatrix}, \pi_1 = 40\%; \\ \mu_2 &= \begin{pmatrix} 3 \\ 1,45 \\ 1,23 \\ 1,54 \\ 1,12 \\ 1,63 \\ 1,66 \\ 1,32 \end{pmatrix}, \sigma_2 = \begin{pmatrix} 1,67 \\ 1,89 \\ 1,56 \\ 1,9 \\ 1,56 \\ 1,34 \\ 1,76 \\ 1,13 \end{pmatrix}, \pi_2 = 50\%; \\ \mu_3 &= \begin{pmatrix} 4 \\ 2,45 \\ 2,23 \\ 2,54 \\ 2,12 \\ 2,63 \\ 2,66 \\ 2,32 \end{pmatrix}, \sigma_3 = \begin{pmatrix} 2,67 \\ 2,89 \\ 2,56 \\ 2,9 \\ 2,56 \\ 2,34 \\ 2,76 \\ 2,13 \end{pmatrix}, \pi_3 = 10\%. \end{aligned}$$

(a) Comentar lo observado en contraste con el ejercicio anterior.

Test for multivariate normality

Mardia mSkewness =	28.42167	chi2(120) =	491.147	Prob>chi2 =	0.0000
Mardia mKurtosis =	119.1498	chi2(1) =	239.486	Prob>chi2 =	0.0000
Henze-Zirkler =	3.806584	chi2(1) =	2707.749	Prob>chi2 =	0.0000
Doornik-Hansen		chi2(16) =	75.323	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

```
Hotelling T2 = 305.22
Hotelling F(8,92) = 35.46
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 = 138.64
Hotelling F(7,93) = 18.60
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

```
Adjusted LR chi2(35) = 169.53
Prob > chi2 = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(28) = 93.63
Prob > chi2 = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

(b) *Efectuar similares contrastes, pero considerando cada partición de X por separado.*

Partición 1:

Test for multivariate normality

```
Mardia mSkewness = 19.60508   chi2(120) = 142.825   Prob>chi2 = 0.0761
Mardia mKurtosis = 78.2123    chi2(1) = 0.200   Prob>chi2 = 0.6549
Henze-Zirkler    = .9268645   chi2(1) = 0.015   Prob>chi2 = 0.9039
Doornik-Hansen   chi2(16) = 11.505   Prob>chi2 = 0.7773
```

Por lo tanto, con un nivel de significancia del 10% (excepto con el test de Mardia mSkewness), estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

```
Hotelling T2 = 791.94
Hotelling F(8,32) = 81.22
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 = 247.35
Hotelling F(7,33) = 29.90
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

```
Adjusted LR chi2(35) = 156.40
Prob > chi2 = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(28) = 30.87
Prob > chi2 = 0.3231
```

Por lo tanto, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

Partición 2:

Test for multivariate normality

```
Mardia mSkewness = 13.51716 chi2(120) = 120.983 Prob>chi2 = 0.4577
Mardia mKurtosis = 75.87215 chi2(1) = 1.331 Prob>chi2 = 0.2486
Henze-Zirkler = .9684794 chi2(1) = 1.195 Prob>chi2 = 0.2744
Doornik-Hansen chi2(16) = 22.179 Prob>chi2 = 0.1375
```

Por lo tanto, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

```
Hotelling T2 = 715.13
Hotelling F(8,42) = 76.62
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 =      96.28
Hotelling F(7,43) =    12.07
Prob > F =      0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

```
Adjusted LR chi2(35) =    68.67
Prob > chi2 =    0.0006
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(28) =    34.75
Prob > chi2 =    0.1771
```

Por lo tanto, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

Partición 3:

Test for multivariate normality

```
Mardia mSkewness = 51.66604   chi2(120) = 119.165   Prob>chi2 = 0.5044
Mardia mKurtosis = 65.33476   chi2(1) = 3.360   Prob>chi2 = 0.0668
Henze-Zirkler = .9390528     chi2(1) = 2.155   Prob>chi2 = 0.1421
Doornik-Hansen      chi2(16) = 27.724   Prob>chi2 = 0.0341
```

Test that all means are 0

```
Hotelling T2 =    1555.29
Hotelling F(8,2) =    43.20
Prob > F =    0.0228
```

Por lo tanto, con un nivel de significancia del 5%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 =    44.12
Hotelling F(7,3) =    2.10
Prob > F =    0.2911
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

```
Adjusted LR chi2(35) =      53.09
Prob > chi2 =      0.0256
```

Por lo tanto, con un nivel de significancia del 5%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(28) =      38.75
Prob > chi2 =      0.0850
```

Por lo tanto, con un nivel de significancia del 10%, estos datos aportan evidencia suficiente para indicar que la matriz de datos es diagonal.

(c) Proponer soluciones al problema observado, incluso considerando la eventualidad de que existan valores atípicos en la muestra que conlleven al mismo. Aplicar la/s soluciones sugeridas y comentar, brevemente, el resultado encontrado.

Opción 1:

Test for multivariate normality

```
Mardia mSkewness = 32.44565   chi2(120) = 101.569   Prob>chi2 = 0.8875
Mardia mKurtosis = 66.93737   chi2(1) = 3.999   Prob>chi2 = 0.0455
Henze-Zirkler    = .9306905   chi2(1) = 0.793   Prob>chi2 = 0.3731
Doornik-Hansen   =             chi2(16) = 16.827   Prob>chi2 = 0.3969
```

Por lo tanto, con un nivel de significancia del 10% (excepto con el test Mardia mKurtosis), estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

```
Hotelling T2 =      235.39
Hotelling F(8,7) =      14.71
Prob > F =      0.0010
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 =      83.54
Hotelling F(7,8) =      6.82
Prob > F =      0.0074
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

```
Adjusted LR chi2(35) =      83.43
Prob > chi2 =      0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(28) =      59.67
Prob > chi2 =      0.0004
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

Opción 2:

Test for multivariate normality

```
Mardia mSkewness =  5.826589   chi2(120) = 100.688   Prob>chi2 =  0.8992
Mardia mKurtosis = 76.76692    chi2(1)  =  1.633   Prob>chi2 =  0.2013
Henze-Zirkler    =  .9373537   chi2(1)  =  0.350   Prob>chi2 =  0.5544
Doornik-Hansen   chi2(16) =  9.871   Prob>chi2 =  0.8733
```

Por lo tanto, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test that all means are 0

```
Hotelling T2 =      311.47
Hotelling F(8,92) =      36.18
Prob > F =      0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que el vector de medias es, estadísticamente, distinto del vector nulo.

Test that all means are the same

```
Hotelling T2 =      83.53
Hotelling F(7,93) =      11.21
Prob > F =      0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las medias de las variables que componen la matriz de datos no son iguales.

Test that covariance matrix is spherical

Adjusted LR chi2(35) =	215.27
Prob > chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los datos no son esféricos.

Test that covariance matrix is diagonal

Adjusted LR chi2(28) =	150.13
Prob > chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que la matriz de datos no es diagonal.

Análisis Estadístico Multivariado | UTDT

Problem Set 5

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

El archivo *ind.dta* contiene información sobre 17 indicadores económicos:

Variable	Indicador
X1	Agricultural land (% of land area)
X2	Agriculture, value added (% of GDP)
X3	CO2 emissions (metric tons per capita)
X4	Exports of goods and services (% of GDP)
X5	Fertility rate, total (births per woman)
X6	Fixed line and mobile phone subscribers (per 1000 people)
X7	GDP growth (annual)
X8	Immunization, measles (% of children ages 12-23 months)
X9	Imports of goods and services (% of GDP)
X10	Industry, value added (% of GDP)
X11	Inflation, GDP deflator (annual %)
X12	Internet users (per 1000 people)
X13	Life expectancy at birth, total (years)
X14	Merchandise trade (% of GDP)
X15	Mortality rate, infant (per 1000 live births)
X16	Mortality rate, under 5 (per 1000)
X17	Population growth (annual %)

- (a) Realice un test de normalidad multivariada.
- (b) Determine el número de factores a extraer.
- (c) Realice el análisis exploratorio de acuerdo con el modelo factorial.
- (d) Reporte las comunialidades.

Ejercicio 2

El archivo *ipc2dig.dta* contiene datos sobre variaciones mensuales de precios desagregados en componentes de la canasta básica de alimentos para el período comprendido entre marzo de 2022 y marzo de 2006.

Variable	Descripción
div1	Alimentos para consumir en el hogar

Variable	Descripción
div2	Bebidas e infusiones para consumir en el hogar
div3	Alimentos y bebidas consumidos fuera del hogar
div4	Ropa
div5	Calzado
div6	Accesorios y servicios para la indumentaria
div7	Alquiler de la vivienda
div8	Servicios básicos y combustibles para la vivienda
div9	Reparaciones y gastos comunes de la vivienda
div10	Equipamiento del hogar
div11	Mantenimiento del hogar
div12	Productos medicinales y accesorios terapéuticos
div13	Servicios para la salud
div14	Transporte
div15	Comunicaciones
div16	Turismo
div17	Equipos, conexiones y servicios de audio, televisión y computación
div18	Diarios, revistas y libros
div19	Juguetes y artículos para deporte
div20	Flores, planes y atención de animales domésticos
div21	Otros servicios de esparcimiento
div22	Servicios educativos
div23	Textos y útiles escolares
div24	Cigarrillos y accesorios
div25	Artículos y servicios para el cuidado personal
div26	Servicios diversos

- Realice un análisis factorial y determine el número de factores a considerar en el mismo.
- Estime los factores.
- Analice los residuos del modelo, con arreglo a los supuestos considerados.
- Obtenga las principales medidas estadísticas que permitan inferir acerca de la bondad del ajuste del modelo estimado.

Trabajo Práctico N° 5**Ejercicio 1.**

El archivo “ind.dta” contiene información sobre 17 indicadores económicos:

Variable	Indicador
X1	Agricultural land (% of land area)
X2	Agriculture, value added (% of GDP)
X3	CO2 emissions (metric tons per capita)
X4	Exports of goods and services (% of GDP)
X5	Fertility rate, total (births per woman)
X6	Fixed line and mobile phone subscribers (per 1000 people)
X7	GDP growth (annual)
X8	Immunization, measles (% of children ages 12-23 months)
X9	Imports of goods and services (% of GDP)
X10	Industry, value added (% of GDP)
X11	Inflation, GDP deflator (annual %)
X12	Internet users (per 1000 people)
X13	Life expectancy at birth, total (years)
X14	Merchandise trade (% of GDP)
X15	Mortality rate, infant (per 1000 live births)
X16	Mortality rate, under 5 (per 1000)
X17	Population growth (annual %)

(a) Realizar un test de normalidad multivariada.

Test for multivariate normality

Mardia mSkewness =	293.0869	chi2(969) =	8076.406	Prob>chi2 =	0.0000
Mardia mKurtosis =	589.9546	chi2(1) =	4467.836	Prob>chi2 =	0.0000
Henze-Zirkler =	1.28147	chi2(1) =	33372.390	Prob>chi2 =	0.0000
Doornik-Hansen		chi2(34) =	10057.382	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Test for multivariate normality

Mardia mSkewness =	101.7785	chi2(969) =	1820.830	Prob>chi2 =	0.0000
Mardia mKurtosis =	364.9691	chi2(1) =	70.893	Prob>chi2 =	0.0000
Henze-Zirkler =	1.014665	chi2(1) =	122.887	Prob>chi2 =	0.0000
Doornik-Hansen		chi2(34) =	313.331	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

(b) Determinar el número de factores a extraer.

Factor analysis/correlation
 Method: principal factors
 Rotation: (unrotated)

Number of obs = 162
 Retained factors = 10
 Number of params = 125

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	6.39667	4.13220	0.5822	0.5822
Factor2	2.26447	1.08372	0.2061	0.7883
Factor3	1.18075	0.47077	0.1075	0.8957
Factor4	0.70998	0.16765	0.0646	0.9604
Factor5	0.54233	0.26020	0.0494	1.0097
Factor6	0.28213	0.09976	0.0257	1.0354
Factor7	0.18238	0.09753	0.0166	1.0520
Factor8	0.08485	0.06604	0.0077	1.0597
Factor9	0.01881	0.01822	0.0017	1.0614
Factor10	0.00059	0.00898	0.0001	1.0615
Factor11	-0.00840	0.01935	-0.0008	1.0607
Factor12	-0.02775	0.03482	-0.0025	1.0582
Factor13	-0.06257	0.03448	-0.0057	1.0525
Factor14	-0.09706	0.02685	-0.0088	1.0437
Factor15	-0.12391	0.03113	-0.0113	1.0324
Factor16	-0.15504	0.04577	-0.0141	1.0183
Factor17	-0.20081	.	-0.0183	1.0000

LR test: independent vs. saturated: $\chi^2(136) = 2464.59$ Prob> $\chi^2 = 0.0000$

Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6	Factor7	Factor8	Factor9	Factor10	Uniqueness
x1	-0.1011	0.0073	-0.2529	0.1506	-0.0530	0.0688	0.3052	0.0205	-0.0004	0.0005	0.8020
x2	-0.7498	-0.0044	-0.1385	0.2422	-0.0394	0.0634	-0.1638	0.1517	-0.0301	-0.0050	0.3036
x3	0.6551	-0.0201	0.3683	-0.1094	0.0635	-0.0960	0.0737	0.1535	-0.0156	-0.0033	0.3804
x4	0.4284	0.8210	0.0432	0.0381	-0.0608	-0.0534	0.0000	0.0313	-0.0574	-0.0006	0.1282
x5	-0.8124	0.1095	0.2020	-0.0115	0.0598	-0.1511	-0.0400	-0.0163	0.0618	0.0011	0.2550
x6	0.7793	-0.1949	0.4131	0.3098	-0.0566	0.0920	0.0597	-0.0461	-0.0030	0.0022	0.0708
x7	0.1398	0.1956	0.0440	-0.1209	0.4829	0.2649	-0.0576	0.0165	-0.0076	-0.0020	0.6186
x8	0.7332	-0.0219	-0.3124	-0.0741	0.0689	-0.0115	0.0677	0.1534	0.0705	0.0014	0.3209
x9	0.2591	0.7625	-0.2627	0.3534	-0.0507	-0.1093	-0.0099	-0.0036	0.0022	0.0032	0.1429
x10	0.2370	0.3700	0.2722	-0.4667	-0.1433	0.0304	0.0685	-0.0054	-0.0204	0.0002	0.4885
x11	-0.2111	0.1827	0.2023	-0.1510	-0.4183	0.0839	-0.0950	0.0575	0.0347	0.0019	0.6627
x12	0.6562	-0.1771	0.5314	0.3422	0.0060	0.0053	-0.0412	0.0197	0.0210	-0.0020	0.1360
x13	0.9098	-0.1873	-0.1503	-0.0537	0.0298	-0.0103	-0.1288	0.0122	-0.0150	0.0172	0.0935
x14	0.2948	0.7954	0.0793	0.0140	0.1124	0.0803	-0.0346	-0.0541	0.0555	-0.0022	0.2477
x15	-0.9450	0.1666	0.2159	0.0522	0.0733	0.1018	0.0686	0.0488	-0.0015	0.0144	0.0069
x16	-0.9385	0.1462	0.2639	0.0913	0.0316	0.0786	0.0749	0.0364	-0.0049	0.0028	0.0057
x17	-0.3169	0.0364	0.1941	-0.0477	0.2597	-0.3415	0.0159	0.0117	-0.0104	0.0021	0.6737

Por lo tanto, el número de factores a extraer es 6.

(c) Realizar el análisis exploratorio de acuerdo con el modelo factorial.

Factor analysis/correlation	Number of obs	=	162
Method: principal factors	Retained factors	=	6
Rotation: (unrotated)	Number of params	=	87

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	6.39667	4.13220	0.5822	0.5822
Factor2	2.26447	1.08372	0.2061	0.7883
Factor3	1.18075	0.47077	0.1075	0.8957
Factor4	0.70998	0.16765	0.0646	0.9604
Factor5	0.54233	0.26020	0.0494	1.0097
Factor6	0.28213	0.09976	0.0257	1.0354
Factor7	0.18238	0.09753	0.0166	1.0520
Factor8	0.08485	0.06604	0.0077	1.0597
Factor9	0.01881	0.01822	0.0017	1.0614
Factor10	0.00059	0.00898	0.0001	1.0615
Factor11	-0.00840	0.01935	-0.0008	1.0607
Factor12	-0.02775	0.03482	-0.0025	1.0582
Factor13	-0.06257	0.03448	-0.0057	1.0525
Factor14	-0.09706	0.02685	-0.0088	1.0437
Factor15	-0.12391	0.03113	-0.0113	1.0324
Factor16	-0.15504	0.04577	-0.0141	1.0183
Factor17	-0.20081	.	-0.0183	1.0000

LR test: independent vs. saturated: $\chi^2(136) = 2464.59$ Prob> $\chi^2 = 0.0000$

Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6	Uniqueness
x1	-0.1011	0.0073	-0.2529	0.1506	-0.0530	0.0688	0.8956
x2	-0.7498	-0.0044	-0.1385	0.2422	-0.0394	0.0634	0.3544
x3	0.6551	-0.0201	0.3683	-0.1094	0.0635	-0.0960	0.4097
x4	0.4284	0.8210	0.0432	0.0381	-0.0608	-0.0534	0.1325
x5	-0.8124	0.1095	0.2020	-0.0115	0.0598	-0.1511	0.2607
x6	0.7793	-0.1949	0.4131	0.3098	-0.0566	0.0920	0.0765
x7	0.1398	0.1956	0.0440	-0.1209	0.4829	0.2649	0.6223
x8	0.7332	-0.0219	-0.3124	-0.0741	0.0689	-0.0115	0.3540
x9	0.2591	0.7625	-0.2627	0.3534	-0.0507	-0.1093	0.1430
x10	0.2370	0.3700	0.2722	-0.4667	-0.1433	0.0304	0.4937
x11	-0.2111	0.1827	0.2023	-0.1510	-0.4183	0.0839	0.6763
x12	0.6562	-0.1771	0.5314	0.3422	0.0060	0.0053	0.1385
x13	0.9098	-0.1873	-0.1503	-0.0537	0.0298	-0.0103	0.1108
x14	0.2948	0.7954	0.0793	0.0140	0.1124	0.0803	0.2549
x15	-0.9450	0.1666	0.2159	0.0522	0.0733	0.1018	0.0142
x16	-0.9385	0.1462	0.2639	0.0913	0.0316	0.0786	0.0127
x17	-0.3169	0.0364	0.1941	-0.0477	0.2597	-0.3415	0.6742

(d) Reportar las communalidades.

```
commonality[17,1]
  commonality
x1      .10443817
x2      .6456483
x3      .59033742
x4      .86754007
x5      .73931917
x6      .92349359
x7      .37773843
x8      .64597902
x9      .85698196
x10     .50634663
x11     .32371151
x12     .8614879
x13     .88924266
x14     .745089
x15     .98584624
x16     .98729607
x17     .32582455
```

Ejercicio 2.

El archivo “ipc2dig.dta” contiene datos sobre variaciones mensuales de precios desagregados en componentes de la canasta básica de alimentos para el período comprendido entre marzo de 2022 y marzo de 2006.

Variable	Descripción
div1	Alimentos para consumir en el hogar
Variable	Descripción
div2	Bebidas e infusiones para consumir en el hogar
div3	Alimentos y bebidas consumidos fuera del hogar
div4	Ropa
div5	Calzado
div6	Accesorios y servicios para la indumentaria
div7	Alquiler de la vivienda
div8	Servicios básicos y combustibles para la vivienda
div9	Reparaciones y gastos comunes de la vivienda
div10	Equipamiento del hogar
div11	Mantenimiento del hogar
div12	Productos medicinales y accesorios terapéuticos
div13	Servicios para la salud
div14	Transporte
div15	Comunicaciones
div16	Turismo
div17	Equipos, conexiones y servicios de audio, televisión y computación
div18	Diarios, revistas y libros
div19	Juguetes y artículos para deporte
div20	Flores, planes y atención de animales domésticos
div21	Otros servicios de esparcimiento
div22	Servicios educativos
div23	Textos y útiles escolares
div24	Cigarrillos y accesorios
div25	Artículos y servicios para el cuidado personal
div26	Servicios diversos

(a) Realizar un análisis factorial y determinar el número de factores a considerar en el mismo.

Test for multivariate normality

Mardia mSkewness =	475.4859	chi2 (3276) =	4297.740	Prob>chi2 =	0.0000
Mardia mKurtosis =	759.9989	chi2 (1) =	8.966	Prob>chi2 =	0.0027
Henze-Zirkler =	1.000247	chi2 (1) =	11.470	Prob>chi2 =	0.0007
Doornik-Hansen		chi2 (52) =	776.759	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Factor analysis/correlation	Number of obs	=	51
Method: principal factors	Retained factors	=	4
Rotation: (unrotated)	Number of params	=	98

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	12.08887	9.82667	0.6040	0.6040
Factor2	2.26220	0.68136	0.1130	0.7170
Factor3	1.58085	0.49465	0.0790	0.7960
Factor4	1.08620	0.23100	0.0543	0.8503
Factor5	0.85521	0.03978	0.0427	0.8930
Factor6	0.81542	0.30611	0.0407	0.9337
Factor7	0.50931	0.14179	0.0254	0.9592
Factor8	0.36753	0.05479	0.0184	0.9775
Factor9	0.31273	0.08655	0.0156	0.9932
Factor10	0.22618	0.02765	0.0113	1.0045
Factor11	0.19853	0.08151	0.0099	1.0144
Factor12	0.11702	0.02778	0.0058	1.0202
Factor13	0.08923	0.03101	0.0045	1.0247
Factor14	0.05822	0.01640	0.0029	1.0276
Factor15	0.04182	0.02055	0.0021	1.0297
Factor16	0.02127	0.02397	0.0011	1.0307
Factor17	-0.00270	0.00399	-0.0001	1.0306
Factor18	-0.00669	0.01393	-0.0003	1.0303
Factor19	-0.02063	0.00605	-0.0010	1.0292
Factor20	-0.02667	0.00824	-0.0013	1.0279
Factor21	-0.03492	0.01923	-0.0017	1.0262
Factor22	-0.05414	0.00437	-0.0027	1.0235
Factor23	-0.05852	0.02775	-0.0029	1.0205
Factor24	-0.08627	0.05588	-0.0043	1.0162
Factor25	-0.14215	0.04044	-0.0071	1.0091
Factor26	-0.18259	.	-0.0091	1.0000

LR test: independent vs. saturated: chi2(325) = 1451.04 Prob>chi2 = 0.0000

Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Uniqueness
div1	0.9243	0.1403	0.0508	-0.0283	0.1226
div2	0.9278	-0.0300	-0.0495	-0.1762	0.1048
div3	0.4967	0.5590	0.3778	0.2111	0.2535
div4	0.6179	0.5234	-0.4220	0.1719	0.1366
div5	0.8875	0.2726	-0.1709	0.0932	0.1002
div6	0.9735	0.0151	-0.0440	0.0602	0.0466
div7	-0.2276	0.3753	0.0376	-0.1729	0.7760
div8	0.2853	-0.1056	0.1629	0.4399	0.6874
div9	0.3114	0.0928	0.3854	-0.1314	0.7286
div10	0.9703	-0.0469	-0.0408	-0.1318	0.0373
div11	0.9436	-0.0683	-0.0171	-0.1674	0.0767
div12	0.8900	0.1640	-0.0467	-0.2200	0.1304
div13	0.2770	0.4537	0.4446	-0.0089	0.5197
div14	0.9204	0.0466	0.2044	0.1893	0.0731
div15	0.4895	-0.4788	0.0907	-0.1398	0.5034
div16	0.1155	-0.3809	0.5300	-0.0282	0.5599
div17	0.9286	-0.1886	-0.1047	-0.1031	0.0806
div18	0.4423	-0.1346	0.1006	0.6517	0.3515
div19	0.9110	-0.1410	-0.1277	-0.0393	0.1324
div20	0.6107	-0.2521	0.2895	0.1006	0.4696
div21	-0.0193	0.5537	0.4005	-0.1749	0.5021
div22	-0.1151	0.4670	-0.2868	0.1314	0.6691
div23	0.8660	-0.1777	-0.1542	0.0110	0.1945
div24	-0.0563	-0.2340	0.2771	0.0114	0.8652
div25	0.9436	-0.0199	-0.0429	-0.1849	0.0732
div26	-0.2469	0.2354	0.2200	-0.2191	0.7872

Por lo tanto, el número de factores a considerar en el análisis factorial es 4.

(b) Estimar los factores.

Scoring coefficients (method = regression)

Variable	Factor1	Factor2	Factor3	Factor4
div1	0.07925	0.18186	-0.05170	-0.59974
div2	0.04326	-0.11339	0.05872	-0.44253
div3	-0.00436	0.23518	0.16104	0.00260
div4	-0.01953	0.49494	-0.53807	0.41634
div5	0.12488	0.03240	-0.02813	0.20538
div6	0.16392	-0.03118	0.05927	-0.04948
div7	-0.01557	0.14109	-0.03078	-0.16704
div8	0.00063	-0.02647	-0.04099	0.06205
div9	0.00216	0.03724	0.10942	-0.12597
div10	0.14911	-0.26471	0.01094	-1.20009
div11	0.09499	0.06966	0.00325	-0.03244
div12	0.01092	0.24549	0.00071	-0.26581
div13	0.02381	0.10769	0.21193	0.03472
div14	0.13740	0.10581	0.60434	1.43553
div15	0.01255	-0.06698	0.04572	-0.03451
div16	-0.01914	-0.03677	0.11613	-0.08001
div17	0.03816	-0.41828	-0.26528	-0.14701
div18	0.03628	-0.13264	0.05431	0.21385
div19	0.05068	-0.03080	-0.18010	0.06339
div20	0.02680	-0.09034	0.13100	0.09015
div21	-0.00201	0.13760	0.18718	-0.13885
div22	-0.00168	0.10451	-0.08293	-0.07340
div23	0.01771	-0.03543	-0.21777	0.40487
div24	0.00482	-0.04115	0.10567	0.04613
div25	0.11943	0.01387	0.03226	0.25898
div26	0.00484	0.04779	0.08075	-0.01031

(c) Analizar los residuos del modelo, con arreglo a los supuestos considerados.

Test for multivariate normality

Mardia mSkewness =	475.4859	chi2 (3276) =	4297.740	Prob>chi2 =	0.0000
Mardia mKurtosis =	759.9989	chi2 (1) =	8.966	Prob>chi2 =	0.0027
Henze-Zirkler =	1.000247	chi2 (1) =	11.470	Prob>chi2 =	0.0007
Doornik-Hansen		chi2 (52) =	601.620	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los residuos no tienen una distribución normal multivariada.

Test that covariance matrix is diagonal

```
Adjusted LR chi2(325) =    944.31
          Prob > chi2 =    0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que la matriz de varianzas y covarianzas de los residuos no es diagonal.

(d) *Obtener las principales medidas estadísticas que permitan inferir acerca de la bondad del ajuste del modelo estimado.*

Coefficiente de correlación al cuadrado entre cada variable observable y los factores:

```
rho2_1 = .98497393
rho2_2 = .98902324
rho2_3 = .93575745
rho2_4 = .98133713
rho2_5 = .9899648
rho2_6 = .99782874
rho2_7 = .39777721
rho2_8 = .52745178
rho2_9 = .46913039
rho2_10 = .99861103
rho2_11 = .99412209
rho2_12 = .98300747
rho2_13 = .72994253
rho2_14 = .9946607
rho2_15 = .74662227
rho2_16 = .68655422
rho2_17 = .99350546
rho2_18 = .87645452
rho2_19 = .98246967
rho2_20 = .77948868
rho2_21 = .74787243
rho2_22 = .5522995
rho2_23 = .96217425
rho2_24 = .25149728
rho2_25 = .99464147
rho2_26 = .38029008
```

Coefficiente de determinación= 0,12818739.

Análisis Estadístico Multivariado | UTDT

Problem Set 6

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

Estime el modelo factorial para la base de datos *eurosec.dta*, de acuerdo con el número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978). Obtenga, luego, la matriz ortogonal $C_{m \times m}$ verificando que las cargas asociadas a cada factor presenten la máxima varianza posible. Finalmente, estime el vector de factores correspondiente al ajuste efectuado.

Ejercicio 2

Aplice el contraste empleado en el primer ejercicio a los datos correspondientes al Problem Set anterior. Explique brevemente el resultado obtenido. ¿Cuáles son sus conclusiones al respecto?

Ejercicio 3

Estime un modelo factorial empleando la base *sachs.dta*, extracto de Gallup, Sachs & Mellinger (1999).

Ejercicio 4

En base a los datos empleados por la Fundación Heritage para construir el *Freedom Index 2010*, contenidos en la base *heritage.dta*, ajustar un modelo factorial y comentar brevemente los resultados obtenidos.

Trabajo Práctico N° 6

Ejercicio 1.

Estimar el modelo factorial para la base de datos “eurosec.dta”, de acuerdo con el número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978). Obtener, luego, la matriz ortogonal C_{mxm} verificando que las cargas asociadas a cada factor presenten la máxima varianza posible. Finalmente, estimar el vector de factores correspondiente al ajuste efectuado.

El número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978) es 5.

Test for multivariate normality

Mardia mSkewness =	47.01711	chi2(165) =	232.414	Prob>chi2 =	0.0004
Mardia mKurtosis =	103.1088	chi2(1) =	0.554	Prob>chi2 =	0.4566
Henze-Zirkler =	.9273321	chi2(1) =	0.274	Prob>chi2 =	0.6009
Doornik-Hansen		chi2(18) =	38.365	Prob>chi2 =	0.0035

Por lo tanto, para los tests Mardia mSkewness y Doornik-Hansen, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada, mientras que, para los tests Mardia mKurtosis y Henze-Zirkler, con un nivel de significancia del 10%, estos datos no aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

Factor analysis/correlation	Number of obs =	26
Method: maximum likelihood	Retained factors =	5
Rotation: (unrotated)	Number of params =	35
	Schwarz's BIC =	242.486
Log likelihood = -64.22616	(Akaike's) AIC =	198.452


Warning: Solution is a Heywood case; that is, invalid or boundary values of uniqueness.

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	1.52115	-1.77206	0.2023	0.2023
Factor2	3.29322	2.16506	0.4381	0.6404
Factor3	1.12816	0.29455	0.1501	0.7905
Factor4	0.83361	0.09196	0.1109	0.9013
Factor5	0.74164	.	0.0987	1.0000

LR test: independent vs. saturated: chi2(36) = 287.00 Prob>chi2 = 0.0000
 LR test: 5 factors vs. saturated: chi2(1) = 93.05 Prob>chi2 = 0.0000
 (tests formally not valid because a Heywood case was encountered)


Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Factor5	Uniqueness
s1	-0.2659	0.9629	0.0356	0.0267	0.0139	0.0000
s2	-0.4405	-0.0559	-0.3140	-0.4046	-0.3988	0.3815
s3	-0.1227	-0.6985	-0.5040	-0.3321	-0.3148	0.0337
s4	0.1273	-0.3618	-0.1427	-0.4032	-0.1399	0.6504
s5	0.0418	-0.5404	-0.6204	0.5668	0.0071	0.0000
s6	0.3981	-0.6656	0.0325	-0.0080	0.6304	0.0000
s7	0.9989	0.0475	0.0002	0.0006	-0.0008	0.0000
s8	0.1438	-0.7632	0.5984	0.1961	-0.0173	0.0000
s9	-0.2156	-0.6515	0.0998	0.1911	-0.2569	0.4166



Factor rotation matrix

	Factor1	Factor2	Factor3	Factor4	Factor5
Factor1	0.0531	-0.0549	0.1924	0.0136	0.9783
Factor2	-0.6777	-0.4943	-0.4266	-0.3240	0.0974
Factor3	0.6435	-0.4475	-0.0440	-0.6180	-0.0428
Factor4	0.2368	-0.6263	-0.1982	0.7156	-0.0189
Factor5	-0.2604	-0.4002	0.8601	-0.0304	-0.1770



Scoring coefficients (method = regression; based on unrotated factors)

Variable	Factor1	Factor2	Factor3	Factor4	Factor5
s1	-0.04594	0.94092	0.69797	1.65016	1.00522
s2	-0.00006	0.00005	0.00001	-0.00004	-0.00004
s3	-0.00041	0.00041	0.00008	-0.00027	-0.00028
s4	-0.00002	0.00002	0.00000	-0.00001	-0.00001
s5	0.00016	-0.01895	-0.43866	1.26563	0.01842
s6	0.00204	-0.02196	0.02186	-0.01714	1.55980
s7	0.98770	0.27076	0.02651	0.21822	-0.33685
s8	0.00205	-0.07422	1.17366	1.21456	-0.12570
s9	-0.00008	0.00008	0.00002	-0.00005	-0.00005

Ejercicio 2.

Aplicar el contraste empleado en el primer ejercicio a los datos correspondientes al Problem Set anterior. Explicar, brevemente, el resultado obtenido. ¿Cuáles son las conclusiones al respecto?

Ejercicio 1:

El número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978) es 4.

Test for multivariate normality

```

Mardia mSkewness = 293.0869   chi2(969) = 8076.406   Prob>chi2 = 0.0000
Mardia mKurtosis = 589.9546   chi2(1) = 4467.836   Prob>chi2 = 0.0000
Henze-Zirkler    = 1.28147    chi2(1) = 33372.390   Prob>chi2 = 0.0000
Doornik-Hansen   chi2(34) = 10057.382   Prob>chi2 = 0.0000

```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

```

Factor analysis/correlation
Method: principal factors
Rotation: (unrotated)
Number of obs    = 162
Retained factors = 4
Number of params = 62


```

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	6.39667	4.13220	0.5822	0.5822
Factor2	2.26447	1.08372	0.2061	0.7883
Factor3	1.18075	0.47077	0.1075	0.8957
Factor4	0.70998	0.16765	0.0646	0.9604
Factor5	0.54233	0.26020	0.0494	1.0097
Factor6	0.28213	0.09976	0.0257	1.0354
Factor7	0.18238	0.09753	0.0166	1.0520
Factor8	0.08485	0.06604	0.0077	1.0597
Factor9	0.01881	0.01822	0.0017	1.0614
Factor10	0.00059	0.00898	0.0001	1.0615
Factor11	-0.00840	0.01935	-0.0008	1.0607
Factor12	-0.02775	0.03482	-0.0025	1.0582
Factor13	-0.06257	0.03448	-0.0057	1.0525
Factor14	-0.09706	0.02685	-0.0088	1.0437
Factor15	-0.12391	0.03113	-0.0113	1.0324
Factor16	-0.15504	0.04577	-0.0141	1.0183
Factor17	-0.20081	.	-0.0183	1.0000


LR test: independent vs. saturated: chi2(136) = 2464.59 Prob>chi2 = 0.0000

Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Uniqueness
x1	-0.1011	0.0073	-0.2529	0.1506	0.9031
x2	-0.7498	-0.0044	-0.1385	0.2422	0.3599
x3	0.6551	-0.0201	0.3683	-0.1094	0.4229
x4	0.4284	0.8210	0.0432	0.0381	0.1390
x5	-0.8124	0.1095	0.2020	-0.0115	0.2871
x6	0.7793	-0.1949	0.4131	0.3098	0.0882
x7	0.1398	0.1956	0.0440	-0.1209	0.9257
x8	0.7332	-0.0219	-0.3124	-0.0741	0.3589
x9	0.2591	0.7625	-0.2627	0.3534	0.1575
x10	0.2370	0.3700	0.2722	-0.4667	0.5151
x11	-0.2111	0.1827	0.2023	-0.1510	0.8583
x12	0.6562	-0.1771	0.5314	0.3422	0.1386
x13	0.9098	-0.1873	-0.1503	-0.0537	0.1118
x14	0.2948	0.7954	0.0793	0.0140	0.2740
x15	-0.9450	0.1666	0.2159	0.0522	0.0299
x16	-0.9385	0.1462	0.2639	0.0913	0.0199
x17	-0.3169	0.0364	0.1941	-0.0477	0.8583



	Factor1	Factor2	Factor3	Factor4
Factor1	-0.8610	0.2428	0.4287	0.1262
Factor2	0.2137	0.9406	-0.1641	0.2064
Factor3	0.4272	-0.0735	0.7547	0.4925
Factor4	0.1745	0.2256	0.4688	-0.8360



Scoring coefficients (method = regression; based on varimax rotated factors)

Variable	Factor1	Factor2	Factor3	Factor4
x1	-0.04944	0.00332	-0.04017	-0.08511
x2	-0.00437	-0.00721	0.01715	-0.27616
x3	0.00188	-0.01766	0.04609	0.20967
x4	0.09793	0.42155	0.01785	0.47535
x5	0.06308	-0.02252	0.02446	0.11973
x6	0.05583	0.01380	0.65309	-0.28414
x7	-0.04678	0.02801	-0.01819	-0.01865
x8	-0.03647	0.03766	-0.01896	-0.03532
x9	0.00509	0.41406	-0.00435	-0.76084
x10	-0.00494	-0.00205	-0.00685	0.25791
x11	-0.00407	-0.00179	-0.01318	0.07225
x12	0.14499	0.00104	0.45527	-0.03547
x13	-0.05347	-0.04905	0.02653	0.18764
x14	0.01073	0.21243	-0.00129	0.23819
x15	0.21322	0.11839	-0.25588	0.34191
x16	0.76200	0.02826	0.67590	-0.16553
x17	0.00965	-0.02258	0.05519	0.00355

Ejercicio 2:

El número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978) es 4.

Test for multivariate normality

Mardia mSkewness =	475.4859	chi2(3276) =	4297.740	Prob>chi2 =	0.0000
Mardia mKurtosis =	759.9989	chi2(1) =	8.966	Prob>chi2 =	0.0027
Henze-Zirkler =	1.000247	chi2(1) =	11.470	Prob>chi2 =	0.0007
Doornik-Hansen		chi2(52) =	776.759	Prob>chi2 =	0.0000

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.


Factor analysis/correlation	Number of obs	=	51
Method: principal factors	Retained factors	=	4
Rotation: (unrotated)	Number of params	=	98

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	12.08887	9.82667	0.6040	0.6040
Factor2	2.26220	0.68136	0.1130	0.7170
Factor3	1.58085	0.49465	0.0790	0.7960
Factor4	1.08620	0.23100	0.0543	0.8503
Factor5	0.85521	0.03978	0.0427	0.8930
Factor6	0.81542	0.30611	0.0407	0.9337
Factor7	0.50931	0.14179	0.0254	0.9592
Factor8	0.36753	0.05479	0.0184	0.9775
Factor9	0.31273	0.08655	0.0156	0.9932
Factor10	0.22618	0.02765	0.0113	1.0045
Factor11	0.19853	0.08151	0.0099	1.0144
Factor12	0.11702	0.02778	0.0058	1.0202
Factor13	0.08923	0.03101	0.0045	1.0247
Factor14	0.05822	0.01640	0.0029	1.0276
Factor15	0.04182	0.02055	0.0021	1.0297
Factor16	0.02127	0.02397	0.0011	1.0307
Factor17	-0.00270	0.00399	-0.0001	1.0306
Factor18	-0.00669	0.01393	-0.0003	1.0303
Factor19	-0.02063	0.00605	-0.0010	1.0292
Factor20	-0.02667	0.00824	-0.0013	1.0279
Factor21	-0.03492	0.01923	-0.0017	1.0262
Factor22	-0.05414	0.00437	-0.0027	1.0235
Factor23	-0.05852	0.02775	-0.0029	1.0205
Factor24	-0.08627	0.05588	-0.0043	1.0162
Factor25	-0.14215	0.04044	-0.0071	1.0091
Factor26	-0.18259	.	-0.0091	1.0000

LR test: independent vs. saturated: chi2(325) = 1451.04 Prob>chi2 = 0.0000


Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Uniqueness
div1	0.9243	0.1403	0.0508	-0.0283	0.1226
div2	0.9278	-0.0300	-0.0495	-0.1762	0.1048
div3	0.4967	0.5590	0.3778	0.2111	0.2535
div4	0.6179	0.5234	-0.4220	0.1719	0.1366
div5	0.8875	0.2726	-0.1709	0.0932	0.1002
div6	0.9735	0.0151	-0.0440	0.0602	0.0466
div7	-0.2276	0.3753	0.0376	-0.1729	0.7760
div8	0.2853	-0.1056	0.1629	0.4399	0.6874
div9	0.3114	0.0928	0.3854	-0.1314	0.7286
div10	0.9703	-0.0469	-0.0408	-0.1318	0.0373
div11	0.9436	-0.0683	-0.0171	-0.1674	0.0767
div12	0.8900	0.1640	-0.0467	-0.2200	0.1304
div13	0.2770	0.4537	0.4446	-0.0089	0.5197
div14	0.9204	0.0466	0.2044	0.1893	0.0731
div15	0.4895	-0.4788	0.0907	-0.1398	0.5034
div16	0.1155	-0.3809	0.5300	-0.0282	0.5599
div17	0.9286	-0.1886	-0.1047	-0.1031	0.0806
div18	0.4423	-0.1346	0.1006	0.6517	0.3515
div19	0.9110	-0.1410	-0.1277	-0.0393	0.1324
div20	0.6107	-0.2521	0.2895	0.1006	0.4696
div21	-0.0193	0.5537	0.4005	-0.1749	0.5021
div22	-0.1151	0.4670	-0.2868	0.1314	0.6691
div23	0.8660	-0.1777	-0.1542	0.0110	0.1945
div24	-0.0563	-0.2340	0.2771	0.0114	0.8652
div25	0.9436	-0.0199	-0.0429	-0.1849	0.0732
div26	-0.2469	0.2354	0.2200	-0.2191	0.7872



Factor rotation matrix

	Factor1	Factor2	Factor3	Factor4
Factor1	0.9783	0.1061	-0.0029	0.1777
Factor2	-0.0463	0.7224	-0.6641	-0.1872
Factor3	-0.1018	0.6833	0.7041	0.1642
Factor4	-0.1742	0.0044	-0.2514	0.9521



Scoring coefficients (method = regression; based on varimax rotated factors)

Variable	Factor1	Factor2	Factor3	Factor4
div1	0.17885	0.10184	-0.00660	-0.59942
div2	0.11868	-0.03913	0.22780	-0.38276
div3	-0.03201	0.27947	-0.04343	-0.01587
div4	-0.05978	-0.01037	-0.81217	0.21191
div5	0.08776	0.01832	-0.09333	0.20704
div6	0.16440	0.03515	0.07440	-0.00240
div7	0.01046	0.07851	-0.07332	-0.19326
div8	-0.00480	-0.04679	-0.02689	0.05741
div9	0.01119	0.10135	0.08398	-0.10855
div10	0.36607	-0.17317	0.48481	-1.06470
div11	0.09502	0.06248	-0.03609	-0.02651
div12	0.04555	0.17782	-0.09572	-0.29695
div13	-0.00931	0.22529	0.06891	0.05193
div14	-0.18207	0.51022	-0.00610	1.47056
div15	0.01674	-0.01596	0.08531	-0.01058
div16	-0.01491	0.05041	0.12636	-0.05363
div17	0.10932	-0.48002	0.12783	-0.09845
div18	-0.00114	-0.05393	0.07244	0.24379
div19	0.05830	-0.13966	-0.12245	0.04555
div20	0.00136	0.02748	0.12948	0.12901
div21	-0.00321	0.22648	0.07534	-0.12757
div22	0.01474	0.01834	-0.10933	-0.10336
div23	-0.02939	-0.17075	-0.23166	0.35948
div24	-0.01218	0.04318	0.09012	0.06983
div25	0.06780	0.04586	-0.05197	0.27049
div26	-0.00390	0.09017	0.02770	-0.00464

Ejercicio 3.

Estimar un modelo factorial empleando la base “sachs.dta”, extracto de Gallup, Sachs & Mellinger (1999).

El número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978) es 4.

Test for multivariate normality

```
Mardia mSkewness = 206.39    chi2(455) = 2457.546    Prob>chi2 = 0.0000
Mardia mKurtosis = 324.3951  chi2(1) = 729.827    Prob>chi2 = 0.0000
Henze-Zirkler    = 1.644722  chi2(1) = 7583.382   Prob>chi2 = 0.0000
Doornik-Hansen   chi2(26) = 4006.593    Prob>chi2 = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.


```
Factor analysis/correlation          Number of obs    =      68
Method: principal factors            Retained factors =       4
Rotation: (unrotated)                Number of params =     46
```

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	5.01467	3.08644	0.5908	0.5908
Factor2	1.92823	1.22268	0.2272	0.8179
Factor3	0.70555	0.07401	0.0831	0.9010
Factor4	0.63155	0.26287	0.0744	0.9754
Factor5	0.36868	0.15252	0.0434	1.0189
Factor6	0.21615	0.14000	0.0255	1.0443
Factor7	0.07616	0.03014	0.0090	1.0533
Factor8	0.04602	0.07192	0.0054	1.0587
Factor9	-0.02591	0.04197	-0.0031	1.0557
Factor10	-0.06788	0.01447	-0.0080	1.0477
Factor11	-0.08235	0.02814	-0.0097	1.0380
Factor12	-0.11049	0.10135	-0.0130	1.0250
Factor13	-0.21184	.	-0.0250	1.0000

LR test: independent vs. saturated: chi2(78) = 691.68 Prob>chi2 = 0.0000


Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Factor4	Uniqueness
gdp95	0.7523	-0.5526	-0.0681	-0.0504	0.1215
lnd100km	0.7707	0.5388	-0.1264	0.1049	0.0887
pop100km	0.7778	0.4087	-0.3223	0.2253	0.0733
lnd100cr	0.8274	0.4465	0.2349	-0.0555	0.0578
pop100cr	0.9009	0.2158	0.1215	0.0874	0.1194
dens95c	0.2788	0.0802	-0.0046	0.1286	0.8993
dens95i	0.1725	0.1317	0.5512	0.0223	0.6486
airdist	-0.5996	0.3105	-0.1676	0.3128	0.4182
ciffob95	-0.5771	0.2979	-0.1212	-0.0757	0.5578
landarea	-0.0529	-0.5398	-0.0316	0.4942	0.4606
open6590	0.6776	-0.4727	-0.0257	-0.2014	0.2761
urbpop95	0.6959	-0.4157	-0.1754	0.0692	0.3073
pop95	-0.0849	-0.1516	0.3634	0.3825	0.6915



Factor rotation matrix

	Factor1	Factor2	Factor3	Factor4
Factor1	0.7546	0.6493	-0.0111	0.0937
Factor2	0.6116	-0.7223	-0.3200	0.0422
Factor3	-0.0970	-0.0306	0.0147	0.9947
Factor4	0.2170	-0.2359	0.9472	-0.0001



Scoring coefficients (method = regression; based on varimax rotated factors)

Variable	Factor1	Factor2	Factor3	Factor4
gdp95	-0.06881	0.51213	0.18654	-0.28673
lnd100km	0.32177	-0.07360	0.37913	0.28969
pop100km	0.40629	-0.21274	-0.04651	-1.16543
lnd100cr	0.28593	-0.25421	-0.90320	0.31861
pop100cr	0.11440	0.32092	0.64413	0.70563
dens95c	0.02714	-0.04003	0.05469	0.02433
dens95i	0.00876	-0.04354	0.10595	0.18612
airdist	0.06427	-0.12876	0.27673	-0.01836
ciffob95	0.01223	-0.05945	-0.07444	-0.11893
landarea	0.01604	-0.06632	0.38983	0.04208
open6590	-0.09585	0.25316	-0.27843	0.17955
urbpop95	0.00689	0.15520	0.12482	-0.18473
pop95	0.00550	-0.00865	0.25192	0.22795

Ejercicio 4.

En base a los datos empleados por la Fundación Heritage para construir el Freedom Index 2010, contenidos en la base "heritage.dta", ajustar un modelo factorial y comentar, brevemente, los resultados obtenidos.

El número de factores resultantes del proceso de selección de modelos introducido por Schwarz (1978) es 3.

Test for multivariate normality

```

Mardia mSkewness = 56.1748    chi2(364) = 1717.712    Prob>chi2 = 0.0000
Mardia mKurtosis = 226.8436    chi2(1) = 463.736    Prob>chi2 = 0.0000
Henze-Zirkler    = 1.070629    chi2(1) = 160.551    Prob>chi2 = 0.0000
Doornik-Hansen   chi2(24) = 365.055    Prob>chi2 = 0.0000

```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que no tienen una distribución normal multivariada.

```

Factor analysis/correlation          Number of obs    =      180
Method: principal factors            Retained factors  =        3
Rotation: (unrotated)               Number of params  =      33

```

Factor	Eigenvalue	Difference	Proportion	Cumulative
Factor1	5.41921	4.23969	0.7939	0.7939
Factor2	1.17951	0.63156	0.1728	0.9667
Factor3	0.54795	0.32643	0.0803	1.0470
Factor4	0.22152	0.09794	0.0325	1.0795
Factor5	0.12358	0.08258	0.0181	1.0976
Factor6	0.04100	0.09542	0.0060	1.1036
Factor7	-0.05441	0.00706	-0.0080	1.0956
Factor8	-0.06147	0.03881	-0.0090	1.0866
Factor9	-0.10028	0.00635	-0.0147	1.0719
Factor10	-0.10662	0.04573	-0.0156	1.0563
Factor11	-0.15235	0.07947	-0.0223	1.0340
Factor12	-0.23183	.	-0.0340	1.0000

LR test: independent vs. saturated: chi2(66) = 1370.91 Prob>chi2 = 0.0000


Factor loadings (pattern matrix) and unique variances

Variable	Factor1	Factor2	Factor3	Uniqueness
propertyrights	0.9027	-0.1412	0.1399	0.1456
judicialefficiency	0.8381	-0.1291	0.1902	0.2448
governmenteffectiveness	0.8810	-0.2028	0.1606	0.1570
taxburden	-0.0549	0.7075	0.0842	0.4894
govtspending	-0.2522	0.5675	-0.0647	0.6101
fiscalhealth	0.2281	0.2526	0.0886	0.8763
businessfreedom	0.7919	0.1061	0.2527	0.2978
laborfreedom	0.4757	0.3060	0.2036	0.6386
monetaryfreedom	0.6318	0.2432	-0.2175	0.4944
tradefreedom	0.7337	0.2255	-0.0519	0.4082
investmentfreedom	0.7414	-0.0206	-0.4439	0.2529
financialfreedom	0.8166	0.0064	-0.3080	0.2383



Factor rotation matrix

	Factor1	Factor2	Factor3
Factor1	0.8502	0.5255	0.0333
Factor2	-0.1095	0.1147	0.9874
Factor3	0.5150	-0.8431	0.1550



Scoring coefficients (method = regression; based on varimax rotated factors)

Variable	Factor1	Factor2	Factor3
propertyri~s	0.36310	-0.12448	-0.10484
judicaleff~s	0.21451	-0.11300	-0.01531
government~y	0.34141	-0.13879	-0.20422
taxburden	0.01266	-0.01098	0.38810
govtspending	-0.03155	0.01738	0.27961
fiscalhealth	-0.00061	0.01366	0.12259
businessfr~m	0.21898	-0.15093	0.20870
laborfreedom	0.07333	-0.05357	0.16750
monetaryfr~m	-0.01848	0.17040	0.13541
tradefreedom	0.05514	0.10121	0.18267
investment~m	-0.17474	0.54042	-0.10334
financialf~m	-0.13248	0.46943	-0.02438

Análisis Estadístico Multivariado | UTDT

Problem Set 7

Alejandra Clemente

Fiona Franco Churruarín

Segundo Trimestre 2023

Ejercicio 1

La base de datos *firmas.dta* contiene información financiera referida a dos tipos de firmas: 12 firmas consideradas de buena performance, y 12 firmas no tan buenas en ese sentido. En la base se podrán observar dos características relevadas en la totalidad de las firmas: EBITASS (ganancias después de impuestos e intereses sobre activos) y ROTC (retorno sobre el capital).

- (a) Realizar un gráfico de las variables relevadas. Interpretarlo.
- (b) Realizar un test de medias multivariado.
- (c) Realizar un análisis discriminante.
- (d) Obtener predicciones para toda la muestra y comparar con la información observada.
- (e) Considere una firma con un EBITASS y un ROTC de 0,1. ¿En qué grupo la clasificaría?

Ejercicio 2

La base de datos *muestra_engh.dta* contiene información proveniente de la Encuesta Nacional de Gastos de los Hogares para tres regiones: Metropolitana, Noreste (NEA) y Sur. Considere responder a las siguientes consignas con las variables desagregadas por capítulo de gasto.

Variable	Descripción
Region	1 = Metropolitana; 4 = NEA; 6 = Sur
cap1	Capítulo 1 - Alimentos y bebidas
cap2	Capítulo 2 - Indumentaria y calzado
cap3	Capítulo 3 - Vivienda
cap4	Capítulo 4 - Equipamiento y funcionamiento del hogar
cap5	Capítulo 5 - Atención médica y gastos para la salud
cap6	Capítulo 6 - Transporte y comunicaciones
cap7	Capítulo 7 - Esparcimiento
cap8	Capítulo 8 - Educación
cap9	Capítulo 9 - Bienes y servicios varios
gctotal	Gasto total en consumo
intotal	Ingreso neto del hogar

- (a) Realice un test de igualdad de medias entre regiones.


- (b) Realice un análisis discriminante.
- (c) Obtenga las predicciones a partir de la/s estimación/es de la función/es discriminante/s.
- (d) Obtenga las predicciones a partir de las distancias de Mahalanobis.
- (e) Complete una tabla de predicción-realización.
- (f) ¿Cómo realizaría el análisis en caso de no poder suponer que las matrices de varianzas y covarianzas son iguales entre grupos? ¿Cuántos parámetros debería estimar?

Trabajo Práctico N° 7

Ejercicio 1.

La base de datos “firmas.dta” contiene información financiera referida a dos tipos de firmas: 12 firmas consideradas de buena performance y 12 firmas no tan buenas en ese sentido. En la base, se podrán observar dos características relevadas en la totalidad de las firmas: EBITASS (ganancias después de impuestos e intereses sobre activos) y ROTC (retorno sobre el capital).

(a) Realizar un gráfico de las variables relevadas. Interpretar.



(b) Realizar un test de medias multivariado.

Estadístico= 34,31241761346325.

P-value= 3,54122225462e-08.

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los grupos no tienen medias iguales.

(c) Realizar un análisis discriminante.

Linear discriminant analysis

Resubstitution classification summary


+-----+			
Key			

Number			
Percent			
+-----+			
		Classified	
True group	0	1	Total

0	12	0	12
	100.00	0.00	100.00
1	1	11	12
	8.33	91.67	100.00

Total	13	11	24
	54.17	45.83	100.00
Priors	0.5000	0.5000	

Por lo tanto, todas las observaciones clasificadas en el grupo 0 están correctamente clasificadas, mientras que una de las observaciones clasificada en el grupo 1 está incorrectamente clasificada.



+-----+					
		Classification		Probabilities	
Obs		True	Class.	0	1
+-----+					
1		0	0	0.9962	0.0038
2		0	0	0.9999	0.0001
3		0	0	0.9998	0.0002
4		0	0	1.0000	0.0000
5		0	0	0.9997	0.0003
+-----+					
6		0	0	0.9999	0.0001
7		0	0	0.9950	0.0050
8		0	0	1.0000	0.0000
9		0	0	0.5373	0.4627
10		0	0	0.9788	0.0212
+-----+					
11		0	0	0.9993	0.0007
12		0	0	0.9994	0.0006
13		1	1	0.0001	0.9999
14		1	1	0.0112	0.9888
15		1	1	0.0086	0.9914
+-----+					
16		1	1	0.0000	1.0000
17		1	1	0.0000	1.0000
18		1	1	0.0004	0.9996
19		1	1	0.0013	0.9987
20		1	0 *	0.5727	0.4273
+-----+					
21		1	1	0.0000	1.0000
22		1	1	0.0239	0.9761
23		1	1	0.0001	0.9999
24		1	1	0.0019	0.9981
+-----+					


* indicates misclassified observations

Classification functions

			group	
			0	1
+-----+				
ebitass			61.23745	2.55117
rotc			21.02689	-1.404444
_cons			-7.7876	-.0033742
+-----+				
Priors			.5	.5

(d) Obtener predicciones para toda la muestra y comparar con la información observada.

(e) Considerar una firma con un EBITASS y un ROTC de 0,1. ¿En qué grupo se la clasificaría?



Por lo tanto, considerando una firma con un EBITASS y un ROTC de 0,1, se la clasificaría en el grupo 0 ("Good performing companies").

Ejercicio 2.

La base de datos “muestra_enh.dta” contiene información proveniente de la Encuesta Nacional de Gastos de los Hogares para tres regiones: Metropolitana, Noreste (NEA) y Sur. Considerar responder a las siguientes consignas con las variables desagregadas por capítulo de gasto.

Variable	Descripción
Region	1 = Metropolitana; 4 = NEA; 6 = Sur
cap1	Capítulo 1 - Alimentos y bebidas
cap2	Capítulo 2 - Indumentaria y calzado
cap3	Capítulo 3 - Vivienda
cap4	Capítulo 4 - Equipamiento y funcionamiento del hogar
cap5	Capítulo 5 - Atención médica y gastos para la salud
cap6	Capítulo 6 - Transporte y comunicaciones
cap7	Capítulo 7 - Esparcimiento
cap8	Capítulo 8 - Educación
cap9	Capítulo 9 - Bienes y servicios varios
gctotal	Gasto total en consumo
intotal	Ingreso neto del hogar

(a) Realizar un test de igualdad de medias entre regiones.

Estadístico= 72,80066506848998.

P-value= 1,50900286966e-08.

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que los grupos no tienen medias iguales.

(b) Realizar un análisis discriminante.

(c) Obtener las predicciones a partir de la/s estimación/es de la función/es discriminante/s.

(d) Obtener las predicciones a partir de las distancias de Mahalanobis.

		predict2			
		1	2	3	Total

predict1					
1		86			86
2			233		233
3				102	102
Total		86	233	102	421

(e) Completar una tabla de predicción-realización.

table1[3,3]			
	predict_1	predict_2	predict_3
id_1	44	60	16
id_2	20	96	19
id_3	22	77	67

Correct= 207.

Incorrect= 214.

Por lo tanto, 207 y 214 observaciones fueron clasificadas correcta e incorrectamente, respectivamente.

Linear discriminant analysis
Resubstitution classification summary

+-----+				
Key				

Number				
Percent				
+-----+				
Classified				
True id	1	2	3	Total
-----+				
1	44	60	16	120
	36.67	50.00	13.33	100.00
2	20	96	19	135
	14.81	71.11	14.07	100.00
3	23	75	68	166
	13.86	45.18	40.96	100.00
-----+				
Total	87	231	103	421
	20.67	54.87	24.47	100.00
Priors	0.3333	0.3333	0.3333	

(f) ¿Cómo se realizaría el análisis en caso de no poder suponer que las matrices de varianzas y covarianzas son iguales entre grupos? ¿Cuántos parámetros se deberían estimar?

```
table2[3,3]
      predict_1 predict_2 predict_3
id_1         36         72         12
id_2         12        113         10
id_3         22        100         44
```

Correct= 193.

Incorrect= 228.

Por lo tanto, 193 y 228 observaciones fueron clasificadas correcta e incorrectamente, respectivamente.

Quadratic discriminant analysis
Resubstitution classification summary

+-----+				
Key				

Number				
Percent				
+-----+				
Classified				
True id	1	2	3	Total
-----+				
1	36	72	12	120
	30.00	60.00	10.00	100.00
2	12	113	10	135
	8.89	83.70	7.41	100.00
3	22	100	44	166
	13.25	60.24	26.51	100.00
-----+				
Total	70	285	66	421
	16.63	67.70	15.68	100.00
Priors	0.3333	0.3333	0.3333	