

Inferencia Estadística

G5: Inferencia Bayesiana

Gabriel Martos
Nicolás Ferrer

Email: gmartos@utdt.edu
Email: nicolas.ferrer.747@gmail.com

Enunciados

1. Si $X|\theta \sim \text{Poiss}(\theta)$, y además podemos asumir que $P(\theta = 2) = 1/3$ y $P(\theta = 3) = 2/3$ (esto es $\Theta = \{2, 3\}$). Dada la información $x_1 = 2$ y $x_2 = 4$, compute la probabilidad a-posteriori¹ para θ . ¿Qué inferencia puede hacer respecto del parámetro θ ?
2. Una de las ventajas del enfoque Bayesiano reside en que el teorema de Bayes se puede utilizar de forma secuencial; y esto es particularmente útil cuando necesitamos 'refrescar el modelo' con información nueva. Imagina que de manera secuencial recibes la información (datos) \mathbf{x}_1 y luego \mathbf{x}_2 , argumenta porque es cierto que:

$$\pi(\theta|\mathbf{x}_1, \mathbf{x}_2) \propto L(\theta|\mathbf{x}_2)\pi(\theta|\mathbf{x}_1).$$

3. Si $X|\theta \sim \text{Poiss}(\theta)$ y $\theta \sim \text{Gamma}(\alpha, \beta)$ ², esto es:

$$\pi(\theta; \alpha, \beta) = \frac{\theta^{\alpha-1} e^{-\theta/\beta}}{\Gamma(\alpha)\beta^\alpha}, \quad \alpha > 0, \beta > 0, \theta > 0,$$

donde α y β son dos hiperparámetros conocidos (elegidos por quien modela el problema).

- (a) Comprobar que la distribución a posteriori de θ es Gamma de parámetros: $\alpha_n = \sum_{i=1}^n x_i + \alpha$ y $\beta_n = \beta/(n\beta + 1)$.
 - (b) ¿A dónde convergen la media y la varianza a posteriori cuando $n \rightarrow \infty$?
 - (c) Imagine que la variable aleatoria X_i da cuenta de la cantidad de delitos registrados en la ciudad en el día i ; y que de una muestra de 10 días se tiene que $\sum_{i=1}^{10} x_i = 140$. Justificando su elección de los parámetros α y β (encuentre algún argumento razonable para elegirlos), obtenga la distribución a posteriori de θ .
 - (d) Reporte la media y varianza a posteriori.
 - (e) Construya un HPD al 95% y 99% e interprete los resultados.
4. El modelo Beta–Bernoulli, asume una prior Beta para el parámetro θ . Obtener la distribución a posteriori si en vez de una prior Beta utilizáramos una distribución uniforme en el intervalo $(0, 1)$ para θ :
 - (a) ¿Cómo interpretas el uso de una prior uniforme en términos prácticos?
 - (b) Calcula en este contexto $E(\theta|\mathbf{x})$ y $V(\theta|\mathbf{x})$.

¹Recuerda que por probabilidad total: $P(X_1 = 2, X_2 = 4) = \sum_{\theta \in \Theta} P(X_1 = 2, X_2 = 4|\Theta = \theta)P(\Theta = \theta)$.

²Bajo esta parametrización la media a priori de θ es $\alpha\beta$ y la varianza $\alpha\beta^2$

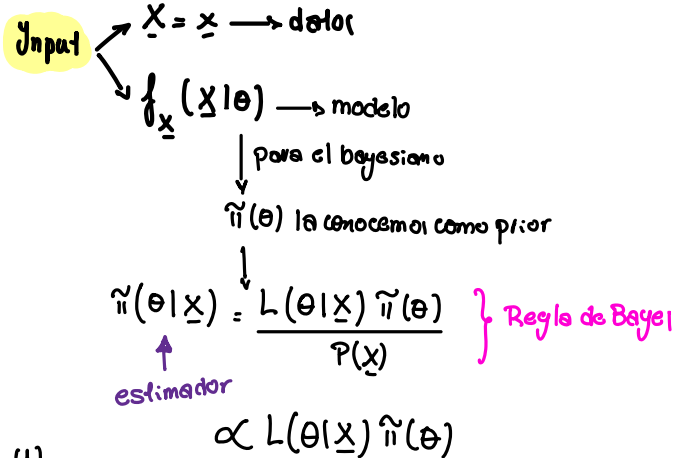
5. En clase discutimos el modelo Normal–Normal. Utiliza la fórmula de Bayes y las propiedades de los modelos conjugados para construir de forma detallada la distribución a posteriori $\pi(\theta | \mathbf{x}) = N(\mu_n, \sigma_n^2)$, que recordemos tiene parámetros:

$$\mu_n = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{n}{\sigma_0^2} \bar{x}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2}} \text{ y } \sigma_n^2 = \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma_0^2} \right)^{-1}.$$

- ¿A dónde convergen los parámetros de la posteriori cuando $n \rightarrow \infty$?
 - ¿Cómo interpretas este resultado?
 - Determina la estructura que tendría un intervalo de confianza creíble a posteriori de probabilidad 0.95. ¿Es tu intervalo el HPD?
6. Imagina que trabajas para la consultora económica XYZ y se te encarga hacer inferencia bayesiana para el parámetro θ = “tasa de desempleo en CABA”. Tomas una muestra de tamaño $n = 100$ de la población relevante y observas que la variable y = Número de desempleados en la muestra = 18. Se pide respuestas a lo siguiente:
- ¿Cómo propondrías elegir la prior sobre θ ?
 - Computa la distribución a-posteriori (para tu elección de prior).
 - Computa la esperanza, moda y varianza aposteriori de θ .
 - Computa la HPD para $\alpha = 5\%$.
 - Un economista amigo, con una visión diametralmente opuesta a la tuya en cuanto a la situación económica actual, presenta estimaciones diferentes utilizando los mismos datos de la encuesta anterior. ¿Cómo es esto posible?
 - ¿Qué crees que ocurriría con la “distancia” entre tus conclusiones y la de tu amigo economista si el tamaño de la muestra fuera 10 veces más grande?


Modelos conjugados

Likelihood	Prior distribution	Posterior distribution
$y_i \sim \text{binomial}(n, \phi)$	$\phi \sim \text{beta}(\alpha, \beta)$	$\phi \sim \text{beta}(\sum y_i + \alpha, n - \sum y_i + \beta)$
$y_i \sim \text{Bernoulli}(\phi)$	$\phi \sim \text{beta}(\alpha, \beta)$	$\phi \sim \text{beta}(\sum_{i=1}^n y_i + \alpha, \sum_{i=1}^n (1 - y_i) + \beta)$
$y_i \sim \text{Poisson}(\lambda)$	$\lambda \sim \text{gamma}(\alpha, \beta)$	$\lambda \sim \text{gamma}(\alpha + \sum_{i=1}^n y_i, \beta + n)$
$y_i \sim \text{normal}(\mu, \sigma^2)$ σ^2 is known.	$\mu \sim \text{normal}(\mu_0, \sigma_0^2)$	$\mu \sim \text{normal}\left(\frac{\left(\frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^n y_i}{\sigma^2}\right)}{\left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)}, \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)^{-1}\right)$
$y_i \sim \text{normal}(\mu, \sigma^2)$ μ is known.	$\sigma^2 \sim$ inverse gamma(α, β)	$\sigma^2 \sim$ inverse gamma $\left(\alpha + \frac{n}{2}, \beta + \frac{\sum_{i=1}^n (y_i - \mu)^2}{2}\right)$
$y_i \sim \text{lognormal}(\mu, \sigma^2)$, μ is known	$\sigma^2 \sim$ inverse gamma(α, β)	$\sigma^2 \sim$ inverse gamma $\left(n/2 + \alpha, \frac{(\log(y_i) - \mu)^2}{2} + \beta\right)$
$y_i \sim \text{lognormal}(\mu, \sigma^2)$ σ^2 is known	$\mu \sim \text{normal}(\mu_0, \sigma_0^2)$	$\mu \sim \text{normal}\left(\frac{\left(\frac{\mu_0}{\sigma_0^2} + \frac{\sum_{i=1}^n \log y_i}{\sigma^2}\right)}{\left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)}, \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)^{-1}\right)$



(1)

1. Si $X|\theta \sim \text{Poiss}(\theta)$, y además podemos asumir que $P(\theta = 2) = 1/3$ y $P(\theta = 3) = 2/3$ (esto es $\Theta = \{2, 3\}$). Dada la información $x_1 = 2$ y $x_2 = 4$, compute la probabilidad a-posteriori¹ para θ . ¿Qué inferencia puede hacer respecto del parámetro θ ?



$$\begin{aligned} \cdot \tilde{\pi}(\theta) &= \begin{pmatrix} 1/3 & 2/3 \end{pmatrix} \begin{matrix} \mathbb{1}_{\{\theta=2\}} & 1-\mathbb{1}_{\{\theta=2\}} \end{matrix} \\ \cdot L(\theta|\underline{x}=\underline{x}) &= \prod_{i=1}^n \frac{e^{-\theta} \cdot \theta^{x_i}}{(x_i)!} = \frac{e^{-\theta} \cdot \theta^2}{2} \cdot \frac{e^{-\theta} \cdot \theta^4}{24} \\ &= \frac{e^{-2\theta} \cdot \theta^6}{48} \end{aligned}$$

$$\begin{aligned} \cdot P(\underline{x}) &= P(\underline{x}|\theta=2) \tilde{\pi}(\theta=2) + P(\underline{x}|\theta=3) \tilde{\pi}(\theta=3) \\ &= \frac{e^{-4} \cdot 2^6}{48} \cdot \frac{1}{3} + \frac{e^{-6} \cdot 3^6}{48} \cdot \frac{2}{3} \end{aligned}$$

$$\approx 0.033$$

$$\begin{aligned} \Rightarrow \tilde{\pi}(\theta|\underline{x}) &= \frac{\left(\frac{e^{-2\theta} \cdot \theta^6}{48} \right) \times \begin{bmatrix} (1/3) & (2/3) \end{bmatrix} \begin{matrix} \mathbb{1}_{\{\theta=2\}} & 1-\mathbb{1}_{\{\theta=2\}} \end{matrix}}{0.033} \\ &\approx \left(\frac{1}{48 \cdot 0.033} \right) \begin{bmatrix} e^{-2\theta} \cdot \theta^6 & (1/3) & (2/3) \end{bmatrix} \begin{matrix} \mathbb{1}_{\{\theta=2\}} & 1-\mathbb{1}_{\{\theta=2\}} \end{matrix} \end{aligned}$$

$$\propto e^{-2\theta} \cdot \theta^6 \begin{pmatrix} 1/3 & 2/3 \end{pmatrix} \begin{matrix} \mathbb{1}_{\{\theta=2\}} & 1-\mathbb{1}_{\{\theta=2\}} \end{matrix}$$

Inferencia respecto a θ : $\hat{\theta}_{MAP}$

$$\left. \begin{aligned} \cdot \tilde{\pi}(\theta=2|\underline{x}) &\propto e^{-4} \cdot 2^6 \cdot \left(\frac{1}{3}\right) \approx 0.39 \\ \cdot \tilde{\pi}(\theta=3|\underline{x}) &\propto e^{-6} \cdot 3^6 \cdot \left(\frac{2}{3}\right) \approx 1.2 \end{aligned} \right\} \therefore \hat{\theta}_{MAP} = 3$$

2. Una de las ventajas del enfoque Bayesiano reside en que el teorema de Bayes se puede utilizar de forma secuencial; y esto es particularmente útil cuando necesitamos 'refrescar el modelo' con información nueva. Imagina que de manera secuencial recibes la información (datos) \mathbf{x}_1 y luego \mathbf{x}_2 , argumenta porque es cierto que:

$$\pi(\theta|\mathbf{x}_1, \mathbf{x}_2) \propto L(\theta|\mathbf{x}_2)\pi(\theta|\mathbf{x}_1).$$

- 3. Si $X|\theta \sim \text{Poiss}(\theta)$ y $\theta \sim \text{Gamma}(\alpha, \beta)$ ², esto es:

$$\pi(\theta; \alpha, \beta) = \frac{\theta^{\alpha-1} e^{-\theta/\beta}}{\Gamma(\alpha) \beta^\alpha}, \quad \alpha > 0, \beta > 0, \theta > 0,$$

donde α y β son dos hiperparámetros conocidos (elegidos por quien modela el problema).

- (a) Comprobar que la distribución aposteriori de θ es Gamma de parámetros: $\alpha_n = \sum_{i=1}^n x_i + \alpha$ y $\beta_n = \beta/(n\beta + 1)$.
- (b) ¿A dónde convergen la media y la varianza a posteriori cuando $n \rightarrow \infty$?
- (c) Imagine que la variable aleatoria X_i da cuenta de la cantidad de delitos registrados en la ciudad en el día i ; y que de una muestra de 10 días se tiene que $\sum_{i=1}^{10} x_i = 140$. Justificando su elección de los parámetros α y β (encuentre algún argumento razonable para elegirlos), obtenga la distribución a posteriori de θ .
- (d) Reporte la media y varianza a posteriori.
- (e) Construya un HPD al 95% y 99% ^{87% 49%} e interprete los resultados.

$$\begin{aligned} (a) \cdot L(\theta|\underline{x}) &= \prod_{\underline{x}} (x_i|\theta) \stackrel{nd}{=} \prod_{i=1}^n (x_i|\theta) = \prod_{i=1}^n \frac{e^{-\theta} \theta^{x_i}}{(x_i)!} = \left(\prod_{i=1}^n \frac{1}{(x_i)!} \right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} \\ \cdot \pi(\theta|\alpha, \beta) &= \frac{\theta^{\alpha-1}}{\Gamma(\alpha)} \cdot \frac{1}{\beta^\alpha} \cdot e^{-\frac{1}{\beta}\theta} \end{aligned}$$

$$\pi(\theta|\underline{x}) \propto L(\theta|\underline{x}) \cdot \pi(\theta|\alpha, \beta)$$

$$\begin{aligned} L(\theta|\underline{x}) \cdot \pi(\theta|\alpha, \beta) &= \left(\prod_{i=1}^n \frac{1}{(x_i)!} \right) e^{-n\theta} \theta^{\sum_{i=1}^n x_i} \cdot \frac{\theta^{\alpha-1}}{\Gamma(\alpha)} \cdot \frac{1}{\beta^\alpha} \cdot e^{-\frac{1}{\beta}\theta} \\ &= \left[\left(\prod_{i=1}^n \frac{1}{(x_i)!} \right) \frac{1}{\Gamma(\alpha) \beta^\alpha} \right] \cdot \left(\theta^{\sum_{i=1}^n x_i + \alpha - 1} \right) \cdot \left(e^{-n\theta - \frac{1}{\beta}\theta} \right) \\ &\propto \theta^{\sum_{i=1}^n x_i + \alpha - 1} \cdot e^{-(n + \frac{1}{\beta})\theta} \end{aligned}$$

$$\left. \begin{aligned} \cdot \alpha_n &= \sum_{i=1}^n x_i + \alpha \\ \cdot \frac{1}{\beta_n} &= \left(n + \frac{1}{\beta} \right) = \frac{\beta n + 1}{\beta} \Rightarrow \beta_n = \beta \left(\frac{1}{\beta n + 1} \right) \end{aligned} \right\} \pi(\theta|\underline{x}) \propto \theta^{\alpha_n - 1} e^{-\frac{1}{\beta_n}\theta} = \Gamma(\alpha_n, \beta_n) = \Gamma\left(\sum_{i=1}^n x_i + \alpha, \beta \left(\frac{1}{\beta n + 1} \right)\right)$$

$$(b) \bullet \mathbb{E}_{\underline{x}}(\theta) = \alpha_n \cdot \beta_n = \left(\sum_{i=1}^n x_i + \alpha \right) \cdot \beta \left(\frac{1}{\beta n + 1} \right) = (n\bar{x} + \alpha) \beta \cdot \left(\frac{1}{\beta n + 1} \right)$$

$$= \underbrace{\frac{\beta n \bar{x}}{\beta n + 1}}_{\bar{x}} + \underbrace{\frac{\alpha \beta}{\beta n + 1}}_{\rightarrow 0}$$

$$\lim_{n \rightarrow \infty} \mathbb{E}_{\underline{x}}(\theta) = \bar{x}$$

$$\bullet \text{Var}_{\underline{x}}(\theta) = \alpha_n \beta_n^2 = (n\bar{x} + \alpha) \left[\beta \left(\frac{1}{\beta n + 1} \right) \right]^2$$

$$\lim_{n \rightarrow \infty} \text{Var}_{\underline{x}}(\theta) = 0$$


$$(c) \cdot \sum_{i=1}^{10} x_i = 140 \Rightarrow \bar{x}_n = 14$$

$$\text{I) } \alpha = 2, \beta = 0.5 \Rightarrow \mathbb{E}_{\alpha, \beta}[\theta] = 1, \text{Var}_{\alpha, \beta}[\theta] = 0.5 \rightarrow \text{priorístico}$$

$$\text{II) Empirical Bayes} \Rightarrow \mathbb{E}_{\alpha, \beta}[\theta] = \bar{x}_n = 14 \Rightarrow \alpha\beta = 14 \rightarrow \text{infinitas combinaciones}$$


$$\begin{aligned} &\alpha = 1 \text{ y } \beta = 14 \\ &\alpha = 2 \text{ y } \beta = 7 \\ &\alpha = 7 \text{ y } \beta = 2 \\ &\alpha = 14 \text{ y } \beta = 1 \end{aligned}$$

mais seguro
=> prior mais
informativo



$$d) \text{ Si } \alpha = 1 \text{ y } \beta = 14 \Rightarrow \hat{\pi}(\theta | \underline{x}) = \Gamma(141, 141/141) \Rightarrow \mathbb{E}_{\underline{x}}[\theta] = 14, \text{Var}_{\underline{x}}[\theta] = 1.39$$

$$\text{ Si } \alpha = 14 \text{ y } \beta = 1 \Rightarrow \hat{\pi}(\theta | \underline{x}) = \Gamma(154, 1/11) \Rightarrow \mathbb{E}_{\underline{x}}[\theta] = 14, \text{Var}_{\underline{x}}[\theta] = 1.2727$$



HDI = $\{\theta \in \Theta : \hat{\pi}(\theta | \underline{x}) \geq \nu_\alpha\} / \nu_\alpha$ es el valor más alto que garantiza $P(\theta \in \text{HPD}(\nu_\alpha) | \underline{x}) = 1 - \alpha$

$$\text{Para } \hat{\pi}(\theta | \underline{x}) = \Gamma(154, 1/11)$$

$$\text{HPD}_{95\%} = [11.876, 16.295]$$

$$\text{HPD}_{99\%} = [11.264, 17.076]$$