

# Inferencia Estadística

## Introducción

Gabriel Martos Venturini  
gmartos@utdt.edu

Matías Pérez  
lic.matiasdperez@gmail.com

UTDT





UNIVERSIDAD  
TORCUATO DI TELLA

# Objetivo y Programa

**Objetivo:** Formalizar conceptos y metodologías de inferencia clásica e introducir métodos modernos de inferencia Bayesiana y Noparamétrica.

- Muestreo y principios de reducción de datos.
- Estimación puntual.
- Nociones de riesgo.
- Propiedades asintóticas de los estimadores.
- Estimación por intervalos y test de hipótesis.
- Elementos de inferencia Bayesiana.
- Tópicos de inferencia no paramétrica.
- @ Programa completo colgado en campus.

# Bibliografía y evaluación



- Evaluación: Examen final (ver prototipo colgado en campus).

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice

# Conceptos preliminares

- Inferir: *Deducir algo o sacarlo como conclusión de otra cosa* (RAE).
- Inferencia Estadística:
  - ▶ Formular juicios sobre cantidades desconocidas (*parámetros*) de una población con información parcial de la misma (muestra = datos).
    - ★ Estimación puntual, por intervalos, test hipótesis, etc.
  - ▶ Cuantificar la incertidumbre en torno a dichos juicios.
    - ★ Error standard de un estimador, amplitud del intervalo, etc.
- Para hacer inferencia estadística nos apoyamos en modelos estadísticos (en este curso, principalmente en modelos paramétricos).

*"All models are wrong, but some are useful" (G. Box)*

## Definición (Modelo Estadístico)

Un modelo estadístico paramétrico  $\mathcal{F} = \{P_\theta : \theta \in \Theta\}$  es una *colección de distribuciones de probabilidad* definidas sobre un *espacio muestral*  $\mathcal{X}$ .

## Example (El modelo exponencial)

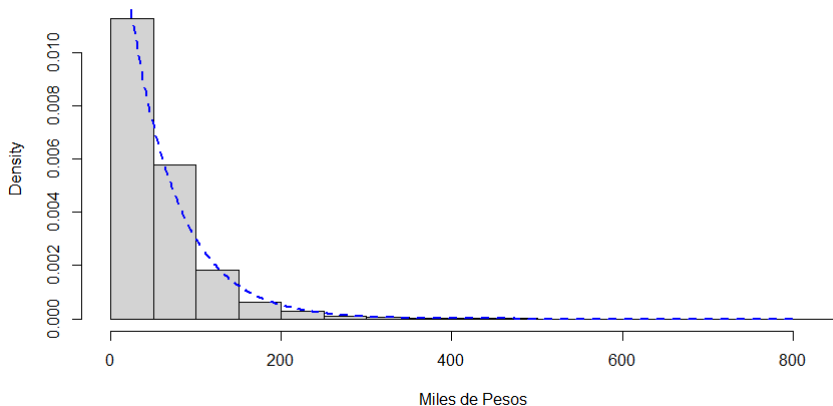
Imaginemos que queremos estudiar la distribución del ingreso, v.a. denotada como  $X$ , en la población argentina. Para ello consideramos

- Modelo estadístico:  $X \sim \text{Exp}(\theta)$ , en otras palabras

$$\mathcal{F} : \{P_\theta(X \leq x) = \int_0^x \theta^{-1} e^{-\frac{t}{\theta}} dt \mid x \geq 0, \theta > 0\}.$$

- Espacio muestral: Los reales no negativos ( $\mathcal{X} := \{x \in \mathbb{R}^+ \cup 0\}$ ).
- Espacio de parámetros: Los reales positivos ( $\Theta := \{\theta \in \mathbb{R}^+\}$ ).

### Ingreso Familiar (eph T12021)



**Figure:** Ingresos familiares en la EPH (1T2021) en miles de pesos. En azul (---), la densidad de una distribución exponencial de parámetro  $\lambda = 56.27$  (EMV).

## Example (Regresión lineal)

Nos interesa modelar  $E(Y|X_1, \dots, X_p) \equiv \mu_{Y|X_1, \dots, X_p}$  (la función de regresión). El modelo de regresión lineal propone:

$$Y = \theta_0 + \theta_1 X_1 + \dots + \theta_p X_p + \varepsilon,$$

donde generalmente asumimos que  $\varepsilon \sim N(0, \sigma^2)$ .

- Modelo estadístico para  $Y|X_1, \dots, X_p$ :

$$\mathcal{F} = \left\{ N\left(\underbrace{\theta_0 + \theta_1 X_1 + \dots + \theta_p X_p}_{\mu_{Y|X_1, \dots, X_p}}, \sigma^2 \right) \right\}$$

- Parámetros del modelo  $\theta = (\theta_0, \dots, \theta_p, \sigma^2) \in \mathbb{R}^{p+1} \times \mathbb{R}^+ = \Theta$ .

- Objetivo: Disponemos de datos, que asumimos provienen del modelo especificado, y con ellos inferimos los parámetros desconocidos  $\theta$ .



## (S)Elección de modelo(s)

- A la hora de trabajar con datos en un problema concreto tendremos que elegir o definir un modelo estadístico para analizar los mismos.
- La (s)**elección** de un modelo estadístico *adecuado* con el que trabajar es una cuestión particularmente importante que resolvemos mediante:
  - 1 Criterios teóricos o científicos.
  - 2 Experimentación previa del fenómeno bajo estudio.
  - 3 Principios filosóficos (parsimonia).
  - 4 Kadane and Lazar: *Methods and Criteria for Model Selection* (JASA).

No abordaremos en profundidad estas cuestiones durante el curso.

# Notación

- Parámetros con letras griegas:  $\mu, \sigma^2, \alpha, \beta \dots$
- Variables aleatorias con mayúsculas:  $X, Y, Z \dots$
- Realizaciones de las variables con minúsculas:  $x, y, z \dots$
- Vector aleatorio (muestra aleatoria):  $\underline{X} \equiv \{X_1, \dots, X_n\}$ .
- Realización de vector aleatorio (datos):  $\underline{x} \equiv \{X_1 = x_1, \dots, X_n = x_n\}$ .
- Función de distribución  $F(x; \theta)$  y de densidad  $f(x; \theta)$ :

$$F(x; \theta) \equiv P_{\theta}(X \leq x) = \int_{-\infty}^x f(t; \theta) dt.$$

- Cuando sea necesario distinguiremos modelos continuos de discretos.
- Reservamos  $\pi(\theta)$  y  $\pi(\theta | \underline{x})$  para Inferencia Bayesiana.
- Las letras góticas  $\mathcal{F}, \mathcal{C}, \mathcal{P}$  denotan en general conjuntos.

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica**
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice

# Estadística Frecuentista vs Bayesiana

- Inferencia **clásica o frecuentista**:

- ▶  $\theta$  es una cantidad fija y desconocida de la población.
- ▶ Los métodos de inferencia tienen garantías de “*largo plazo*”.
- ★ Ejemplo: Intervalos de Confianza.

- Inferencia **Bayesiana**:

- ▶ Las hipótesis subjetivas (creencias) sobre  $\theta$  se codifican en términos probabilísticos: Distribución a-priori (subjetiva)  $\pi(\theta)$  para  $\theta$ .
- ▶ Con los datos (la verosimilitud) corregimos  $\pi(\theta)$  de forma coherente.
- ▶ Con la distribución a-posteri  $\pi(\theta | \text{Datos})$  hacemos inferencia para  $\theta$ .

# Modelos Paramétricos y Noparamétricos

- **Modelos paramétricos:** Cada elemento de  $\mathcal{F}$  se puede identificar mediante una cantidad finita de parámetros. En otras palabras,  $\mathcal{F}$  está indexado por  $\theta \in \Theta \subseteq \mathbb{R}^m$  con  $m \in \mathbb{N}$  y  $m < \infty$ . Escribimos:

$$\mathcal{F}_p = \{f(\bullet; \theta) \mid \theta \in \Theta\}.$$

- **Modelos noparamétricos:**  $\mathcal{F}$  contiene distribuciones que **no** se pueden representar mediante una cantidad finita de parámetros. Por ejemplo:  $\mathcal{F}$  es el conjunto de todos los modelos de probabilidad cuyas funciones de densidad son  $m \in \mathbb{N}$  veces diferenciables:

$$\mathcal{F}_{np} = \{f(\bullet) \mid f \in C^m\}.$$

- **Modelos semi-paramétricos:**

$$\mathcal{F} = \{\alpha f_1(\bullet; \theta) + (1 - \alpha)f_2(\bullet) \mid f_1 \in \mathcal{F}_p, f_2 \in \mathcal{F}_{np}, \text{ y } \alpha \in (0, 1)\}.$$

- En la primera parte de este curso trabajaremos con modelos paramétricos (regulares e identificables), ASUMIENDO que:

$$f \in \mathcal{F} = \{f(\bullet; \theta) \mid \theta \in \Theta \subseteq \mathbb{R}^m\},$$

donde  $f$  es la “verdadera distribución” que genera datos en la pob.

- Existe un valor  $\theta \in \Theta$  (en general desconocido) que se corresponde con el verdadero valor del parámetro en la población:  $f(x) \equiv f(x; \theta)$ .
- En general no nos interesa  $\theta$  per-se, sino una función (o funcional) del mismo  $\psi(\theta)$ . A  $\psi(\theta)$  lo llamaremos el parámetro de interés.
  - ▶ Ejemplo: La media, la varianza, la mediana, etc.
- Discutiremos métodos generales para estimar  $\psi(\theta)$ , testear hipótesis sobre  $\psi(\theta)$  y construir regiones de confianza para  $\psi(\theta)$ .
- Para tener un marco de discusión amplio, será conveniente agrupar los modelos paramétricos en familias de distribuciones.

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala**
- 4 Muestreo aleatorio y distribuciones en el muestreo
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice

# Introducción

- Los modelos paramétricos que discutimos con los ejemplos–Normal, Exponencial, etc– comparten ciertas características y propiedades.
- Vamos a introducir un nivel de abstracción mayor agrupando dichos modelos en torno a una *familia* (conjunto amplio) de distribuciones.
- Marco de referencia más amplio para hacer inferencia.
  - ▶ Toda vez que podamos probar propiedades en una familia extensa de distribuciones, éstas serán válidas para todos los modelos de probabilidad que pertenecen dicha familia.
- Familias relevantes:
  - 1 Exponencial (ojo, no se trata de la distribución exponencial!).
  - 2 Localización y Escala.



# Familia exponencial de 1 parámetro

- Consideremos  $\mathcal{F} \equiv \{f(x; \theta) \mid \theta \in \Theta \subseteq \mathbb{R}\}$  donde:

$$f(x; \theta) = h(x)c(\theta) \exp\left(w(\theta)t(x)\right).$$

- $h(x) \geq 0$  y  $t(x)$  **no** pueden depender de  $\theta$ .
- $c(\theta) > 0$  y  $w(\theta)$  **no** pueden depender de  $x$ .
  - Por lo tanto el *soporte* de  $f(x; \theta)$  no depende de  $\theta$ .

$$\text{Soporte}(f(x; \theta)) \equiv \{x \in \mathbb{R} \mid f(x; \theta) > 0\}$$

- Para **contrastar** que un modelo pertenece a la familia exponencial debes identificar las funciones  $h$ ,  $c$ ,  $w$  y  $t$  y verificar que se cumplen las condiciones arriba mencionada sobre cada una de estas funciones.
- Ejemplo: Modelo Bernoulli. Contraejemplo: Modelo Uniforme.

- Con  $t(X)$  construimos un estadístico suficiente para  $\theta$ .
  - ▶  $t(x)$  sintetiza toda la información relevante sobre  $\theta$ .
- Nos van a interesar computar los momentos y la distribución (exacta o aproximada) del estadístico suficiente (para hacer inferencia).

$$E(t(X)) = \frac{d'(\theta)}{w'(\theta)} \text{ y } V(t(X)) = \frac{d''(\theta)w'(\theta) - d'(\theta)w''(\theta)}{[w'(\theta)]^3}$$

donde  $d(\theta) = -\log(c(\theta))$ .

- ▶ Ejemplo: Modelo Bernoulli.
- La familia exponencial también es relevante en:
  - ▶ Inferencia con modelos lineales generalizados.
  - ▶ Modelos conjugados e inferencia Bayesiana.

# Familia exponencial de $k$ parámetros

- Consideremos  $\mathcal{F} \equiv \{f(x; \boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta \subseteq \mathbb{R}^k\}$  donde:

$$f(x; \boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp \left( \sum_{i=1}^k w_i(\boldsymbol{\theta}) t_i(x) \right).$$

- $h(x) \geq 0$  y  $t_1(x), \dots, t_k(x)$  **no** pueden depender de  $\boldsymbol{\theta}$ .
- $c(\boldsymbol{\theta}) > 0$  y  $w_1(\boldsymbol{\theta}), \dots, w_k(\boldsymbol{\theta})$  **no** pueden depender de  $x$ .
- El soporte de  $f(x; \boldsymbol{\theta})$  no depende de  $\boldsymbol{\theta}$ .
- Ejemplo: Modelos Normal, Beta, Gamma.

Si  $w$  y  $t$  son funciones vectoriales entonces:  $w_i(\boldsymbol{\theta}) t_i(x) \equiv \langle w_i(\boldsymbol{\theta}), t_i(x) \rangle$ .

# Reparametrización (BackUp)

- La densidad  $f(x; \theta)$  se suele reparametrizar como:

$$f(x; \phi) = h(x)c(\phi) \exp \left( \sum_{i=1}^k \phi_i t_i(x) \right),$$

donde  $\phi_i = w_i(\theta)$  para  $i = 1, \dots, k$  se llaman *parámetros naturales*.

- Notar que  $h(x)$  y  $t_1(x), \dots, t_k(x)$  son las mismas funciones.
- El conjunto  $\Phi$  definido como

$$\Phi : \left\{ (\phi_1, \dots, \phi_k) \mid \int h(x) \exp \left( \sum_{i=1}^k \phi_i t_i(x) \right) dx < \infty \right\}$$

es llamado *espacio paramétrico natural* y se cumple que

$$c(\phi) = \left[ \int h(x) \exp \left( \sum_{i=1}^k \phi_i t_i(x) \right) dx \right]^{-1}.$$

# Familias de Localización y Escala


El objetivo es construir familias de modelos a partir de una densidad (o pmf en el caso discreto) que difieren solo en su *localización* y/o su *escala*.

- Si  $f(x)$  es una densidad (o pmf en el caso discreto), entonces definimos la familia de **localización y escala** relativa a  $f(x)$  como:

$$\mathcal{F} \equiv \left\{ f(x; \mu, \sigma) = \frac{1}{\sigma} f\left(\frac{x - \mu}{\sigma}\right) \mid \mu \in \mathbb{R} \text{ y } \sigma > 0 \right\}.$$

- **Location-family:** Si  $f$  es una pdf y  $\mu$  una constante, entonces  $f(x - \mu)$  es una familia de localización con parámetro  $\mu$ .
- **Scale-family:** Si  $f$  es una pdf y  $\sigma > 0$  una constante, entonces  $\sigma^{-1}f(x/\sigma)$  es una familia de escala con parámetro  $\sigma$ .
- Ejemplo: Si  $f(x) = e^{-x^2/2}/\sqrt{2\pi}$ , la familia de localización y escala relativa a esta densidad es el conjunto  $\{N(\mu, \sigma^2) \mid \mu \in \mathbb{R} \text{ y } \sigma^2 > 0\}$ .

# Familias de Localización y Escala



# Propiedades

- Si  $Z \sim f(z)$  y  $X \sim \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right)$  (es decir que  $X$  sigue un modelo de localización y escala a partir de  $f(z)$ ), luego se cumple que:

$$E(X) = \sigma E(Z) + \mu \text{ y } V(X) = \sigma^2 V(Z).$$

- ▶ Notar que  $E(X) = \mu$  sólo cuando  $E(Z) = 0$  y que  $V(X) = \sigma^2$  sólo cuando  $V(Z) = 1$  (esto ocurre en el ejemplo dado en § 21).
- Los cuantiles de  $X$  y  $Z$  también están relacionados de manera lineal:
  - ▶  $x_p = z_p \sigma + \mu$  para todo  $p \in (0, 1)$ , donde

$$x_p = \inf\{x \in \mathbb{R} : F_X(x) \geq p\} \text{ y } z_p = \inf\{z \in \mathbb{R} : F_Z(z) \geq p\}.$$

- Ejemplo:  $Z \sim f(z) = 2z$  con  $z \in [0, 1]$  (más ejemplos en CB § 3.4).

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo**
  - Muestra aleatoria y distribución de los estadísticos
  - Estadísticos de orden
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice



# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo**
  - Muestra aleatoria y distribución de los estadísticos
  - Estadísticos de orden
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice

# Muestra aleatoria

- La colección de variables aleatorias (va)  $\underline{X} \equiv \{X_1, \dots, X_n\}$  se dice una **muestra aleatoria** de tamaño  $n$  de una población donde  $X$  tiene una densidad  $f(x; \theta)$  si se cumplen las dos condiciones siguientes:
  - El conjunto de va  $\{X_1, \dots, X_n\}$  son simultáneamente independientes<sup>1</sup>.
  - El conjunto de va  $\{X_1, \dots, X_n\}$  sigue la misma distribución que  $X$ .
    - ▶ Escribimos indistintamente:  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$  o  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f$ .
- Bajo el supuesto iid, la pdf de la muestra aleatoria  $\{X_1, \dots, X_n\}$  es:

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta).$$

- ▶ Responder preguntas probabilísticas respecto de la muestra aleatoria.
- Ejemplo: Modelo Exponencial.
- Poblaciones finitas y pequeñas: Muestreo con reposición.

---

<sup>1</sup>Si  $X \sim f_X(x) \perp\!\!\!\perp Y \sim f_Y(y)$  entonces  $f_{X|Y=y}(x) = f_X(x)$  y  $f_{X,Y}(x,y) = f_X(x)f_Y(y)$ .

# Estadísticos

- **Definición:** Un *estadístico*  $T(X_1, \dots, X_n)$  es una función (posiblemente vectorial) de los elementos de una muestra aleatoria.
- Por lo tanto un estadístico es una variable (vector) aleatoria(o).
- La definición de estadístico es muy amplia, sólo le pedimos a  $T$  que **no dependa** de forma explícita de  $\theta$ , el parámetro del modelo.
- Estadístico y Estimador (terminología).
- La distribución del estadístico  $T$  se denomina distribución *muestral*, puesto que  $T$  se origina a partir de una muestra aleatoria.
- Veamos algunos ejemplos de estadísticos (estimadores) importantes.

# Dos estadísticos importantes

Para  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$  definimos:

- Media muestral

$$\bar{X}_n = \frac{1}{n} \underbrace{\sum_{i=1}^n X_i}_{T(X_1, \dots, X_n)}.$$

- La (cuasi)varianza muestral

$$S_n^2 = \frac{1}{n-1} \underbrace{\sum_{i=1}^n (X_i - \bar{X}_n)^2}_{T(X_1, \dots, X_n)}.$$

- Denotaremos con letras pequeñas  $(\bar{x}_n, s_n^2)$  a las realizaciones de estas variables aleatorias (dada una muestra en concreto de la población).

# Algunas propiedades importantes de $\bar{X}_n$ y $S_n^2$

No importa como se distribuya  $X$  en la población se tiene que:

- 1  $E(\bar{X}_n) = E(X)$ .
- 2  $Var(\bar{X}_n) = Var(X)/n$ .
- 3  $E(S_n^2) = Var(X)$ .

Por la LGN se verifica que (refresh en apéndice):

- $\bar{X}_n \rightarrow_P E(X)$ .
- $S_n^2 \rightarrow_P Var(X)$  (porque  $\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow_P E(X^2)$  y  $\bar{X}_n^2 \rightarrow_P E(X)^2$ ).
  - ▶ Con  $n$  grande, es altamente probable que  $\bar{X}_n$  y  $S_n^2$  tomen valores cercanos a  $E(X)$  y  $Var(X)$  (cantidades en general desconocidas).

Si conocemos (o asumimos) la distribución de  $X$  en la población, podremos caracterizar mejor la distribución muestral de ambos estadísticos...

# Muestreo aleatorio en poblaciones normales

- Sea  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ , es decir que:

$$P(X \leq x) = \int_{-\infty}^x \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}}_{f(X=t; \theta=(\mu, \sigma^2))} dt.$$

- Entonces las variables aleatorias  $\bar{X}_n$  y  $S_n^2$  verifican que:

- 1  $\bar{X}_n$  y  $S_n^2$  son variables aleatorias independientes (T. Basu).
- 2  $\bar{X}_n \sim N(\mu, \sigma^2/n)$ .
- 3  $(n-1)S_n^2/\sigma^2 \sim \chi_{n-1}$ .

- Momentos de las variables aleatorias  $\bar{X}_n$  y  $S_n^2$ :

- 1  $E(\bar{X}_n) = \mu$  y  $E(S_n^2) = \sigma^2$ .
- 2  $V(\bar{X}_n) = \sigma^2/n$  y  $V(S_n^2) = 2\sigma^4/(n-1)$ .

# Distribución en el muestreo en familias exponenciales

- Sea  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$  con:

$$f(x; \theta) = h(x)c(\theta) \exp \left( w(\theta)t(x) \right).$$

- El estadístico (suficiente y completo para  $\theta$ ):

$$T(X_1, \dots, X_n) = \sum_{i=1}^n t(X_i).$$

bajo condiciones generales<sup>2</sup>, sigue una distribución que también pertenece a la familia exponencial:

$$T \sim f_T(u; \theta) = H(u)c(\theta)^n \exp \left( w(\theta)u \right).$$

- No necesitas integrar para computar los momentos de  $T$  (ver § 18).

---

<sup>2</sup>CB pp 212, Th 5.2.5.

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo**
  - Muestra aleatoria y distribución de los estadísticos
  - Estadísticos de orden
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice



# Definiciones relevantes

- Los estadísticos de orden relativos a  $\underline{X} = \{X_1, \dots, X_n\} \stackrel{iid}{\sim} F$  son simplemente los valores ordenados de dichas variables aleatorias que denotamos como  $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ .
- Algunos ejemplos de estadísticos de orden:
  - ▶ **Mínimo:**  $X_{(1)} = \min\{X_1, \dots, X_n\}$ .
  - ▶ **Máximo:**  $X_{(n)} = \max\{X_1, \dots, X_n\}$ .
  - ▶ **Mediana:**  $M = X_{(n+1)/2}$  si  $n$  es impar y  $M = \frac{X_{(n/2)} + X_{(n/2+1)}}{2}$  si  $n$  es par.
  - ▶ **Rango:**  $R = X_{(n)} - X_{(1)}$ .
- Lo que resulta realmente interesante, es que la distribución de estos estadísticos se puede escribir de manera bastante general en términos de  $f(x; \theta)$  y  $F(x; \theta)$  (para demostraciones formales ver CB § 5.5).

# Distribuciones marginales

- Sea  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$  siendo  $X$  una variable aleatoria continua (discreta) con densidad (p.m.f.)  $f(x; \theta)$  y distribución  $F(x; \theta)$ .
- La función de densidad de  $X_{(j)}$  (para  $j = 1, \dots, n$ ) se escribe como:

$$f_{X_{(j)}}(x; \theta) = \frac{n!}{(j-1)!(n-j)!} f(x; \theta) [F(x; \theta)]^{j-1} [1 - F(x; \theta)]^{n-j}.$$

- Notar que para el máximo y el mínimo,  $X_{(1)}$  y  $X_{(n)}$  respectivamente, la funciones de densidad de estos estadísticos se reducen a:

$$f_{X_{(1)}}(x; \theta) = nf(x; \theta)[1 - F(x; \theta)]^{n-1}, \text{ y } f_{X_{(n)}}(x; \theta) = nf(x; \theta)[F(x; \theta)]^{n-1}$$

- Ejemplo I: Si  $X \sim \text{Exp}(\lambda)$  entonces  $X_{(1)} \sim \text{Exp}(\lambda/n)$ .
- Ejemplo II: Modelo uniforme (próxima slide).

- Si  $X \sim \text{Unif}(0, 1)$ , luego  $f(x) = 1$  y  $F(x) = x$ , para  $x \in (0, 1)$ .
- Luego reemplazando en

$$f_{X_{(j)}}(x) = \frac{n!}{(j-1)!(n-j)!} f(x) [F(x)]^{j-1} [1 - F(x)]^{n-j},$$

- Distribución del mínimo:

$$f_{X_{(1)}}(x) = n(1-x)^{n-1}, \text{ para } x \in (0, 1).$$

- Distribución del máximo:

$$f_{X_{(n)}}(x) = nx^{n-1}, \text{ para } x \in (0, 1).$$

- Se puede demostrar que para  $X \sim \text{Unif}(0, 1)$ :

$$f_{X_{(j)}}(x) = \text{Beta}(j, n-j+1), \text{ para } x \in (0, 1).$$

# Distribución conjuntas

- Llamemos  $f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n; \theta)$  a la densidad de del vector aleatorio ordenado  $(X_{(1)}, \dots, X_{(n)})$ , se puede demostrar que:

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n; \theta) = \begin{cases} n! \prod_{i=1}^n f(x_i; \theta), & \text{si } -\infty < x_1 < \dots < x_n < \infty, \\ 0 & \text{en otro caso.} \end{cases}$$

- A partir de esta expresión podemos obtener las distribuciones condicionales de los estadísticos de orden. Ej. con  $1 \leq i \leq j \leq n$ :

$$f_{X_{(i)}, X_{(j)}}(x_i, x_j; \theta) = n! \frac{f(x_i; \theta) f(x_j; \theta) [F(x_i; \theta)]^{i-1} [F(x_j; \theta) - F(x_i; \theta)]^{j-1-i} [1 - F(x_j; \theta)]^{n-j}}{(i-1)! (j-1-i)! (n-j)!}$$

- Para una discusión completa respecto de la distribución de los estadísticos de orden consultar CB § 5.5.

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice

# Motivación

- En las secciones anteriores discutimos algunos estadísticos muestrales habituales (ej: media y varianza) y su distribución en el muestreo.
- Cuando nos interesan ciertas *funciones de los estadísticos*—una nueva variable aleatoria  $g(T)$ —, cuya distribución no conocemos, entonces podemos utilizar el método delta para aproximar dicha distribución.
- No vale para cualquier estadístico y/o cualquier transformación  $g$ .
  - ▶  $T$  (estandarizado) tiene que converger en distribución a una normal.
  - ▶  $g$  tiene que ser diferenciable respecto de  $\theta$ .

## Example (Odds ratio)

$\{X_1, \dots, X_n\} \stackrel{iid}{\sim} \text{Bernulli}(\theta)$ : Si el parámetro de interés es  $g(\theta) = \theta/(1 - \theta)$ ; el estadístico con el que vamos a inferir  $g(\theta)$  será  $g(\bar{X}) = \bar{X}/(1 - \bar{X})$ .

# Método delta

- Piensa en  $X_n$  como un estadístico que depende de  $n$  (media muestral).

## Theorem (First order Delta method)

Sea  $\{X_1, \dots, X_n\}$  una secuencia de v.a. donde  $\sqrt{n}(X_n - \theta) \rightarrow_F N(0, \sigma^2)$ .  
Para una función  $g$  diferenciable en  $\theta$  y con  $g'(\theta) \neq 0$ , se tiene que:

$$\sqrt{n}(g(X_n) - g(\theta)) \rightarrow_F N(0, \sigma^2[g'(\theta)]^2).$$

## Theorem (Second order Delta method)

Sea  $\{X_1, \dots, X_n\}$  una secuencia de v.a. donde  $\sqrt{n}(X_n - \theta) \rightarrow_F N(0, \sigma^2)$ .  
Para  $g$  2 veces diferenciable en  $\theta$  con  $g'(\theta) = 0$  y  $g''(\theta) \neq 0$ , se cumple:

$$\sqrt{n}(g(X_n) - g(\theta)) \rightarrow_F \sigma^2 \frac{g''(\theta)}{2} \chi_1^2.$$

- Ejemplo del odds ratio (§ 38).

# Agenda

- 1 Introducción
- 2 Frecuentista vs Bayesina / Paramétrica vs Noparametrica
- 3 Familia Exponencial y de Localización–Escala
- 4 Muestreo aleatorio y distribuciones en el muestreo
- 5 Distribución aproximada de funciones de un estadístico (método delta)
- 6 Apéndice



# Refresh I: Convergencia en probabilidad

## Definición (Convergencia en probabilidad)

Una sucesión de variables aleatorias  $\{X_1, \dots, X_n\}$  converge en probabilidad a la variable aleatoria  $X$  si, para todo  $\varepsilon > 0$ , se verifica que:

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0, \text{ o equivalentemente } \lim_{n \rightarrow \infty} P(|X_n - X| < \varepsilon) = 1.$$

- Típicamente en inferencia asumimos condiciones de tipo *iid* y nos interesan las convergencias a constantes. Ej: Ley grandes números.

## Theorem (Ley débil de los grandes números)

Si  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$ , y  $E(X^2) < \infty$ , entonces:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - E(X)| \geq \varepsilon) = 0,$$

donde  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ . Denotamos esta convergencia con  $\bar{X}_n \rightarrow_P E(X)$ .

# Álgebra de convergencia en probabilidad

Sea  $a_n$  es una sucesión de números reales tal que  $a_n \rightarrow a$ . Sean  $X_n$  y  $Y_n$  dos variables aleatorias tales que  $X_n \rightarrow_P X$  y  $Y_n \rightarrow_P Y$ . Entonces:

- 1  $a_n + X_n \rightarrow_P a + X$ .
- 2  $a_n X_n \rightarrow_P aX$ .
- 3  $X_n + Y_n \rightarrow_P X + Y$ .
- 4  $X_n Y_n \rightarrow_P XY$ .
- 5 Si  $P(Y = 0) = 0$ ,  $X_n/Y_n \rightarrow_P X/Y$ .
- 6 Si  $g : \mathbb{R} \rightarrow \mathbb{R}$  es continua luego  $g(X_n) \rightarrow_P g(X)$ .
- 7 Si  $g : \mathbb{R}^2 \rightarrow \mathbb{R}$  es continua luego  $g(X_n, Y_n) \rightarrow_P g(X, Y)$ .

## Definición (Convergencia multivariante en probabilidad)

La sucesión de vectores aleatorios  $\{X_1, \dots, X_n\}$   $d$ -dimensionales converge en probabilidad al vector aleatorio  $X$  si, para todo  $\varepsilon > 0$ :

$$\lim_{n \rightarrow \infty} P(\|X_n - X\|_\infty \geq \varepsilon) = 0,$$

donde  $\|(y_1, \dots, y_d)\|_\infty \equiv \max_{i=1, \dots, d} \{y_1, \dots, y_d\}$ .

# Utilidad de la convergencia en proba

- Dada  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$ , recordemos que:

$$\text{Var}(X) = E(X^2) - (E(X))^2.$$

- Sabemos que  $\bar{X}_n$  es un estimador consistente de  $E(X)$  porque (LGN)  $\bar{X}_n \rightarrow_P E(X)$ . Por lo tanto, utilizando la propiedad (6) con  $f(x) = x^2$ :

$$f(\bar{X}_n) = (\bar{X}_n)^2 \rightarrow_P f(E(X)) = E(X)^2.$$

- Por la ley de los grandes números sabemos además que:

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow_P E(X^2) = \text{Var}(X) + E(X)^2.$$

- De los dos resultados anteriores más la propiedad (3):

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \rightarrow_P \text{Var}(X).$$

# Refresh II: Convergencia en distribución

## Definición (Convergencia en distribución)

Una sucesión de variables aleatorias  $\{X_1, \dots, X_n\}$  converge en distribución a la variable aleatoria  $X$  si se cumple que:

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$

en todo punto de continuidad de  $F_X$ . Escribimos  $X_n \rightarrow_F X$ .

- Cuando  $n \gg 0$  la CDF de  $X_n$  está cerca de la CDF de  $X$ .
  - ▶ Esto no implica que  $X_n$  esté cerca de  $X$ .
- Relaciones entre convergencias:
  - ▶ Si  $X_n \rightarrow_p X \Rightarrow X_n \rightarrow_F X$  (y viceversa si  $X = c$ ).
  - ▶ Si  $X_n \rightarrow_F X$  y  $Y_n \rightarrow_p c \Rightarrow$  (a)  $Y_n X_n \rightarrow_F cX$  y (b)  $X_n + Y_n \rightarrow_F X + c$ .

# Convergencia en distribución (caso multivariante)

Lo presentamos para el caso en que  $d = 2$ , la extensión al más caso general es directa a partir de la definición que sigue.

## Definición (Convergencia en distribución multivariante)

Una sucesión de variables aleatorias bi-variantes  $\{X_1, \dots, X_n\}$  converge en distribución a la variable aleatoria bivalente  $X$  con función de distribución  $F_X(x_1, x_2)$  si se cumple que:

$$\lim_{n \rightarrow \infty} F_{X_n}(x_1, x_2) = F_X(x_1, x_2)$$

en todo punto de continuidad  $(x_1, x_2)$  de  $F_X$ . Escribimos  $X_n \rightarrow_F X$ .

# Refresh III: Teorema del Límite Central

## Definición (CLT (strong))

Si  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} X$  con  $0 < V(X) < \infty$ ; llamemos  $G_n$  a la CDF de la variable aleatoria  $Z_n \equiv \sqrt{n}(\bar{X}_n - \mu)/\sigma$ , luego:

$$\lim_{n \rightarrow \infty} G_n(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt.$$

Es decir que  $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma$  converge en distribución a una  $N(0, 1)$ .

- Supuestos: *iid* y varianza finita.
- No importa como se distribuya  $X$  en la población.
- El resultado es válido en términos asintóticos, pero no nos dice cuan buena es esta “aproximación” para un  $n$  en general.

# Polinomio de Taylor

Si  $g$  una función que admite  $r$  derivadas ( $g \in C^r$ ). Para una constante  $x_0$ , el polinomio de Taylor de orden  $r$  en torno a el punto  $x_0$  se define como:

$$P_r(x) = \sum_{i=0}^r \frac{g^{(i)}(x_0)}{i!} (x - x_0)^i + R_r(x),$$

- $P_r(x)$  nos permite aproximar  $g$  en un entorno de  $x_0$ .
- $R_r(x) = P_r(x) - g(x)$  tiende a cero a una tasa más rápida que  $r$ .
- Nos interesan los momentos (y la distribución) aproximados de  $g(T)$ .
- La aproximación la hacemos en torno a  $\theta$  (parámetro de interés).

# El método delta (demostración simplificada)

- Hacemos una aproximación de primer orden:

$$g(T) \approx g(\theta) + g'(\theta)(T - \theta)$$

- Si  $\sqrt{n}(T - \theta) \rightarrow_F N(0, \sigma^2)$ , luego se tiene que:

$$\sqrt{n}(g(T) - g(\theta)) = g'(\theta)\sqrt{n}(T - \theta) + \underbrace{O_P(1)}_{\text{Resto}} \rightarrow_F N(0, \sigma^2[g'(\theta)]^2)$$