

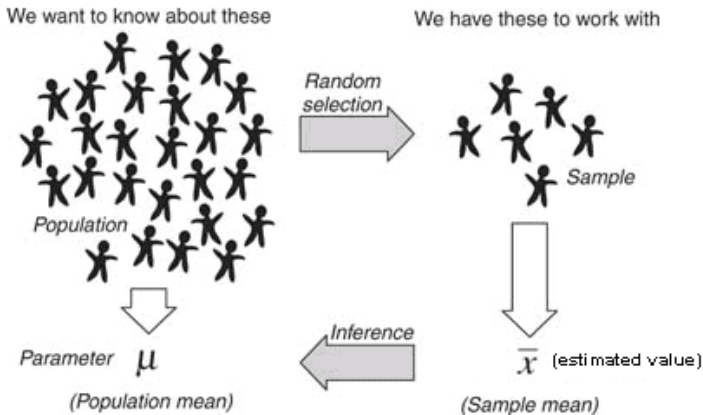
Inferencia Estadística

Principios de Reducción

Gabriel Martos Venturini
gmartos@utdt.edu

UTDT

Recapitulación



- Modelos estadísticos (familia exponencial y localización–escala).
- Estimador/estadístico: Principios y propiedades.

- Un estadístico $T_n(\underline{X})$ (donde $\underline{X} \equiv \{X_1, \dots, X_n\}$) es una v.a. con la que típicamente intentamos estimar cierto parámetro de interés:

$$\{X_1, \dots, X_n\} \stackrel{iid}{\sim} \text{Bern}(\theta), \text{ y consideremos } T_n(\underline{X}) = \sum_{i=1}^n X_i/n.$$

- T_n constituye una *reducción* de \underline{X} y debería cumplir ciertos principios:
 - ▶ **Suficiencia:** No queremos *perder información* al pasar de $\{X_1, \dots, X_n\}$ a T_n cuando intentamos estimar (en cualquier sentido) a θ .
 - ▶ **Verosimilitud:** Una vez realizada la muestra, toda la información relevante sobre θ está contenida en la función de verosimilitud.
 - ▶ **Invarianza:** Las conclusiones que sacamos de $\{X_1 = x_1, \dots, X_n = x_n\}$ no deberían cambiar cuando la escala en la que observamos los datos y los parámetros del modelo estadístico cambian de manera compatible.

Agenda

1 Principio de Suficiencia

- Definición y algunos ejemplos
- Ancillaridad y Completitud (Teorema de Basu)

2 Principio de Verosimilitud

3 Principio de Invarianza

4 Apéndice

Agenda

1 Principio de Suficiencia

- Definición y algunos ejemplos
 - Suficiencia minimal
 - Ancillaridad y Completitud (Teorema de Basu)

2 Principio de Verosimilitud

3 Principio de Invarianza

4 Apéndice

- Sea $\underline{X} = \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ y $T_n \equiv T(\underline{X})$.

Informal: T_n es suficiente para el parámetro θ si **contiene toda la información** que hay en la muestra aleatoria \underline{X} respecto de θ .

- Si T_n es un estadístico suficiente para θ , entonces la información respecto de θ que tenemos en \underline{x} y $T_n(\underline{x}) = t$ es equivalente.
- El estimador de θ debería ser función de un estadístico suficiente.

Definition (Suficiencia)

Un estadístico T_n es suficiente para el parámetro θ si la distribución condicional de $\underline{X} | T_n = t$ no depende de θ . Es decir se cumple que:

$$P(\underline{X} = \underline{x} | T_n(\underline{x}) = t) \text{ es constante respecto de } \theta.$$

- La suficiencia es una propiedad asociada al modelo estadístico.
- En la practica no es sencillo determinar la distribución de $\underline{X} | T_n = t$.

Condición a verificar para la suficiencia

- Si $\underline{X} = \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ luego $\underline{X} \sim f(\underline{x}; \theta) \equiv \prod_{i=1}^n f(x_i; \theta)$.

Teorema (Factorización de Fisher–Neyman)

Un estadístico T_n es suficiente para θ si y solo si existen funciones $g(T_n(\underline{x}); \theta)$ y $h(\underline{x})$ tales que podemos factorizar $f(\underline{x}; \theta)$ como:

$$f(\underline{x}; \theta) \equiv g(T_n(\underline{x}); \theta) h(\underline{x}) \text{ para todo } \underline{x} \text{ y } \theta \in \Theta.$$

Remark: Notar que $g(T_n(\underline{x}); \theta) \geq 0$ solo puede depender de los datos a través de T_n y que $h(\underline{x}) \geq 0$ no puede depender del parámetro.

- Ejemplo 1: Cantidad de éxitos cuando $X \sim \text{Bern}(\theta)$.
- Ejemplo 2: Media muestral cuando $X \sim N(\theta, \sigma_0^2)$.
- Ejemplo 3: El máximo en la muestra cuando $X \sim U(0, \theta)$.

Suficiencia en familias exponenciales de 1 parámetro

- Sea $\underline{X} := \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta) = h(x)c(\theta) \exp(w(\theta)t(x))$.
- El estadístico $T_n \equiv \sum_{i=1}^n t(X_i)$ es suficientes para θ .

$$\begin{aligned}\underline{X} \sim f(\underline{x}; \theta) &= \prod_{i=1}^n h(x_i)c(\theta) \exp(t(x_i)w(\theta)), \\ &= \underbrace{\left(\prod_{i=1}^n h(x_i)\right)}_{h(\underline{x})} \underbrace{c^n(\theta) \exp\left(\sum_{i=1}^n t(x_i)w(\theta)\right)}_{g(T_n(\underline{x}); \theta)}.\end{aligned}$$

- Ejemplo: Modelo Geométrico en la familia exponencial.

$$f(x; \theta) = \mathbb{1}_{[\mathbb{N}]}(x)\theta(1 - \theta)^{x-1}, \text{ luego } t(X) = X.$$

- Por lo tanto $T_n = \sum_{i=1}^n X_i$ es suficiente para θ .

Familias exponenciales de k parámetros

- Sea $\underline{X} := \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \boldsymbol{\theta})$, con $f(x; \boldsymbol{\theta})$ en la familia exponencial y $\boldsymbol{\theta} \in \Theta \subseteq \mathbb{R}^k$, entonces:

$$f(x; \boldsymbol{\theta}) = h(x)c(\boldsymbol{\theta}) \exp \left(\sum_{i=1}^k w_i(\boldsymbol{\theta}) t_i(x) \right), \text{ donde } \boldsymbol{\theta} = (\theta_1, \dots, \theta_k).$$

- Notar que X_1 puede ser una variable o un vector aleatorio.
- Luego los estadísticos:

$$\mathbf{T}_n(\underline{X}) = \left(T_{n,1}(\underline{X}) = \sum_{j=1}^n t_1(X_j), \dots, T_{n,k}(\underline{X}) = \sum_{j=1}^n t_k(X_j) \right),$$

son suficientes para $\boldsymbol{\theta}$.

- Ejemplo: Modelo normal ($k = 2$).

Recapitulación

- **Principio de Suficiencia:** Es deseable que la inferencia sobre el **parámetro de interés** esté basada en un **estadístico suficiente**.
- Criterio de factorización de Fisher–Neyman / Familia Exponencial.
- La suficiencia es una propiedad vinculada al modelo estadístico.
- Una transformación biyectiva de un **estadístico suficiente** da como resultado otro estadístico suficiente, en otras palabras **no son únicos**.
 - ▶ Ejemplo: $T_n = \sum_{i=1}^n X_i$ es suficiente para θ cuando $X \sim \text{Bern}(\theta)$ entonces también lo es $\bar{X}_n = T_n/n$ (transformación biyectiva).
- En familias exponenciales los estimadores máximo verosímiles son **funciones de los estadísticos suficientes** (lo formalizamos en S3).
 - ▶ En caso de existir un estimador UMVUE, éste es función de un estadístico suficiente (ver Lehmann—Scheffé en S4).

Estadístico suficiente minimal

Para $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$:

- En general existen muchos estadísticos suficientes, el mismo vector aleatorio \underline{X} es un estadístico suficiente (pero poco reductor) para θ .
- La suficiencia minimal apunta a identificar estadísticos que compacten al máximo la información de la muestra sin perder información de θ .

Definition (Estadístico suficiente minimal)

T_n es **minimal suficiente** para θ si para cualquier otro estadístico suficiente T'_n , se cumple que si $T'_n(\underline{x}) = T'_n(\underline{y})$ entonces $T_n(\underline{x}) = T_n(\underline{y})$.

- $T_n(\underline{X}) = \underline{X}$ NO es minimal suficiente cuando $X \sim \text{Bern}(\theta)$.
 - ▶ Para $\underline{x} = \{1, 1, 0\}$ e $\underline{y} = \{1, 0, 1\}$: $T_n(\underline{x}) = \underline{x} \neq T_n(\underline{y}) = \underline{y}$.
 - ▶ Sin embargo: $T'(\underline{x}) = \sum_{i=1}^3 x_i = 2 = T'(\underline{y})$ (T' es suficiente para θ).

Criterio para suficiencia minimal

Sea $f_{\underline{X}}(\underline{x}; \theta)$ la densidad de \underline{X} , T_n es minimal suficiente para θ cuando:

$$\frac{f_{\underline{X}}(\underline{x}; \theta)}{f_{\underline{X}}(\underline{y}; \theta)} \text{ es constante para todo } \theta \in \Theta \iff T_n(\underline{x}) = T_n(\underline{y})$$

Es decir que se cumplen, simultáneamente, las siguientes dos condiciones:

- Si para un par de muestras (datos) \underline{x} e \underline{y} se cumple que:

$$\frac{f_{\underline{X}}(\underline{x}; \theta)}{f_{\underline{X}}(\underline{y}; \theta)} \text{ es constante para todo } \theta \in \Theta,$$

entonces debe verificarse que $T_n(\underline{x}) = T_n(\underline{y})$.

- Si para un par de muestras \underline{x} e \underline{y} se cumple que $T_n(\underline{x}) = T_n(\underline{y})$, entonces tiene que verificarse que:

$$\frac{f_{\underline{X}}(\underline{x}; \theta)}{f_{\underline{X}}(\underline{y}; \theta)} \text{ es constante para todo } \theta \in \Theta.$$

Ejemplo: $X \sim \text{Bern}(\theta)$ ($\theta \in (0, 1)$) y $T_n = \sum_{i=1}^n X_i$

$$\frac{f_X(\underline{x}; \theta)}{f_X(\underline{y}; \theta)} = \frac{\theta^{T_n(\underline{x})}(1 - \theta)^{n - T_n(\underline{x})}}{\theta^{T_n(\underline{y})}(1 - \theta)^{n - T_n(\underline{y})}} = \frac{\left(\frac{\theta}{1 - \theta}\right)^{T_n(\underline{x})}}{\left(\frac{\theta}{1 - \theta}\right)^{T_n(\underline{y})}} = \left(\frac{\theta}{1 - \theta}\right)^{T_n(\underline{x}) - T_n(\underline{y})}.$$

- $\frac{f_X(\underline{x}; \theta)}{f_X(\underline{y}; \theta)} = 1 \iff T_n(\underline{x}) = T_n(\underline{y})$, para todo $\theta \in (0, 1)$.
- Luego T_n es minimal suficiente.
- Bajo condiciones generales, en la familia exponencial:

$$X \sim f(x; \theta) = h(x)c(\theta) \exp\left(w(\theta)t(x)\right),$$

$T_n = \sum_{i=1}^n t(X_i)$ es suficiente y minimal para θ .

- Un estadístico minimal suficiente no es necesariamente único.

► Ej: $T_n = \sum_{i=1}^n X_i$ y $T'_n = \sum_{i=1}^n X_i/n$ con $X \sim \text{Bern}(\theta)$.

Agenda

1 Principio de Suficiencia

- Definición y algunos ejemplos
- Ancillaridad y Completitud (Teorema de Basu)

2 Principio de Verosimilitud

3 Principio de Invarianza

4 Apéndice

Estadístico Ancillar

- El concepto de *Ancillaridad* está contrapuesto al de Suficiencia:
 - ▶ S_n se dice ancillar para θ si con S_n no puedo inferir nada respecto de θ .
 - ▶ En otras palabras: S_n **NO contiene información sobre θ** .
- Paradójicamente, un estadístico ancillar combinado con otro suficiente para θ , facilitan y enriquecen los métodos de inferencia.
 - ▶ Ver ejemplo en § 19.

Definition (Estadístico ancillar)

Un estadístico $S_n(\underline{X})$ es ancillar para θ si la distribución de S_n **NO** depende de θ . En otras palabras, para cualquier conjunto \mathcal{A} se cumple que:

$$P(S_n(\underline{X}) \in \mathcal{A}) \text{ es constante para todo } \theta \in \Theta.$$

Ejemplos

- Para un modelo normal $N(\mu, \sigma^2)$, S_n^2 es ancillar para μ .

► Puesto que: $\frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}$.

- Dada $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \mu, \theta)$ donde:

$$f(x; \mu, \theta) = \frac{1}{2\theta}, \text{ si } \mu - \theta \leq x \leq \mu + \theta.$$

- X_1 sigue un modelo de localización a partir de una uniforme en $[-\theta, \theta]$.
- Se puede demostrar que la densidad de $R_n \equiv X_{(n)} - X_{(1)}$ es:

$$R_n \sim f(r, \theta) = \frac{n(n-1)r^{n-2}}{(2\theta)^{n-1}} \left(1 - \frac{r}{2\theta}\right), \text{ si } 0 \leq r \leq 2\theta.$$

- Luego R_n es ancillar para μ (Ejemplo 4.12 en KK).

Teorema de Basu

- Siendo la Suficiencia y la Ancillaridad conceptos contrapuestos, se tiende a pensar que dos estadísticos T_n y S_n , suficiente y ancilar para θ (en relación al modelo $f(x; \theta)$), deberían ser independientes:

$$P(T_n = t, S_n = s) = P(T_n = t)P(S_n = s) \text{ y } P(T_n = t | S_n = s) = P(T_n = t)$$

► Y por lo tanto: $\text{Cov}(T_n, S_n) = 0$.

- Generalmente esto es cierto, sin embargo no siempre vale.

► Un contraejemplo en CB (§ 6.1.11, pp 259).

- **Basu:** Un estadístico T_n minimal suficiente para θ es **independiente** de todos los estadísticos ancillares de θ cuando $f_T(t; \theta)$ es **completo**.

- 1 ¿Porqué esto es importante? Necesitamos que el estadístico ancilar y suficiente sean independientes para diseñar herramientas de inferencia.
- 2 ¿Cómo aseguramos la completitud?

Complejitud

Definition (Complejitud)

$T_n \sim f_T(t; \theta)$ es completo si para toda función (medible) g para la que $E_\theta(g(T_n)) = 0 \ \forall \theta \in \Theta$; se cumple que $P_\theta(g(T_n) = 0) = 1 \ \forall \theta \in \Theta$.

- La completitud es una propiedad del modelo estadístico.
- Si $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$, con $f(x; \theta) = h(x)c(\theta) \exp(w(\theta)t(x))$.
 - ▶ $T_n = \sum_{i=1}^n t(X_i)$ es completo y minimal suficiente.

Example

Si $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ (familia exponencial), \bar{X}_n es completo y (minimal) suficiente respecto de μ . Por otro lado S_n^2 es ancilar para μ . Por el teorema de Basu: \bar{X}_n y S_n^2 resultan variables aleatorias independientes.

Utilidad de los resultados expuestos

- Si $X \sim N(\mu, \sigma^2)$, por T. Basu \bar{X}_n y S_n^2 son independientes, luego*

$$\text{Como } \bar{X}_n \perp S_n^2 \Rightarrow \frac{\frac{(\bar{X}_n - \mu)}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S_n^2}{(n-1)\sigma^2}}} = \frac{Z}{\sqrt{\chi_{n-1}^2/(n-1)}} = \frac{(\bar{X}_n - \mu)}{S_n/\sqrt{n}} \sim t_{n-1}.$$

- Nos permite construir intervalos de confianza para μ en poblaciones normales cuando σ^2 es desconocido:

$$P(\bar{X}_n - t_{\alpha/2, n-1} S_n/\sqrt{n} \leq \mu \leq \bar{X}_n + t_{\alpha/2, n-1} S_n/\sqrt{n}) = 1 - \alpha.$$

*Si $Z \sim N(0, 1)$ y $V \sim \chi_n$ son v.a. independientes: $Z/\sqrt{V/n} \sim t_n$.

Recapitulemos:

- T_n suficiente: Contiene toda la información sobre θ en la muestra.
- S_n ancillar: No contiene información sobre θ en la muestra.
- Los estadísticos en familias exponenciales de k parámetros:

$$\mathbf{T}_n(\underline{X}) = \left(T_{n,1}(\underline{X}) = \sum_{j=1}^n t_1(X_j), \dots, T_{n,k}(\underline{X}) = \sum_{j=1}^n t_k(X_j) \right),$$

son minimal suficientes y completos para θ (en general).

- Basu: Si T_n es (minimal) suficiente y completo $\Rightarrow T_n$ es independiente respecto de cualquier otro estadístico ancillar de θ .
- Si T_j es ancillar respecto del parámetro que estimamos con T_i ($i \neq j$)
 - ▶ $P(T_i = t_i | T_j = t_j) = P(T_i = t_i) \Rightarrow \text{Cov}(T_i, T_j) = 0$.

Agenda

- 1 Principio de Suficiencia
- 2 Principio de Verosimilitud**
- 3 Principio de Invarianza
- 4 Apéndice

Función de Verosimilitud

- Sea $\underline{X} = \underline{x}$ (datos, una realización de $\underline{X} \equiv \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ con $\theta \in \Theta$) definimos la función de verosimilitud como:

$$L(\theta) \equiv L_n(\theta|\underline{x}) = \prod_{i=1}^n f(x_i; \theta).$$

- En el apéndice se discute como construir $L(\theta)$ en muestreos NO iid.
- $L(\theta)$ debe entenderse como una función de θ , las $\underline{X} = \underline{x}$ están fijas.
- En el caso discreto: $L(\theta) = P_\theta(\underline{X} = \underline{x}) = P_\theta(\text{Datos} | \text{Modelo})$.
- $L(\theta)$ NO indica probabilidades de θ (que está fijo en la población!).
- Ejemplo: $X \sim \text{Bern}(\theta)$ y $x_1 = 1, x_2 = 1, x_3 = 0$.
- En la familia exponencial en general se cumple que $L(\theta|\underline{x})$ depende de los datos (fijos) a través del valor que toma el estadístico suficiente.




Figure: Función de verosimilitud del ejemplo anterior.

Ratio de verosimilitud

- La función de verosimilitud nos permite juzgar la plausibilidad de observar $\underline{X} = \underline{x}$ entre diferentes valores posibles de $\theta \in \Theta$.
- Comparamos la verosimilitud de θ_1 contra θ_2 a partir del ratio:

$$\frac{L(\theta_1|\underline{x})}{L(\theta_2|\underline{x})} = \frac{P(\text{Observar } \underline{x} | X \sim f(x; \theta_1))}{P(\text{Observar } \underline{x} | X \sim f(x; \theta_2))}.$$

- ¿Cómo interpretamos el ratio?
 - ▶ Si $L(\theta_1|\underline{x})/L(\theta_2|\underline{x}) > 1 \Rightarrow$ Es más factible observar $\underline{X} = \underline{x}$ (datos de la muestra) si en la población $X \sim f(x; \theta_1)$ que si $X \sim f(x; \theta_2)$.
 - ★ θ_1 es más verosímil que θ_2 dada la evidencia \underline{x} ¹.
- Ej: $X \sim \text{Bern}(\theta)$ con $X_1 = 1, X_2 = 1, X_3 = 0$ y $\theta_1 = 0.5$ vs $\theta_2 = 0.75$.

¹Y asumiendo que en la población $X \sim f(x; \theta)$.

Otros ejemplos con $X \sim \text{Bern}(\theta)$




Figure: Izquierda $\sum_{i=1}^{100} X_i = 15$, centro $\sum_{i=1}^{100} X_i = 25$, y derecha $\sum_{i=1}^{100} X_i = 40$.

Interpretación de la gráfica de la izquierda:

- Es más factible que los datos de la muestra se hayan generado de una población $\text{Bern}(\theta \approx 0.3)$ que de una población $\text{Bern}(\theta \approx 0.9)$.
- La inferencia del punto anterior no se modifica si observamos dos muestras distintas \underline{x} y \underline{x}' tales que $T_n(\underline{x}) = T_n(\underline{x}') = \sum_{i=1}^{100} X_i = 15$.

Interpretando la verosimilitud en el caso continuo

- Para todo $\varepsilon > 0$ y dada $\underline{X} = \underline{x}$, $B(\underline{x}, \varepsilon)$ representa el conjunto de todas las muestras “ ε -parecidas a \underline{x} ”. Luego se tiene que:

$$P_{\theta}(\underline{X} \in B(\underline{x}, \varepsilon)) \approx c(\varepsilon, \underline{x}) f_{\underline{X}}(\underline{x}; \theta) = c(\varepsilon, \underline{x}) L(\theta | \underline{x}).$$

- Al igual que en el caso discreto, podemos comparar la plausibilidad de que los datos se generen de un modelo con θ_1 o θ_2 (en un entorno de la evidencia \underline{x}) utilizando el ratio de verosimilitudes, ya que:

$$\frac{P_{\theta_1}(\underline{X} \in B(\underline{x}, \varepsilon))}{P_{\theta_2}(\underline{X} \in B(\underline{x}, \varepsilon))} \approx \frac{c(\varepsilon, \underline{x}) L(\theta_1 | \underline{x})}{c(\varepsilon, \underline{x}) L(\theta_2 | \underline{x})} = \frac{L(\theta_1 | \underline{x})}{L(\theta_2 | \underline{x})}.$$

Por tanto decimos que θ_1 es más verosímil que θ_2 , dada la evidencia $\underline{X} = \underline{x}$, si el ratio de verosimilitud es mayor que uno y viceversa.

- Ej: $X \sim \text{Exp}(\theta)$ con $X_1 = 1, X_2 = 3, X_3 = 2$ y $\theta_1 = 2$ vs $\theta_2 = 0.5$.

El principio de verosimilitud

- Sean \underline{x} e \underline{y} dos realizaciones de la muestra tales que

$$L(\theta|\underline{x}) = c(\underline{x}, \underline{y})L(\theta|\underline{y}) \text{ para todo } \theta \in \Theta,$$

donde $c(\underline{x}, \underline{y})$ no depende de θ .

- La inferencia que hacemos respecto de θ con \underline{x} tiene que ser la misma que hacemos con \underline{y} , ya que para cualquier par $\theta_1, \theta_2 \in \Theta$ se cumple:

$$\text{Si } \frac{L(\theta_1|\underline{x})}{L(\theta_2|\underline{x})} > 1 \Rightarrow \frac{L(\theta_1|\underline{x})}{L(\theta_2|\underline{x})} = \frac{c(\underline{x}, \underline{y})L(\theta_1|\underline{y})}{c(\underline{x}, \underline{y})L(\theta_2|\underline{y})} = \frac{L(\theta_1|\underline{y})}{L(\theta_2|\underline{y})} > 1.$$

- Las conclusiones que extraemos de \underline{x} e \underline{y} son las mismas:

$$L(\theta_1|\underline{x}) > L(\theta_2|\underline{x}) \Leftrightarrow L(\theta_1|\underline{y}) > L(\theta_2|\underline{y}).$$

- El principio de verosimilitud sugiere entonces que $L(\theta)$ contiene toda la información relevante para hacer inferencias respecto de θ .

Agenda

- 1 Principio de Suficiencia
- 2 Principio de Verosimilitud
- 3 Principio de Invarianza**
- 4 Apéndice

- Invarianza de Escala: Si el modelo $f(x; \theta)$ y la evidencia empírica \underline{x} están fijos, los cambios de escala en \underline{x} solo deben producir cambios de escala en las estimaciones que hacemos de θ . Discutamos un ejemplo:
 - ▶ Dos investigadores utilizan el mismo modelo $f(x; \theta)$ y la misma muestra \underline{x} . Al primero se le reporta \underline{x} en escala de metros, al segundo en escala de centímetros. La inferencia de ambos debe ser compatible.
- Si hacemos inferencia sobre θ utilizando la función de verosimilitud, entonces el procedimiento/método será invariante (ver apéndice).
- Equivarianza: Imaginemos 2 investigadores resolviendo problemas de inferencia diferentes pero utilizando el mismo modelo estadístico $f(x; \theta)$. Si la evidencia de ambos coincide: $\underline{x}_1 = \underline{x}_2$, la inferencia que hacen ambos investigadores sobre θ debería ser la misma.
 - ▶ Si hacemos inferencia sobre θ utilizando la función de verosimilitud, entonces el procedimiento/método será equivariante.

Agenda

- 1 Principio de Suficiencia
- 2 Principio de Verosimilitud
- 3 Principio de Invarianza
- 4 Apéndice**

Verosimilitud y datos dependientes

- Sea $\underline{X} \equiv \{X_1, \dots, X_n\} \stackrel{id}{\sim} f(x; \theta)$ (v.a. dependientes) con $\theta \in \Theta$.
Dada $\underline{X} = \underline{x}$, podemos definir la función de verosimilitud como:

$$L(\theta|\underline{x}) = f(x_1; \theta) \prod_{i=2}^n f(x_i; \theta | x_1, \dots, x_{i-1}).$$

- ▶ La anterior expresión surge de la “regla del producto”.
- En el contexto de datos dependientes, solemos hacer algunos supuestos adicionales sobre la estructura probabilística subyacente. Por ejemplo, asumiendo que la secuencia $\{X_1, \dots, X_n\}$ se observa de forma ordenada (por ejemplo en el tiempo) y que el modelo tiene estructura Markoviana, luego:

$$L(\theta|\underline{x}) = f(x_1; \theta) \prod_{i=2}^n f(x_i; \theta | x_{i-1}).$$

- El caso no *id* es menos relevante en la práctica.

Verosimilitud e Invarianza de Escala

- Sea $\underline{X} \equiv \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ con $\theta \in \Theta$. Dada $\underline{X} = \underline{x}$, consideremos la transformación biyectiva $Z = g(X)^2$.
- Como $f(z; \theta) = f(x; \theta) |J|_x$, donde $J_x = dX/dZ$ es el inverso del Jacobiano de la transformación g (que NO depende de θ), luego:

$$L(\theta|\underline{z}) = L(\theta|\underline{x})c(\underline{x}).$$

- ▶ Donde $c(\underline{x}) = \prod_{i=1}^n |J_{x_i}| > 0$ es una constante que no depende de θ .
- Como la verosimilitud $L(\theta|\underline{z})$ es proporcional a $L(\theta|\underline{x})$, la inferencia que hacemos con $\underline{z} = g(\underline{x})$ en el contexto del modelo $f(z; \theta)$ es equivalente a la que hacemos con \underline{x} en el contexto del modelo $f(x; \theta)$.

$$L(\theta_1|\underline{x}) > L(\theta_2|\underline{x}) \Leftrightarrow L(\theta_1|\underline{z}) > L(\theta_2|\underline{z}).$$

²Consideremos la muestra aleatoria: $\underline{Z} \equiv \{Z_1 = g(X_1), \dots, Z_n = g(X_n)\}$.