

# Inferencia Estadística

## Riesgo y Nociones de Optimalidad

Gabriel Martos Venturini  
gmartos@utdt.edu

UTDT

- Un estimador puntual es un estadístico con el que típicamente pretendemos inferir el parámetro desconocido del modelo.
- Idealmente, la distribución de probabilidad del estimador debería estar *concentrada* en torno del verdadero valor del parámetro.
- La que sigue es una discusión sobre cómo cuantificar esta característica deseable de un estimador. La noción de *riesgo* permite definir estimadores en algún sentido óptimos.
  - ▶ No es necesario circunscribir la discusión al caso de los estimadores de momentos o los estimadores máximo verosímiles; por este motivo denotaremos con  $W_n$  al estimador de interés (función de una muestra aleatoria de tamaño  $n$ ) de cierto modelo estadístico de referencia.

# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
- 3 Estimadores minimax
- 4 Apéndice

# Riesgo de un estimador

- $\underline{X} = \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$  con  $\underline{X} \in \mathcal{X}$  y  $\underline{X} \sim f_{\underline{X}}(\underline{x}; \theta)$ .
- $W_n(\underline{X}) \equiv W_n$  es un estimador de  $\theta \in \Theta$ .
- Consideramos una función de pérdida  $l : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ .
  - ▶ Pérdida cuadrática:  $l(W_n, \theta) = (W_n - \theta)^2$  (descomposición).
  - ▶ Pérdida absoluta:  $l(W_n, \theta) = |W_n - \theta|$ .
  - ▶ Debe reflejar las consecuencias del error en la estimación.
- El riesgo del estimador  $W_n$  se define como:

$$R(W_n, \theta) = E(l(W_n, \theta)) = \int_{\mathcal{X}} l(w_n(\underline{x}), \theta) f_{\underline{X}}(\underline{x}; \theta) d\underline{x}.$$

- Representa la pérdida esperada (en la métrica  $l$ ) al estimar  $\theta$  con  $W_n$ .
- Elementos de “Teoría de la Decisión” (CB: § 7.3.4, pp. 348).

# Error Cuadrático Medio

- $ECM(W_n, \theta) = E[(W_n - \theta)^2] \equiv \underbrace{[E(W_n) - \theta]^2}_{\text{Sesgo}_\theta^2(W_n)} + \underbrace{E[(W_n - E(W_n))^2]}_{\text{Var}_\theta(W_n)}.$

Demostración ( ▶ Intuición ).

$$\begin{aligned} ECM(W_n, \theta) &= E[(W_n - E(W_n) + E(W_n) - \theta)^2] \\ &= E[(W_n - E(W_n))^2 + (E(W_n) - \theta)^2 + 2(W_n - E(W_n))(E(W_n) - \theta)] \\ &= E[(W_n - E(W_n))^2] + \underbrace{E[(E(W_n) - \theta)^2]}_{E(cte)=cte} + 2 \underbrace{E[(W_n - E(W_n))(E(W_n) - \theta)]}_{(E(W_n) - E(W_n))(E(W_n) - \theta) = 0} \end{aligned} \quad \square$$

- $W_n$  es **insesgado** si  $ECM(W_n, \theta) = \text{Var}_\theta(W_n)$  (para todo  $n$  y  $\theta \in \Theta$ ).
- ECM de los estimadores máximo verosímiles cuando  $X \sim N(\mu, \sigma^2)$ .
  - ▶ Compara el ECM de  $\hat{\sigma}_n^2$  vs el del estimador insesgado  $S_n^2$ .

- Nota: Los estimadores insesgados no siempre son los de menor riesgo.





Figure: En algunos contextos específicos puede convenir asumir algo de sesgo a cambio de reducciones contundentes en la varianza del estimador.

- ▶ En regresión: Ridge y Lasso (intercambiamos sesgo por varianza).
- ¿Existe  $W_n : R(W_n, \theta) \leq R(W'_n, \theta)$ , para todo  $\theta \in \Theta$  y  $n \geq 1$ ?

## Contraejemplo

$\{X_1, \dots, X_n\} \stackrel{iid}{\sim} N(\theta, \sigma^2 = 1)$ :  $\hat{\theta}_1 = \bar{X}_n$  vs.  $\hat{\theta}_2 = 3$ .

$n = 1$ :  $\text{ECM}(\hat{\theta}_1, \theta) = \text{Var}(\hat{\theta}_1) = \frac{\sigma^2}{n} = 1$ , y  $\text{ECM}(\hat{\theta}_2, \theta) = \text{Sesgo}^2(\hat{\theta}_2) = (\theta - 3)^2$



En general no existe un estimador *uniformemente mejor* (sobre  $\Theta$ ).

► C2

- Para poder establecer criterios de optimalidad:

### 1 Acotamos el conjunto de potenciales estimadores:

- ▶ Consideramos únicamente estimadores insesgados del parámetro.
- ▶ Dentro de este (sub)conjunto (o clase), el mejor estimador (menor ECM) será aquel que tenga la menor varianza (mayor eficiencia).

### 2 Identificamos la curva de riesgo con un número, de forma de poder *ordenar* a los estimadores en base a dicha cantidad.

- ▶ Mini-max: Minimizan el máximo riesgo (criterio conservador).

### 3 Estimadores de mínimo riesgo Bayesiano.

- ▶ Buscamos el estimador que minimiza la pérdida esperada a posteriori.
- ▶ Postergamos esta discusión hasta discutir métodos Bayesianos.



# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
  - Definiciones y cota de Cramér–Rao
  - Rao–Blackwell y Lehmann–Scheffé
- 3 Estimadores minimax
- 4 Apéndice

# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
  - Definiciones y cota de Cramér–Rao
  - Rao–Blackwell y Lehmann–Scheffé
- 3 Estimadores minimax
- 4 Apéndice

Para  $X \sim f(x; \theta)$

- Denotaremos  $\mathcal{C}_\theta$  al conjunto de todos los estimadores insesgados de  $\theta$ :

$$\mathcal{C}_\theta = \{W_n \mid E(W_n) = \theta \text{ para todo } n \geq 1 \text{ y } \theta \in \Theta\}.$$

- Si  $W_n \in \mathcal{C}_\theta$ , luego  $\text{ECM}(W_n, \theta) = \text{Var}(W_n)$ .

### Definition (Estimador UMVUE)

$W_n^* \in \mathcal{C}_\theta$  es el **mejor estimador insesgado** de  $\theta$  (UMVUE) si se cumple que  $\text{Var}(W_n^*) \leq \text{Var}(W_n)$  para todo  $n \geq 1$ ,  $W_n \in \mathcal{C}_\theta$  y  $\theta \in \Theta$ .

- UMVUE: Uniform Minimum Variance Unbiased Estimator.
- No siempre existen y encontrar estos estimadores no es trivial.
  - ▶ Ejemplo:  $\bar{X}_n$  y  $S_n^2$  para  $\lambda$  en modelo Poisson.
- Estrategia: Hallar cota inferior para la varianza de los estimadores de  $\theta$ , y si un estimador insesgado alcanza la cota entonces es UMVUE.

## Condiciones de regularidad (BackUp Slide)

- Se cumplen, en general, en los modelos de la familia exponencial.

$H_1$ )  $f(x; \theta)$  es *suficientemente suave* como función de  $\theta$ , de forma que:

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx.$$

- Esta condición no suele cumplirse en los modelos cuyos soportes dependen de los parámetros (por ejemplo el modelo Uniforme).

$H_2$ ) Le pedimos al conjunto de estimadores de  $\theta$  que estemos considerando que sus esperanzas sean funciones diferenciables respecto de  $\theta$ .

Llamemos  $m_W(\theta) = E(W_n)$ , luego pedimos que  $\frac{\partial}{\partial \theta} m_W(\theta)$  exista.

# Resultado general

## Teorema (Cota de Cramér–Rao)

Sea  $\underline{X} = \{X_1, \dots, X_n\}$  una muestra (no necesariamente iid) tal que  $\underline{X} \sim f_{\underline{X}}(\underline{x}; \theta)$  verifica  $H_1$  y sea  $W_n$  cualquier estimador de  $\theta$  que verifica  $H_2$ :

$$V(W_n) \geq \frac{\left(\frac{\partial}{\partial \theta} E(W_n)\right)^2}{E\left(\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}(\underline{X}; \theta)\right]^2\right)}.$$

- Proof: CB § 7.3.1 pp 336 (Cauchy–Schwarz).
- Si adicionalmente asumimos que
  - ▶  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ .
  - ▶  $W_n \in \mathcal{C}_\theta$ ,
- La cota tiene una expresión más simple.

- Si  $W_n \in \mathcal{C}_\theta$  entonces  $\frac{\partial}{\partial \theta} E(W_n) = \frac{\partial}{\partial \theta} \theta = 1$ .

- Si  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$ , luego:

$$E\left(\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}(\underline{X}; \theta)\right]^2\right) \stackrel{i}{=} E\left(\left[\frac{\partial}{\partial \theta} \underbrace{\log \prod_{i=1}^n f(X_i; \theta)}_{\ell(\theta|\mathbf{x})}\right]^2\right) \stackrel{id}{=} n \underbrace{E\left(\left[\frac{\partial}{\partial \theta} \log f(X; \theta)\right]^2\right)}_{i(\theta)}.$$

- **Información de Fisher:**  $I_n(\theta) = ni(\theta)$  (no depende del estimador).

Theorem (Cramér–Rao (iid +  $W_n \in \mathcal{C}_\theta$ ))

Sea  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(x; \theta)$  y  $W_n \in \mathcal{C}_\theta$  (satisfacen  $H_1$  y  $H_2$ ), luego:

$$V(W_n) \geq \frac{1}{nE\left(\left[\frac{\partial}{\partial \theta} \log f(X; \theta)\right]^2\right)} = [I_n(\theta)]^{-1}.$$

- Notar que:  $E\left(\left[\frac{\partial}{\partial \theta} \log f(X; \theta)\right]^2\right) = \int_{\mathcal{X}} \left[\frac{\partial}{\partial \theta} \log f(x; \theta)\right]^2 f(x; \theta) dx$ .

- Si  $W_n \in \mathcal{C}_\theta$  y  $\text{Var}(W_n) = 1/I_n(\theta)$ , entonces  $W_n$  es el UMVUE de  $\theta$ .

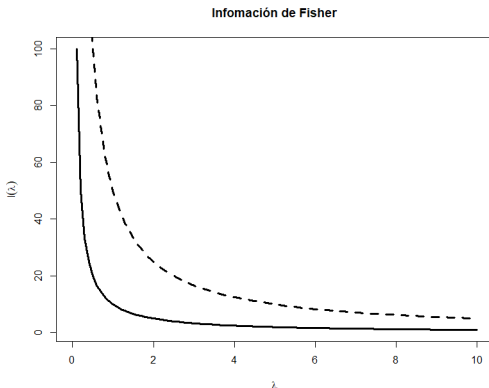
► Ejemplo: Si  $X \sim \text{Pois}(\lambda)$ , entonces  $\hat{\lambda}_n = \bar{X}_n$  es el UMVUE de  $\lambda$ .

- Notar que:

$$I_n(\theta) = E\left(\left[\frac{\partial}{\partial \theta} \underbrace{\log f_{\underline{X}}(\underline{X}; \theta)}_{\ell(\theta)}\right]^2\right) \stackrel{iid}{=} n E\left(\underbrace{\left[\frac{\partial}{\partial \theta} \log f(X; \theta)\right]^2}_{i(\theta)}\right).$$

... qué nos dice la Información de Fisher? Qué relación tiene ésta con la función de (log) verosimilitud?

- $I_n(\theta) \equiv ni(\theta)$  (depende del tamaño de la muestra).
- En el ejemplo Poisson:  $i(\lambda) = 1/\lambda$ . Si  $\lambda$  es pequeño, media y varianza de  $X$  es pequeña (la población es homogénea). Cada elemento de  $\underline{X}$  aporta mucha información sobre  $\lambda$  (mucha información = cota baja).



**Figure:** Información de Fisher para  $X \sim \text{Pois}(\lambda)$ : En la línea continua (—)  $n = 10$  y en línea punteada (- -)  $n = 50$ . A medida que  $\lambda \rightarrow 0$ ,  $I_n(\lambda) \rightarrow \infty$  para todo  $n$ .



$$I_n(\theta) = \text{Var}\left(\frac{\partial}{\partial \theta} \ell(\theta; \underline{X})\right)$$




Figure: La información de Fisher cuantifica la concavidad de  $\ell$  en torno a  $\theta^*$ .

- En la slide anterior ocurre que:  $I_n(\lambda = 1) > I_n(\lambda = 10)$ .

# Familias exponenciales

- Los modelos de la familia exponencial, verifican que:

$$E\left(\left[\frac{\partial}{\partial\theta}\log f(X;\theta)\right]^2\right) = -E\left(\frac{\partial^2}{\partial\theta^2}\log f(X;\theta)\right) = i(\theta).$$

- Luego:

$$I_n(\theta) \stackrel{iid}{=} -nE\left(\frac{\partial^2}{\partial\theta^2}\log f(X;\theta)\right) = -E\left(\frac{\partial^2}{\partial\theta^2}\ell(\theta|\underline{X})\right).$$

- Simplificando cálculo de la cota, en particular cuando:  $\frac{\partial^2}{\partial\theta^2}\ell(\theta|\underline{X}) = c$ .
- Revisitando el calculo de la cota de varianza para estimadores insesgados en el contexto del modelo Poisson / Exponencial.
- Dada  $\underline{X} = \underline{x}$ , llamamos información *observada* a:

$$J_n(\theta) = -\left(\frac{\partial^2}{\partial\theta^2}\ell(\theta|\underline{x})\right) = \sum_{i=1}^n \frac{\partial^2 \log f(x_i; \theta)}{\partial\theta^2}.$$

## Caso multiparámetro (familias exponenciales)

- $\underline{X} = \{X_1, \dots, X_n\} \stackrel{iid}{\sim} f(\underline{x}; \boldsymbol{\theta})$ , con  $\boldsymbol{\theta} \in \Theta \subseteq \mathbb{R}^d$ .
- Consideramos estimadores  $\mathbf{W}$  insesgados para  $\boldsymbol{\theta}$  ( $E(\mathbf{W}) = \boldsymbol{\theta}$ ).
- Ahora  $\mathbf{I}(\boldsymbol{\theta})$  será una matriz de  $d \times d$ :

$$\begin{aligned} [\mathbf{I}(\boldsymbol{\theta})]_{ij} &= E\left(\left\{\frac{\partial}{\partial \theta_i} \log f_{\underline{X}}(\underline{X}; \boldsymbol{\theta})\right\} \left\{\frac{\partial}{\partial \theta_j} \log f_{\underline{X}}(\underline{X}; \boldsymbol{\theta})\right\}\right) \\ (\text{fam. exp.}) &= -E\left(\frac{\partial^2}{\partial \theta_i \partial \theta_j} \ell(\boldsymbol{\theta} | \underline{X})\right), \\ (iid) &= -nE\left(\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log f(X; \boldsymbol{\theta})\right) \end{aligned}$$

- La cota de CR será  $[\mathbf{I}(\boldsymbol{\theta})]^{-1}$ , y por tanto se verifica que:

$$\text{Var}(\mathbf{W}) \geq [\mathbf{I}(\boldsymbol{\theta})]^{-1}.$$

## 'Algoritmo' para encontrar un UMVUE:

- 1) Check: Insesgadez y computo de varianza de tu estimador.
- 2) Construye la log-verosimilitud asociada al modelo.
- 3) Computa la derivada segunda de la log-verosimilitud.
- 4) Calcular esperanza en (3).
- 5) Utiliza (4) para calcular la información Fisher.
- 6) Compara la varianza de tu estimador contra la cota CR.

Otro ejemplo (alumnos lo resuelven en clase):

- $X \sim \text{Bern}(\theta)$  y consideramos  $\hat{\theta} = \sum_{i=1}^n \frac{X_i}{n}$  (insesgado y  $\text{Var}(\hat{\theta}) = \frac{\theta(1-\theta)}{n}$ ).
  - ▶ Insesgado + varianza alcanza la cota de CR  $\Rightarrow$  UMVUE.

# Condición para alcanzar la cota

## Teorema

Asumiendo que el modelo estadístico cumple  $H_1$  y  $W_n \in \mathcal{C}_\theta$ , luego  $W_n$  alcanza la cota de CR si y solo si existe una función  $a(\theta)$  que verifica:

$$a(\theta)[w_n - \theta] = \frac{\partial}{\partial \theta} \ell(\theta) = S(\theta) \quad (\text{proof: CB § 7.3.2}).$$

- Ejemplo:  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} N(\mu_0, \sigma^2)$  con  $\mu_0$  conocida. Existe un estimador que alcanza la cota y es  $\hat{\sigma}_n^2$  (el EMV) ya que:

$$\underbrace{\frac{\partial}{\partial \sigma^2} \ell(\sigma^2 | \mu_0)}_{a(\sigma^2)} = \underbrace{\frac{n}{2\sigma^4} \left[ \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2 - \sigma^2 \right]}_{\hat{\sigma}_n^2} = a(\sigma^2)[\hat{\sigma}_n^2 - \sigma^2].$$

- $\hat{\sigma}_n^2$  es el UMVUE: Insesgado (cuando  $\mu$  es conocida) + alcanza cota.

# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
  - Definiciones y cota de Cramér–Rao
  - Rao–Blackwell y Lehmann–Scheffé
- 3 Estimadores minimax
- 4 Apéndice

- En nuestra discusión en torno a los UMVUE no utilizamos el concepto de suficiencia. Existen dos resultados teóricos relevantes a destacar:
  - ▶ Rao–Blackwell: Un estimador insesgado de  $\theta$  se puede “mejorar” (reducir su varianza) si es condicionado por un estadístico suficiente.
    - ★ Corolario: En nuestra búsqueda de estimadores UMVUE debemos considerar solo aquellos que resultan funciones de el/los estadístico/s suficientes para el/los parámetro/s de interés.
    - ★ Los EMV en familias exponenciales son suficientes y completos :)
  - ▶ Lehmann–Scheffé: Si existe estimador insesgado de  $\theta$  que sea función de un estadístico suficiente y completo, éste es el único estimador UMVUE de  $\theta$ .

# “Rao–Blackwellización” de estimadores

## Theorem (Rao–Blackwell)

Si  $W_n \in \mathcal{C}_\theta$  y  $T$  es suficiente para  $\theta$ ;  $\phi(T) = E(W_n|T)$  es preferible a  $W_n$ :

- a)  $\phi(T)$  es insesgado:  $E(\phi(T)) = \theta$ , (esperanza total) y
- b)  $V(\phi(T)) \leq V(W_n)$  (varianza total).
- c) La distribución de  $\phi(T)$  es independiente de  $\theta$  (suficiencia).

(proof: CB § 7: pp–342)

- Si  $W_n \in \mathcal{C}_\theta$  pero no es función de un estadístico suficiente:
  - ▶  $\text{ECM}(\phi(T), \theta) \leq \text{ECM}(W_n, \theta)$  para todo  $\theta \in \Theta$  y  $n \geq 1$ .
- **COROLARIO:** Un estimador insesgado que no es función de un estadístico suficiente será peor (mayor ECM) que otro que sí lo es.
  - ▶ Ejemplo:  $\hat{\mu}_n = \bar{X}_n$  vs la Mediana cuando  $X \sim N(\mu, \sigma^2)$ .



# Unicidad

- En el contexto de un modelo  $X \sim f(x; \theta)$ .

## Theorem (Lehmann–Scheffé)

Sea  $T$  un estadístico suficiente y completo para  $\theta$  y  $\phi$  una función cualquiera de  $T$ ; luego  $\phi(T)$  es el **único** estimador UMVUE de  $E(\phi(T))$ .

- Si logramos encontrar una función  $\phi$  del estadístico suficiente y completo  $T$  tal que  $E(\phi(T)) = \theta$  (centramos correctamente a  $T$ ), entonces  $\phi(T)$  es el **único** estimador UMVUE de  $\theta$ .
  - ▶ Ideal para modelos de la familia Exponencial ya que sabemos que el estadístico  $T = \sum_{i=1}^n t(X_i)$  es completo y suficiente para  $\theta$ .
  - ▶ Ejemplos:  $\phi(T) = T/n$  resulta insesgado para los parámetros de los modelos Poisson, Exponencial y Bernoulli. Luego como  $T$  es suficiente y completo (modelos de la familia exponencial), entonces  $T/n$  es el único estimador UMVUE de dichos parámetros.

# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
- 3 Estimadores minimax**
- 4 Apéndice

# Admisibilidad de un estimador

- Dada una función de riesgo  $R$  y un estimador  $W_n$  de  $\theta \in \Theta$ , decimos que  $W_n$  es **inadmisible** si existe otro estimador  $W'_n$  tal que:
  - ▶  $R(W'_n, \theta) \leq R(W_n, \theta)$  para todo  $\theta \in \Theta$ , y
  - ▶  $R(W'_n, \theta) < R(W_n, \theta)$  para al menos algún  $\theta \in \Theta$ .
- Un estimador es **admisibile** si no es inadmisibile.
  - ▶ La admisibilidad es la ausencia de una propiedad negativa.
- Los estimadores UMVUE no son necesariamente admisibles.
- ¿Existen estimadores admisibles? ¿Cómo los construimos?
  - ▶ Estimadores **minimax**.
  - ▶ Estimadores Bayesianos.

# Estimadores minimax

- Como lo sugiere su nombre, los estimadores minimax buscan minimizar una cota máxima para el riesgo.
- $W_n$  se dice estimador mini-max de  $\theta$  si para cualquier otro estimador  $W'_n$  (en una clase  $\mathcal{W}$ ) y una función de riesgo  $R$  ocurre que:

$$\sup_{\theta \in \Theta} R(W_n, \theta) \leq \sup_{\theta \in \Theta} R(W'_n, \theta).$$

- Criterio conservador para definir optimalidad: Podríamos estar descartando estimadores  $W'_n$  que tienen poco riesgo en casi todo  $\Theta$  excepto quizá en regiones pequeñas de  $\Theta$ .
  - ▶ En este curso no vamos a abordar este criterio de optimalidad.
- Este tipo de aproximaciones conservadores son más simples de abordar desde el paradigma Bayesiano, dando como resultado estimadores de “regla bayesiana” que verifican también el principio de admisibilidad.

# Optimalidad Bayesiana

- $W_n$  es un estimador que sigue la regla (criterio) Bayesiana(o) si minimiza un promedio ponderado del riesgo Bayesiano  $r(\pi, W_n)$ .
- Dicha función se define, para una prior  $\pi$  de  $\theta$ , como:

$$r(\pi, W_n) = E_{\pi}[R(W_n, \theta)] = \int_{\Theta} R(W_n, \theta) \pi(\theta) d\theta.$$

- $W_n$  se dice una regla de estimación Bayesiana de  $\theta$  con respecto a una prior  $\pi$ , si para cualquier otro estimador  $W'_n$  ocurre que:

$$r(W_n, \pi) \leq r(W'_n, \pi).$$

- Bajo ciertas condiciones de regularidad sobre el modelo estadístico, podemos encontrar la expresión de  $W_n$  que minimiza  $r(W_n, \pi)$  (y que en general dependerá de la elección de tu prior  $\pi(\theta)$ ).

# Agenda

- 1 Riesgo: Error Cuadrático Medio
- 2 Mejores estimadores insesgados
- 3 Estimadores minimax
- 4 Apéndice




Figure: ¿Cómo será el ECM en cada caso? [▶ volver](#)

## Reforzando el mensaje:

- Si  $W_n$  tiene sesgo y varianza pequeños, entonces tiene un ECM bajo.
  - ▶ En otras palabras, la distribución de probabilidad de  $W_n$  está concentrada en torno de  $\theta$ , o lo que es lo mismo
  - ▶ Con alta probabilidad el estimador  $W_n$  tomará valores cercanos al parámetro desconocido  $\theta$  (garantiza que estimo razonablemente bien).
- COROLARIO: Si tengo dos estimadores  $W_n$  y  $W'_n$  y (por ejemplo)  $\text{ECM}(W_n, \theta) < \text{ECM}(W'_n, \theta)$  para todo posible valor de  $\theta$  en la población, entonces *prefiero*  $W_n$  a  $W'_n$  como estimador de  $\theta$ .
- Desafortunadamente, encontrar estimadores uniformemente mejores no es posible en general (ver otro contraejemplo en las próximas slides).



## Estimar el parámetro de una Bernoulli

$\{X_1, \dots, X_n\} \stackrel{iid}{\sim} \text{Bern}(p)$  y comparamos dos estimadores  $\hat{p}_1$  y  $\hat{p}_2$ :

$\hat{p}_1$  la media muestral:

$$\hat{p}_1 = \bar{X}_n.$$

$\hat{p}_2$  agrega 2 fracasos y 2 éxitos artificiales a la muestra:

$$\hat{p}_2 = \frac{\sum_{i=1}^n X_i + 2}{n + 4}.$$

Calculemos primero el ECM de  $\hat{p}_1$ . Sabemos que:

$$E(\hat{p}_1) = p, \quad y \quad \text{Var}(\hat{p}_1) = \frac{p(1-p)}{n}$$

$$\text{Entonces el } \text{ECM}(\hat{p}_1, p) = E[(\hat{p}_1 - p)^2] = \frac{p(1-p)}{n}.$$

Sesgo y varianza de  $\hat{p}_2$  (notar que  $\sum_{i=1}^n X_i = T \sim \text{Bin}(n, p)$ ).

$$E\left(\frac{T+2}{n+4}\right) - p = \frac{E(T+2)}{n+4} - p = \frac{np+2}{n+4} - p = \frac{2(1-2p)}{n+4}.$$

El sesgo no es cero, salvo cuando  $p = 0.5$ . Sin embargo converge a cero cuando  $n \rightarrow \infty$ .

$$\text{Var}\left(\frac{T+2}{n+4}\right) = \frac{\text{Var}(T+2)}{(n+4)^2} = \frac{\text{Var}(T)}{(n+4)^2} = \frac{np(1-p)}{(n+4)^2}.$$

Entonces:

$$\text{ECM}(\hat{p}_2, p) = E((\hat{p}_2 - p)^2) = \left(\frac{2(1-2p)}{n+4}\right)^2 + \frac{np(1-p)}{(n+4)^2}.$$

¿Cuál es mejor?




Figure: Error cuadrático medio para  $\hat{p}_1$  (naranja) y  $\hat{p}_2$  (azul).

[volver](#)