

# Inferencia Estadística

## Métodos de Inferencia Basados en Remuestreos

Gabriel Martos Venturini  
gmartos@utdt.edu

UTDT

Monographs  
on Statistics and  
Applied Probability 57

# An Introduction to the Bootstrap

Bradley Efron  
Robert J. Tibshirani



SPRINGER-SCIENCE+BUSINESS MEDIA, B.V.

**BRADLEY EFRON  
TREVOR HASTIE**

# COMPUTER AGE STATISTICAL INFERENCE

**ALGORITHMS, EVIDENCE, AND DATA SCIENCE**

# Agenda

- 1 Introducción
- 2 Jackknife
- 3 Bootstrap
- 4 Permutation test

# Motivación (Jackknife y Bootstrap)

Con  $\underline{x} \equiv \{x_1, \dots, x_n\} \stackrel{iid}{\sim} F$  y  $\hat{\theta}_n(\underline{x})$ , pretendo estimar  $se(\hat{\theta}_n) \equiv \sqrt{\text{Var}(\hat{\theta}_n)}$ .

- $\hat{\theta}_n(\underline{x})$  es virtualmente cualquier función de los datos.
- En general resulta complejo (o imposible) obtener una expresión cerrada para (la estimación de) el error estándar de un estimador.
- ¿Y para qué quiero estimar  $se(\hat{\theta}_n)$ ?
  - ▶ Cuantificar la incertidumbre respecto del parámetro estimado.
- Si pudiera samplear muchas veces de  $F$ , podríamos aproximar  $se(\hat{\theta}_n)$  a partir de la distribución empírica de  $\hat{\theta}_n$  (imposible en la práctica!).
  - ▶ Jackknife y Bootstrap proponen re-muestrear (de maneras diferentes) de la única muestra que disponemos ( $\underline{X} = \underline{x}$ ) con el fin de estimar  $se(\hat{\theta}_n)$ .
  - ▶ Jackknife tiene algunas ventajas computacionales.
  - ▶ Bootstrap tiene algunas propiedades estadísticas.

# Agenda

- 1 Introducción
- 2 Jackknife**
- 3 Bootstrap
- 4 Permutation test

- Disponemos de datos  $\underline{x} = \{x_1, \dots, x_n\}$  y un estadístico  $\hat{\theta}_n(\underline{x})$ .
- Consideremos  $\underline{x}_{-i} \equiv \{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n\}$ , para  $i = 1, \dots, n$ .
- Sea  $\hat{\theta}_{-i} \equiv \hat{\theta}_{n-1}(\underline{x}_{-i})$ , la estimación Jackknife de  $\text{Var}(\hat{\theta}_n)$  es:

$$v_{\text{jack}}(\hat{\theta}_n) = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{-i} - \bar{\theta}_n)^2 \text{ y } \text{se}_{\text{jack}} = \sqrt{v_{\text{jack}}},$$

donde  $\bar{\theta}_n = \sum_{i=1}^n \hat{\theta}_{-i} / n$ .

- La estimación Jackknife del sesgo es:

$$b_{\text{jack}}(\hat{\theta}_n) = (n-1)(\bar{\theta}_n - \hat{\theta}_n).$$

- Por lo que la estimación Jackknife del parámetro se escribe como:

$$\hat{\theta}_{\text{jack}} = \hat{\theta}_n - b_{\text{jack}}(\hat{\theta}_n) = n\hat{\theta}_n - (n-1)\bar{\theta}_n.$$

- Ejemplo en R.

# Algunas consideraciones importantes

- El método sirve para aproximar la varianza de cualquier estadístico de interés sin necesidad de asumir un modelo particular para los datos.
- ¿Porqué estimar  $\text{Var}(\hat{\theta}_n)$  con  $v_{\text{jack}}(\hat{\theta}_n)$ ?
  - ▶ Porque quizá no se estimar  $\text{Var}(\hat{\theta}_n)$  (ej: Estimador de correlación).
- Cuando  $\hat{\theta}_n$  no es una función suave de los datos (i.e.  $\hat{\theta}_n = \text{mediana muestral}$ ),  $v_{\text{jack}}(\hat{\theta}_n)$  es un estimador inconsistente de  $\text{Var}(\hat{\theta}_n)$ .
- La estimación Jackknife de  $\text{Var}(\hat{\theta}_n)$  es más rápida de computar en comparación con la estimación Bootstrap (eficiencia computacional).
- ¿Porqué utilizar  $\hat{\theta}_{\text{jack}}$  en lugar de  $\hat{\theta}_n$ ?
  - ▶ Recordemos que  $\text{MSE}(\hat{\theta}_n, \theta) = \text{bias}^2(\hat{\theta}_n) + \text{var}(\hat{\theta}_n)$ . Resulta que en general  $\text{bias}^2(\hat{\theta}_n)$  converge más lento a 0 que  $\text{bias}^2(\hat{\theta}_{\text{jack}})$ .

# Agenda

- 1 Introducción
- 2 Jackknife
- 3 Bootstrap**
- 4 Permutation test



- Cambiamos el esquema de re-muestreo:

- 1 Muestreamos  $\underline{x}^* = \{x_1^*, \dots, x_n^*\}$  de  $\{x_1, \dots, x_n\}$  con reemplazamiento ( $\{X_1^*, \dots, X_n^*\} \stackrel{iid}{\sim} F_n$ ) y con esta remuestra computamos  $\hat{\theta}_n^* \equiv \hat{\theta}_n(\underline{x}_n^*)$ .
- 2 Repetimos  $B \gg n$  veces el paso anterior para obtener  $\{\hat{\theta}_{n,1}^*, \dots, \hat{\theta}_{n,B}^*\}$ .
- 3 La estimación Bootstrap de  $\text{Var}(\hat{\theta}_n)$  es:

$$v_{\text{boot}}(\hat{\theta}_n) = \frac{1}{B} \sum_{b=1}^B (\hat{\theta}_{n,b}^* - \frac{1}{B} \sum_{b=1}^B \hat{\theta}_{n,b}^*)^2 \text{ y } \text{se}_{\text{boot}} = \sqrt{v_{\text{boot}}}.$$

- Como  $F_n \approx F$  cuando  $n \gg 0$  ocurre que  $v_{\text{boot}}(\hat{\theta}_n) \approx \text{Var}(\hat{\theta}_n)$ .

$$F_n \stackrel{n \gg 0}{\approx} F \stackrel{iid \sim F_n}{\implies} \{\underline{x}_1^*, \dots, \underline{x}_B^*\} \stackrel{B \gg 0}{\implies} \text{se}_{\text{boot}} \approx \text{se}(\hat{\theta}_n).$$

- Idealmente  $B \gg 0$  ( $B > 200$  para estimar  $\text{Var}(\hat{\theta}_n)$ ).
- Ejemplo: Estimando el error standard del  $R^2$ .

# Intervalos de Confianza Bootstrap

- Empíricos: Con  $\{\hat{\theta}_b^*\}_{b=1}^B$  computamos  $G_B(t) = \sum_{b=1}^B \mathbb{I}(\hat{\theta}_b^* \leq t)/B$ .

$$\text{IC}_\alpha(\theta) = [G_B^{-1}(\alpha/2), G_B^{-1}(1 - \alpha/2)].$$

- Cuando  $\hat{\theta}_n$  tiene una distribución aproximadamente normal podemos considerar el intervalo:  $\hat{\theta}_n \pm z_{\alpha/2} \text{se}_{\text{boot}}$ .
- Existen versiones más sofisticadas en torno a estos métodos (ver por ejemplo  $t$ -Bootstrap en § 12 de Efron y Tibshirani y en § 11 de CASI).
- Caso de estudio en R.

# Agenda

- 1 Introducción
- 2 Jackknife
- 3 Bootstrap
- 4 Permutation test**

## Marco general

- Habitualmente utilizado para comparar poblaciones (no normales).
- Test no paramétrico:  $\{X_1, \dots, X_n\} \stackrel{iid}{\sim} F_X$  e  $\{Y_1, \dots, Y_m\} \stackrel{iid}{\sim} F_Y$ :

$$H_0 : F_X = F_Y \quad \text{vs.} \quad H_1 : F_X \neq F_Y.$$

- Sea  $S \equiv S(X_1, \dots, X_n, Y_1, \dots, Y_m)$  un estadístico de contraste con el que generalmente rechazamos  $H_0$  cuando  $S$  toma valores grandes:
  - ▶ Ej:  $S_1 = |\bar{X}_n - \bar{Y}_m|$ ,  $S_2 = (S_X^2 - S_Y^2)^2$ ,  $S_3 = \sup_t |\hat{F}_X(t) - \hat{F}_Y(t)|$
  - ▶ ¿Cómo proceder cuando no podemos aproximar la distribución de  $S$ ?
- Bajo  $H_0$  ocurre que:  $\{X_1, \dots, X_n, Y_1, \dots, Y_m\} \stackrel{iid}{\sim} F = F_X = F_Y$ .
- Llamemos  $s^{(\text{obs})} \equiv s(\underline{x}, \underline{y})$  al estadístico observado y consideremos las  $N = (n + m)!$  permutaciones de los datos para computar  $s^1, \dots, s^N$ .

$$\text{p-val} = \sum_{i=1}^N \mathbb{I}(s^i > s^{(\text{obs})}) / N.$$


## Algunos detalles

- Cuando  $n$  y  $m$  son grandes aproximamos el p-valor utilizando el método de Monte Carlo (después de elegir un estadístico  $S$ ):
  - 1 Con los datos de las muestras computamos  $s^{(\text{obs})}$ .
  - 2 Para una secuencia de  $K \ll N$  permutaciones aleatorias de los datos (muestreo sin reemplazamiento) calculamos  $s^1, \dots, s^K$  y luego:

$$\text{p-val} \approx \sum_{i=1}^K \mathbb{I}(s^i > s^{(\text{obs})}) / K.$$

- Este tipo de test es particularmente útil cuando quiero comparar poblaciones y los tamaños muestrales son relativamente pequeños.
- Caso de estudio en R (próxima slide).

# Caso de estudio



**Figure:** Diferencia en los patrones de consumo de 'alitas de pollo' entre hombres y mujeres (caso tomado de *Mathematical Statistics with resampling in R*).

- Tamaño muestral reducido:  $n = m = 15$ .