

Econometría
Problem Set 2
Tópicos en el Modelo Lineal

1 Un breve repaso...

La traza de una matriz cuadrada es la suma de los elementos de su diagonal principal. Algunas propiedades:

1. $tr(A + B) = tr(A) + tr(B)$
2. $tr(A') = tr(A)$
3. $tr(AB) = tr(BA)$
4. El rango de una matriz idempotente es igual a su traza.

Sea A una matriz cuadrada con autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$. Entonces:

1. $\det A = \lambda_1 \lambda_2 \dots \lambda_n$. Si A es una matriz no singular entonces todos sus autovalores son no nulos.
2. $tr A = \lambda_1 + \lambda_2 + \dots + \lambda_n$.
3. Si A es una matriz idempotente entonces sus autovalores son 0 o 1.

Algunos Teoremas (ver Apéndice del Greene) que nos serán útiles:

Theorem 1 (B.8) Si $x \sim N(0, I)$ y A es idempotente, entonces $x'Ax \sim \chi_k^2$ donde $k = \text{rank}(A) = \#$ autovalores iguales a 1.

Theorem 2 (B.12) Sean $x \sim N(0, I)$, Lx una transformación lineal de x , y $x'Ax$ con A idempotente y simétrica. Entonces Lx y $x'Ax$ son independientes si $LA = 0$.

Recordar del Problem Set 0 el siguiente resultado:

Sea x un vector aleatorio de $n \times 1$ tal que $x \sim N(\mu, \Sigma)$, donde Σ es una matriz simétrica y definida positiva. Entonces:

$$(x - \mu)' \Sigma^{-1} (x - \mu) \sim \chi_n^2$$

Recordar también:

Sea x un vector aleatorio con $E(x) = \mu$ y $\text{Var}(x) = E[(x - \mu)(x - \mu)'] = \Sigma$ ("matriz de varianzas y covarianzas"), entonces, dada una matriz $A : E[Ax] = A\mu$ y $\text{Var}[Ax] = A\Sigma A'$.

2 Problemas

1. Por el supuesto de normalidad: $u|X \sim N(0, \sigma_u^2 I_n)$.

Sea y :

$$y = X\beta + u$$

Puede verse que y es una transformación afín de u , condicional a los regresores. Luego, y tiene distribución normal. A partir del supuesto de exogeneidad estricta,

$$E(y|X) = X\beta + E(u|X) = X\beta$$

Además, por el supuesto de errores esféricos,

$$\begin{aligned}\Sigma_y &= E \{ [y - E(y|X)] [y - E(y|X)]' / X \} \\ &= E \{ [y - X\beta] [y - X\beta]' / X \} \\ &= E \{ uu' / X \} \\ &= \sigma_u^2 I_n\end{aligned}$$

Luego,

$$\boxed{y|X \sim \mathcal{N}(X\beta, \sigma_u^2 I_n)}$$

Sea $\hat{\beta}$:

$$\hat{\beta} = (X'X)^{-1} X'y = \beta + (X'X)^{-1} X'u$$

El estimador de MCC se escribe como una transformación afín de u . Entonces es normal. Sus momentos ya han sido calculados en el práctico pasado. Luego,

$$\boxed{\hat{\beta}/X \sim \mathcal{N}(\beta, \sigma_u^2 (X'X)^{-1})}$$

Sea ahora \hat{u} :

$$\begin{aligned}\hat{u} &= y - X\hat{\beta} \\ &= y - X(X'X)^{-1} X'y \\ &= My \\ &= MX\beta + Mu \\ &= Mu\end{aligned}$$

En el último paso se usó que $MX = (I - X(X'X)^{-1} X')X = X - X = 0$. El vector de residuos de MCC es entonces una transformación lineal del vector u . Entonces, es normal. Sus momentos relevantes son, bajo los supuestos de exogeneidad estricta y errores esféricos:

$$\begin{aligned}E(\hat{u}/X) &= ME(u|X) = 0_n \\ \Sigma_{\hat{u}} &= E[\hat{u}\hat{u}'/X] \\ &= E[Muu'M'/X] \\ &= E[Muu'M/X] \\ &= ME[uu'/X] M \\ &= \sigma_u^2 MM \\ &= \sigma_u^2 M\end{aligned}$$

en virtud de que M es simétrica e idempotente. Luego,

$$\boxed{\hat{u}/X \sim \mathcal{N}(0_n, \sigma_u^2 M)}$$

Sea $\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2}$:

$$\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} = \frac{\frac{RSS}{n-k}(n-k)}{\sigma_u^2} = \frac{RSS}{\sigma_u^2}$$

$$\begin{aligned}\text{Además :} \quad & RSS = \hat{u}'\hat{u} = u'M'Mu = u'Mu \\ \text{Entonces :} \quad & \frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} = \frac{u'Mu}{\sigma_u^2}\end{aligned}$$

Notar que M es idempotente y que $\frac{u}{\sigma_u} \sim N(0, I)$, entonces podemos aprovechar el Teorema B.8 para afirmar que:

$$\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} = \frac{u'Mu}{\sigma_u^2} \sim$$

$\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2}$ y $\hat{\beta}$ son transformaciones de u :

$$\begin{aligned}\hat{\beta} &= \beta + (X'X)^{-1} X'u \\ \frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} &= \frac{\hat{u}'\hat{u}}{\sigma_u^2} = \frac{u'Mu}{\sigma_u^2} \sim \chi_{\nu}^2\end{aligned}$$

Donde $v = \text{rank}(M) = \text{tr}(M)$ dado que M es idempotente. La traza de M es $n - k$:

$$\begin{aligned}
 \text{tr}(M) &= \text{tr}(I_n - X(X'X)^{-1}X') \\
 &= \text{tr}(I_n) - \text{tr}\left[(X)((X'X)^{-1}X')\right] \\
 &= \text{tr}(I_n) - \text{tr}\left[((X'X)^{-1}X')(X)\right] \\
 &= \text{tr}(I_n) - \text{tr}(I_k) \\
 &= n - k
 \end{aligned}$$

Entonces:

$$\boxed{\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} \sim \chi_{n-k}^2}$$

$\frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2}$ y $\hat{\beta}$ son transformaciones de u :

$$\begin{aligned}
 \hat{\beta} &= \beta + (X'X)^{-1}X'u \\
 \frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} &= \frac{\hat{u}'\hat{u}}{\sigma_u^2} = \frac{u'Mu}{\sigma_u^2}
 \end{aligned}$$

Aprovechando el Teorema 8.12, sabemos que estos dos vectores aleatorios son independientes si y sólo si:

$$\begin{aligned}
 (X'X)^{-1}X'M &= O_{k \times n} \\
 (X'X)^{-1}X'M' &= O_{k \times n} \\
 (X'X)^{-1}(MX)' &= O_{k \times n} \\
 (X'X)^{-1}O_{k \times n} &= O_{k \times n} \quad \checkmark
 \end{aligned}$$

2. Para este ejercicio se utilizarán las distribuciones derivadas en el punto 1. Sea $\hat{\beta}$:

$$\begin{aligned}
 \hat{\beta}/X &\sim \mathcal{N}\left(\beta, \sigma_u^2(X'X)^{-1}\right) \\
 (\hat{\beta} - \beta)' \left[\sigma_u^2(X'X)^{-1} \right]^{-1} (\hat{\beta} - \beta) &\sim \chi_k^2 \\
 \frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{\sigma_u^2} &\sim \chi_k^2 \\
 \frac{\hat{\sigma}_u^2(n-k)}{\sigma_u^2} &\sim \chi_{n-k}^2 \\
 \Rightarrow \frac{\left\{ \frac{[(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)]}{\sigma_u^2} \right\}}{\left\{ \frac{[\hat{\sigma}_u^2(n-k)]}{n-k} \right\}} &\sim \mathcal{F}(k, n-k) \\
 \frac{\left[\frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{k} \right]}{[\hat{\sigma}_u^2]} &\sim \mathcal{F}(k, n-k) \\
 \frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{k \hat{\sigma}_u^2} &\sim \mathcal{F}(k, n-k)
 \end{aligned}$$

La región de confianza es conceptualmente análoga al intervalo de confianza, para vectores de parámetros. En este caso,

$$\begin{aligned}
 P \left(\frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{k \hat{\sigma}_u^2} \leq \mathcal{F}_{1-\alpha}(k, n-k) \right) &= 1 - \alpha \\
 \boxed{C \left(\frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{k \hat{\sigma}_u^2} \leq \mathcal{F}_{1-\alpha}(k, n-k) \right)} &= 1 - \alpha
 \end{aligned}$$

La siguiente expresión:

$$\frac{(\hat{\beta} - \beta)' (X'X) (\hat{\beta} - \beta)}{k\hat{\sigma}_u^2} = \mathcal{F}_{1-\alpha}(k, n-k)$$

es simplemente una curva de nivel de una forma cuadrática. Para el caso $k = 2$, tiene representación gráfica como una elipse (o círculo, según los valores) en el espacio \mathbb{R}^2 .

Sea ahora $c'\beta$, c no nulo:

$$\begin{aligned} c'\hat{\beta}/X &\sim \mathcal{N}(c'\beta, \sigma_u^2 c'(X'X)^{-1}c) \\ \frac{c'(\hat{\beta} - \beta)}{\sqrt{\sigma_u^2 c'(X'X)^{-1}c}} &\sim \mathcal{N}(0, 1) \\ \frac{c'(\hat{\beta} - \beta)}{\sigma_u \sqrt{c'(X'X)^{-1}c}} &\sim \mathcal{N}(0, 1) \\ \frac{\left[\frac{c'(\hat{\beta} - \beta)}{\sigma_u \sqrt{c'(X'X)^{-1}c}} \right]}{\sqrt{\frac{(\hat{\sigma}_u^2 (n-k))}{\sigma_u^2}} \frac{1}{n-k}} &\sim \tau_{n-k} \\ \frac{\left[\frac{c'(\hat{\beta} - \beta)}{\sqrt{c'(X'X)^{-1}c}} \right]}{[\hat{\sigma}_u]} &\sim \tau_{n-k} \\ \frac{c'(\hat{\beta} - \beta)}{\hat{\sigma}_u \sqrt{c'(X'X)^{-1}c}} &\sim \tau_{n-k} \\ \hat{\sigma}_u \sqrt{c'(X'X)^{-1}c} &= \widehat{Se(c'\hat{\beta})} \end{aligned}$$

El intervalo de confianza es:

$$\begin{aligned} P\left(\left| \frac{c'(\hat{\beta} - \beta)}{\widehat{Se(c'\hat{\beta})}} \right| \leq \tau_{1-\alpha, n-k}\right) &= 1 - \alpha \\ P\left(-\tau_{1-\alpha, n-k} \leq \frac{c'(\hat{\beta} - \beta)}{\widehat{Se(c'\hat{\beta})}} \leq \tau_{1-\alpha, n-k}\right) &= 1 - \alpha \\ P\left(-\tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})} \leq c'(\hat{\beta} - \beta) \leq \tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})}\right) &= 1 - \alpha \\ C\left(-c'\hat{\beta} - \tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})} \leq -c'\beta \leq -c'\hat{\beta} + \tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})}\right) &= 1 - \alpha \\ \boxed{C\left(c'\hat{\beta} - \tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})} \leq c'\beta \leq c'\hat{\beta} + \tau_{1-\alpha, n-k} \widehat{Se(c'\hat{\beta})}\right)} &= 1 - \alpha \end{aligned}$$

3. $y_t = \beta_1 x_{1t} + \beta_2 x_{2t} + \beta_3 x_{3t} + u_t, \quad (t = 1, \dots, n)$

El primero es un Test de Significatividad Individual:

$$t = \frac{\hat{\beta}_2}{se(\hat{\beta}_2)} \sim t_{n-k}$$

Según los resultados obtenidos en el Problem Set 1:

$$t = \frac{\hat{\beta}_2}{se(\hat{\beta}_2)} = \frac{1}{\sqrt{\frac{1}{30}}} = \sqrt{30} = 5.4772$$

El segundo es un Test de Wald:

$$R = [1 \quad 1 \quad 0]$$

$$r = 2$$

$$H_0 : R\beta = 2$$

$$W = \frac{(R\hat{\beta} - r)' (R\hat{\sigma}^2 (X'X)^{-1} R')^{-1} (R\hat{\beta} - r)}{\#r} \sim F_{\#r, n-k}$$

Según los resultados obtenidos en el Problem Set 1:

$$W = \frac{10}{3} = 3.33.$$

4. Algunas consideraciones previas. Considere el modelo:

$$y = X\beta + u = X_1\beta_1 + X_2\beta_2 + u$$

Donde X_1 y X_2 son las observaciones de dos sets de variables.

De la condición de primer orden de minimización de RSS obteníamos:

$$\begin{aligned} (X'X)\hat{\beta} &= X'y \\ \left[(X_1 : X_2)'(X_1 : X_2) \right] \hat{\beta} &= (X_1 : X_2)'y \\ \left[\begin{bmatrix} X_1' \\ \vdots \\ X_2' \end{bmatrix} (X_1 : X_2) \right] \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} &= \begin{bmatrix} X_1' \\ \vdots \\ X_2' \end{bmatrix} y \\ \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} &= \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix} \end{aligned}$$

Tenemos entonces el siguiente sistema de ecuaciones:

$$X_1'X_1\hat{\beta}_1 + X_1'X_2\hat{\beta}_2 = X_1'y$$

$$X_2'X_1\hat{\beta}_1 + X_2'X_2\hat{\beta}_2 = X_2'y$$

Consideremos la primera parte de este sistema:

$$X_1'X_1\hat{\beta}_1 = X_1'y - X_1'X_2\hat{\beta}_2 \Rightarrow \hat{\beta}_1 = (X_1'X_1)^{-1}X_1'y - (X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2 \Rightarrow \hat{\beta}_1 = (X_1'X_1)^{-1}X_1'(y - X_2\hat{\beta}_2)$$

Notar que si $X_1'X_2 = 0$, entonces $\hat{\beta}_1 = (X_1'X_1)^{-1}X_1'y$, que es el resultado de regresar y sobre X_1 . Esto es un teorema: **en un modelo de regresión lineal múltiple de y sobre dos sets de variables X_1 y X_2 , si los dos sets de variables son ortogonales, entonces el vector de coeficientes estimados asociados a X_1 se puede obtener haciendo una regresión de y únicamente sobre X_1 ; idem para el vector de coeficientes estimados asociados a X_2 .**

Ahora tomemos la segunda parte del sistema e insertemos la expresión obtenida para $\hat{\beta}_1$:

$$X_2'X_1\hat{\beta}_1 + X_2'X_2\hat{\beta}_2 = X_2'y$$

$$X_2'X_1(X_1'X_1)^{-1}X_1'(y - X_2\hat{\beta}_2) + X_2'X_2\hat{\beta}_2 = X_2'y$$

$$X_2'X_1(X_1'X_1)^{-1}X_1'y - X_2'X_1(X_1'X_1)^{-1}X_1'X_2\hat{\beta}_2 + X_2'X_2\hat{\beta}_2 = X_2'y$$

$$X_2'(X_1(X_1'X_1)^{-1}X_1'y - y) = X_2'(X_1(X_1'X_1)^{-1}X_1'X_2 - X_2)\hat{\beta}_2$$

$$X_2'(X_1(X_1'X_1)^{-1}X_1' - I)y = X_2'(X_1(X_1'X_1)^{-1}X_1' - I)X_2\hat{\beta}_2$$

$$X_2'(I - X_1(X_1'X_1)^{-1}X_1')y = X_2'(I - X_1(X_1'X_1)^{-1}X_1')X_2\hat{\beta}_2$$

$$[X_2'(I - X_1(X_1'X_1)^{-1}X_1')X_2]^{-1}X_2'(I - X_1(X_1'X_1)^{-1}X_1')y = \hat{\beta}_2$$

$$\hat{\beta}_2 = [X_2'M_1X_2]^{-1}X_2'M_1y$$

Finalmente:

$$\hat{\beta}_1 = [X_1'M_2X_1]^{-1}X_1'M_2y$$

Ahora bien, en el ejercicio 1 se vio que, dado $y = X\beta + u$, los residuos de la regresión pueden escribirse: $\hat{u} = My$, donde $M = I - X(X'X)^{-1}X'$. Análogamente, podemos ver a M_1X_2 como una matriz de residuos, donde cada columna de M_1X_2 es un vector de residuos provenientes de una regresión de dicha columna de X_2 contra X_1 . Esta observación nos lleva al Teorema de Frisch-Waugh:

Theorem 3 Teorema de Frisch-Waugh. *En una regresión lineal de y contra dos sets de variables, X_1 y X_2 , el subvector $\hat{\beta}_2$ se puede obtener regresando los residuos provenientes de regresar y contra X_1 , contra los residuos provenientes de regresar cada columna de X_2 contra X_1 .*

Demostración:

Se realizan las regresiones de y y de todas las columnas de X_2 sobre X_1 :

$$\begin{aligned} y &= X_1\gamma + v \\ X_2 &= X_1\Delta + W \end{aligned}$$

El segundo modelo es simplemente una notación compactada de todas las regresiones de cada columna de X_2 . Nótese que Δ y W son matrices de coeficientes y residuos, respectivamente. Los estimadores de MCC y residuos asociados son:

$$\begin{aligned}\hat{\gamma} &= (X_1' X_1)^{-1} X_1' y \\ \hat{v} &= y - X_1 \hat{\gamma} = M_1 y \\ \hat{\Delta} &= (X_1' X_1)^{-1} X_1' X_2 \\ \widehat{W} &= X_2 - X_1 \hat{\Delta} = M_1 X_2 \\ \text{Donde } M_1 &= I_n - X_1 (X_1' X_1)^{-1} X_1'\end{aligned}$$

Sea ahora la regresión de los residuos del primer modelo sobre la matriz de residuos del segundo modelo:

$$\begin{aligned}\hat{v} &= \widehat{W} \phi + \varepsilon \\ \hat{\phi} &= (\widehat{W}' \widehat{W})^{-1} \widehat{W}' \hat{v} \\ \hat{\phi} &= (X_2' M_1' M_1 X_2)^{-1} X_2' M_1' M_1 y \\ \hat{\phi} &= (X_2' M_1 X_2)^{-1} X_2' M_1 y\end{aligned}$$

Por los resultados de regresión particionada,

$$\hat{\beta}_2 = (X_2' M_1 X_2)^{-1} X_2' M_1 y$$

Luego,

$$\boxed{\hat{\phi} = \hat{\beta}_2}$$

que es el resultado de Frisch-Waugh. Intercambiando los subíndices 1 y 2 es claro que también vale para $\hat{\beta}_1$.

Notar:

$$\begin{aligned}\hat{\phi} &= (X_2' X_2)^{-1} X_2' y \Leftrightarrow M_1 X_2 = X_2 \\ \Leftrightarrow X_2 - X_1 (X_1' X_1)^{-1} X_1' X_2 &= X_2 \\ \Leftrightarrow X_1 (X_1' X_1)^{-1} X_1' X_2 &= O \\ \Leftrightarrow \boxed{X_1' X_2 = O}\end{aligned}$$

En este caso se dice que los regresores son ortogonales.

Nótese entonces que en un modelo de regresión lineal múltiple con variable dependiente salario y variables explicativas educación y promedio en la carrera de grado, para obtener la estimación de mínimos cuadrados clásicos del coeficiente de educación se puede:

-Empezar regresando salario sobre promedio; y educación sobre promedio.

-Obtener los residuos de la primera regresión y regresarlos sobre los residuos de la segunda regresión.

Así acabamos haciendo solamente regresiones simples.

5. Sea el modelo

$$y = X\beta + c.z + u = \begin{bmatrix} X & \vdots & z \end{bmatrix} \begin{bmatrix} \beta \\ \cdots \\ c \end{bmatrix} + u$$

donde z es un vector columna con las observaciones de uno de los regresores del modelo. Se asume que la primer columna de X es una columna de unos.

Considere las regresiones parciales respecto de X y los residuos asociados:

$$\begin{aligned}y^* &= y - X\hat{\theta} \\ z^* &= z - X\hat{\eta}\end{aligned}$$

Como ambas regresiones tienen intercepto,

$$\sum_{i=1}^n y_i^* = \sum_{i=1}^n z_i^* = 0 \Rightarrow \overline{y^*} = \overline{z^*} = 0$$

Del ejercicio anterior sabemos que podemos obtener \hat{c} de regresar y^* contra z^* : $y^* = cz^* + \varepsilon$.

El coeficiente de correlación (muestral) parcial entre y, z respecto de X es:

$$r_{y,z;X} = r_{y^*,z^*} = \frac{\frac{1}{n} \sum_{i=1}^n (y_i^* - \bar{y}^*) (z_i^* - \bar{z}^*)}{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i^* - \bar{y}^*)^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (z_i^* - \bar{z}^*)^2}} = \frac{y^{*T} z^*}{\sqrt{y^{*T} y^*} \sqrt{z^{*T} z^*}}$$

De acuerdo a los resultados de regresión particionada y de de MCC,

$$\begin{aligned} y^* &= \hat{c} z^* + \hat{\varepsilon} : z^{*T} \hat{\varepsilon} = 0 \\ y^{*T} &= \hat{c} z^{*T} + \hat{\varepsilon}' \\ y^{*T} z^* &= \hat{c} z^{*T} z^* + \hat{\varepsilon}' z^* = c (z^{*T} z^*) \end{aligned}$$

Reemplazando esta expresión en el coeficiente de correlación parcial,

$$r_{y,z;X} = \hat{c} \frac{\sqrt{z^{*T} z^*}}{\sqrt{y^{*T} y^*}}$$

6. Sea Q_n la matriz sample demeaning:

$$\begin{aligned} Q_n x &= \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} - \begin{bmatrix} \bar{x} \\ \vdots \\ \bar{x} \end{bmatrix} = \tilde{x} \\ Q_n &= I_n - \frac{1}{n} 1_n 1_n' \end{aligned}$$

Sea el modelo con intercepto:

$$y = X\beta + u$$

y la partición:

$$y = \begin{bmatrix} 1_n & \vdots & X_{-1} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_{-1} \end{bmatrix} + u$$

donde β_1 es el intercepto del modelo.

Por los resultados de regresión particionada,

$$\begin{aligned} \hat{\beta}_{-1} &= (X_{-1}' M_1 X_{-1})^{-1} X_{-1}' M_1 y \\ \hat{\beta}_{-1} &= (X_{-1}' M_1' M_1 X_{-1})^{-1} X_{-1}' M_1' M_1 y \\ \hat{\beta}_{-1} &= [(M_1 X_{-1})' (M_1 X_{-1})]^{-1} (M_1 X_{-1})' (M_1 y) \\ M_1 &= I_n - 1_n (1_n' 1_n)^{-1} 1_n' \\ M_1 &= I_n - 1_n (n)^{-1} 1_n' \\ M_1 &= I_n - \frac{1}{n} 1_n 1_n' \\ &\Rightarrow M_1 = Q_n \\ \hat{\beta}_{-1} &= [(Q_n X_{-1})' (Q_n X_{-1})]^{-1} (Q_n X_{-1})' (Q_n y) \\ &\quad \boxed{\hat{\beta}_{-1} = [\tilde{X}_{-1}' \tilde{X}_{-1}]^{-1} \tilde{X}_{-1}' \tilde{y}} \end{aligned}$$

7. El estimador de mínimos cuadrados restringidos es el estimador de β que resuelve el siguiente problema:

$$\begin{aligned} &\min_{\tilde{\beta}} (y - X\tilde{\beta})' (y - X\tilde{\beta}) \\ \text{s.a.} \quad &R\tilde{\beta} = r \end{aligned}$$

El lagrangiano del problema es:

$$\begin{aligned} \mathcal{L} &= (y - X\tilde{\beta})' (y - X\tilde{\beta}) - 2\lambda' (R\tilde{\beta} - r) \\ &= y'y - 2y'X\tilde{\beta} + \tilde{\beta}'X'X\tilde{\beta} - 2\lambda' (R\tilde{\beta} - r) \end{aligned}$$

Las condiciones de primer orden son:

$$\begin{aligned} -2X'y + 2X'X\tilde{\beta} - 2R'\lambda &= 0 \\ R\tilde{\beta} &= r \end{aligned}$$

Trabajamos un poco las expresiones:

$$\begin{aligned} -X'y + X'X\tilde{\beta} - R'\lambda &= 0 \\ -R(X'X)^{-1}X'y + R(X'X)^{-1}X'X\tilde{\beta} &= R(X'X)^{-1}R'\lambda \\ -R\hat{\beta} + R\tilde{\beta} &= R(X'X)^{-1}R'\lambda \\ -R\hat{\beta} + r &= R(X'X)^{-1}R'\lambda \\ (R(X'X)^{-1}R')^{-1}(r - R\hat{\beta}) &= \lambda \\ -X'y + X'X\tilde{\beta} - R'(R(X'X)^{-1}R')^{-1}(r - R\hat{\beta}) &= 0 \end{aligned}$$

$$\begin{aligned} X'X\tilde{\beta} &= X'y + R'(R(X'X)^{-1}R')^{-1}(r - R\hat{\beta}) \\ \tilde{\beta} &= (X'X)^{-1}X'y + (X'X)^{-1}R'(R(X'X)^{-1}R')^{-1}(r - R\hat{\beta}) \\ \tilde{\beta} &= \hat{\beta} + (X'X)^{-1}R'(R(X'X)^{-1}R')^{-1}(r - R\hat{\beta}) \\ \tilde{\beta} &= \hat{\beta} - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r) \\ \tilde{\beta} &= \left\{ I_k - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R \right\} \hat{\beta} \\ &\quad + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}r \end{aligned}$$

Reescribimos usando $\hat{\beta} = \beta + (X'X)^{-1}X'u$

$$\begin{aligned} \tilde{\beta} &= \left\{ I_k - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R \right\} \beta \\ &\quad + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}r \\ &\quad + \left\{ I_k - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R \right\} (X'X)^{-1}X'u \\ &= \beta - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R\beta \\ &\quad + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}r \\ &\quad + \left\{ I_k - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R \right\} (X'X)^{-1}X'u \\ &= \beta + \left\{ I_k - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R \right\} (X'X)^{-1}X'u \\ &= \beta + Cu \end{aligned}$$

que es una transformación afín de u . Luego, es normal. Busquemos la esperanza y varianza:

$$\begin{aligned} E(\tilde{\beta}/X) &= \beta \\ Var(\tilde{\beta}/X) &= E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' / X] \\ &= E[Cu(Cu)' / X] \\ &= CE[uu' / X]C \\ &= \sigma_u^2 CC' \\ &= \sigma_u^2 \left\{ (X'X)^{-1} - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1} \right\} \end{aligned}$$

La distribución es:

$$\widehat{\beta}_R/X \sim \mathcal{N} \left(\beta, \sigma_u^2 \left\{ (X'X)^{-1} - (X'X)^{-1} R' \left[R (X'X)^{-1} R' \right]^{-1} R (X'X)^{-1} \right\} \right)$$

8. El vector de residuos restringidos y su suma de cuadrados son:

$$\begin{aligned} \widehat{u}_R &= y - X\widehat{\beta}_R \\ &= y - X\widehat{\beta}_R + X\widehat{\beta} - X\widehat{\beta} \\ &= \widehat{u} - X(\widehat{\beta}_R - \widehat{\beta}) \\ \widehat{u}_R' \widehat{u}_R &= [\widehat{u} - X(\widehat{\beta}_R - \widehat{\beta})]' [\widehat{u} - X(\widehat{\beta}_R - \widehat{\beta})] \\ &= \widehat{u}' \widehat{u} + (\widehat{\beta}_R - \widehat{\beta})' X' X (\widehat{\beta}_R - \widehat{\beta}) \\ &\quad - (\widehat{\beta}_R - \widehat{\beta})' X' \widehat{u} - \widehat{u}' X (\widehat{\beta}_R - \widehat{\beta}) \\ X' \widehat{u} &= 0_k \Rightarrow \widehat{u}_R' \widehat{u}_R = \widehat{u}' \widehat{u} + (\widehat{\beta}_R - \widehat{\beta})' X' X (\widehat{\beta}_R - \widehat{\beta}) \\ \widehat{\beta}_R - \widehat{\beta} &= -(X'X)^{-1} R' [R (X'X)^{-1} R']^{-1} (R\widehat{\beta} - r) \\ (\widehat{\beta}_R - \widehat{\beta})' X' X (\widehat{\beta}_R - \widehat{\beta}) &= (R\widehat{\beta} - r)' [R (X'X)^{-1} R']^{-1} R (X'X)^{-1} (X'X) \\ &\quad (X'X)^{-1} R' [R (X'X)^{-1} R']^{-1} (R\widehat{\beta} - r) \\ &= (R\widehat{\beta} - r)' [R (X'X)^{-1} R']^{-1} R (X'X)^{-1} \\ &\quad R' [R (X'X)^{-1} R']^{-1} (R\widehat{\beta} - r) \\ &= (R\widehat{\beta} - r)' [R (X'X)^{-1} R']^{-1} (R\widehat{\beta} - r) \\ &\Rightarrow \boxed{\widehat{u}_R' \widehat{u}_R - \widehat{u}' \widehat{u} = (R\widehat{\beta} - r)' [R (X'X)^{-1} R']^{-1} (R\widehat{\beta} - r) \geq 0} \end{aligned}$$

Este resultado implica que el estadístico F equivale al siguiente estadístico de residuos restringidos:

$$\begin{aligned} \frac{\left[\frac{\widehat{u}_R' \widehat{u}_R - \widehat{u}' \widehat{u}}{q} \right]}{\widehat{\sigma}_u^2} &\sim {}^{H_0} \mathcal{F}(q, n-k) \\ \frac{\left[\frac{\widehat{u}_R' \widehat{u}_R - \widehat{u}' \widehat{u}}{q} \right]}{\left[\frac{\widehat{u}' \widehat{u}}{n-k} \right]} &\sim {}^{H_0} \mathcal{F}(q, n-k) \\ &\boxed{\frac{\left[\frac{SSR_R - SSR}{q} \right]}{\left[\frac{SSR}{n-k} \right]} \sim {}^{H_0} \mathcal{F}(q, n-k)} \end{aligned}$$

9. Para probar este resultado, nótese que la inclusión de nuevos regresores a un modelo puede pensarse como un caso particular de una restricción de exclusión de q variables:

$$y = X\beta + \varepsilon \rightarrow y = X\beta + Z\gamma + u \Leftrightarrow \gamma = 0_q$$

donde Z es la matriz de observaciones de q regresores adicionales. Sean RSS_0 la suma de residuos cuadrados del modelo restringido y RSS_1 , del modelo ampliado. Estas sumas pueden pensarse como:

$$\begin{aligned} RSS_1 &= RSS = \widehat{u}' \widehat{u} \\ RSS_0 &= RSS_R = \widehat{\varepsilon}' \widehat{\varepsilon} = \widehat{u}_R' \widehat{u}_R \end{aligned}$$

Por el resultado del ejercicio 8:

$$\begin{aligned}
\hat{u}'_R \hat{u}_R &\geq \hat{u}' \hat{u} \\
\frac{\hat{u}'_R \hat{u}_R}{y'y - n\bar{y}^2} &\geq \frac{\hat{u}' \hat{u}}{y'y - n\bar{y}^2} \\
-\frac{\hat{u}'_R \hat{u}_R}{y'y - n\bar{y}^2} &\leq -\frac{\hat{u}' \hat{u}}{y'y - n\bar{y}^2} \\
1 - \frac{\hat{u}'_R \hat{u}_R}{y'y - n\bar{y}^2} &\leq 1 - \frac{\hat{u}' \hat{u}}{y'y - n\bar{y}^2} \\
\boxed{R_0^2 \leq R_1^2} &\checkmark
\end{aligned}$$

10. Probamos la convergencia en probabilidad. Sea

$$\begin{aligned}
\hat{\sigma}_u^2 &= \frac{\hat{u}' \hat{u}}{n - k} \\
&= \frac{u' M u}{n - k} \\
&= \frac{u' u - u' X (X' X)^{-1} X' u}{n - k} \\
&= \frac{n}{n - k} \left(\frac{u' u}{n} - \frac{u' X}{n} \left(\frac{X' X}{n} \right)^{-1} \frac{X' u}{n} \right) \\
p \lim \hat{\sigma}_u^2 &= 1. (E(u_i^2) - 0'_k Q^{-1} 0_k) \\
p \lim \hat{\sigma}_u^2 &= E(u_i^2) \\
p \lim \hat{\sigma}_u^2 &= \sigma_u^2
\end{aligned}$$

11. Sea el modelo simple

$$y_i = \alpha + \beta x_i^* + u_i$$

El investigador estima en su lugar el siguiente modelo

$$\begin{aligned}
y_i &= \alpha + \beta (x_i - \varepsilon_i) + u_i \\
y_i &= \alpha + \beta x_i + u_i - \beta \varepsilon_i \\
y_i &= \alpha + \beta x_i + v_i
\end{aligned}$$

Por tratarse de un modelo simple:

$$\begin{aligned}
\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}) (\alpha + \beta x_i + v_i)}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}) \alpha}{\sum_{i=1}^n (x_i - \bar{x})^2} + \beta \frac{\sum_{i=1}^n (x_i - \bar{x}) x_i}{\sum_{i=1}^n (x_i - \bar{x})^2} + \frac{\sum_{i=1}^n (x_i - \bar{x}) v_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
\hat{\beta} &= \beta + \frac{\sum_{i=1}^n (x_i - \bar{x}) v_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
&= \beta + \frac{\left(\frac{\sum_{i=1}^n (x_i - \bar{x}) v_i}{n} \right)}{\left(\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \right)} \\
p \lim \hat{\beta} &= \beta + \frac{cov(x_i, v_i / X)}{var(x_i / X)}
\end{aligned}$$

En este caso,

$$\begin{aligned}
cov(x_i^*, \varepsilon_i/X) &= 0 \\
var(x_i/X) &= \sigma_{x^*}^2 + \sigma_\varepsilon^2 \\
cov(x_i, v_i/X) &= E(x_i \cdot v_i/X) \\
&= E(x_i \cdot u_i/X) - \beta E(x_i \cdot \varepsilon_i/X) \\
&= E(x_i \cdot u_i/X) - \beta E((x_i^* + \varepsilon_i) \cdot \varepsilon_i/X) \\
&= 0 - \beta 0 - \beta \sigma_\varepsilon^2 \\
&= -\beta \sigma_\varepsilon^2 \\
\Rightarrow p \lim \hat{\beta} &= \beta - \frac{\beta \sigma_\varepsilon^2}{\sigma_{x^*}^2 + \sigma_\varepsilon^2} \\
p \lim \hat{\beta} &= \beta \left[1 - \frac{\sigma_\varepsilon^2}{\sigma_{x^*}^2 + \sigma_\varepsilon^2} \right] \\
&= \beta \left[\frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_\varepsilon^2} \right] \\
&= \beta \left[\frac{1}{1 + \left(\frac{\sigma_\varepsilon^2}{\sigma_{x^*}^2} \right)} \right]
\end{aligned}$$

El estimador de MCC del coeficiente pendiente es inconsistente. El parámetro aparece multiplicado por un factor menos a uno, que se conoce como "sesgo de atenuación". El tamaño de este sesgo depende de la varianza relativa de la variable y el error de medición. Si este error fuera sistemático, $\sigma_\varepsilon^2 = 0$, el estimador preservaría la consistencia.