

Trabajo Práctico N° 0: **Repaso de Matemática.**

Ejercicio 1.

Si A es una matriz simétrica y definida positiva, mostrar que puede hallarse una matriz P no singular tal que se verifica que $A = PP'$.

Como A es una matriz cuadrada simétrica ($A = A'$), se puede diagonalizar ortogonalmente:

$$A = CDC'$$

$$A = CD^{\frac{1}{2}}D^{\frac{1}{2}}C'$$

$$\text{donde } D^{\frac{1}{2}} = \text{diag}(\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_K})$$

$$A = CD^{\frac{1}{2}}(D^{\frac{1}{2}})'C'$$

$$A = CD^{\frac{1}{2}}(CD^{\frac{1}{2}})'$$

$$A = PP',$$

$$\text{donde } P = CD^{\frac{1}{2}}.$$

A su vez, se tiene que:

$$\det(P) = \det(CD^{\frac{1}{2}})$$

$$\det(P) = \det(C) \det(D^{\frac{1}{2}})$$

$$\det(P) \neq 0.$$

Como A es una matriz diagonalizable ortogonalmente (producto de ser una matriz cuadrada simétrica), $\det(C) \neq 0$ y, como A es definida positiva, $\det(D^{\frac{1}{2}}) \neq 0$, por lo que $\det(P) \neq 0$ y, por lo tanto, P es una matriz no singular.

Ejercicio 2.

Sea x un vector aleatorio de $n \times 1$ tal que $x \sim \mathcal{N}(\mu, \Sigma)$, donde Σ es una matriz simétrica y definida positiva. Mostrar que $(x - \mu)' \Sigma^{-1} (x - \mu) \sim \chi^2(n)$.

Como Σ es una matriz simétrica y definida positiva, existe una matriz P no singular tal que:

$$\Sigma = PP'.$$

Luego, se tiene:

$$\Sigma^{-1} = (PP')^{-1}$$

$$\Sigma^{-1} = (P')^{-1} P^{-1}$$

$$(x - \mu)' \Sigma^{-1} (x - \mu) = (x - \mu)' (P')^{-1} P^{-1} (x - \mu)$$

$$(x - \mu)' \Sigma^{-1} (x - \mu) = (x - \mu)' (P^{-1})' P^{-1} (x - \mu)$$

$$(x - \mu)' \Sigma^{-1} (x - \mu) = [P^{-1} (x - \mu)]' P^{-1} (x - \mu)$$

$$(x - \mu)' \Sigma^{-1} (x - \mu) = y'y, \quad \text{donde } y = P^{-1} (x - \mu).$$

Notar que:

$$E(y) = E[P^{-1} (x - \mu)]$$

$$E(y) = P^{-1} E(x - \mu)$$

$$E(y) = P^{-1} [E(x) - E(\mu)]$$

$$E(y) = P^{-1} (\mu - \mu)$$

$$E(y) = P^{-1} * 0$$

$$E(y) = 0.$$

y

$$V(y) = E(yy')$$

$$V(y) = E\{P^{-1} (x - \mu) [P^{-1} (x - \mu)]'\}$$

$$V(y) = E[P^{-1} (x - \mu) (x - \mu)' (P^{-1})']$$

$$V(y) = P^{-1} E[(x - \mu) (x - \mu)'] (P^{-1})'$$

$$V(y) = P^{-1} \Sigma (P^{-1})'$$

$$V(y) = P^{-1} PP' (P')^{-1}$$

$$V(y) = I$$

$$V(y) = I.$$

Por lo tanto, y es una transformación afín de un vector de variables normales, pero no son necesariamente independientes.

Siendo $y = g(x) \Rightarrow g^{-1}(y) = x$, entonces (cambio de variable):

$$f_Y(y) = f_X(g^{-1}(y)) |\det(\nabla g^{-1}(y))|.$$

Ahora, considerando:

$$y = P^{-1}(x - \mu)$$

$$y = P^{-1}x - P^{-1}\mu \equiv g(x).$$

$$x = Py + \mu \equiv g^{-1}(y).$$

$$\nabla g^{-1}(y) = P.$$

Y, teniendo en cuenta que:

$$f_X(x) = \frac{1}{(2\pi)^{\frac{n}{2}}(\det(\Sigma))^{\frac{1}{2}}} e^{\left[\frac{-1}{2}(x-\mu)' \Sigma^{-1}(x-\mu)\right]}$$

Y que:

$$\det(\Sigma) = \det(PP')$$

$$\det(\Sigma) = \det(P) \det(P')$$

$$\det(\Sigma) = \det(P) \det(P)$$

$$\det(\Sigma) = [\det(P)]^2$$

$$\sqrt{\det(\Sigma)} = |\det(P)|.$$

Entonces, se tiene:

$$f_Y(y) = f_X(g^{-1}(y)) |\det(\nabla g^{-1}(y))|$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}[\det(\Sigma)]^{\frac{1}{2}}} e^{\left[\frac{-1}{2}(g^{-1}(y)-\mu)' \Sigma^{-1}(g^{-1}(y)-\mu)\right]} |\det(P)|$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}[\det(\Sigma)]^{\frac{1}{2}}} e^{\left[\frac{-1}{2}(Py+\mu-\mu)' \Sigma^{-1}(Py+\mu-\mu)\right]} \sqrt{\det(\Sigma)}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left[\frac{-1}{2}(Py)' \Sigma^{-1}Py\right]}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left(\frac{-1}{2}y'P'\Sigma^{-1}Py\right)}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left[\frac{-1}{2}y'P'(PP')^{-1}Py\right]}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left[\frac{-1}{2}y'P'(P')^{-1}P^{-1}Py\right]}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left(\frac{-1}{2}y'IIy\right)}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left(\frac{-1}{2}y'Iy\right)}$$

$$f_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{\left(\frac{-1}{2}y'y\right)}.$$

En conclusión, $y \sim \mathcal{N}(0_n, I_n)$ y, considerando que la suma de variables aleatorias normales estándar independientes elevadas al cuadrado tiene una distribución χ_n^2 , se tiene:

$$y_1^2 + y_2^2 + \dots + y_n^2 \sim \chi_n^2$$

$$y'y \sim \chi_n^2$$

$$(x - \mu)' \Sigma^{-1} (x - \mu) \sim \chi_n^2.$$

Ejercicio 3.

Sea x un vector aleatorio de $n \times 1$, siendo $x \sim \mathcal{N}(0_n, I_n)$, y A y B son matrices de $n \times n$ simétricas e idempotentes. Mostrar que las formas cuadráticas $x'Ax$ y $x'Bx$ son independientes si y sólo si $AB = 0$.

Dado que A y B son matrices simétricas e idempotentes, se tiene:

$$\begin{aligned} x'Ax &= x'AAx \\ x'Ax &= x'A'Ax \\ x'Ax &= (Ax)'Ax \\ x'Ax &= g(Ax) \end{aligned}$$

y

$$\begin{aligned} x'Bx &= x'BBx \\ x'Bx &= x'B'Bx \\ x'Bx &= (Bx)'Bx \\ x'Bx &= g(Bx). \end{aligned}$$

Luego, como Ax y Bx son transformaciones lineales de un vector normal estándar, se tiene:

$$\begin{aligned} Ax &\sim \mathcal{N}(0_n, AA') \\ Ax &\sim \mathcal{N}(0_n, A) \end{aligned}$$

y

$$\begin{aligned} Bx &\sim \mathcal{N}(0_n, BB') \\ Bx &\sim \mathcal{N}(0_n, B). \end{aligned}$$

Entonces, se tiene:

$$\begin{aligned} \text{Cov}(Ax, Bx) &= E[(Ax)(Bx)'] \\ \text{Cov}(Ax, Bx) &= E(Axx'B) \\ \text{Cov}(Ax, Bx) &= A E(xx') B \\ \text{Cov}(Ax, Bx) &= A E(xx') B \\ \text{Cov}(Ax, Bx) &= A I_n B \\ \text{Cov}(Ax, Bx) &= AB. \end{aligned}$$

Por lo tanto, si $AB = 0$, entonces, Ax y Bx son independientes (por tratarse de vectores normales) y, si estos lo son, las formas cuadráticas $x'Ax$ y $x'Bx$ también lo son.

Ejercicio 4.

Sean x e y variables aleatorias con función de densidad conjunta:

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{\frac{-C}{2(1-\rho^2)}}, \quad x, y \in \mathbb{R},$$

donde

$$C = \left(\frac{x-\mu_x}{\sigma_x}\right)^2 \left(\frac{y-\mu_y}{\sigma_y}\right)^2 - 2\rho \frac{x-\mu_x}{\sigma_x} \frac{y-\mu_y}{\sigma_y},$$

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_x\sigma_y},$$

$$\sigma_x^2 = \text{Var}(X), \quad \sigma_y^2 = \text{Var}(Y).$$

Mostrar que las variables aleatorias u y v , $u = \frac{x-\mu_x}{\sigma_x}$ y $v = \frac{y-\mu_y}{\sigma_y}$, son independientes y tienen distribución normal con media cero y varianzas $2(1+\rho)$ y $2(1-\rho)$, respectivamente.

Trabajando con C , se tiene:

$$C = \left(\frac{x-\mu_x}{\sigma_x}\right)^2 \left(\frac{y-\mu_y}{\sigma_y}\right)^2 - 2\rho \frac{x-\mu_x}{\sigma_x} \frac{y-\mu_y}{\sigma_y}$$

$$C = \frac{1}{\sigma_x^2} (x - \mu_x)^2 \frac{1}{\sigma_y^2} (y - \mu_y)^2 - \frac{2\rho}{\sigma_x\sigma_y} (x - \mu_x)(y - \mu_y)$$

$$C = \begin{bmatrix} x - \mu_x & y - \mu_y \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_x^2} & \frac{-\rho}{\sigma_x\sigma_y} \\ \frac{-\rho}{\sigma_x\sigma_y} & \frac{1}{\sigma_y^2} \end{bmatrix} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}.$$

Ahora, se define:

$$\Sigma = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix},$$

Entonces, se tiene:

$$\Sigma^{-1} = \frac{1}{\det(\Sigma)} \text{adj}(\Sigma)$$

$$\Sigma^{-1} = \frac{1}{\sigma_x^2\sigma_y^2 - \sigma_{xy}^2} \begin{bmatrix} \sigma_y^2 & -\sigma_{xy} \\ -\sigma_{xy} & \sigma_x^2 \end{bmatrix}$$

$$\Sigma^{-1} = \frac{1}{\sigma_x^2\sigma_y^2 - \rho^2\sigma_x^2\sigma_y^2} \begin{bmatrix} \sigma_y^2 & -\sigma_{xy} \\ -\sigma_{xy} & \sigma_x^2 \end{bmatrix}$$

$$\Sigma^{-1} = \frac{1}{(1-\rho^2)\sigma_x^2\sigma_y^2} \begin{bmatrix} \sigma_y^2 & -\sigma_{xy} \\ -\sigma_{xy} & \sigma_x^2 \end{bmatrix}$$

$$\Sigma^{-1} = \frac{1}{(1-\rho^2)} \begin{bmatrix} \frac{1}{\sigma_x^2} & \frac{-\rho}{\sigma_x\sigma_y} \\ \frac{-\rho}{\sigma_x\sigma_y} & \frac{1}{\sigma_y^2} \end{bmatrix}$$

$$(1 - \rho^2) \Sigma^{-1} = \begin{bmatrix} \frac{1}{\sigma_x^2} & \frac{-\rho}{\sigma_x^2 \sigma_y^2} \\ \frac{-\rho}{\sigma_x^2 \sigma_y^2} & \frac{1}{\sigma_y^2} \end{bmatrix}.$$

Relacionándolo con el resultado anterior, se tiene:

$$C = [x - \mu_x \quad y - \mu_y] (1 - \rho^2) \Sigma^{-1} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}$$

$$\frac{C}{1 - \rho^2} = [x - \mu_x \quad y - \mu_y] \Sigma^{-1} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}.$$

Se definen los vectores aleatorios $z = \begin{bmatrix} x \\ y \end{bmatrix}$ y $\mu_z = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}$, de modo que:

$$\frac{C}{1 - \rho^2} = (z - \mu_z)' \Sigma^{-1} (z - \mu_z).$$

Luego:

$$f_Z(z) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{\frac{-C}{2(1-\rho^2)}}$$

$$f_Z(z) = \frac{1}{2\pi} \frac{1}{\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{\frac{-1}{2}(z-\mu_z)'\Sigma^{-1}(z-\mu_z)}$$

$$f_Z(z) = \frac{1}{2\pi} \frac{1}{\sqrt{\det \Sigma}} e^{\frac{-1}{2}(z-\mu_z)'\Sigma^{-1}(z-\mu_z)}.$$

Entonces, $z \sim \mathcal{N}(\mu_z, \Sigma)$.

Se considera el siguiente vector aleatorio:

$$w = \begin{bmatrix} u \\ v \end{bmatrix}$$

$$w = \begin{bmatrix} \frac{x-\mu_x}{\sigma_x} + \frac{y-\mu_y}{\sigma_y} \\ \frac{x-\mu_x}{\sigma_x} - \frac{y-\mu_y}{\sigma_y} \end{bmatrix}$$

$$w = \begin{bmatrix} \frac{1}{\sigma_x} & \frac{1}{\sigma_y} \\ \frac{1}{\sigma_x} & \frac{-1}{\sigma_y} \end{bmatrix} \begin{bmatrix} x - \mu_x \\ y - \mu_y \end{bmatrix}$$

$$w = \begin{bmatrix} \frac{1}{\sigma_x} & \frac{1}{\sigma_y} \\ \frac{1}{\sigma_x} & \frac{-1}{\sigma_y} \end{bmatrix} (z - \mu_z) \equiv h(z).$$

Y vale que:

$$z = \begin{bmatrix} \frac{1}{\sigma_x} & \frac{1}{\sigma_y} \\ \frac{1}{\sigma_x} & \frac{-1}{\sigma_y} \end{bmatrix}^{-1} w + \mu_z$$

$$Z = \frac{1}{\frac{1}{\sigma_x} \left(\frac{-1}{\sigma_y} \right) - \frac{1}{\sigma_y \sigma_x}} \begin{bmatrix} \frac{-1}{\sigma_y} & \frac{-1}{\sigma_y} \\ \frac{-1}{\sigma_x} & \frac{1}{\sigma_x} \end{bmatrix} W + \mu_Z$$

$$Z = \frac{1}{\frac{-1}{\sigma_x \sigma_y} - \frac{1}{\sigma_y \sigma_x}} \begin{bmatrix} \frac{-1}{\sigma_y} & \frac{-1}{\sigma_y} \\ \frac{-1}{\sigma_x} & \frac{1}{\sigma_x} \end{bmatrix} W + \mu_Z$$

$$Z = \frac{1}{\frac{-2}{\sigma_y \sigma_x}} \begin{bmatrix} \frac{-1}{\sigma_y} & \frac{-1}{\sigma_y} \\ \frac{-1}{\sigma_x} & \frac{1}{\sigma_x} \end{bmatrix} W + \mu_Z$$

$$Z = \frac{-\sigma_y \sigma_x}{2} \begin{bmatrix} \frac{-1}{\sigma_y} & \frac{-1}{\sigma_y} \\ \frac{-1}{\sigma_x} & \frac{1}{\sigma_x} \end{bmatrix} W + \mu_Z$$

$$Z = \frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W + \mu_Z \equiv h^{-1}(W).$$

$$\nabla h^{-1}(W) = \frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix}.$$

Nuevamente, se usa que:

$$f_W(W) = f_Z(h^{-1}(W)) |\det(\nabla h^{-1}(W))|$$

$$f_Y(Y) = \frac{1}{2\pi\sqrt{\det(\Sigma)}} e^{\left\{ \frac{-1}{2} [h^{-1}(W) - \mu_Z]' \Sigma^{-1} [h^{-1}(W) - \mu_Z] \right\}} \left| \frac{-\sigma_x \sigma_y}{2} \right|$$

$$f_Y(Y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{\left\{ \frac{-1}{2} \left[\frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W + \mu_Z - \mu_Z \right]' \Sigma^{-1} \left[\frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W + \mu_Z - \mu_Z \right] \right\}} \frac{\sigma_x \sigma_y}{2}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left\{ \frac{-1}{2} \left[\frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W \right]' \Sigma^{-1} \left[\frac{1}{2} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W \right] \right\}}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left\{ \frac{-1}{2} \left(\frac{1}{2} W' \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} \Sigma^{-1} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W \right) \right\}}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left\{ \frac{-1}{8} W' \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} \Sigma^{-1} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W \right\}}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left[\frac{-1}{8} W' \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} \left(\frac{1}{(1-\rho^2)} \begin{bmatrix} \frac{1}{\sigma_x^2} & \frac{-\rho}{\sigma_x \sigma_y} \\ \frac{-\rho}{\sigma_x \sigma_y} & \frac{1}{\sigma_y^2} \end{bmatrix} \begin{bmatrix} \sigma_x & \sigma_x \\ \sigma_y & -\sigma_y \end{bmatrix} W \right) \right]}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left[\frac{-1}{8(1-\rho^2)} W' \begin{bmatrix} \sigma_x & \sigma_y \\ \sigma_x & -\sigma_y \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_x} - \frac{\rho}{\sigma_x} & \frac{1}{\sigma_x} + \frac{\rho}{\sigma_x} \\ \frac{1}{\sigma_y} - \frac{\rho}{\sigma_y} & \frac{-1}{\sigma_y} - \frac{\rho}{\sigma_y} \end{bmatrix} W \right]}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left[\frac{-1}{8(1-\rho^2)} W' \begin{bmatrix} \sigma_x & \sigma_y \\ \sigma_x & -\sigma_y \end{bmatrix} \begin{bmatrix} \frac{1-\rho}{\sigma_x} & \frac{1+\rho}{\sigma_x} \\ \frac{1-\rho}{\sigma_y} & \frac{-1-\rho}{\sigma_y} \end{bmatrix} W \right]}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left[\frac{-1}{8(1-\rho^2)} W' \begin{bmatrix} 2(1-\rho) & 0 \\ 0 & 2(1+\rho) \end{bmatrix} W \right]}$$

$$f_Y(Y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left[\frac{-2}{8(1-\rho)(1+\rho)} W' \begin{bmatrix} (1-\rho) & 0 \\ 0 & (1+\rho) \end{bmatrix} W \right]}$$

$$f_Y(y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left(\frac{-1}{4}w' \begin{bmatrix} \frac{1}{1+\rho} & 0 \\ 0 & \frac{1}{1-\rho} \end{bmatrix} w\right)}$$

$$f_Y(y) = \frac{1}{2\pi 2\sqrt{1-\rho^2}} e^{\left(\frac{-1}{4}[u \ v] \begin{bmatrix} \frac{1}{1+\rho} & 0 \\ 0 & \frac{1}{1-\rho} \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix}\right)}$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{2\pi}} \left[\frac{1}{4(1-\rho^2)}\right]^{\frac{1}{2}} e^{\left[\frac{-1}{4}\left(\frac{u^2}{1+\rho} + \frac{v^2}{1-\rho}\right)\right]}$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{2\pi}} \left[\frac{1}{2(1-\rho)2(1+\rho)}\right]^{\frac{1}{2}} e^{\left[\frac{-u^2}{4(1+\rho)}\right]} e^{\left[\frac{-v^2}{4(1-\rho)}\right]}$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi 2(1+\rho)}} e^{\left[\frac{-1}{2} \frac{u^2}{2(1+\rho)}\right]} \frac{1}{\sqrt{2\pi 2(1-\rho)}} e^{\left[\frac{-1}{2} \frac{v^2}{2(1-\rho)}\right]}.$$

La densidad conjunta de u y v es el producto de las densidades marginales de u y v:

$$u \sim \mathcal{N}(0, 2(1+\rho)),$$

$$v \sim \mathcal{N}(0, 2(1-\rho)),$$

y ambas son independientes entre sí.

Por lo tanto, las variables aleatorias u y v, $u = \frac{x-\mu_x}{\sigma_x}$ y $v = \frac{y-\mu_y}{\sigma_y}$, son independientes y tienen distribución normal con media cero y varianza $2(1+\rho)$ y $2(1-\rho)$, respectivamente.

Trabajo Práctico N° 1: **Mínimos Cuadrados Clásicos.**

Ejercicio 1.

Considerar el siguiente modelo de regresión lineal:

$$y = X\beta + u,$$

donde y es un vector de $n \times 1$, X es una matriz de $n \times k$ observaciones de variables de rango(X) = $k < n$ (con probabilidad 1), β es un vector de $k \times 1$ parámetros desconocidos, y u es un vector de perturbación estocástica de $n \times 1$ con $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I_n$.

(a) Probar que el estimador OLS es el estimador MELI (Mejor Estimador Lineal e Insesgado) (o BLUE -Best Linear Unbiased Estimator-) de β . Indicar el rol de cada supuesto de Gauss-Markov en la prueba.

El estimador OLS es:

$$\hat{\beta} = (X'X)^{-1}X'y.$$

Por el supuesto de linealidad, se puede reescribir al estimador como:

$$\begin{aligned}\hat{\beta} &= (X'X)^{-1}X'(\beta X + u) \\ \hat{\beta} &= (X'X)^{-1}X'X\beta + (X'X)^{-1}X'u \\ \hat{\beta} &= I\beta + (X'X)^{-1}X'u \\ \hat{\beta} &= \beta + (X'X)^{-1}X'u.\end{aligned}$$

Por lo tanto, por el supuesto de exogeneidad estricta, se tiene:

$$\begin{aligned}E(\hat{\beta} | X) &= E[\beta + (X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= E(\beta | X) + E[(X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= \beta + (X'X)^{-1}X' E(u | X) \\ E(\hat{\beta} | X) &= \beta + (X'X)^{-1}X' * 0 \\ E(\hat{\beta} | X) &= \beta + 0 \\ E(\hat{\beta} | X) &= \beta.\end{aligned}$$

Entonces, el estimador de OLS es insesgado.

Sea $\Sigma_{\hat{\beta}}$ la matriz de varianzas y covarianzas del estimador OLS condicional en X :

$$\begin{aligned}\Sigma_{\hat{\beta}} &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)' | X] \\ \Sigma_{\hat{\beta}} &= E\{[(X'X)^{-1}X'u][(X'X)^{-1}X'u]' | X\} \\ \Sigma_{\hat{\beta}} &= E[(X'X)^{-1}X'uu'X(X'X)^{-1} | X] \\ \Sigma_{\hat{\beta}} &= (X'X)^{-1}X' E(uu' | X) X(X'X)^{-1} \\ \Sigma_{\hat{\beta}} &= (X'X)^{-1}X'\sigma^2 I_n X(X'X)^{-1}\end{aligned}$$

$$\Sigma_{\hat{\beta}} = \sigma^2 (X'X)^{-1} X'X (X'X)^{-1}$$

$$\Sigma_{\hat{\beta}} = \sigma^2 I_n (X'X)^{-1}$$

$$\Sigma_{\hat{\beta}} = \sigma^2 (X'X)^{-1}.$$

Sea $\tilde{\beta}$ otro estimador linealmente insesgado. Por linealidad, $\tilde{\beta} = \tilde{D}y$, con $\tilde{D}$ siendo una matriz de $k \times n$. Se puede reescribir como $\tilde{\beta} = \tilde{D}X\beta + \tilde{D}u$. Para que sea insesgado, se necesita que:

$$E(\tilde{\beta} | X) = E[(\tilde{D}X\beta + \tilde{D}u) | X]$$

$$E(\tilde{\beta} | X) = E(\tilde{D}X\beta | X) + E(\tilde{D}u | X)$$

$$E(\tilde{\beta} | X) = \tilde{D}X\beta + \tilde{D} E(u | X)$$

$$E(\tilde{\beta} | X) = I\beta + \tilde{D} * 0$$

$$E(\tilde{\beta} | X) = \beta + 0$$

$$E(\tilde{\beta} | X) = \beta.$$

La matriz de varianzas y covarianzas de $\tilde{\beta}$ condicional en X , $\Sigma_{\tilde{\beta}}$, es:

$$\Sigma_{\tilde{\beta}} = E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' | X]$$

$$\Sigma_{\tilde{\beta}} = E[(\tilde{D}u)(\tilde{D}u)' | X]$$

$$\Sigma_{\tilde{\beta}} = E(\tilde{D}uu'\tilde{D}' | X)$$

$$\Sigma_{\tilde{\beta}} = \tilde{D} E(uu' | X) \tilde{D}'$$

$$\Sigma_{\tilde{\beta}} = \tilde{D} \sigma^2 \tilde{D}'$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 \tilde{D} \tilde{D}'.$$

Para probar que $\hat{\beta}$ es de varianza mínima basta con probar que $\Sigma_{\tilde{\beta}} - \Sigma_{\hat{\beta}}$ es una matriz semidefinida positiva. Con este fin, se define $D = \tilde{D} - (X'X)^{-1}X'$. Notar que $DX = 0$, lo cual implica también que $X'D' = 0$. $\Sigma_{\tilde{\beta}}$ se puede reescribir entonces:

$$\Sigma_{\tilde{\beta}} = \sigma^2 [D + (X'X)^{-1}X'] [D + (X'X)^{-1}X']'$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 [D + (X'X)^{-1}X'] [D' + X(X'X)^{-1}]$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 [DD' + (X'X)^{-1}X'D' + DX(X'X)^{-1} + (X'X)^{-1}X'X(X'X)^{-1}]$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 [DD' + (X'X)^{-1} * 0 + 0 * (X'X)^{-1} + I(X'X)^{-1}]$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 [DD' + 0 + 0 + (X'X)^{-1}]$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 [DD' + (X'X)^{-1}]$$

$$\Sigma_{\tilde{\beta}} = \sigma^2 DD' + \sigma^2 (X'X)^{-1}.$$

Como DD' es una matriz semidefinida positiva, entonces, $\Sigma_{\tilde{\beta}} - \Sigma_{\hat{\beta}} = \sigma^2 DD'$ es semidefinida positiva. Esto prueba que el estimador OLS de β es el de mínima varianza, y completa la prueba que son BLUE.

(b) Sea c un vector de $k \times 1$ de constantes. Mostrar que $c'\hat{\beta}$ es el estimador BLUE de $c'\beta$.

Sea $\theta = c'\beta$, donde c es un vector de $k \times 1$ variables, se desea construir un estimador BLUE de θ . Se quiere probar que el estimador BLUE es $c'\hat{\beta}$, con $\hat{\beta}$ como el estimador OLS de β . Como es lineal, considerar el estimador $\hat{\theta} = a'y$, donde a es un vector de $n \times 1$ variables. Como $\hat{\theta}$ debe ser insesgado, se tiene:

$$E(\hat{\theta} | X) = E[a'(X\beta + u) | X]$$

$$E(\hat{\theta} | X) = E[(a'X\beta + a'u) | X]$$

$$E(\hat{\theta} | X) = E(a'X\beta | X) + E(a'u | X)$$

$$E(\hat{\theta} | X) = a'X\beta + a' E(u | X)$$

$$E(\hat{\theta} | X) = a'X\beta + a' * 0$$

$$E(\hat{\theta} | X) = a'X\beta + 0$$

$$E(\hat{\theta} | X) = a'X\beta.$$

De aquí, se desprende que:

$$\hat{\theta} = a'X\beta + a'u$$

$$\hat{\theta} - a'X\beta = a'u$$

$$\hat{\theta} - \theta = a'u.$$

Ejercicio 2.

Verificar la condición de segundo orden del problema de minimización de residuos al cuadrado.

Ejercicio 3.

Evaluar las consecuencias sobre el estimador de Mínimos Cuadrados Clásicos de un modelo lineal de un cambio de escala en todas las variables, por un lado, y de una traslación de los regresores, por otro lado.

Ejercicio 4.

Ejercicio 5.

Ejercicio 6.

Ejercicio 7.

Ejercicio 8.

Trabajo Práctico N° 2:
Tópicos en el Modelo Lineal.

Ejercicio 1.

Ejercicio 2.

Ejercicio 3.

Ejercicio 4.

Ejercicio 5.

Ejercicio 6.

Ejercicio 7.

Ejercicio 8.

Ejercicio 9.

Ejercicio 10.

Ejercicio 11.

Ejercicio 12.

Ejercicio 13.

Ejercicio 14.

Trabajo Práctico N° 3:
Heterocedasticidad y Autocorrelación.

Ejercicio 1.

Ejercicio 2.

Ejercicio 3.

Ejercicio 4.

Ejercicio 5.

Ejercicio 6.

Trabajo Práctico N° 4:
Máxima Verosimilitud.

Ejercicio 1.

Ejercicio 2.

Ejercicio 3.

Ejercicio 4.

Ejercicio 5.

Ejercicio 6.

Ejercicio 7.

Ejercicio 8.

Ejercicio 9.

Trabajo Práctico N° 5:
Modelos Multiecuacionales.

Ejercicio 1.

Ejercicio 2.

Ejercicio 3.

Ejercicio 4.