

# Econometría de Datos de Panel

Maestrías en Economía y Econometría

## Lecture 1


# Agenda

- 1 Introducción
- 2 Teoría Asintótica
- 3 Modelos de Datos de Panel Lineales
- 4 Modelos de Efectos Fijos y Aleatorios
  - Modelo de Efectos Aleatorios
  - Modelo de Efectos Fijos
    - Transformación de Efectos Fijos ó Within Transformation
    - Modelo de Variables Binarias (LSDV)
    - Transformación de Diferencias Finitas
    - Transformación por Desviaciones Ortogonales
- 5 Two-Way Fixed Effects Model

# Introducción

- Datos de Corte Transversal  
 $j = 1, 2, \dots, N$
- Datos de Series Temporales  
 $t = 1, 2, \dots, T$
- Datos de Panel  
 $j = 1, 2, \dots, N$  y  $t = 1, 2, \dots, T$

# Introducción



- Datos Longitudinales.  $N$  es fijo y  $T \rightarrow \infty$ .
- Datos de Panel.  $N \rightarrow \infty$  y  $T$  es fijo.

# Convergencia en Probabilidad

- (1) Una secuencia de variables aleatorias  $\{x_N : N = 1, 2, \dots\}$  converge en probabilidad a la constante  $a$  si para todo  $\epsilon > 0$ ,

$$P[|x_N - a| > \epsilon] = 0 \text{ cuando } N \rightarrow \infty$$

En general, escribimos  $x_N \xrightarrow{p} a$  y decimos que  $a$  es el plímite de  $x_N$ .

- (2) En el caso especial en que  $a = 0$ , también decimos que  $\{x_N\}$  es  $o_p(1)$  (o pequeña  $p$  uno). En este caso escribimos  $x_N = o_p(1)$  ó  $x_N \xrightarrow{p} 0$ .

- (3) Una secuencia de variables aleatorias  $\{x_N\}$  está limitada en probabilidad (bounded in probability) sí y solo sí para cada  $\epsilon > 0$ , existe un  $b_\epsilon < \infty$  y un entero  $N_\epsilon$ , tal que:

$$P[|x_N| \geq b_\epsilon] < \epsilon \text{ para todo } N > N_\epsilon$$

# Convergencia en Probabilidad

- En este caso escribimos  $x_N = O_p(1)$  ( $\{x_N\}$  es  $O$  grande  $p$  uno).
- **Lema 1:** si  $x_N \xrightarrow{p} a$ , entonces  $x_N = O_p(1)$
- (4) Una secuencia aleatoria  $\{x_N : N = 1, 2, \dots\}$  es  $o_p(N^\delta)$  para  $\delta \in \Re$  si  $N^{-\delta}x_N = o_p(1)$ .
- **Lema 2:** si  $w_N = o_p(1)$ ,  $x_N = o_p(1)$ ,  $y_N = O_p(1)$ , y  $z_N = O_p(1)$ , entonces
  - (i)  $w_N + x_N = o_p(1)$ ;
  - (ii)  $y_N + z_N = O_p(1)$ ;
  - (iii)  $y_N \times z_N = O_p(1)$ ;
  - (iv)  $x_N \times z_N = o_p(1)$ .
- Todas las definiciones anteriores se aplican elemento por elemento a secuencias de vectores y matrices.
- **Lema 3:** Sea  $\{Z_N : N = 1, 2, \dots\}$  una secuencia de matrices  $J \times K$  tal que  $Z_N = o_p(1)$ , y sea  $\{x_N\}$  una secuencia de vectores aleatorios  $J \times 1$  tal que  $x_N = O_p(1)$ . Entonces  $Z_N'x_N = o_p(1)$ .

# Convergencia en Probabilidad

- **Lema 4 (Teorema de Slutsky):** Sea  $g : \mathbb{R}^K \rightarrow \mathbb{R}^J$  una función continua en algún punto  $c \in \mathbb{R}^K$ . Sea  $\{x_N : N = 1, 2, \dots\}$  una secuencia de vectores aleatorios  $K \times 1$  tal que  $x_N \xrightarrow{p} c$ . Entonces  $g(x_N) \xrightarrow{p} g(c)$  cuando  $N \rightarrow \infty$ . En otras palabras:  $\text{plim } g(x_N) = g(\text{plim } x_N)$  si  $g(\cdot)$  es continua en  $\text{plim } x_N$ .
- **Definición 1:** Sea  $(\Omega, \mathfrak{F}, P)$  un espacio de probabilidad. Una secuencia de eventos  $\{\Omega_N : N = 1, 2, \dots\} \subset \mathfrak{F}$  se dice que ocurre con probabilidad aproximándose a uno (w.p.a 1) sí y solo sí  $P(\Omega_N) \rightarrow 1$  cuando  $N \rightarrow \infty$ .
- **Corolario 1:** Sea  $\{Z_N : N = 1, 2, \dots\}$  una secuencia de matrices aleatorias  $K \times K$ , y sea  $A$  una matriz invertible no aleatoria  $K \times K$ . Si  $Z_N \xrightarrow{p} A$  entonces:
  - (1)  $Z_N^{-1}$  existe w.p.a. 1
  - (2)  $Z_N^{-1} \xrightarrow{p} A^{-1}$

# Convergencia en Distribución

- **Definición 2:** Una secuencia de variables aleatorias  $\{x_N : N = 1, 2, \dots\}$  converge en distribución a la variable aleatoria continua  $x$  sí y solo sí  $F_N(\xi) \rightarrow F(\xi)$  cuando  $N \rightarrow \infty$  para todo  $\xi \in \mathbb{R}$ .
- Donde  $F_N$  es la función de distribución acumulada de  $x_N$  y  $F$  es la función de distribución acumulada de  $x$ . En este caso escribimos:  $x_N \xrightarrow{d} x$
- **Definición 3:** Una secuencia de vectores aleatorios  $\{x_N : N = 1, 2, \dots\}$   $K \times 1$  converge en distribución al vector aleatorio continuo  $x$  sí y solo sí para cualquier vector no aleatorio  $K \times 1$ ,  $c$  tal que  $c'c = 1$ ,  $c'x_N \xrightarrow{d} c'x$  y escribimos  $x_N \xrightarrow{d} x$ .
- **Lema 5:** Si  $x_N \xrightarrow{d} x$ , donde  $x$  es cualquier vector aleatorio  $K \times 1$ , entonces  $x_N = O_p(1)$ .



# Convergencia en Distribución

- **Lema 6 (Continuous mapping theorem):** Sea  $\{x_N\}$  una secuencia de vectores aleatorios  $K \times 1$ , tal que  $x_N \xrightarrow{d} x$ . Si  $g : \mathbb{R}^K \rightarrow \mathbb{R}^J$  es una función continua, entonces  $g(x_N) \xrightarrow{d} g(x)$ .
- **Corolario 2:** Si  $\{z_N\}$  es una secuencia de vectores aleatorios  $K \times 1$ , tal que  $z_N \xrightarrow{d} N(0, V)$ . Entonces:
  - (1) Para cualquier matriz no aleatoria  $K \times M$ ,  $A: A'z_N \xrightarrow{d} N(0, A'VA)$ .
  - (2)  $z_N'V^{-1}z_N \xrightarrow{d} \chi_K^2$ .
- **Lema 7:** Sean  $\{x_N\}$  y  $\{z_N\}$  secuencias de vectores aleatorios  $K \times 1$ . Si  $z_N \xrightarrow{d} z$  y  $z_N - x_N \xrightarrow{p} 0$ . Entonces  $x_N \xrightarrow{d} z$ .
- **Teorema 1:** Sea  $\{w_j : j = 1, 2, \dots\}$  una secuencia de vectores aleatorios  $G \times 1$ , independientes, idénticamente distribuidos tal que  $E(|w_{jg}|) < \infty$ ,  $g = 1, 2, \dots, G$ . Entonces la secuencia satisface la ley débil de los grandes números (WLLN):  $N^{-1} \sum_{j=1}^N w_j \xrightarrow{p} \mu_w$  donde  $\mu_w = E(w_j)$ .

- **Teorema 2 (Lindeberg-Levy):** Sea  $\{w_j : j = 1, 2, \dots\}$  una secuencia de vectores aleatorios  $G \times 1$ , independientes, idénticamente distribuidos tal que  $E(|w_{jg}^2|) < \infty$ ,  $g = 1, 2, \dots, G$  y  $E(w_j) = 0$ . Entonces la secuencia satisface el teorema central del límite (CLT):  $N^{-1/2} \sum_{j=1}^N w_j \xrightarrow{d} N(0, B)$  donde  $B = \text{Var}(w_j) = E(w_j w_j')$ .

# Modelos de Datos de Panel Lineales

- **Supuestos:** se dispone de una muestra aleatoria de la población. Esto es, tenemos observaciones de **CORTE TRANSVERSAL**  $\{(X_j, y_j) : j = 1, 2, \dots, N\}$  que son independientes e idénticamente distribuídas.
- $X_j$  es una matriz  $T \times K$  que incluye como primera columna un vector  $T \times 1$  de unos e  $y_j$  es un vector  $T \times 1$ .
- El modelo lineal multivariante para una muestra aleatoria de la población puede escribirse como:

$$y_{jt} = x_{jt}\beta + u_{jt}, \quad j = 1, 2, \dots, N; t = 1, 2, \dots, T \quad (1)$$

$$y_j = X_j\beta + u_j, \quad j = 1, 2, \dots, N \quad (2)$$

donde  $\beta$  es el vector,  $K \times 1$ , de parámetros a estimar y  $u_j$  es un vector  $T \times 1$  de errores no observables.

# Modelos de Datos de Panel Lineales

- Dado el modelo planteado en (2) la pregunta relevante es **cuáles son los supuestos que se necesitan para poder estimar  $\beta$  consistentemente?**.
- Una posibilidad es asumir que  $x_{jt}$  y  $u_{jt}$  son ortogonales en sentido condicional:

$$E(u_{jt}|x_{jt}) = 0, \quad t = 1, 2, \dots, T \quad (3)$$

Esta relación recibe el nombre de **exogeneidad contemporánea de  $x_{jt}$** .

- Es importante distinguir el supuesto de la ecuación (3) del más fuerte:

$$E(u_{jt}|x_{j1}, x_{j2}, \dots, x_{jT}) = 0, \quad t = 1, 2, \dots, T \quad (4)$$

denominado **exogeneidad estricta de las variables explicativas**, ya que implica que  $u_{jt}$  no está correlacionado con las variables explicativas en **NINGUNO** de los períodos temporales.

- La estimación consistente de  $\beta$  depende crucialmente de si se asume (3) ó (4).

# Modelos de Datos de Panel Lineales

- En general, para poder estimar  $\beta$  en (2) en forma consistente por OLS necesitamos:
- **Supuesto 1:**  $E(X_j' u_j) = 0$ .
- El **supuesto 1** implica que  $E(u_j) = 0$ .
- En el caso de datos de panel  $X_j' u_j = \sum_{t=1}^T x_{jt}' u_{jt}$ , por lo tanto una condición natural para que el **supuesto 1** se satisfaga es  $E(x_{jt}' u_{jt}) = 0$ ,  $t = 1, 2, \dots, T$ .
- Note que la ecuación anterior **NO** impone exogeneidad estricta. Bajo el **supuesto 1**, el vector  $\beta$  satisface:

$$\begin{aligned} E[X_j'(y_j - X_j\beta)] &= 0 \\ E(X_j'X_j)\beta &= E(X_j'y_j) \end{aligned} \tag{5}$$

Para poder estimar  $\beta$  necesitamos asumir que es el único vector  $K \times 1$  que satisface (5).

# Modelos de Datos de Panel Lineales

- **Supuesto 2.**  $A \equiv E(X_j'X_j)$  es una matriz no aleatoria y no singular. Es decir,  $\text{Rango}[E(X_j'X_j)] = K$ .
- Bajo los **supuestos 1 y 2** podemos escribir:

$$\beta = [E(X_j'X_j)]^{-1}E(X_j'y_j) \quad (6)$$

- El principio de analogía sugiere estimar  $\beta$  con el análogo muestral de (6)

$$\hat{\beta} = \left( \frac{1}{N} \sum_{j=1}^N X_j'X_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j'y_j \right) \quad (7)$$

- Note que en la ecuación anterior

$$\sum_{j=1}^N X_j'X_j = \sum_{j=1}^N \sum_{t=1}^T x_{jt}'x_{jt} \quad y \quad \sum_{j=1}^N X_j'y_j = \sum_{j=1}^N \sum_{t=1}^T x_{jt}'y_{jt}$$

# Modelos de Datos de Panel Lineales

$$\begin{aligned}\hat{\beta} &= \left( \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} x_{jt} \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} y_{jt} \right) \\ &= \beta + \left( \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} x_{jt} \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} u_{jt} \right) \\ &\xrightarrow{p} \beta + \left( E \sum_{t=1}^T x'_{jt} x_{jt} \right)^{-1} \times \left( E \sum_{t=1}^T x'_{jt} u_{jt} \right) \\ &\xrightarrow{p} \beta + A^{-1} \text{por supuesto 2} \times 0 \text{ por supuesto 1}\end{aligned} \tag{8}$$

- La ecuación (8) recibe el nombre de **Pool OLS**.

# Modelos de Datos de Panel Lineales

- Para realizar inferencia estadística lo único que necesitamos es la varianza asintótica del estimador.
- De la derivación anterior:

$$\sqrt{N}(\hat{\beta} - \beta) = \left( \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} x_{jt} \right)^{-1} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} u_{jt} \right) \quad (9)$$

- Como por el **Supuesto 1**,  $E \left( \sum_{t=1}^T x'_{jt} u_{jt} \right) = 0$  lo único que necesitamos asumir para aplicar el CLT es:  $E \left( \sum_{t=1}^T x'_{jt} u_{jt} u'_{jt} x_{jt} \right) < \infty$
- Con este supuesto adicional el CLT implica que:

$\frac{1}{\sqrt{N}} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} u_{jt} \xrightarrow{d} \text{Normal}(0, B)$ , donde:

$$B \equiv E \left( \sum_{t=1}^T x'_{jt} u_{jt} u'_{jt} x_{jt} \right) = \text{Var} \left( \sum_{t=1}^T x'_{jt} u_{jt} \right)$$



# Modelos de Datos de Panel Lineales

- Por lo tanto usando el **Supuesto 2** junto con el resultado anterior en (9), tenemos:

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &\xrightarrow{d} A^{-1}\text{Normal}(0, B) \\ &\xrightarrow{d} \text{Normal}(0, A^{-1}BA^{-1})\end{aligned}\quad (10)$$

- Por lo tanto, la varianza asintótica del estimador de  $\beta$  es:

$$A\text{Var}(\hat{\beta}) = A^{-1}BA^{-1}/N \quad (11)$$

- Para realizar inferencia estadística necesitamos una estimación consistente de esta varianza asintótica:

$$\hat{A} = \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} x_{jt}$$

# Modelos de Datos de Panel Lineales

- Usando el principio de analogía, se puede obtener una estimación consistente de  $B$  como

$$\hat{B} = \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} u_{jt} u'_{jt} x_{jt} \xrightarrow{p} B$$

- En la estimación anterior no conocemos los errores y por lo tanto deben ser reemplazados por los residuos del modelo. Esto es:

$$\hat{B} = \frac{1}{N} \sum_{j=1}^N \sum_{t=1}^T x'_{jt} \hat{u}_{jt} \hat{u}'_{jt} x_{jt} \xrightarrow{p} B$$

- Ahora, la última convergencia debe probarse. Note que:

$$\hat{B} = \frac{1}{N} \sum_{j=1}^N X'_j \hat{u}_j \hat{u}'_j X_j \quad y \quad \hat{u}_j = y_j - X_j \beta = u_j - X_j(\hat{\beta} - \beta)$$

# Modelos de Datos de Panel Lineales

- Entonces,

$$\begin{aligned}\hat{B} &= \frac{1}{N} \sum_{j=1}^N X_j' [u_j - X_j(\hat{\beta} - \beta)] [u_j - X_j(\hat{\beta} - \beta)]' X_j \\ &= \frac{1}{N} \sum_{j=1}^N X_j' u_j u_j' X_j + \frac{1}{N} \sum_{j=1}^N X_j' X_j (\hat{\beta} - \beta) (\hat{\beta} - \beta)' X_j' X_j \\ &\quad + \frac{1}{N} \sum_{j=1}^N X_j' u_j (\hat{\beta} - \beta) X_j' X_j + \frac{1}{N} \sum_{j=1}^N X_j' X_j (\hat{\beta} - \beta) u_j' X_j \quad (12) \\ &\xrightarrow{P} B + o_p(1) + o_p(1) + o_p(1)\end{aligned}$$

# Modelos de Datos de Panel Lineales

- Por lo tanto  $AVar[\sqrt{N}(\hat{\beta} - \beta)]$  puede estimarse consistentemente con  $\hat{A}^{-1}\hat{B}\hat{A}^{-1}$
- Y la varianza asintótica de  $\hat{\beta}$  se estima con:

$$\hat{V} = \left( \sum_{j=1}^N X_j' X_j \right)^{-1} \left( \sum_{j=1}^N X_j' \hat{u}_j \hat{u}_j' X_j \right) \left( \sum_{j=1}^N X_j' X_j \right)^{-1} \quad (13)$$

- **Remark 1.** Bajo los **supuestos 1 y 2** se puede realizar inferencia estadística sobre  $\beta$  porque  $\hat{\beta}$  se distribuye con una distribución normal con media  $\beta$  y matriz de varianzas y covarianzas dada por la ecuación (13).
- **Remark 2.** La raíz cuadrada de los elementos de la diagonal principal de (13) se reportan usualmente como los errores estándar asintóticos de los estimadores.

# Modelos de Datos de Panel Lineales

- **Remark 3.** El cociente  $t, \hat{\beta}_j/\text{se}(\hat{\beta}_j)$ , tiene distribución normal bajo la hipótesis nula  $H_0 : \beta_j = 0$ . Usualmente estos estadísticos son tratados siguiendo una distribución  $t$ -Student con  $N \times T - K$  grados de libertad, que es una aproximación asintóticamente válida.
- **Remark 4.** La ecuación (13) es válida sin haber hecho ningún supuesto sobre el momento de orden dos de los errores.
- El **Remark 4** implica que la matriz  $T \times T$  de varianzas y covarianzas de los errores no está restringida de ninguna manera (i.e.  $\Omega = E(u_j u_j')$ ).
- $\Omega$  no restringida permite cualquier tipo de correlación serial y varianzas de los disturbios que varíen en el tiempo.
- Inferencia sobre múltiples hipótesis puede realizarse utilizando el estadístico de Wald.

# Modelos de Datos de Panel Lineales

- El estadístico (robusto) de Wald para contrastar la hipótesis nula  $H_0 : R\beta = r$ , donde  $R$  es  $Q \times K$  con rango  $Q$  y  $r$  es  $Q \times 1$  sigue la expresión usual:

$$W = (R\hat{\beta} - r)'[R\hat{V}R']^{-1}(R\hat{\beta} - r) \xrightarrow{d} \chi_Q^2 \quad (14)$$

- El test de Wald permite contrastar cualquier hipótesis sobre  $\beta$  sin tener que asumir homocedasticidad ni independencia serial de los errores.
- Para aplicar los estadísticos usuales de OLS para la estimación pool, necesitamos asumir homocedasticidad y ausencia de correlación serial en el tiempo. Las formas más débiles de estos supuestos son:

**Supuesto 3:** (a)  $E(u_{jt}^2 x'_{jt} x_{jt}) = \sigma^2 E(x'_{jt} x_{jt})$ ,  $t = 1, 2, \dots, T$  y  $\sigma^2 = E(u_{jt}^2)$  para todo  $t$ . (b)  $E(u_{jt} u_{js} x'_{jt} x_{js}) = 0$ ,  $t \neq s$ ,  $t, s = 1, 2, \dots, T$ .

# Modelos de Datos de Panel Lineales

- El supuesto 3 implica que,

$$B \equiv E \left( \sum_{t=1}^T x'_{jt} u_{jt} u'_{jt} x_{jt} \right) = \sigma^2 E \left( \sum_{t=1}^T x'_{jt} x_{jt} \right) = \sigma^2 A$$

y por lo tanto,  $\text{AVar}(\hat{\beta}) = \sigma^2 A/N$

- El estimador apropiado es entonces,

$$\hat{V} = \widehat{\text{AVar}}(\hat{\beta}) = \hat{\sigma}^2 \left( \sum_{j=1}^N \sum_{t=1}^T x'_{jt} x_{jt} \right)^{-1} \quad (15)$$

- En la ecuación anterior,  $\hat{\sigma}^2$  es el estimador usual de la varianza de los errores del modelo estimado por Pool OLS.
- Si el supuesto 3 se satisface, los estadísticos  $t$  y  $F$  son válidos.
- Si el supuesto 3 no se satisface, una alternativa a OLS es mínimos cuadrados generalizados (GLS).

# Modelos de Datos de Panel Lineales

- Para poder establecer la consistencia de GLS necesitamos reforzar el **supuesto 1**.
- **Supuesto 1'**.  $E(X_j \otimes u_j) = 0$ . Esto es, cada elemento de  $u_j$  no está correlacionado con cada elemento de  $X_j$ .
- Una condición suficiente para que se cumpla el **supuesto 1'** es  $E(u_j|X_j) = 0$ .
- En lugar del **supuesto 2**, necesitamos
- **Supuesto 2'**.  $\Omega$  es positiva definida y  $E(X_j' \Omega^{-1} X_j)$  no es singular.
- Pre-multiplicando el modelo (2) por  $\Omega^{-1/2}$  tenemos:

$$\begin{aligned}\Omega^{-1/2} y_j &= \Omega^{-1/2} X_j \beta + \Omega^{-1/2} u_j \\ y_j^* &= X_j^* \beta + u_j^*\end{aligned}\tag{16}$$

- Ahora  $E(u_j^* u_j^{*'}) = I_T$ .



# Modelos de Datos de Panel Lineales

- Aplicando OLS a (16) obtenemos:

$$\begin{aligned}\tilde{\beta} &= \left( \frac{1}{N} \sum_{j=1}^N X_j^{*'} X_j^* \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j^{*'} y_j^* \right) \\ &= \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} y_j \right)\end{aligned}\quad (17)$$

$$= \beta + \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right)\quad (18)$$

- Por la ley de los grandes números (WLLN)

$$\left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right) \xrightarrow{P} E(X_j' \Omega^{-1} X_j) \equiv A$$

# Modelos de Datos de Panel Lineales

- Ahora, por el **Supuesto 2'** y el **Lema 4 (teorema de Slutsky)** tenemos que:

$$\left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \xrightarrow{p} A^{-1}$$

- Por la ley de los grandes números (WLLN)

$$\left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) \xrightarrow{p} E (X_j' \Omega^{-1} u_j)$$

- Bajo el **Supuesto 1'**:  $E (X_j' \Omega^{-1} u_j) = 0$

- Proof:**

$$\begin{aligned} \text{Vec} [E (X_j' \Omega^{-1} u_j)] &= E [u_j' \otimes X_j'] \text{Vec} (\Omega^{-1}) \\ &= E [(u_j \otimes X_j)'] \text{Vec} (\Omega^{-1}) = 0 \end{aligned}$$

# Modelos de Datos de Panel Lineales

- Usando la ecuación (18) tenemos,

$$\sqrt{N}(\tilde{\beta} - \beta) = \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) \quad (19)$$

- Como vimos, por la WLLN y el **Supuesto 1'**,  $E(X_j' \Omega^{-1} u_j) = 0$  por lo tanto, por el CLT

$$\left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) \xrightarrow{d} \text{Normal}(0, B)$$

where  $B = E(X_j' \Omega^{-1} u_j u_j' \Omega^{-1} X_j)$ .

# Modelos de Datos de Panel Lineales

- Usando los resultados anteriores, tenemos

$$\begin{aligned}\sqrt{N}(\tilde{\beta} - \beta) &= \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) \\ &\xrightarrow{d} A^{-1} \text{Normal}(0, B) \\ &\xrightarrow{d} \text{Normal}(0, A^{-1} B A^{-1})\end{aligned}$$

- Por lo tanto  $A\text{Var}(\tilde{\beta}) = A^{-1} B A^{-1} / N$ .
- Para poder estimar el modelo por GLS necesitamos conocer  $\Omega$ . En la práctica rara vez conocemos esta matriz y el método no puede ser utilizado empíricamente.
- Sin embargo, existe un método que es asintóticamente equivalente conocido como **mínimos cuadrados generalizados estimados** o **FGLS**.

# Modelos de Datos de Panel Lineales

- En FGLS reemplazamos  $\Omega$  con una estimación consistente.
- En general se utiliza el siguiente procedimiento.
  - (1) Obtenga el estimador Pool OLS de  $\beta$ ,  $\hat{\beta}$ , from (8).
  - (2) Obtenga los residuos  $\hat{u}_j = y_j - X_j \hat{\beta}$ .
  - (3) Estime  $\Omega$  con  $\tilde{\Omega} = \sum_{j=1}^N \hat{u}_j \hat{u}_j'$ .
- Note que,  $\hat{u}_j = u_j - X_j(\hat{\beta} - \beta)$ , por lo tanto

$$\begin{aligned}\hat{u}_j \hat{u}_j' &= u_j u_j' - u_j (\hat{\beta} - \beta)' X_j' - X_j (\hat{\beta} - \beta) u_j' \\ &\quad + X_j (\hat{\beta} - \beta) (\hat{\beta} - \beta)' X_j'\end{aligned}$$

# Modelos de Datos de Panel Lineales

- El segundo término del lado derecho puede escribirse como

$$\begin{aligned}\frac{1}{N} \sum_{j=1}^N \text{Vec}[u_j(\hat{\beta} - \beta)' X_j'] &= \frac{1}{N} \sum_{j=1}^N (X_j \otimes u_j) \text{Vec}(\hat{\beta} - \beta)' \\ &\xrightarrow{p} E(X_j \otimes u_j) \times o_p(1)\end{aligned}$$

- El último término del lado derecho puede escribirse como:

$$\begin{aligned}\frac{1}{N} \sum_{j=1}^N X_j(\hat{\beta} - \beta)(\hat{\beta} - \beta)' X_j' &= \frac{1}{N} \sum_{j=1}^N (X_j \otimes X_j') \text{Vec}(\hat{\beta} - \beta)(\hat{\beta} - \beta)' \\ &\xrightarrow{p} O_p(1) \times o_p(1)\end{aligned}$$

# Modelos de Datos de Panel Lineales

- Por lo tanto

$$\tilde{\Omega} = \sum_{j=1}^N u_j u_j' + o_p(1) \implies \tilde{\Omega} \xrightarrow{p} \Omega \quad (20)$$

- El estimador FGLS de  $\beta$  es entonces:

$$\begin{aligned} \hat{\tilde{\beta}} &= \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} y_j \right) \\ &= \beta + \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} u_j \right) \end{aligned} \quad (21)$$

# Modelos de Datos de Panel Lineales

- De la última expresión tenemos

$$\sqrt{N}(\hat{\beta} - \beta) = \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)^{-1} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} u_j \right)$$

- Ahora,

$$\begin{aligned} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} u_j \right) - \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) &= \\ \left[ \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' (\tilde{\Omega}^{-1} - \Omega^{-1}) u_j \right] &= \\ \left[ \frac{1}{\sqrt{N}} \sum_{j=1}^N (u_j \otimes X_j)' \right] \text{Vec}(\tilde{\Omega}^{-1} - \Omega^{-1}) &\xrightarrow{p} O_p(1) \times o_p(1) \end{aligned}$$



# Modelos de Datos de Panel Lineales

- Por lo tanto

$$\left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} u_j \right) = \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) + o_p(1)$$

- Usando el mismo argumento

$$\left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right) = \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right) + o_p(1)$$

- Utilizando los dos resultados anteriores tenemos que

$$\begin{aligned} \sqrt{N}(\hat{\tilde{\beta}} - \beta) &= \left( \frac{1}{N} \sum_{j=1}^N X_j' \Omega^{-1} X_j \right)^{-1} \left( \frac{1}{\sqrt{N}} \sum_{j=1}^N X_j' \Omega^{-1} u_j \right) + o_p(1) \\ &= \sqrt{N}(\tilde{\beta} - \beta) + o_p(1) \implies \sqrt{N}(\hat{\tilde{\beta}} - \tilde{\beta}) = o_p(1) \end{aligned}$$

y ambos estimadores, SGLS y FGLS, son asintóticamente equivalentes ( $\sqrt{N}$  equivalentes).

# Modelos de Datos de Panel Lineales

- **Remark 5:** Empíricamente, la equivalencia asintótica de los estimadores de GLS y FGLS implica que para realizar inferencia estadística sobre  $\beta$  usando FGLS, no hay que preocuparse de que  $\tilde{\Omega}$  sea un estimador de  $\Omega$ .
- **Resumen:** Bajo los supuestos 1' y 2',

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(0, A^{-1}BA^{-1})$$

- Bajo FGLS un estimador consistente de  $A$  es:

$$\tilde{A} = \left( \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)$$

- Un estimador consistente de  $B$  es,

$$\tilde{B} = \frac{1}{N} \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} \tilde{u}_j \tilde{u}_j' \tilde{\Omega}^{-1} X_j \quad \text{con} \quad \tilde{u}_j = y_j - X_j \hat{\beta}.$$

# Modelos de Datos de Panel Lineales

- Usando los resultados anteriores una estimación de la varianza asintótica del estimador FGLS es:

$$\hat{V} = \widehat{AVar}(\hat{\beta}) = \tilde{A}^{-1} \tilde{B} \tilde{A}^{-1} / N = \left( \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)^{-1} \left( \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} \tilde{u}_j \tilde{u}_j' \tilde{\Omega}^{-1} X_j \right) \left( \sum_{j=1}^N X_j' \tilde{\Omega}^{-1} X_j \right)^{-1} \quad (22)$$

- La especificación anterior es la más general que se pueda tener en términos de los supuestos acerca de la estimación de la varianza asintótica.
- Supuesto 3'.**  $E(X_j' \Omega^{-1} u_j u_j' \Omega^{-1} X_j) = E(X_j' \Omega^{-1} X_j)$ , con  $\Omega = E(u_j u_j')$ .
- Bajo los **supuestos 1', 2' y 3'**, la varianza asintótica del estimador FGLS es:

$$AVar(\hat{\beta}) = A^{-1} / N = [E(X_j' \Omega^{-1} X_j)]^{-1} / N$$

# Modelos de Datos de Panel Lineales

- Uno obtiene un estimador consistente de la varianza asintótica usando un estimador consistente de  $A$ .

$$\widehat{AVar}(\hat{\beta}) = \hat{A}^{-1}/N = \left( \sum_{j=1}^N x_j' \tilde{\Omega}^{-1} x_j \right)^{-1} \quad (23)$$

- Los errores estándar asintóticos de los coeficientes estimados se obtienen en forma usual utilizando la raíz cuadrada de la diagonal principal de (22) o de (23).
- Contrastes de múltiples hipótesis pueden realizarse utilizando el estadístico de Wald definido anteriormente en la ecuación (14).
- La única decisión importante es la elección de la estimación de la varianza asintótica correcta.
- El estadístico de Wald estándar usa (23) mientras que el robusto utiliza (14).

# Contraste de Correlación Serial en POLS

- Supongamos correlación serial de primer orden:  $u_{jt} = \alpha_1 u_{jt-1} + e_{jt}$ , con  $E(e_{jt} | X_{jt}, u_{jt-1}, \dots) = 0$ .
- LM Test para  $H_0 : \alpha_1 = 0$ 
  - (1) Estime por POLS  $y_{jt} = x_{jt}\beta + u_{jt}$  y obtenga  $\hat{u}_{jt}$
  - (2) Estime por POLS  $\hat{u}_{jt} = x_{jt}\beta + \alpha_1 \hat{u}_{jt-1} + e_{jt}$  (ax)
  - (3)  $LM = \text{Obs} \times R_{ax}^2 \sim \chi_1^2$ .
  - (4) Regla de decisión: si el valor-p(LM) < nivel de error del test, entonces rechazar  $H_0$ .
- El test tiene las generalizaciones usuales para correlación de mayor orden.

# Contraste de Heterocedasticidad en POLS

- Este test es válido si se asume  $E(u_{jt}|x_{jt}) = 0$ ,  $t = 1, 2, \dots, T$ .
- La hipótesis nula es entonces  $E(u_{jt}^2|x_{jt}) = \sigma^2$ ,  $t = 1, 2, \dots, T$ .
- Bajo  $H_0$ ,  $u_{jt}^2$  no está correlacionado con ninguna función de  $x_{jt}$ . Denotemos por  $h_{jt}$  a un vector de dimensión  $1 \times Q$  de funciones no constantes de  $x_{jt}$ .
  - (1) Estime por POLS  $y_{jt} = x_{jt}\beta + u_{jt}$  y obtenga  $\hat{u}_{jt}$  y  $\hat{u}_{jt}^2$ .
  - (2) Estime por POLS  $\hat{u}_{jt}^2$  sobre una constante y  $h_{jt}$  y obtenga el  $R_{ax}^2$ .
  - (3)  $LM = N \times T \times R_{ax}^2 \sim \chi_Q^2$ .
  - (4) Regla de decisión: si el valor-p(LM) < nivel de error del test, entonces rechazar  $H_0$ .

# Modelos de Datos de Panel Lineales

- Hasta ahora, hemos supuesto, como mínimo que no existía correlación entre el error del período y las variables explicativas del modelo.
- Para ciertos datos de panel este supuesto es demasiado fuerte. Hay varios casos en los que uno debiera esperar una correlación entre variables observables y no observables.
- Un ejemplo clásico de este problema es el del **error de medición**. Si la variable explicativa que observamos no se mide correctamente el error de la ecuación contendrá este error de medición y por lo tanto estará correlacionado con la variable explicativa mal medida.
- Otro ejemplo posible es el de **variable omitida**.
- Justamente, uno de los usos más frecuentes de los datos de panel, es el de resolver los problemas de variables omitidas.
- Es fácil ver como los datos de panel nos pueden ayudar a resolver el problema de variables omitidas.

# Modelos de Datos de Panel Lineales

- Sean  $x = (x_1, x_2, \dots, x_k)$  e  $y$  variables aleatorias observables; y  $c$  una variable aleatoria no observable.
- Usualmente, estamos interesados en estimar los efectos parciales de las variables explicativas observables sobre la variable dependiente.
- **El Problema:** asumiendo un modelo lineal,

$$E(y|x, c) = \beta_0 + x\beta + c$$

- Estamos interesados en el vector  $\beta$ .
- Si  $\text{Cov}(x_j, c) \neq 0$  para algún  $j$ , no podemos estimar consistentemente el vector  $\beta$  ni con OLS ni con GLS.
- En el contexto de datos de panel  $c$  recibe el nombre de **componente no observable, efecto no observable o heterogeneidad no observable**.
- La solución al problema de variables omitidas en panel consiste simplemente en transformar el modelo para eliminar  $c$  y luego estimar.



# Modelos de Efectos Fijos y Aleatorios

- Consideremos un modelo para variables observadas a través de unidades de corte transversal durante varios períodos de tiempo.  $\beta$  es el parámetro que estamos interesados en estimar y  $c_i$  es un efecto no observado, invariante en el tiempo, denominado **efecto individual**, **heterogeneidad individual** ó **heterogeneidad no observada**:

$$y_{it} = c_i + x_{it}\beta + u_{it} \quad (24)$$

donde  $x_{it}$  es  $1 \times K$  y  $u_{it}$  es el error idiosincrático. Este modelo se denomina **modelo de efectos no observables**.

- Tradicionalmente, existen dos modelos basados en la discusión acerca de si  $c_i$  puede tratarse como un **efecto aleatorio** o como un **efecto fijo**.
- Estas discusiones se centraban en si el efecto individual era una variable aleatoria o podía considerarse como un parámetro a ser estimado.

# Modelos de Efectos Fijos y Aleatorios

- En el análisis de panel tradicional  $c_i$  se llama un efecto aleatorio cuando se lo trata como variable aleatoria y un efecto fijo cuando se lo trata como parámetro a ser estimado.
- Modernamente, la discusión ha cambiado y lo que se discute es básicamente si el efecto no observable está o no correlacionado con las variables explicativas observables.
- Ahora, efecto aleatorio es sinónimo de ausencia de correlación entre las variables explicativas observables y el efecto no observable:  
$$\text{Cov}(x_{it}, c_i) = 0, t = 1, 2, \dots, T.$$
- En los trabajos empíricos cuando se dice que el modelo tiene un efecto aleatorio individual es porque se está asumiendo que no existe correlación entre las variables explicativas observables y el efecto no observable
- Similarmente, el término efecto fijo, no quiere decir que  $c_i$  se trate como no aleatorio, sino que implica que se permite la correlación entre  $c_i$  y  $x_{it}$ .

# Exogeneidad Estricta

- $E(y_{it}|x_{i1}, x_{i2}, \dots, x_{iT}, c_i) = E(y_{it}|x_{it}, c_i) = x_{it}\beta + c_i$   
con  $t = 1, 2, \dots, T$ .
- Cuando la ecuación anterior se satisface, se dice que las **variables explicativas son estrictamente exógenas condicionando en el efecto no observable**.
- La condición de exogeneidad estricta puede establecerse en términos de los errores idiosincráticos usando el modelo (24),

$$E(u_{it}|x_{i1}, x_{i2}, \dots, x_{iT}, c_i) = 0, \quad t = 1, 2, \dots, T. \quad (25)$$

- La ecuación (25) implica que las variables explicativas en cada período de tiempo no están correlacionadas con el error idiosincrático en cada período de tiempo:

$$E(x'_{is} u_{it}) = 0, \quad s, t = 1, 2, \dots, T \quad (26)$$

# Exogeneidad Estricta

- Este supuesto de exogeneidad es mucho más fuerte que el de ausencia de correlación contemporánea
- $E(x'_{it} u_{it}) = 0, \quad t = 1, 2, \dots, T.$
- No obstante, note que (25) permite correlación arbitraria entre las variables explicativas observables y el efecto individual no observable.
- Estimación del modelo de efectos no observables con POLS
- Re-escribamos el modelo (24) como:

$$y_{it} = x_{it}\beta + v_{it} \quad t = 1, 2, \dots, T \quad (27)$$

donde  $v_{it} = c_i + u_{it}$ ,  $t = 1, 2, \dots, T$  son los **errores compuestos**.

- De acuerdo a lo que hemos visto, sabemos que la ecuación anterior puede estimarse por OLS y obtener estimadores consistentes si  $E(x'_{it} v_{it}) = 0, \quad t = 1, 2, \dots, T.$

# Modelos de Panel Lineales

- La última condición implica que estamos asumiendo que:
- $E(x'_{it}u_{it}) = 0$  y  $E(x'_{it}c_i) = 0$ ,  $t = 1, 2, \dots, T$ .
- Note que el supuesto restrictivo aquí es la segunda condición.
- En modelos de panel dinámicos la segunda condición no puede cumplirse porque la variable dependiente rezagada (i.e.  $y_{it-1}$ ) y  $c_i$  están necesariamente correlacionadas.
- Note que aún cuando las condiciones anteriores se satisfagan los errores compuestos estarán correlacionados debido a la presencia de  $c_i$  en cada período temporal.
- Una consecuencia del punto anterior es que para realizar inferencia usando POLS se deben calcular los errores estándar de los coeficientes usando la ecuación (13).
- Otra consecuencia que afectará nuestro análisis más adelante es que como  $v_{it}$  depende de  $c_i$  para todo  $t$ , la correlación entre  $v_{it}$  y  $v_{it-s}$ ,  $s > 0$  no decrece con  $s$ .
- En el lenguaje de las series temporales:  $v_{it}$  no tiene dependencia débil a través del tiempo.

# Agenda

- 1 Introducción
- 2 Teoría Asintótica
- 3 Modelos de Datos de Panel Lineales
- 4 Modelos de Efectos Fijos y Aleatorios**
  - Modelo de Efectos Aleatorios
  - Modelo de Efectos Fijos
    - Transformación de Efectos Fijos ó Within Transformation
    - Modelo de Variables Binarias (LSDV)
    - Transformación de Diferencias Finitas
    - Transformación por Desviaciones Ortogonales
- 5 Two-Way Fixed Effects Model

# Modelo de Efectos Aleatorios

- Como en el caso de POLS, los métodos de efectos aleatorios ponen a  $c_i$  en el término de error.
- En general el análisis de efectos aleatorios necesita supuestos más fuertes que POLS: exogeneidad estricta más ortogonalidad entre  $c_i$  y  $x_{it}$ .
- **Supuesto RE.1:**
  - (a)  $E(u_{it}|X_i, c_i) = 0$  y
  - (b)  $E(c_i|X_i) = 0$  con  $X_i = (x_{i1}, x_{i2}, \dots, x_{iT})$
- Necesitamos (a) porque RE estima por GLS, debido a la correlación serial y como vimos antes, GLS necesita exogeneidad estricta para conseguir estimadores consistentes.
- Bajo RE.1 podemos escribir el modelo como:

$$y_{it} = x_{it}\beta + v_{it} \quad (28)$$

# Modelo de Efectos Aleatorios

- En (28)  $E(v_{it}|X_i) = 0$ ,  $t = 1, 2, \dots, T$ .
- Note que esta última ecuación implica que  $\{x_{it}, t = 1, 2, \dots, T\}$  satisface el supuesto de exogeneidad estricta 1' en POLS.
- Por lo tanto podemos aplicar GLS tomando en cuenta la estructura de la matriz de varianzas y covarianzas del error.
- Escribamos el modelo *stacking* sobre  $T$ .

$$y_i = X_i\beta + v_i, \quad v_i = c_i J_T + u_i$$

donde  $J_T$  es un vector  $T \times 1$  de unos.

- Definamos la matriz de varianzas y covarianzas de los errores del modelo como:  $\Omega = E(v_i v_i')$ , una matriz  $T \times T$  positiva definida.
- Recuerde que esta matriz **es la misma para todo  $i$**  por el supuesto de muestra aleatoria.



# Modelo de Efectos Aleatorios

- Para obtener estimadores consistentes por GLS necesitamos: **Supuesto RE.2:**  
 $\text{rango} E(X_i' \Omega^{-1} X_i) = K.$
- Aplicando los resultados vistos antes para GLS sabemos que podemos obtener estimadores consistentes y asintóticamente normales con  $N \longrightarrow \infty$  y usando una matriz  $\Omega$  general.
- Pero podemos hacerlo mejor porque conocemos la estructura de los errores.
- Los supuestos tradicionales de RE son:
  - (i)  $E(u_{it}^2) = \sigma_u^2, \quad t = 1, 2, \dots, T.$
  - (ii)  $E(u_{it} u_{is}) = 0, \quad \forall t \neq s.$

En este caso:

$$\begin{aligned}\Omega = E(v_i v_i') &= E[(c_i J_T + u_i)(c_i J_T + u_i)'] \\ &= E\{c_i^2 J_T J_T' + c_i u_i J_T' + c_i J_T u_i' + u_i u_i'\} \\ &= \sigma_c^2 J_T J_T' + \sigma_u^2 I_T\end{aligned}$$

# Modelo de Efectos Aleatorios

- De la ecuación anterior tenemos:

$$\Omega = E(v_i v_i') = \begin{bmatrix} \sigma_c^2 + \sigma_u^2 & \sigma_c^2 & \cdots & \sigma_c^2 \\ \sigma_c^2 & \sigma_c^2 + \sigma_u^2 & \cdots & \sigma_c^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_c^2 & \sigma_c^2 & \cdots & \sigma_c^2 + \sigma_u^2 \end{bmatrix} \quad (29)$$

- Cuando  $\Omega$  tiene la forma (29) se dice que tiene la estructura de efectos aleatorios.
- Note que en este caso  $\Omega$  depende solo de dos parámetros  $\sigma_c^2$  y  $\sigma_u^2$ , independientemente del tamaño de  $T$ .
- Para obtener estimadores eficientes necesitamos que: (iii)  $E(v_i v_i' | X_i) = E(v_i v_i')$
- El siguiente supuesto implica (i), (ii) e (iii)
- Supuesto RE.3:**
  - (a)  $E(u_i u_i' | X_i, c_i) = \sigma_u^2 I_T$
  - (b)  $E(c_i^2 | X_i) = \sigma_c^2$ .

Bajo RE.3,  $\Omega$  tiene la forma (29).

# Modelo de Efectos Aleatorios

- **Implementación:** Necesitamos un estimador consistente de  $\Omega$ .
- Asumamos que tenemos estimadores consistentes de  $\sigma_c^2$  y  $\sigma_u^2$  entonces:

$$\hat{\Omega} = \hat{\sigma}_c^2 J_T J_T' + \hat{\sigma}_u^2 I_T \quad (30)$$

- El estimador FGLS que usa (30) se conoce como **estimador de efectos aleatorios**.

●

$$\hat{\beta}^{RE} = \left( \sum_{i=1}^N x_i' \hat{\Omega}^{-1} x_i \right)^{-1} \left( \sum_{i=1}^N x_i' \hat{\Omega}^{-1} y_i \right)$$

- El estimador anterior es consistente bajo **RE.1 y RE.2**.

$$\hat{\beta}^{RE} = \beta + \left( \sum_{i=1}^N x_i' \hat{\Omega}^{-1} x_i \right)^{-1} \left( \sum_{i=1}^N x_i' \hat{\Omega}^{-1} v_i \right)$$

# Modelo de Efectos Aleatorios

- Bajo el supuesto RE.3, el estimador de efectos aleatorios es eficiente.
- La matriz usual de varianzas-covarianzas de FGLS (23) es válida pero con  $\hat{\Omega}$  dada por (30) en lugar de  $\tilde{\Omega}$ .

$$\widehat{\text{AVar}}(\hat{\beta}) = \left( \sum_{j=1}^N \mathbf{x}_j' \hat{\Omega}^{-1} \mathbf{x}_j \right)^{-1} \quad (31)$$

- Para poder implementar FGLS necesitamos las estimaciones consistentes de  $\sigma_c^2$  y  $\sigma_u^2$ . Para esto definamos  $\sigma_v^2 = \sigma_c^2 + \sigma_u^2$ .
- Bajo el supuesto RE.3(a),  $\sigma_v^2 = T^{-1} \sum_{t=1}^T E(v_{it}^2)$  para todo  $i$ .
- Por lo tanto, un estimador consistente de  $\sigma_v^2$  es:

$$\hat{\sigma}_v^2 = \frac{1}{NT - K} \sum_{i=1}^N \sum_{t=1}^T \hat{v}_{it}^2$$

Donde  $\hat{v}_{it}$  son los residuos de POLS.

# Modelo de Efectos Aleatorios

- Para encontrar un estimador consistente de  $\sigma_c^2$ , recuerde que  $\sigma_c^2 = E(v_{it}v_{is})$ , para todo  $t \neq s$ .
- Un estimador consistente es entonces:

$$\hat{\sigma}_c^2 = \frac{1}{[NT(T-1) - 1]/2 - K} \sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is} \quad (32)$$

- Con estos resultados podemos estimar consistentemente:  $\hat{\sigma}_u^2 = \hat{\sigma}_v^2 - \hat{\sigma}_c^2$ .
- En la práctica, la ecuación para estimar  $\sigma_c^2$  no garantiza una estimación POSITIVA.
- Si la estimación da negativa entonces eso es un signo de que existe correlación negativa en  $u_{it}$  lo que implica que RE.3 no se cumple.
- En este caso debieramos estimar FGLS sin restricciones.

# Modelo de Efectos Aleatorios

- Si el supuesto RE.3 no se cumple es importante poder realizar inferencia estadística sin ese supuesto.
- Para ello, simplemente utilizamos la estimación robusta de la matriz de varianzas y covarianzas dada por la ecuación (22), reemplazando  $\tilde{u}_i$  por  $\hat{v}_i = y_i - X_i \hat{\beta}^{RE}$ ,  $i = 1, 2, \dots, N$

$$\hat{V} = \left( \sum_{i=1}^N X_i' \hat{\Omega}^{-1} X_i \right)^{-1} \left( \sum_{i=1}^N X_i' \hat{\Omega}^{-1} \hat{v}_i \hat{v}_i' \hat{\Omega}^{-1} X_i \right) \left( \sum_{i=1}^N X_i' \hat{\Omega}^{-1} X_i \right)^{-1} \quad (33)$$

- Los errores estándar robustos se obtienen de la raíz cuadrada de la diagonal principal de (33), y el test de Wald robusto se obtiene con la fórmula:

$$W = (R \hat{\beta}^{RE} - r)' [R \hat{V} R']^{-1} (R \hat{\beta}^{RE} - r) \xrightarrow{d} \chi_Q^2 \quad (34)$$

donde  $\hat{V}$  es la matriz de varianzas y covarianzas estimada en forma robusta.

# Modelo de Efectos Aleatorios

- Si los errores idiosincráticos  $\{u_{it} : t = 1, 2, \dots, T\}$  son heterocedásticos y/o tienen correlación serial, se debe utilizar un estimador de  $\Omega$  más general:

$$\hat{\Omega} = N^{-1} \sum_{i=1}^N \hat{\mathbf{v}}_i \hat{\mathbf{v}}_i'$$

donde  $\hat{\mathbf{v}}_i$  son los residuos de POLS.

- Con  $N$  grande el estimador de FGLS más general es tan eficiente como RE.
- El estimador de FGLS más general es más eficiente que RE si  $E(\mathbf{v}_i \mathbf{v}_i' | \mathbf{X}_i) = \Omega$ , pero  $\Omega$  no tiene la estructura de efectos aleatorios.
- Por qué entonces no se usa siempre el modelo más general?
- Históricamente, la estructura de la matriz de varianzas y covarianzas de RE se consideró sinónimo de efectos no observables.

# Modelo de Efectos Aleatorios

- Contraste por la presencia de un efecto no observable.
- Si los **supuestos RE.1-RE.3** se cumplen pero **no existe un efecto no observable**, entonces POLS es eficiente y todos los estadísticos asociados a POLS son asintóticamente válidos.
- La ausencia de un efecto no observable es estadísticamente equivalente a  $H_0 : \sigma_c^2 = 0$ .
- El estadístico de contraste se basa en (32) y en la distribución asintótica de

$$N^{-1/2} \sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is} \quad (35)$$

que es esencialmente el estimador de  $\sigma_c^2$  escalado por  $N^{-1/2}$ .

- Por el supuesto de exogeneidad estricta la distribución de (35) es la misma con los residuos de POLS que con los errores verdaderos.



# Modelo de Efectos Aleatorios

- $N^{-1/2} \sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T v_{it} v_{is}$  tiene distribución normal con varianza dada por  $E \left( \sum_{t=1}^{T-1} \sum_{s=t+1}^T v_{it} v_{is} \right)$
- Haciendo el cociente entre (35) y su error estándar tenemos un estadístico de contraste con distribución normal estandar.

$$Z = \frac{\sum_{i=1}^N \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is}}{\left( \sum_{i=1}^N \left( \sum_{t=1}^{T-1} \sum_{s=t+1}^T \hat{v}_{it} \hat{v}_{is} \right)^2 \right)^{1/2}} \quad (36)$$

- El estadístico (36) tiene la capacidad de detectar muchas formas de correlación serial en el error compuesto.
- Tradicionalmente, el estadístico de contraste utilizado para detectar la presencia de efectos no observables es el estadístico del multiplicador de Lagrange (Breusch-Pagan, 1980).

# Modelo de Efectos Aleatorios

- La hipótesis nula del test de Breusch-Pagan es la misma:  $H_0 : \sigma_c^2 = 0$ , y el estadístico de contraste es:

$$LM = \frac{NT}{2(T-1)} \left[ \frac{\sum_{i=1}^N \left( \sum_{t=1}^T \hat{v}_{it} \right)^2}{\sum_{i=1}^N \sum_{t=1}^T \hat{v}_{it}^2} - 1 \right]^2 \quad (37)$$

- Bajo la hipótesis nula (37) se distribuye como una  $\chi_1^2$  siempre y cuando los errores tengan **DISTRIBUCION NORMAL**.
- Como (36) no hace ningún supuesto sobre la distribución de los errores compuestos es preferible a (37).

# Agenda

- 1 Introducción
- 2 Teoría Asintótica
- 3 Modelos de Datos de Panel Lineales
- 4 Modelos de Efectos Fijos y Aleatorios**
  - Modelo de Efectos Aleatorios
  - Modelo de Efectos Fijos**
    - Transformación de Efectos Fijos ó Within Transformation
    - Modelo de Variables Binarias (LSDV)
    - Transformación de Diferencias Finitas
    - Transformación por Desviaciones Ortogonales
- 5 Two-Way Fixed Effects Model

# Modelo de Efectos Fijos

- Consideremos nuevamente el **modelo de componentes no observados**

$$\begin{aligned}y_{it} &= x_{it}\beta + c_i + u_{it} \quad \forall i, t \\ y_i &= X_i\beta + c_iJ_T + u_i \quad \forall i\end{aligned}\tag{38}$$

donde:

$$y_i = \begin{bmatrix} y_{i1} \\ \vdots \\ y_{iT} \end{bmatrix} ; \quad X_i = \begin{bmatrix} x_{i1} \\ \vdots \\ x_{iT} \end{bmatrix} ; \quad J_T = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$$

- Como vimos, el procedimiento de RE para estimar  $\beta$  es poner a  $c_i$  en el término de error bajo el supuesto de que  $c_i$  es ortogonal a  $X_i$  y luego tomar en cuenta la correlación serial del error compuesto usando GLS.

# Modelo de Efectos Fijos

- En muchas aplicaciones, todo el punto de trabajar con datos de panel es permitir que  $c_i$  y  $X_i$  estén arbitrariamente correlacionados.
- El modelo de **efectos fijos** asume que  $\text{cov}(c_i, x_{it}) \neq 0$  y por lo tanto  $E(v_{it}|X_i) \neq 0$ . En otras palabras, una o más variables explicativas están correlacionadas con el error compuesto y FGLS dará estimaciones sesgadas e inconsistentes.
- Para obtener estimaciones consistentes, el **modelo de efectos fijos** asume **exogeneidad estricta de las variables explicativas condicionadas en  $c_i$** .
- **Supuesto FE.1:**  $E(u_{it}|X_i, c_i) = 0, \quad t = 1, 2, \dots, T$
- Note que este supuesto es exactamente el mismo que **RE.1(a)**.
- La diferencia fundamental con RE es que **no asumimos RE.1(b)**. Esto es, el análisis de efectos fijos permite que  $E(c_i|X_i)$  sea una función de  $X_i$ .

# Modelo de Efectos Fijos

- Relajando el supuesto RE.1(b) podemos estimar en forma consistente efectos parciales en presencia de variables omitidas constantes en el tiempo.
- En este último sentido, el análisis de FE es más robusto que el de RE.
- Sin embargo, esta mayor robustez tiene un precio.
- No podemos incluir en  $x_{it}$  factores constantes en el tiempo.
- La idea detrás de la estimación de  $\beta$  bajo el supuesto FE.1 es transformar (38) para eliminar el efecto no observable  $c_i$ .
- Existen varias transformaciones que logran eliminar  $c_i$ .
- Nosotros trabajaremos con tres transformaciones:
  - (a) Efectos fijos (FE ó within transformation)
  - (b) Diferencias finitas
  - (c) Desviaciones ortogonales (forward orthogonal deviations)

# Modelo de Efectos Fijos

- Within Transformation
- La transformación de FE se obtiene promediando la ecuación (38) sobre  $t = 1, 2, \dots, T$  para obtener la ecuación de corte transversal:

$$\bar{y}_i = \bar{x}_i \beta + c_i + \bar{u}_i \quad (39)$$

donde  $\bar{y}_i = (1/T) \sum_{t=1}^T y_{it}$ ,  $\bar{x}_i = (1/T) \sum_{t=1}^T x_{it}$  y  $\bar{u}_i = (1/T) \sum_{t=1}^T u_{it}$ .

- Restando miembro a miembro (39) de (38) se obtiene

$$\begin{aligned} y_{it} - \bar{y}_i &= (x_{it} - \bar{x}_i) \beta + u_{it} - \bar{u}_i \\ \ddot{y}_{it} &= \ddot{x}_{it} \beta + \ddot{u}_{it} \end{aligned} \quad (40)$$

donde  $\ddot{y}_{it} = y_{it} - \bar{y}_i$ ,  $\ddot{x}_{it} = x_{it} - \bar{x}_i$  y  $\ddot{u}_{it} = u_{it} - \bar{u}_i$ .

- Con  $c_i$  fuera de la ecuación es lógico pensar en estimar (40) por POLS.

# Modelo de Efectos Fijos

- Recordemos que para obtener estimadores consistentes por POLS necesitamos que se cumplan los **supuestos 1 y 2**. Esto es:

$$E(\ddot{x}_{it}' \ddot{u}_{it}) = 0, \quad t = 1, 2, \dots, T \quad (41)$$

- Para cada  $t$ , (41) puede escribirse como:

$$E[(x_{it} - \bar{x}_i)'(u_{it} - \bar{u}_i)]$$

- Bajo el **supuesto FE.1** de exogeneidad estricta (41) se cumple.
- Por lo tanto, POLS puede aplicarse para obtener estimaciones consistentes.
- Note que el supuesto de exogeneidad estricta no puede relajarse a algo como exogeneidad contemporánea porque este último supuesto no garantiza que se cumpla (41).
- El **estimador de efectos fijos**, denotado por  $\hat{\beta}^{FE}$  es el estimador POLS de la regresión de  $\ddot{y}_{it}$  sobre  $\ddot{x}_{it} \forall i, t$ .



# Modelo de Efectos Fijos

- Entonces el estimador de efectos fijos de  $\beta$ ,  $\hat{\beta}^{FE}$  es:

$$\begin{aligned}\hat{\beta}^{FE} &= \left( \sum_{i=1}^N \ddot{X}_i' \ddot{X}_i \right)^{-1} \left( \sum_{i=1}^N \ddot{X}_i' \ddot{y}_i \right) \\ &= \left( \sum_{i=1}^N X_i' Q_T X_i \right)^{-1} \left( \sum_{i=1}^N X_i' Q_T y_i \right) \\ &= \left( \ddot{X}' \ddot{X} \right)^{-1} \ddot{X}' \ddot{y} \\ &= [X'(I_N \otimes Q_T)X]^{-1} X'(I_N \otimes Q_T)y\end{aligned}\tag{42}$$

donde  $Q_T = I_T - J_T(J_T' J_T)^{-1} J_T'$  es la matriz **time-demeaning** que es una matriz simétrica e idempotente de rango  $T - 1$ .

- Note que  $Q_T \times J_T = 0$ ;  $Q_T \times y_i = \ddot{y}_i$  y  $Q_T \times X_i = \ddot{X}_i$ .

# Modelo de Efectos Fijos

- Para que el estimador de FE se comporte bien asintóticamente necesitamos la condición de rango estándar:
- **Supuesto FE.2:**  $\text{rango} \left[ \sum_{t=1}^T E(\ddot{x}_{it}' \ddot{x}_{it}) \right] = \text{rango} \left[ E(\ddot{X}_i' \ddot{X}_i) \right] = K$
- Note que si  $x_{it}$  contiene algún elemento que no varía en el tiempo para cualquier  $i$ , entonces el elemento correspondiente en  $\ddot{x}_{it}$  es idénticamente igual a cero.
- Como  $\ddot{X}_i$  contendría una columna de ceros, el **supuesto FE.2** no podría ser verdadero.
- Esto muestra explícitamente porque las variables constantes en el tiempo no están permitidas en el análisis.
- El estimador de efectos fijos (42) recibe usualmente el nombre de **within estimator** porque utiliza la variación temporal dentro de cada corte transversal.

# Modelo de Efectos Fijos

- Existe un segundo estimador de  $\beta$  conocido como el **between estimator**.
- El between estimator consiste en aplicar OLS a la ecuación promediada en el tiempo (39):  $\bar{y}_i = \bar{x}_i\beta + c_i + \bar{u}_i$
- Este estimador **NO** es consistente bajo el supuesto FE.1 porque  $E(\bar{x}_i'c_i) \neq 0$ .
- Para obtener un estimador consistente en (39) necesitamos asumir **RE.1** y la **condición de rango estándar**.

# Modelo de Efectos Fijos

- Inferencia Asintótica en FE
- El siguiente supuesto asegura que el estimador de FE es el más eficiente:
- **Supuesto FE.3:**  $E(u_i u_i' | X_i, c_i) = \sigma_u^2 I_T$ .
- El **supuesto FE.3** es idéntico a **RE.3(a)**.
- Como  $E(u_i | X_i, c_i) = 0$  por FE.1, el supuesto FE.3 es igual a decir que  $\text{Var}(u_i | X_i, c_i) = \sigma_u^2 I_T$ .
- El supuesto FE.3 junto con el supuesto FE.1 aseguran que la matriz de varianzas y covarianzas marginal del error compuesto tiene la estructura que vimos para RE, pero sin el supuesto RE.3(b).
- Este resultado que es importante para RE no tiene ninguna importancia para hacer inferencia bajo FE.

► Back

# Modelo de Efectos Fijos

- Considere la siguiente ecuación

$$\ddot{y}_{it} = \ddot{x}_{it}\beta + \ddot{u}_{it} \quad (43)$$

- Para que POLS aplicado a (43) resulte eficiente necesitamos que los errores sean homocedásticos y que no estén serialmente correlacionados en el tiempo.
- La varianza de  $\ddot{u}_{it}$  puede calcularse como:

$$\begin{aligned} E(\ddot{u}_{it}^2) &= E[(u_{it} - \bar{u}_i)^2] = E(u_{it}^2) + E(\bar{u}_i^2) - 2E(u_{it}\bar{u}_i) \\ &= \sigma_u^2 + \sigma_u^2/T - 2\sigma_u^2/T = \sigma_u^2(1 - 1/T) \end{aligned}$$

lo que verifica la homocedasticidad.

- La covarianza entre  $\ddot{u}_{it}$  y  $\ddot{u}_{is}$  es:

$$\begin{aligned} E(\ddot{u}_{it}\ddot{u}_{is}) &= E[(u_{it} - \bar{u}_i)(u_{is} - \bar{u}_i)] \\ &= E(u_{it}u_{is}) + E(\bar{u}_i^2) - E(u_{it}\bar{u}_i) - E(u_{is}\bar{u}_i) \\ &= 0 + \sigma_u^2/T - \sigma_u^2/T - \sigma_u^2/T = -\sigma_u^2/T \end{aligned}$$

# Modelo de Efectos Fijos

- Combinando las dos expresiones anteriores tenemos:

$$\text{Corr}(\ddot{u}_{it}, \ddot{u}_{is}) = -1/(T - 1)$$

Lo que muestra que los errores transformados tienen correlación serial negativa en el tiempo. Para encontrar la varianza asintótica del estimador de FE escribamos (42) de la siguiente manera:

$$\begin{aligned}\hat{\beta}^{FE} &= \left( \sum_{i=1}^N \ddot{X}_i' \ddot{X}_i \right)^{-1} \left( \sum_{i=1}^N \ddot{X}_i' \ddot{y}_i \right) \\ &= \beta + \left( \sum_{i=1}^N \ddot{X}_i' \ddot{X}_i \right)^{-1} \left( \sum_{i=1}^N \ddot{X}_i' u_i \right) \Rightarrow \\ \sqrt{N}(\hat{\beta}^{FE} - \beta) &= \left( N^{-1} \sum_{i=1}^N \ddot{X}_i' \ddot{X}_i \right)^{-1} \left( N^{-1/2} \sum_{i=1}^N \ddot{X}_i' u_i \right)\end{aligned}\tag{44}$$

# Modelo de Efectos Fijos

- La ecuación anterior surge de utilizar la siguiente relación:

$$\ddot{X}_i' \ddot{u}_i = (Q_T X_i)' Q_T u_i = X_i' Q_T u_i = \ddot{X}_i' u_i$$

- Por el supuesto FE.3:  $E(u_i u_i' | X_i, c_i) = \sigma_u^2 I_T$ .
- Por lo tanto:

$$\sqrt{N}(\hat{\beta}^{FE} - \beta) \xrightarrow{d} \text{Normal} \left( 0, \sigma_u^2 [E(\ddot{X}_i' \ddot{X}_i)]^{-1} \right)$$

- Y además:  $\text{Avar}(\hat{\beta}^{FE}) = \sigma_u^2 [E(\ddot{X}_i' \ddot{X}_i)]^{-1} / N$
- Dado un estimador consistente de  $\sigma_u^2$ , la varianza asintótica puede ser estimada reemplazando la esperanza por su análogo muestral.

$$\widehat{\text{Avar}}(\hat{\beta}^{FE}) = \hat{\sigma}_u^2 \left( \sum_{i=1}^N \ddot{X}_i' \ddot{X}_i \right)^{-1} = \hat{\sigma}_u^2 \left( \sum_{i=1}^N \sum_{t=1}^T \ddot{x}_{it}' \ddot{x}_{it} \right)^{-1} \quad (45)$$

# Modelo de Efectos Fijos

- Los errores estándar asintóticos se obtienen con la raíz cuadrada de los elementos de la diagonal principal de (45).
- El único punto a tener en cuenta es la estimación de  $\sigma_u^2$ .
- Note que sumando sobre  $t$ ,  $E(\ddot{u}_{it}^2)$  obtenemos  $(T - 1)\sigma_u^2$ . Por lo tanto:

$$\frac{1}{T - 1} \sum_{t=1}^T E(\ddot{u}_{it}^2) = \sigma_u^2 \quad (46)$$

- Definamos los residuos de FE como:

$$\hat{\ddot{u}}_{it} = \ddot{y}_{it} - \ddot{x}_{it}\hat{\beta}^{FE}, \quad \forall i, t$$

- Un estimador consistente de  $\sigma_u^2$  es entonces:

$$\hat{\sigma}_u^2 = \frac{1}{N(T - 1) - K} \sum_{i=1}^N \sum_{t=1}^T \hat{\ddot{u}}_{it}^2 \quad (47)$$



# Modelo de Efectos Fijos

- Piense que uno podría haber conseguido un estimador para  $\sigma_u^2$  aplicando el principio de analogía en (46) y reemplazar la esperanza por su análogo muestral.
- Un punto a tener en cuenta es que el denominador de (47) NO son los grados de libertad que uno obtendría de aplicar POLS a la ecuación transformada por FE (43).
- La estimación de la varianza de los errores en (43) sería  $RSS/(NT - K)$ .
- La diferencia entre esta última estimación y (47) puede ser grande si  $T$  es chico.
- En general los errores estándar reportados directamente de (43) tienden a ser pequeños comparados con los verdaderos.

- Bajo los **supuestos FE.1-FE.3** restricciones múltiples en los coeficientes pueden ser contrastadas utilizando la fórmula estándar del test de Wald:

$$F = \frac{(RSS_r - RSS_u)/Q}{RSS_u/[N(T-1) - K]} \xrightarrow{d} F_{Q, N(T-1)-K}$$

# Modelo de Efectos Fijos

- El Modelo de Variables Binarias (LSDV)
- El enfoque tradicional de FE es ver a  $c_i$  como parámetros a ser estimados.
- Si cambiamos el supuesto FE.2 a su versión de muestra finita:  $\text{rango} \ddot{X}' \ddot{X} = K$ , el modelo satisface todos los supuestos de Gauss-Markov.
- Para estimar el modelo se definen  $N$  variables binarias, una para cada observación de corte transversal.
- Luego se estima por POLS una regresión de  $y_{it}$  sobre las variables binarias,  $x_{it}$  con  $t = 1, 2, \dots, T$ ;  $j = 1, 2, \dots, N$ .
- Los coeficientes que acompañan a las variables binarias son las estimaciones de los  $c_i$ .
- El estimador obtenido de esta última regresión es exactamente igual al estimador de FE. Debido a esto, el estimador de FE recibe el nombre de **estimador de variables binarias**.

# Modelo de Efectos Fijos

- Considere el siguiente modelo,

$$y = X\beta + C\gamma + u = X\beta + (I_N \otimes J_T)\gamma + u \quad (48)$$

donde  $\gamma$  es  $N \times 1$  y es el vector de coeficientes que acompañan a las variables binarias.

- Re-escribiendo (48) como

$$y = [X|(I_N \otimes J_T)] \begin{pmatrix} \beta \\ \gamma \end{pmatrix} + u \quad (49)$$

- Obtenemos,

$$\hat{\beta}^{LSDV} = [X'(I_N \otimes Q_T)X]^{-1} X'(I_N \otimes Q_T)y \quad (50)$$

- Los residuos del modelo LSDV son exactamente iguales a los de (43).
- Una ventaja del modelo LSDV es que produce el estimador correcto de la varianza de los errores porque usa como grados de libertad  $NT - N - K = N(T - 1) - K$ .

# Modelo de Efectos Fijos

- Un problema con el enfoque LSDV es que los estimadores de  $c_i$  son insesgados pero no son consistentes.
- El estimador de FE es consistente y asintóticamente normal si se cumplen FE.1 y FE.2.
- Si no se cumple FE.3, entonces (45) nos dará un estimador incorrecto de la matriz de varianzas y covarianzas de los estimadores.
- Si no se cumple FE.3, entonces debemos reemplazar (45) por una estimación robusta.
- Aplicando los resultados ya vistos, podemos utilizar la ecuación (13) reemplazando los residuos por los estimados por FE.

$$\hat{V} = \left( \sum_{j=1}^N \ddot{X}_j' \ddot{X}_j \right)^{-1} \left( \sum_{j=1}^N \ddot{X}_j' \hat{u}_j \hat{u}_j' \ddot{X}_j \right) \left( \sum_{j=1}^N \ddot{X}_j' \ddot{X}_j \right)^{-1} \quad (51)$$

- Los errores estándar de los estimadores de FE se obtienen de la raíz cuadrada de los elementos de la diagonal principal de (51).

# Modelo de Efectos Fijos

- En lugar de calcular una matriz de varianzas y covarianzas robusta para el estimador FE, se podría relajar el supuesto FE.3 para permitir una matriz no restringida general y aplicar GLS.
- Supuesto FEGLS.3:  $E(u_i u_i' | X_i, c_i) = \Lambda$ , una matriz  $T \times T$  definida positiva.
- Bajo FEGLS.3,  $E(\ddot{u}_i \ddot{u}_i' | \ddot{X}_i) = E(\ddot{u}_i \ddot{u}_i')$  y usando el hecho de que  $\ddot{u}_i = Q_T u_i$ , tenemos,
- $E(\ddot{u}_i \ddot{u}_i') = Q_T \Lambda Q_T$ , que tiene rango  $T - 1$ .
- Esto es un problema porque no podemos invertir esta matriz para obtener los estimadores GLS.
- Dos soluciones:
  - (i) trabajar con la inversa generalizada.
  - (ii) eliminar un período temporal.

# Modelo de Efectos Fijos

- Supongamos que eliminamos el período  $T$ . Entonces tenemos las siguientes ecuaciones:

$$\begin{aligned}\ddot{y}_{i1} &= \ddot{x}_{i1}\beta + \ddot{u}_{i1} \\ \vdots &= \vdots \quad \quad \quad \vdots \\ \ddot{y}_{iT-1} &= \ddot{x}_{iT-1}\beta + \ddot{u}_{iT-1}\end{aligned}$$

- Podemos re-escribir este sistema como si fuera (42) con la única diferencia que ahora los vectores y matrices tienen dimensión  $(T - 1)$ .
- Definamos la matriz  $(T - 1) \times (T - 1)$ :  $\Omega = E(\ddot{u}_i \ddot{u}_i')$
- Para estimar  $\Omega$ , tenemos que estimar  $\beta$  por FE en un primer paso.
- Después hay que eliminar el período  $T$  y construir los  $(T - 1) \times 1$  residuos

$$\hat{\hat{u}}_i = \ddot{y}_i - \ddot{X}_i \hat{\beta}^{FE}, \quad i = 1, 2, \dots, N$$

# Modelo de Efectos Fijos

- Un estimador consistente de  $\Omega$  es:

$$\hat{\Omega} = N^{-1} \sum_{i=1}^N \hat{u}_i \hat{u}_i'$$

- El estimador de FE por GLS se define como:

$$\hat{\beta}^{FEGLS} = \left( \frac{1}{N} \sum_{j=1}^N \ddot{X}_j' \hat{\Omega}^{-1} \ddot{X}_j \right)^{-1} \left( \frac{1}{N} \sum_{j=1}^N \ddot{X}_j' \hat{\Omega}^{-1} \ddot{y}_j \right) \quad (52)$$

donde las variables están definidas sin el último período temporal.

- Para obtener consistencia necesitamos una nueva condición de rango:
- Supuesto FEGLS.2:**  $\text{rango} E(\ddot{X}_j' \Omega^{-1} \ddot{X}_j) = K$ .
- Bajo FE.1 y FEGLS.2 el estimador de FEGLS es consistente.



# Modelo de Efectos Fijos

- Adicionando el supuesto FEGLS.3, la matriz de varianzas y covarianzas asintótica se estima por:

$$\widehat{\text{Avar}}(\hat{\beta}^{FEGLS}) = \left( \sum_{j=1}^N \ddot{X}_i' \hat{\Omega}^{-1} \ddot{X}_i \right)^{-1}$$

# Modelo de Efectos Fijos

- Aparte de la **within transformation** existen otras transformaciones para eliminar la heterogeneidad no observada. Una de las más utilizadas es la **transformación de diferencias finitas (FD)**.
- Considere el modelo de componentes no observados escrito para los períodos  $t$  y  $t - 1$ ,

$$y_{it} = \alpha_i + x_{it}\beta + u_{it} \quad (53)$$

$$y_{it-1} = \alpha_i + x_{it-1}\beta + u_{it-1} \quad (54)$$

- Restando miembro a miembro,

$$y_{it} - y_{it-1} = (x_{it} - x_{it-1})\beta + (u_{it} - u_{it-1}) \quad (55)$$

$$\Delta y_{it} = \Delta x_{it}\beta + \Delta u_{it} \quad (56)$$

- Como ocurría con la transformación de FE, FD también elimina el efecto individual

# Modelo de Efectos Fijos

- El estimador de diferencias finitas de  $\beta$ ,  $\hat{\beta}^{FD}$ , es:

$$\begin{aligned}\hat{\beta}^{FD} &= \left( \sum_{i=1}^N \Delta X_i' \Delta X_i \right)^{-1} \left( \sum_{i=1}^N \Delta X_i' \Delta y_i \right) \\ &= \left( \sum_{i=1}^N (DX_i)' DX_i \right)^{-1} \left( \sum_{i=1}^N (DX_i)' Dy_i \right) \\ &= \left( \sum_{i=1}^N X_i' D' DX_i \right)^{-1} \left( \sum_{i=1}^N X_i' D' Dy_i \right)\end{aligned}\tag{57}$$

donde

$$D = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \ddots & -1 & 1 \end{bmatrix}\tag{58}$$

# Modelo de Efectos Fijos

- Note que para que este estimador sea consistente necesitamos que se cumpla que:  
**Supuesto FD.1** :  $E(u_{it}|X_i, c_i) = 0, \quad t = 1, 2, \dots, T$
- El **supuesto FD.1**, es igual a **FE.1** y a **RE.1(a)**.
- Bajo **supuesto FD.1**, POLS en (56) será consistente porque  $E(\Delta x'_{it} \Delta u_{it}) = 0, \quad t = 2, \dots, T$ , respectivamente.
- Recuerde que además de este supuesto necesitamos una condición de rango estándar: **supuesto FD.2**:  $\text{rango} E(\Delta X'_i \Delta X_i) = K$ .
- Una de las razones para preferir FD sobre FE es que es fácil de calcular usando un paquete estadístico común.
- Lo único que debemos tener en cuenta es que las observaciones correspondientes a los períodos  $1, T + 1, 2T + 1, \dots, (N - 1)T + 1$  deben considerarse como no disponibles.

# Modelo de Efectos Fijos

- Sin embargo, bajo los **supuestos FE.1-FE.3**, el estimador de FE es el más eficiente dentro de la clase de estimadores que utilizan el supuesto de exogeneidad estricta.
- Una consecuencia de este último punto es que el estimador de **FD** debe ser **menos eficiente si se cumple FE.3**. ► FE.3
- Si se cumple **FE.3**, entonces:  $E(Du_i u_i' D' | X_i, c_i) = DE(u_i u_i' | X_i, c_i) D' = \sigma_u^2 DD'$
- Lo que muestra que los errores estarán correlacionados para períodos adyacentes.
- En este caso, argumentos estándares de GLS nos darán el siguiente estimador óptimo:

$$\hat{\beta}^{FDGLS} = \left( \sum_{i=1}^N X_i' D' (DD')^{-1} D X_i \right)^{-1} \left( \sum_{i=1}^N X_i' D' (DD')^{-1} D y_i \right) \quad (59)$$

# Modelo de Efectos Fijos

- Note que en este caso  $GLS \equiv FGLS$  porque  $DD'$  es conocida.
- Otro punto interesante es que, la matriz idempotente  $D'(DD')^{-1}D$  también puede escribirse como:

$$D'(DD')^{-1}D \equiv I_T - J_T(J_T'J_T)^{-1}J_T' = Q_T$$

donde  $Q_T$  es la matriz **time demeaning** que vimos antes.

- Esto muestra que:  $\hat{\beta}^{FDGLS} = \hat{\beta}^{FE}$
- Si no se cumple **FE.3** entonces uno puede asumir que la primera diferencia de los errores idiosincráticos no tienen correlación serial.
- **Supuesto FD.3:**  $E(e_i e_i' | X_i, c_i) = \sigma_e^2 I_{T-1}$ , donde  $e_i$  es el vector que contiene a  $e_{it} = \Delta u_{it}$ ,  $t = 2, \dots, T$  (ó  $e_i = Du_i$ ).

# Modelo de Efectos Fijos

- Bajo el supuesto FD.3, podemos escribir los errores idiosincráticos como:

$$u_{it} = u_{it-1} + e_{it}$$

- Tal que, ausencia de correlación serial en  $e_{it}$  implica que  $u_{it}$  sigue un paseo al azar (i.e. tiene una dependencia serial muy fuerte).
- Es decir que el supuesto FD.3 representa el otro extremo de FE.3
- Bajo los supuestos FD.1-FD.3, el estimador de FD es el más eficiente dentro de la clase de estimadores que cumplen FE.1.
- Utilizando los resultados de POLS en (57) tenemos que:

$$\widehat{\text{Avar}}(\widehat{\beta}^{FD}) = \hat{\sigma}_e^2 \left( \sum_{i=1}^N X_i' D' D X_i \right)^{-1}$$

donde  $\hat{\sigma}_e^2$  es un estimador consistente de  $\sigma_e^2$ .

# Modelo de Efectos Fijos

- El estimador más simple se obtiene calculando los residuos

$$\hat{e}_{it} = y_{it} - x_{it}\hat{\beta}^{FD}$$

- Y luego estimando  $\sigma_e^2$  como:

$$\hat{\sigma}_e^2 = \frac{1}{N(T-1) - K} \sum_{i=1}^N \sum_{t=1}^T \hat{e}_{it}^2$$

- Si el supuesto FD.3 no se cumple, entonces debemos utilizar una matriz de varianzas y covarianzas robusta.
- Usando (13) tenemos:

$$\hat{V} = \left( \sum_{i=1}^N X_i' D' D X_i \right)^{-1} \left( \sum_{i=1}^N X_i' D' \hat{e}_i \hat{e}_i' D X_i \right) \left( \sum_{i=1}^N X_i' D' D X_i \right)^{-1} \quad (60)$$



# Modelo de Efectos Fijos

- Transformación de Helmert
- Otra forma de eliminar el efecto individual en (38) es mediante la transformación de Helmert ó desviaciones ortogonales hacia adelante:

$$y_{it}^* = \sqrt{\frac{T-t}{T-t+1}} \left[ y_{it} - \frac{1}{T-t} (y_{it+1} + \dots + y_{iT}) \right], \quad t = 1, 2, \dots, T-1$$

- El modelo transformado es entonces:

$$y_{it}^* = x_{it}^* \beta + u_{it}^* \quad (61)$$

- Tal como ocurría con FD y FE, la transformación de Helmert elimina el efecto individual.
- El estimador de desviaciones ortogonales es el estimador POLS en (61).

# Modelo de Efectos Fijos

- Definamos la matriz  $H_T$  de dimensión  $(T - 1) \times T$ :  $H_T = (DD')^{-1/2}D$ .
- Eligiendo  $(DD')^{-1/2}$  como la matriz triangular superior que surge de la factorización de Cholesky, tenemos:

$$H_T = \text{diag}[(T - 1)/T, \dots, 1/2]^{-1/2}H^+$$

con

$$H^+ \equiv \begin{bmatrix} 1 & (1 - T)^{-1} & (1 - T)^{-1} & \dots & (1 - T)^{-1} & (1 - T)^{-1} & (1 - T)^{-1} \\ 0 & 1 & (2 - T)^{-1} & \dots & (2 - T)^{-1} & (2 - T)^{-1} & (2 - T)^{-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 1 & -1/2 & -1/2 \\ 0 & 0 & 0 & \dots & 0 & 1 & -1 \end{bmatrix}$$

# Modelo de Efectos Fijos

- Usando esta matriz  $H_T$  el modelo (61) puede escribirse como:

$$H_T y_i = H_T x_i \beta + H_T u_i$$

- El estimador HT es entonces:

$$\begin{aligned}\hat{\beta}^{HT} &= \left( \sum_{i=1}^N X_i' H_T' H_T X_i \right)^{-1} \left( \sum_{i=1}^N X_i' H_T' H_T y_i \right) \\ &= \beta + \left( \sum_{i=1}^N X_i' H_T' H_T X_i \right)^{-1} \left( \sum_{i=1}^N X_i' H_T' H_T u_i \right)\end{aligned}\tag{62}$$

- Bajo que supuestos este estimador es consistente?
- Claramente como  $H_T = (DD')^{-1/2}D$ , entonces  $H_T' H_T = Q_T$ . Y por lo tanto

$$\hat{\beta}^{FE} \equiv \hat{\beta}^{FDGLS} \equiv \hat{\beta}^{HT}$$

# Modelo de Efectos Fijos

- El último punto implica que necesitamos:
- **Supuesto HT.1:**  $E(u_{it}|X_i, c_i) = 0, \quad t = 1, 2, \dots, T$
- El **supuesto HT.1** es igual a **FE.1**, a **FD.1** y a **RE.1(a)**.
- **Supuesto HT.2:**  $\text{rango}[E(X_i' H_T' H_T X_i)] = K$
- Bajo los **supuestos HT.1 y HT.2**, el estimador  $\hat{\beta}^{HT}$  es consistente.
- Note que como  $H_T = (DD')^{-1/2}D$ , entonces  $H_T H_T' = I_{T-1}$ , y por lo tanto si se cumple **FE.3**:

$$E(u_i^* u_i^{*'} | X_i, c_i) = H_T E(u_i u_i' | X_i, c_i) H_T' = \sigma_u^2 I_{T-1}.$$

- Queda claro de (62) que

$$\begin{aligned} \hat{\beta}^{HT} &= \beta + \left( \sum_{i=1}^N X_i' H_T' H_T X_i \right)^{-1} \left( \sum_{i=1}^N X_i' H_T' H_T u_i \right) \\ &= \beta + \left( \sum_{i=1}^N X_i' Q_T X_i \right)^{-1} \left( \sum_{i=1}^N X_i' Q_T u_i \right) = \hat{\beta}^{FE} \end{aligned} \quad (63)$$

# Modelo de Efectos Fijos

- Por lo tanto, bajo HT.1-HT.2 y FE.3,

$$\sqrt{N}(\hat{\beta}^{HT} - \beta) \xrightarrow{d} \text{Normal}(0, \sigma_u^2 [E(X_i' H_T' H_T X_i)]^{-1})$$

- Y además:  $\text{Avar}(\hat{\beta}^{HT}) = \sigma_u^2 [E(X_i' H_T' H_T X_i)]^{-1} / N$ .
- Dado un estimador consistente de  $\sigma_u^2$ , la varianza asintótica puede ser estimada reemplazando la esperanza por su análogo muestral.

$$\widehat{\text{Avar}}(\hat{\beta}^{HT}) = \hat{\sigma}_u^2 \left[ \sum_{i=1}^N X_i' H_T' H_T X_i \right]^{-1} \quad (64)$$

- Los errores estándar asintóticos se obtienen con la raíz cuadrada de los elementos de la diagonal principal de (64).
- Al igual que ocurría con la transformación de FE, el único punto a tener en cuenta es la estimación de  $\sigma_u^2$ .

# Modelo de Efectos Fijos

- Un estimador consistente de  $\sigma_u^2$  es:

$$\hat{\sigma}_u^2 = \frac{1}{N(T-1) - K} \sum_{i=1}^N \sum_{t=1}^T \hat{u}_{it}^* \hat{u}_{it}^{*'} \quad (65)$$

donde,  $\hat{u}_{it}^* = y_{it}^* - x_{it}^* \hat{\beta}^{HT}$ .

- Si FE.3 no se satisface, entonces debemos reemplazar (64) por una estimación robusta.
- Aplicando los resultados ya vistos, podemos utilizar la ecuación (13) reemplazando los residuos por los estimados por HT.

$$\hat{V} = \left( \sum_{i=1}^N x_i^{*'} x_i^* \right)^{-1} \left( \sum_{i=1}^N x_i^{*'} \hat{u}_i^* \hat{u}_i^{*'} x_i^* \right) \left( \sum_{i=1}^N x_i^{*'} x_i^* \right)^{-1} \quad (66)$$

- Los errores estándar de los estimadores de HT se obtienen de la raíz cuadrada de los elementos de la diagonal principal de (66).

# Modelo de Efectos Fijos

- Relación entre FE y RE
- Escribamos la matriz de varianzas y covarianzas con la estructura de RE:

$$\begin{aligned}\Omega &= \sigma_u^2 I_T + \sigma_c^2 J_T J_T' = \sigma_u^2 I_T + T \sigma_c^2 J_T (J_T' J_T)^{-1} J_T' \\ &= \sigma_u^2 I_T + T \sigma_c^2 P_T = (\sigma_u^2 + T \sigma_c^2) (P_T + \eta Q_T)\end{aligned}$$

donde  $P_T \equiv I_T - Q_T = J_T (J_T J_T')^{-1} J_T'$ , y  $\eta = \sigma_u^2 / (\sigma_u^2 + T \sigma_c^2)$ .

- Note que de la definición de  $P_T$  tenemos las siguientes relaciones:
  - (i)  $P_T + Q_T = I_T$
  - (ii)  $P_T Q_T = 0$
  - (iii)  $P_T P_T = P_T$
- Ahora definamos  $S_T = P_T + \eta Q_T$ .  $S_T^{-1} = P_T + (1/\eta) Q_T$  y  $S_T^{-1/2} = P_T + (1/\sqrt{\eta}) Q_T$ .

# Modelo de Efectos Fijos

- Usando álgebra:  $S_T^{-1/2} = (1 - \lambda)^{-1}[I_T - \lambda P_T]$ , con  $\lambda = 1 - \sqrt{\eta}$ .
- Por lo tanto,

$$\begin{aligned}\Omega^{-1/2} &= (\sigma_u^2 + T\sigma_c^2)^{-1/2}(1 - \lambda)^{-1}[I_T - \lambda P_T] \\ &= (1/\sqrt{\sigma_u^2})[I_T - \lambda P_T]\end{aligned}$$

donde  $\lambda = 1 - [\sigma_u^2/(\sigma_u^2 + T\sigma_c^2)]^{1/2}$ .

- Asumamos por un momento que conocemos  $\lambda$ . Entonces, RE se obtiene con la ecuación transformada:  $C_T y_i = C_T X_i \beta + C_T u_i$  con  $C_T = [I_T - \lambda P_T]$ .
- Escribamos la ecuación transformada como:

$$\check{y}_i = \check{X}_i \beta + \check{u}_i$$

- La varianza de  $\check{u}_i$  es  $E(\check{u}_i \check{u}_i') = C_T \Omega C_T = \sigma_u^2 I_T$ .



# Modelo de Efectos Fijos

- Claramente el elemento  $t$  de  $\check{y}_i$  es

$$y_{it} - \lambda \bar{y}_i$$

- Por lo tanto RE es POLS en:

$$y_{it} - \lambda \bar{y}_i = (x_{it} - \lambda \bar{x}_i)\beta + (u_{it} - \lambda \bar{u}_i), \quad \forall i, t \quad (67)$$

- Los errores de esta ecuación son homocedásticos y no están serialmente correlacionados bajo el **supuesto RE.3**.
- FGLS se obtiene reemplazando  $\lambda$  con un estimador consistente.
- Si  $\hat{\lambda}$  es un estimador consistente de  $\lambda$ , entonces:

$$\hat{\beta}^{RE} = \left( \sum_{i=1}^N \sum_{t=1}^T \check{x}'_{it} \check{x}_{it} \right)^{-1} \sum_{i=1}^N \sum_{t=1}^T \check{x}'_{it} \check{y}_{it} \quad (68)$$

# Modelo de Efectos Fijos

- Los estadísticos  $t$  y  $F$  usuales son válidos asintóticamente bajo los **supuestos RE.1-RE.3**.
- La ecuación (68) muestra que el estimador de RE se puede obtener con lo que se denomina **quasi-time-demeaning**.
- En lugar de sacarle la media temporal, los RE le sacan una fracción  $\hat{\lambda}$  de la media temporal a las variables.
- Si  $\hat{\lambda}$  es cercano a 1, entonces **RE y FE tienden a acercarse**.
- Para ver cuando esto ocurre escribamos  $\hat{\lambda}$  como:

$$\hat{\lambda} = 1 - \{1/[1 + T(\sigma_c^2/\sigma_u^2)]\}^{1/2}$$

- Por lo tanto:  $\hat{\lambda} \longrightarrow 1$  **cuando**  $T \longrightarrow \infty$  **ó**  $(\sigma_c^2/\sigma_u^2) \longrightarrow \infty$ .

# Inferencia en Modelos de Panel

- Como la consideración fundamental para elegir entre FE y RE es el hecho de que los efectos no observables estén o no correlacionados con las variables explicativas, es importante tener un test que contraste este supuesto.
- Hausman (1978) propuso un test basado en las diferencias entre los estimadores de FE y RE.
- La hipótesis nula del test asume no correlación entre  $c_i$  y  $x_{it}$  por lo tanto ambos FE y RE son consistentes, pero FE es ineficiente.
- La hipótesis alternativa asume que hay correlación entre  $c_i$  y  $x_{it}$  por lo tanto FE es consistente, pero RE no.
- Por lo tanto bajo la nula, los dos estimadores no debieran diferir mucho.
- Denotemos por  $\hat{\delta}^{RE}$  al vector de estimadores de RE sin los coeficientes que acompañan a variables constantes en el tiempo; y por  $\hat{\delta}^{FE}$  a los correspondientes estimadores de FE.

# Inferencia en Modelos de Panel

- Suponiendo que ambos vectores de estimadores tienen dimensión  $M \times 1$ , el estadístico del test de Hausman es:

$$H = (\hat{\delta}^{FE} - \hat{\delta}^{RE})' [\widehat{Var}(\delta)^{FE} - \widehat{Var}(\delta)^{RE}]^{-1} (\hat{\delta}^{FE} - \hat{\delta}^{RE}) \Rightarrow \chi_M^2 \quad (69)$$

- Si estamos interesados en un único parámetro podemos transformar el test de Hausman en un test  $t$ .
- Asumamos que estamos interesados en  $\delta_1$ . El test se vuelve:

$$t = \frac{(\hat{\delta}_1^{FE} - \hat{\delta}_1^{RE})}{\sqrt{[\widehat{Var}(\delta_1)^{FE} - \widehat{Var}(\delta_1)^{RE}]}} \Rightarrow N(0, 1) \quad (70)$$

# Inferencia en Modelos de Panel

- **Remark 1:** Se mantienen el supuesto de exogeneidad estricta RE.1(a) bajo la nula y la alternativa.
- **Remark 2:** El test se implementa usualmente asumiendo que RE.3 se cumple bajo la nula.

# Extensión del Modelo de Efectos Fijos

- Una generalización del modelo de componentes no observados incluye efectos fijos temporales.
- Esto es:

$$y_{it} = \alpha_i + \lambda_t + x_{it}\beta + u_{it}, \quad i \in \{1, \dots, N\}, \quad t \in \{1, \dots, T\}$$

- La inclusión de  $\alpha_i$  controla por factores no observables específicos de las unidades pero constantes en el tiempo.
- La inclusión de  $\lambda_t$  controla por factores específicos en el tiempo pero constantes en el corte transversal.
- Ahora, además de calcular las medias temporales de cada variable,  $\bar{y}_i = (1/T) \sum_{t=1}^T y_{it}$ , necesitamos calcular las medias a través del corte transversal:  $\bar{y}_t = (1/N) \sum_{i=1}^N y_{it}$  y las medias totales:  $\bar{y} = (1/NT) \sum_{i=1}^N \sum_{t=1}^T y_{it}$

# Extensión del Modelo de Efectos Fijos

- Para estimar este modelo considere la siguiente transformación:

$$y_{it} = \alpha_i + \lambda_t + x_{it}\beta + u_{it} \quad (71)$$

$$\bar{y}_i = \alpha_i + \bar{\lambda} + \bar{x}_i\beta + \bar{u}_i \quad (72)$$

$$\bar{y}_t = \bar{\alpha} + \lambda_t + \bar{x}_t\beta + \bar{u}_t \quad (73)$$

$$\bar{y} = \bar{\alpha} + \bar{\lambda} + \bar{x}\beta + \bar{u} \quad (74)$$

# Extensión del Modelo de Efectos Fijos

- Restando miembro a miembro de la ecuación (71) la (72) y la (73) y sumando la (74) tenemos

$$\begin{aligned}y_{it} - \bar{y}_i - \bar{y}_t + \bar{y} &= (x_{it} - \bar{x}_i - \bar{x}_t + \bar{x})\beta + (u_{it} - \bar{u}_i - \bar{u}_t + \bar{u}) \\ \ddot{y}_{it} &= \ddot{x}_{it}\beta + \ddot{u}_{it}\end{aligned}\tag{75}$$

- El estimador de MCC de la ecuación (75) se conoce en la literatura como **two-way fixed effects estimator**.