

**Datos de Panel**  
**Problem Set 0**  
**Repaso OLS, GLS & FGLS**  
**Lectura y resumen de datos de panel en Stata**

---

1. Considere el siguiente modelo de regresión:

$$ltotexp_i = \beta_0 + \beta_1 suppins_i + \beta_2 phylim_i + \beta_3 actlim_i + \beta_4 totchr_i + \beta_5 age_i + \beta_6 female_i + \beta_7 income_i + u_i, \quad i = 1, \dots, N$$

- a) Use la base de datos “mus03data.dta”, la cual contiene datos de corte transversal de gastos médicos, para estimar la ecuación por OLS usando comandos de matrices en Stata. Adicionalmente, reporte los errores estándar usuales de OLS y los estadísticos  $t$  asociados.
  - b) Utilice el comando `regress` para verificar los resultados obtenidos.
  - c) Implemente un test de significatividad individual para `totchr`.
  - d) Implemente un test de significatividad conjunta para todas las variables del modelo, excluyendo el intercepto.
2. En este ejercicio vamos a aprender cómo setear los datos como panel en Stata y cómo generar estadísticas descriptivas del panel. Adicionalmente, veremos cómo convertir los datos de *wide form* a *long form* y cómo generar un panel para simulaciones.
- a) Utilice la base `mus08psidextract.dta` y describa la base de datos de la manera usual y como un panel.
  - b) Utilice la base `pigweights.dta`. Los datos se encuentran en formato *wide*. Utilice el comando `reshape` para llevarlos a formato *long*. Luego, describa la base de la misma forma que en el inciso (a).
  - c) Genere un panel de 5000 observaciones con 10 períodos temporales y 500 unidades en el corte transversal. El panel debe estar en formato *long*. Genere observaciones de  $x_{it} \sim \mathcal{N}(0, 1)$ ,  $u_{it} \sim \mathcal{N}(0, 1)$  y además  $y_{it} = 1 + x_{it} + u_{it}$ . Estime por POLS.
3. Considere el siguiente modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i, \quad i = 1, \dots, N$$
$$u_i = \sqrt{\exp(-1 + 0,2 \cdot x_{2i})} \cdot \varepsilon_i, \quad i = 1, \dots, N$$

con  $\beta_1 = 1$ ,  $\beta_2 = 1$ ,  $\beta_3 = 1$ ,  $x_2 \sim \mathcal{N}(0, 25)$ ,  $x_3 \sim \mathcal{N}(0, 25)$  y  $\varepsilon \sim \mathcal{N}(0, 25)$ . Luego, el error  $u$  es heterocedástico con una varianza condicional igual a  $25 \cdot \exp(-1 + 0,2 \cdot x_2)$ .

- a) Genere 1000 muestras de  $N=10$  observaciones a partir del modelo presentado. Para cada muestra estime por OLS, GLS y FGLS los parámetros del modelo y realice un test de hipótesis para contrastar que  $H_0 : \beta_3 = 1$ . Reporte tamaño del test al 1 %. Adicionalmente, reporte la media, mediana y desvío estándar de las estimaciones de  $\beta_1$ ,  $\beta_2$  y  $\beta_3$ .
- b) Repita el punto anterior con  $N$  igual a 20, 30, 100, 200 y 500.
- c) Describa detalladamente las propiedades de muestra finita de FGLS de acuerdo a lo que observó de los puntos anteriores.

## **Trabajo Práctico N° 0:** **Repaso OLS, GLS y FGLS. Lectura y Resumen de Datos de Panel en Stata.**

### **Ejercicio 1.**

Considerar el siguiente modelo de regresión:

$$ltotexp_i = \beta_0 + \beta_1 suppins_i + \beta_2 phylim_i + \beta_3 actlim_i + \beta_4 totchr_i + \beta_5 age_i + \beta_6 female_i + \beta_7 income_i + u_i, i = 1, \dots, N.$$

(a) Usar la base de datos “mus03data.dta”, la cual contiene datos de corte transversal de gastos médicos, para estimar la ecuación por OLS usando comandos de matrices en Stata. Adicionalmente, reportar los errores estándar usuales de OLS y los estadísticos  $t$  asociados.

|         | beta       | se        | t          |
|---------|------------|-----------|------------|
| suppins | .25564276  | .04622641 | 5.5302312  |
| phylim  | .30205979  | .05697091 | 5.3020003  |
| actlim  | .35600541  | .06211178 | 5.7316894  |
| totchr  | .37582014  | .01842273 | 20.399812  |
| age     | .00380163  | .00365613 | 1.039797   |
| female  | -.08432753 | .0455442  | -1.8515536 |
| income  | .00254982  | .0010194  | 2.5013046  |
| _cons   | 6.7037374  | .27675999 | 24.222206  |

(b) Utilizar el comando regress para verificar los resultados obtenidos.

| Source   | SS         | df    | MS         | Number of obs | = | 2,955  |
|----------|------------|-------|------------|---------------|---|--------|
| Model    | 1264.72124 | 7     | 180.674463 | F(7, 2947)    | = | 124.98 |
| Residual | 4260.16814 | 2,947 | 1.44559489 | Prob > F      | = | 0.0000 |
|          |            |       |            | R-squared     | = | 0.2289 |
|          |            |       |            | Adj R-squared | = | 0.2271 |
| Total    | 5524.88938 | 2,954 | 1.87030785 | Root MSE      | = | 1.2023 |

| ltotexp | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |
|---------|-------------|-----------|-------|-------|----------------------|
| suppins | .2556428    | .0462264  | 5.53  | 0.000 | .1650034 .3462821    |
| phylim  | .3020598    | .0569709  | 5.30  | 0.000 | .190353 .4137666     |
| actlim  | .3560054    | .0621118  | 5.73  | 0.000 | .2342185 .4777923    |
| totchr  | .3758201    | .0184227  | 20.40 | 0.000 | .3396974 .4119429    |
| age     | .0038016    | .0036561  | 1.04  | 0.299 | -.0033672 .0109705   |
| female  | -.0843275   | .0455442  | -1.85 | 0.064 | -.1736292 .0049741   |
| income  | .0025498    | .0010194  | 2.50  | 0.012 | .000551 .0045486     |
| _cons   | 6.703737    | .27676    | 24.22 | 0.000 | 6.161075 7.2464      |

(c) Implementar un test de significatividad individual para totchr.

```
(1) totchr = 0
```

```
F( 1, 2947) = 416.15  
Prob > F = 0.0000
```

Por lo tanto, se puede observar que, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que la variable *totchr* es estadísticamente significativa.

**(d)** *Implementar un test de significatividad conjunta para todas las variables del modelo, excluyendo el intercepto.*

```
(1) suppins = 0  
(2) phylim = 0  
(3) actlim = 0  
(4) totchr = 0  
(5) age = 0  
(6) female = 0  
(7) income = 0
```

```
F( 7, 2947) = 124.98  
Prob > F = 0.0000
```

Por lo tanto, con un nivel de significancia del 1%, estos datos aportan evidencia suficiente para indicar que las variables del modelo, en conjunto, son estadísticamente significativas.

**Ejercicio 2.**

En este ejercicio, se va a aprender cómo setear los datos como panel en Stata y cómo generar estadísticas descriptivas del panel. Adicionalmente, se verá cómo convertir los datos de wide form a long form y cómo generar un panel para simulaciones.

(a) Utilizar la base “mus08psidextract.dta” y describir la base de datos de la manera usual y como un panel.

Stata.

(b) Utilizar la base “pigweights.dta”. Los datos se encuentran en formato wide. Utilizar el comando reshape para llevarlos a formato long. Luego, describir la base de la misma forma que en el inciso (a).

Stata.

(c) Generar un panel de 5000 observaciones con 10 períodos temporales y 500 unidades en el corte transversal. El panel debe estar en formato long. Generar observaciones de  $x_{it} \sim \mathcal{N}(0, 1)$ ,  $u_{it} \sim \mathcal{N}(0, 1)$  y, además,  $y_{it} = 1 + x_{it} + u_{it}$ . Estimar por POLS.

|          |  |            |       |            |               |   |         |
|----------|--|------------|-------|------------|---------------|---|---------|
| Source   |  | SS         | df    | MS         | Number of obs | = | 5,000   |
| Model    |  | 5006.33835 | 1     | 5006.33835 | F(1, 4998)    | = | 4972.58 |
| Residual |  | 5031.92865 | 4,998 | 1.00678844 | Prob > F      | = | 0.0000  |
| Total    |  | 10038.267  | 4,999 | 2.00805501 | R-squared     | = | 0.4987  |
|          |  |            |       |            | Adj R-squared | = | 0.4986  |
|          |  |            |       |            | Root MSE      | = | 1.0034  |

  

|       |  |             |           |       |       |                      |
|-------|--|-------------|-----------|-------|-------|----------------------|
| y     |  | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |
| x     |  | 1.01052     | .0143303  | 70.52 | 0.000 | .9824264 1.038614    |
| _cons |  | 1.02376     | .0141901  | 72.15 | 0.000 | .9959417 1.051579    |

**Ejercicio 3.**

Considerar el siguiente modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i, i = 1, \dots, N.$$

$$u_i = \sqrt{e^{(-1+0,2x_{2i})}} \varepsilon_i, i = 1, \dots, N.$$

con  $\beta_1 = 1, \beta_2 = 1, \beta_3 = 1, x_2 \sim \mathcal{N}(0, 25), x_3 \sim \mathcal{N}(0, 25)$  y  $\varepsilon \sim \mathcal{N}(0, 25)$ . Luego, el error  $u$  es heterocedástico con un varianza condicional igual a  $25e^{(-1+0,2x_2)}$ .

(a) Generar 1.000 muestras de  $N = 10$  observaciones a partir del modelo presentado. Para cada muestra, estimar por OLS, GLS y FGLS los parámetros del modelo y realizar un test de hipótesis para contrastar que  $H_0: \beta_3 = 1$ . Reportar tamaño del test al 1%. Adicionalmente, reportar la media, mediana y desvío estándar de las estimaciones de  $\beta_1, \beta_2$  y  $\beta_3$ .

(b) Repetir el inciso anterior con  $N$  igual a 20, 30, 100, 200 y 500.

|              | N_10      | N_20      | N_30      | N_100     | N_200     | N_500     |
|--------------|-----------|-----------|-----------|-----------|-----------|-----------|
| tam_test_1~s | .8        | 1.1       | .8        | 1         | .8        | .8        |
| media_b1_ols | 1.0054159 | 1.0233711 | .9913776  | 1.0073724 | .99101667 | 1.0004401 |
| mediana_b1~s | 1.0432544 | 1.0316013 | 1.011929  | 1.000255  | 1.0050259 | 1.0013884 |
| de_b1_ols    | 1.4418954 | .90375325 | .72169432 | .39574087 | .28065068 | .18146336 |
| media_b2_ols | .99360726 | 1.0100861 | 1.0053778 | 1.003707  | .99668205 | 1.0001666 |
| mediana_b2~s | 1.001702  | 1.0022839 | 1.0072177 | 1.001808  | .99718451 | 1.001999  |
| de_b2_ols    | .37958122 | .24111343 | .19670063 | .11009015 | .07716763 | .05011949 |
| media_b3_ols | 1.0118828 | .99105405 | .98908491 | 1.0008243 | .99812821 | 1.0005964 |
| mediana_b3~s | 1.0206553 | 1.0012873 | .99137709 | 1.0031048 | .99734056 | 1.0004818 |
| de_b3_ols    | .30943622 | .18576126 | .15294122 | .07752204 | .05484899 | .03532914 |
| tam_test_1~s | .8        | 1.6       | .7        | .8        | .7        | 1.3       |
| media_b1_gls | 1.0280305 | 1.0098569 | .99142743 | 1.0028527 | .99508303 | 1.0002454 |
| mediana_b1~s | 1.0521936 | 1.0215993 | .99141711 | .97967514 | .99639186 | 1.0007963 |
| de_b1_gls    | 1.2535653 | .78859652 | .6326124  | .34452127 | .24216176 | .15728003 |
| media_b2_gls | 1.0041153 | .99966412 | 1.0056483 | 1.0009635 | .99825912 | 1.0002415 |
| mediana_b2~s | 1.0016103 | 1.0011113 | 1.0057288 | .99995628 | .99866092 | 1.0011777 |
| de_b2_gls    | .27698551 | .14838535 | .10750797 | .05216017 | .03670627 | .02233929 |
| media_b3_gls | .99808488 | .99177559 | .99704105 | 1.0014807 | .99794066 | 1.0011461 |
| mediana_b3~s | 1.0007759 | .99349907 | 1.0007703 | 1.0030935 | .99855053 | 1.0003986 |
| de_b3_gls    | .23968415 | .13024611 | .10009673 | .05074781 | .03363409 | .02125601 |
| tam_test_1~s | 2.6       | 1.9       | 1.1       | 1.3       | .8        | 1.1       |
| media_b1_f~s | 1.01992   | 1.01678   | .9940748  | 1.0072039 | .99260909 | 1.0000234 |
| mediana_b1~s | 1.0103357 | 1.023284  | .98835871 | .98473564 | .99415511 | .99863401 |
| de_b1_fgls   | 1.3995429 | .84752793 | .66857393 | .35431677 | .24580091 | .15830694 |
| media_b2_f~s | 1.0032334 | 1.0017987 | 1.0081194 | 1.0025778 | .99772954 | 1.000189  |
| mediana_b2~s | 1.0093035 | 1.0049713 | 1.0057506 | 1.0009448 | .99776992 | 1.0012414 |
| de_b2_fgls   | .33065581 | .18431274 | .13396221 | .0558778  | .0377256  | .02264737 |
| media_b3_f~s | 1.006726  | .99314471 | .99556178 | 1.0007816 | .99824046 | 1.0011263 |
| mediana_b3~s | 1.0098851 | .99663675 | .99534097 | 1.0025634 | .99817607 | 1.0005233 |
| de_b3_fgls   | .29018109 | .14444993 | .11601262 | .05232108 | .03433107 | .02134511 |

(c) Describir, detalladamente, las propiedades de muestra finita de FGLS de acuerdo a lo que se observó de los puntos anteriores.

Las propiedades de muestra finita de FGLS, de acuerdo a lo que se observó de los puntos anteriores, son:

- Sesgo: El estimador FGLS puede estar sesgado si el modelo subyacente no se especifica correctamente o si la estructura de correlación verdadera en los datos se impone de manera incorrecta. Sin embargo, a medida que el tamaño de muestra aumenta, este sesgo tiende a disminuir.
- Eficiencia relativa: La eficiencia relativa del estimador FGLS en comparación con otros estimadores (como el estimador OLS) puede variar dependiendo de la estructura de correlación verdadera en los datos y del modelo. Sin embargo, en algunos casos, el estimador FGLS puede proporcionar estimaciones más precisas que el estimador OLS, especialmente cuando la estructura de correlación de los errores es ignorada por las estimaciones por OLS.
- Varianza finita: La varianza del estimador FGLS depende del tamaño de muestra y de la estructura de correlación verdadera en los datos. A diferencia de las propiedades asintóticas, en muestras finitas, la varianza del estimador FGLS puede no converger a la varianza asintótica y puede ser mayor o menor dependiendo de las características específicas de los datos y del modelo.
- Robustez: El estimador FGLS puede ser más robusto que otros estimadores en presencia de violaciones de los supuestos de homocedasticidad y de correlación serial en los datos. Esto significa que el estimador FGLS puede proporcionar estimaciones más precisas, incluso cuando los supuestos clásicos no se cumplan completamente.

**Datos de Panel**  
**Problem Set 1**  
**Modelo de Regresión Lineal**

---

1. Utilice la base de datos provista “*cornwell.dta*”.

- a) A partir de los datos de los siete años, y utilizando los logaritmos de todas las variables, estime un modelo por POLS que relacione la tasa de crimen con *prbarr*, *prbconv*, *prbpris*, *avgsen* y *polpc* y que incluya un conjunto de *dummies* de año.
- b) Compute los errores estándar robustos a heteroscedasticidad arbitraria y a autocorrelación serial arbitraria.
- c) Implemente un contraste de Correlación Serial.
- d) Implemente un contraste de Heterocedasticidad.
- e) Asuma que se cumple el supuesto de exogeneidad estricta y que  $u_{it}$  sigue un proceso AR(1). Compute el estimador de FGLS siguiendo el enfoque de Prais-Winsten. Una descripción del procedimiento puede encontrarla en Wooldridge (2010), sección 7.8.6.

**Observación:** GLS necesita exogeneidad estricta para conseguir estimadores consistentes.

- f) Compute los errores estándar robustos a heteroscedasticidad arbitraria y a autocorrelación serial arbitraria para el modelo con las variables transformadas del inciso previo.

**Sugerencia de Wooldridge.** “..If we have any doubts about the homoskedasticity assumption, or whether the AR(1) assumption sufficiently captures the serial dependence, we can just apply the usual fully robust variance matrix and associated statistics to pooled OLS on the transformed variables. This allows us to probably obtain an estimator more efficient than POLS (on the original data) but also guards against the rather simple structure we imposed on  $\Omega$ . Of course, failure of strict exogeneity generally causes the Prais-Winsten estimator of  $\beta$  to be inconsistent.”

2. En este ejercicio examinará un modelo para el costo total de producción en la industria aeronáutica a modo de ilustrar una aplicación de un modelo heteroscedástico por grupos. Considere la siguiente función de costos:

$$\ln \text{cost}_{jt} = \beta_1 + \beta_2 \ln \text{output}_{jt} + \beta_3 \text{load factor}_{jt} + \beta_4 \ln \text{fuel price}_{jt} \\ + \delta_2 \text{Firm}_2 + \delta_3 \text{Firm}_3 + \delta_4 \text{Firm}_4 + \delta_5 \text{Firm}_5 + \delta_6 \text{Firm}_6 + \varepsilon_{jt}$$

- a) Utilice la base de datos provista “*greene97.dta*”, la cual contiene datos para seis compañías aéreas observadas anualmente durante 15 años. Estime la ecuación por POLS.
- b) Ahora, asuma que dentro de cada compañía aérea se tiene que:

$$\text{Var}[\varepsilon_{jt} \mid \mathbf{x}_{jt}] = \sigma_j^2, \quad t = 1, \dots, T$$

Por lo tanto, si las varianzas fueran conocidas, el estimador de GLS sería:

$$\hat{\beta} = \left[ \sum_{j=1}^N \left( \frac{1}{\sigma_j^2} \right) \mathbf{X}_j' \mathbf{X}_j \right]^{-1} \left[ \sum_{j=1}^N \left( \frac{1}{\sigma_j^2} \right) \mathbf{X}_j' \mathbf{y}_j \right]$$

donde  $\mathbf{X}_j$  es una matriz  $T \times K$ . Sin embargo, en este caso práctico las varianzas son desconocidas. Luego, se le solicita computar el estimador de FGLS a través de los siguientes métodos:

- 1) Estime el modelo calculando el estimador necesario para la varianza específica de la compañía aérea a partir de los residuos de OLS, es decir,  $\hat{\sigma}_j^2 = \frac{\mathbf{e}_j' \mathbf{e}_j}{n_j}$ .
  - 2) Estimar el modelo tratándolo como una forma del modelo de heteroscedasticidad multiplicativa de Harvey (1976). Utilice el procedimiento en dos etapas.
  - c) Compare los resultados obtenidos en el inciso b).
3. Considere la siguiente ecuación de salarios:

$$y_{jt} = \beta_0 + \beta_1 x_{jt} + u_{jt}, \quad j = 1, 2, \dots, N; t = 1, 2 \quad (1)$$

donde  $\beta_0 = \beta_1 = 1$ ,  $u_j \sim N(0, \Omega)$ ,  $\Omega = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$  y  $x_j \sim U[1, 20]$

Genere 1000 muestras de  $N = 5$  observaciones de corte transversal a partir del modelo (1). Para cada muestra estime por FGLS los parámetros del modelo y realice un test de hipótesis para contrastar que  $H_0 : \beta_1 = 1$ . Reporte tamaño del test al 1% y el poder del test cuando  $\beta_1 = 0,8$ . Luego, repita el procedimiento con  $N = 500$ . ¿Se aprecia algún cambio en el tamaño y/o en el poder del test ante el incremento de  $N$ ?



## **Trabajo Práctico N° 1:** **Modelo de Regresión Lineal.**

### **Ejercicio 1.**

Utilizar la base de datos provista “cornwell.dta”.

(a) A partir de los datos de los siete años, y utilizando los logaritmos de todas las variables, estimar un modelo por POLS que relacione la tasa de crimen con *prbarr*, *prbconv*, *prbpris*, *avgsen* y *polpc* y que incluya un conjunto de dummies de año.

**POLS:**

|          |            |     |            |               |   |        |
|----------|------------|-----|------------|---------------|---|--------|
| Source   | SS         | df  | MS         | Number of obs | = | 630    |
| Model    | 117.644669 | 11  | 10.6949699 | F(11, 618)    | = | 74.49  |
| Residual | 88.735673  | 618 | .143585231 | Prob > F      | = | 0.0000 |
|          |            |     |            | R-squared     | = | 0.5700 |
|          |            |     |            | Adj R-squared | = | 0.5624 |
| Total    | 206.380342 | 629 | .328108652 | Root MSE      | = | .37893 |

  

| lcrmrte  | Coefficient | Std. err. | t      | P> t  | [95% conf. interval] |           |
|----------|-------------|-----------|--------|-------|----------------------|-----------|
| lprbarr  | -.7195033   | .0367657  | -19.57 | 0.000 | -.7917042            | -.6473024 |
| lprbconv | -.5456589   | .0263683  | -20.69 | 0.000 | -.5974413            | -.4938765 |
| lprbpris | .2475521    | .0672268  | 3.68   | 0.000 | .1155314             | .3795728  |
| lavgsen  | -.0867575   | .0579205  | -1.50  | 0.135 | -.2005023            | .0269872  |
| lpolpc   | .3659886    | .0300252  | 12.19  | 0.000 | .3070248             | .4249525  |
| d82      | .0051371    | .057931   | 0.09   | 0.929 | -.1086284            | .1189026  |
| d83      | -.043503    | .0576243  | -0.75  | 0.451 | -.1566662            | .0696601  |
| d84      | -.1087542   | .057923   | -1.88  | 0.061 | -.222504             | .0049957  |
| d85      | -.0780454   | .0583244  | -1.34  | 0.181 | -.1925835            | .0364928  |
| d86      | -.0420791   | .0578218  | -0.73  | 0.467 | -.15563              | .0714719  |
| d87      | -.0270426   | .056899   | -0.48  | 0.635 | -.1387815            | .0846963  |
| _cons    | -2.082293   | .2516253  | -8.28  | 0.000 | -2.576438            | -1.588149 |

(b) Computar los errores estándar robustos a heteroscedasticidad arbitraria y a autocorrelación serial arbitraria.

POLS (con errores estándar robustos):

|                   |               |   |        |
|-------------------|---------------|---|--------|
| Linear regression | Number of obs | = | 630    |
|                   | F(11, 89)     | = | 37.19  |
|                   | Prob > F      | = | 0.0000 |
|                   | R-squared     | = | 0.5700 |
|                   | Root MSE      | = | .37893 |

(Std. err. adjusted for 90 clusters in county)

|  |          | Robust      |           |       |       |                      |
|--|----------|-------------|-----------|-------|-------|----------------------|
|  | lcrmrte  | Coefficient | std. err. | t     | P> t  | [95% conf. interval] |
|  | lprbarr  | -.7195033   | .1095979  | -6.56 | 0.000 | -.9372719 -.5017347  |
|  | lprbconv | -.5456589   | .0704368  | -7.75 | 0.000 | -.6856152 -.4057025  |
|  | lprbpris | .2475521    | .1088453  | 2.27  | 0.025 | .0312787 .4638255    |
|  | lavgsen  | -.0867575   | .1130321  | -0.77 | 0.445 | -.3113499 .1378348   |
|  | lpolpc   | .3659886    | .121078   | 3.02  | 0.003 | .1254092 .6065681    |
|  | d82      | .0051371    | .0367296  | 0.14  | 0.889 | -.0678439 .0781181   |
|  | d83      | -.043503    | .033643   | -1.29 | 0.199 | -.1103509 .0233448   |
|  | d84      | -.1087542   | .0391758  | -2.78 | 0.007 | -.1865956 -.0309127  |
|  | d85      | -.0780454   | .0385625  | -2.02 | 0.046 | -.1546683 -.0014224  |
|  | d86      | -.0420791   | .0428788  | -0.98 | 0.329 | -.1272783 .0431201   |
|  | d87      | -.0270426   | .0381447  | -0.71 | 0.480 | -.1028353 .0487502   |
|  | _cons    | -2.082293   | .8647054  | -2.41 | 0.018 | -3.800445 -.3641423  |

(c) Implementar un contraste de Correlación Serial.

Stata.

Se rechaza la hipótesis nula de no correlación serial.

(d) Implementar un contraste de Heterocedasticidad.

Stata.

Se rechaza la hipótesis nula de homocedasticidad.

(e) Asumir que se cumple el supuesto de exogeneidad estricta y que  $u_{it}$  sigue un proceso AR(1). Computar el estimador de FGLS siguiendo el enfoque de Prais-Winsten. Una descripción del procedimiento se puede encontrar en Wooldridge (2010), sección 7.8.6. Observación: GLS necesita exogeneidad estricta para conseguir estimadores consistentes.

FGLS:

|          |            |     |            |               |   |         |
|----------|------------|-----|------------|---------------|---|---------|
| Source   | SS         | df  | MS         | Number of obs | = | 630     |
| Model    | 885.585523 | 12  | 73.7987936 | F(12, 618)    | = | 2050.54 |
| Residual | 22.2417551 | 618 | .035989895 | Prob > F      | = | 0.0000  |
|          |            |     |            | R-squared     | = | 0.9755  |
|          |            |     |            | Adj R-squared | = | 0.9750  |
| Total    | 907.827278 | 630 | 1.44099568 | Root MSE      | = | .18971  |

  

| tilde_lcrmrte  | Coefficient | Std. err. | t      | P> t  | [95% conf. interval] |           |
|----------------|-------------|-----------|--------|-------|----------------------|-----------|
| tilde_lprbarr  | -.481208    | .0333124  | -14.45 | 0.000 | -.5466271            | -.4157888 |
| tilde_lprbconv | -.3353095   | .0209135  | -16.03 | 0.000 | -.3763796            | -.2942395 |
| tilde_lprbpris | -.1624321   | .0339271  | -4.79  | 0.000 | -.2290585            | -.0958058 |
| tilde_lavgsen  | -.0203981   | .0289633  | -0.70  | 0.482 | -.0772766            | .0364804  |
| tilde_lpolpc   | .3806954    | .0298461  | 12.76  | 0.000 | .3220834             | .4393074  |
| tilde_d82      | .0120433    | .0222954  | 0.54   | 0.589 | -.0317405            | .0558272  |
| tilde_d83      | -.0721363   | .0288915  | -2.50  | 0.013 | -.1288737            | -.0153989 |
| tilde_d84      | -.1092092   | .0333946  | -3.27  | 0.001 | -.1747898            | -.0436286 |
| tilde_d85      | -.1018016   | .0364716  | -2.79  | 0.005 | -.1734249            | -.0301784 |
| tilde_d86      | -.0775719   | .0381852  | -2.03  | 0.043 | -.1525605            | -.0025834 |
| tilde_d87      | -.0395482   | .0394024  | -1.00  | 0.316 | -.1169271            | .0378307  |
| tilde_ones     | -2.027131   | .2099692  | -9.65  | 0.000 | -2.439471            | -1.614792 |

(f) *Computar los errores estándar robustos a heteroscedasticidad arbitraria y a autocorrelación serial arbitraria para el modelo con las variables transformadas del inciso previo. Sugerencia de Wooldridge: “... If we have any doubts about the homoskedasticity assumption, or whether the AR(1) assumption sufficiently captures the serial dependence, we can just apply the usual fully robust variance matrix and associated statistics to pooled OLS on the transformed variables. This allows us to probably obtain an estimator more efficient than POLS (on the original data) but also guards against the rather simple structure we imposed on  $\Omega$ . Of course, failure of strict exogeneity generally causes the Prais-Winsten estimator of  $\beta$  to be inconsistent.”*

FGLS (con errores estándar robustos):

|                   |               |   |        |
|-------------------|---------------|---|--------|
| Linear regression | Number of obs | = | 630    |
|                   | F(12, 89)     | = | 837.00 |
|                   | Prob > F      | = | 0.0000 |
|                   | R-squared     | = | 0.9755 |
|                   | Root MSE      | = | .18971 |

  

(Std. err. adjusted for 90 clusters in county)

| tilde_lcrmrte  | Coefficient | Robust std. err. | t     | P> t  | [95% conf. interval] |           |
|----------------|-------------|------------------|-------|-------|----------------------|-----------|
| tilde_lprbarr  | -.481208    | .0718373         | -6.70 | 0.000 | -.6239471            | -.3384689 |
| tilde_lprbconv | -.3353095   | .0440331         | -7.61 | 0.000 | -.4228023            | -.2478168 |
| tilde_lprbpris | -.1624321   | .0500207         | -3.25 | 0.002 | -.2618222            | -.0630421 |
| tilde_lavgsen  | -.0203981   | .0258077         | -0.79 | 0.431 | -.0716774            | .0308813  |
| tilde_lpolpc   | .3806954    | .106039          | 3.59  | 0.001 | .1699982             | .5913925  |
| tilde_d82      | .0120433    | .015186          | 0.79  | 0.430 | -.0181309            | .0422176  |
| tilde_d83      | -.0721363   | .01852           | -3.90 | 0.000 | -.1089352            | -.0353374 |
| tilde_d84      | -.1092092   | .0215974         | -5.06 | 0.000 | -.1521229            | -.0662956 |
| tilde_d85      | -.1018016   | .0244324         | -4.17 | 0.000 | -.1503483            | -.053255  |
| tilde_d86      | -.0775719   | .0236838         | -3.28 | 0.002 | -.1246312            | -.0305126 |
| tilde_d87      | -.0395482   | .0252489         | -1.57 | 0.121 | -.0897173            | .0106209  |
| tilde_ones     | -2.027131   | .7465981         | -2.72 | 0.008 | -3.510606            | -.5436569 |

## Ejercicio 2.

En este ejercicio, se examinará un modelo para el costo total de producción en la industria aeronáutica a modo de ilustrar una aplicación de un modelo heterocedástico por grupos. Considerar la siguiente función de costos:

$$\ln cost_{jt} = \beta_1 + \beta_2 \ln output_{jt} + \beta_3 load\ factor_{jt} + \beta_4 \ln fuel\ price_{jt} + \delta_2 Firm_2 + \delta_3 Firm_3 + \delta_4 Firm_4 + \delta_5 Firm_5 + \delta_6 Firm_6 + \varepsilon_{jt}.$$

(a) Utilizar la base de datos provista “greene97.dta”, la cual contiene datos para seis compañías áreas observadas, anualmente, durante 15 años. Estimar la ecuación por POLS.

| Source   | SS         | df | MS         | Number of obs | = | 90      |
|----------|------------|----|------------|---------------|---|---------|
| Model    | 113.74827  | 8  | 14.2185338 | F(8, 81)      | = | 3935.79 |
| Residual | .292622888 | 81 | .003612628 | Prob > F      | = | 0.0000  |
|          |            |    |            | R-squared     | = | 0.9974  |
|          |            |    |            | Adj R-squared | = | 0.9972  |
| Total    | 114.040893 | 89 | 1.28135835 | Root MSE      | = | .06011  |

  

| lc    | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |           |
|-------|-------------|-----------|-------|-------|----------------------|-----------|
| lq    | .9192845    | .0298901  | 30.76 | 0.000 | .8598126             | .9787565  |
| lf    | -1.070396   | .20169    | -5.31 | 0.000 | -1.471696            | -.6690961 |
| lpf   | .4174918    | .0151991  | 27.47 | 0.000 | .3872503             | .4477333  |
| id    |             |           |       |       |                      |           |
| 2     | -.0412359   | .025184   | -1.64 | 0.105 | -.0913441            | .0088722  |
| 3     | -.2089211   | .0427986  | -4.88 | 0.000 | -.294077             | -.1237653 |
| 4     | .1845557    | .0607527  | 3.04  | 0.003 | .0636769             | .3054345  |
| 5     | .0240547    | .0799041  | 0.30  | 0.764 | -.1349293            | .1830387  |
| 6     | .0870617    | .0841995  | 1.03  | 0.304 | -.080469             | .2545924  |
| _cons | 9.705942    | .193124   | 50.26 | 0.000 | 9.321686             | 10.0902   |

(b) Ahora, asumir que, dentro de cada compañía área, se tiene que:

$$Var[\varepsilon_{jt} | x_{jt}] = \sigma_j^2, t = 1, \dots, T.$$

Por lo tanto, si las varianzas fueran conocidas, el estimador GLS sería:

$$\hat{\beta} = [\sum_{j=1}^N \frac{1}{\sigma_j^2} X_j' X_j]^{-1} \sum_{j=1}^N \frac{1}{\sigma_j^2} X_j' y_j,$$

donde  $X_j$  es una matriz  $T \times K$ . Sin embargo, en este caso práctico, las varianzas son desconocidas. Luego, se solicita computar el estimador de FGLS a través de los siguientes métodos:

(i) Estimar el modelo calculando el estimador necesario para la varianza específica de la compañía áreas a partir de los residuos de OLS, es decir,  $\hat{\sigma}_j^2 = \frac{e_j' e_j}{n_j}$ .

|          |            |    |            |               |   |         |
|----------|------------|----|------------|---------------|---|---------|
| Source   | SS         | df | MS         | Number of obs | = | 90      |
|          |            |    |            | F(8, 81)      | = | 5526.83 |
| Model    | 118.222298 | 8  | 14.7777873 | Prob > F      | = | 0.0000  |
| Residual | .216579991 | 81 | .002673827 | R-squared     | = | 0.9982  |
|          |            |    |            | Adj R-squared | = | 0.9980  |
| Total    | 118.438878 | 89 | 1.33077391 | Root MSE      | = | .05171  |

  

|       |             |           |       |       |                      |
|-------|-------------|-----------|-------|-------|----------------------|
| lc    | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |
| lq    | .925765     | .0267809  | 34.57 | 0.000 | .8724795 .9790506    |
| lf    | -1.216307   | .1855858  | -6.55 | 0.000 | -1.585565 -.8470495  |
| lpf   | .4056077    | .0125488  | 32.32 | 0.000 | .3806395 .4305758    |
| id    |             |           |       |       |                      |
| 2     | -.046026    | .0237611  | -1.94 | 0.056 | -.0933031 .0012511   |
| 3     | -.2020985   | .0361494  | -5.59 | 0.000 | -.2740246 -.1301725  |
| 4     | .1905462    | .0551602  | 3.45  | 0.001 | .0807946 .3002977    |
| 5     | .0371723    | .0704438  | 0.53  | 0.599 | -.1029887 .1773334   |
| 6     | .094588     | .0743639  | 1.27  | 0.207 | -.0533728 .2425488   |
| _cons | 9.942316    | .1622899  | 61.26 | 0.000 | 9.61941 10.26522     |

(ii) *Estimar el modelo tratándolo como una forma del modelo de heteroscedasticidad multiplicativa de Harvey (1976). Utilizar el procedimiento en dos etapas.*

|                                   |               |   |          |
|-----------------------------------|---------------|---|----------|
| Heteroskedastic linear regression | Number of obs | = | 90       |
| Two-step GLS estimation           |               |   |          |
|                                   | Wald chi2(8)  | = | 36250.22 |
|                                   | Prob > chi2   | = | 0.0000   |

|          | lc    | Coefficient | Std. err. | z      | P> z  | [95% conf. interval] |           |
|----------|-------|-------------|-----------|--------|-------|----------------------|-----------|
| lc       | lq    | .932333     | .0295289  | 31.57  | 0.000 | .8744574             | .9902086  |
|          | lf    | -1.115165   | .1991174  | -5.60  | 0.000 | -1.505428            | -.7249023 |
|          | lpf   | .4086271    | .0141468  | 28.88  | 0.000 | .3808999             | .4363543  |
|          | id    |             |           |        |       |                      |           |
|          | 2     | -.0387054   | .0242462  | -1.60  | 0.110 | -.0862271            | .0088163  |
|          | 3     | -.1929047   | .0407071  | -4.74  | 0.000 | -.2726892            | -.1131203 |
|          | 4     | .2082512    | .0589261  | 3.53   | 0.000 | .0927583             | .3237442  |
|          | 5     | .0572051    | .0780464  | 0.73   | 0.464 | -.0957631            | .2101733  |
|          | 6     | .1207862    | .0825116  | 1.46   | 0.143 | -.0409335            | .2825059  |
|          | _cons | 9.841375    | .1768449  | 55.65  | 0.000 | 9.494765             | 10.18798  |
| lnsigma2 | id    |             |           |        |       |                      |           |
|          | 2     | .9333314    | .8111556  | 1.15   | 0.250 | -.6565043            | 2.523167  |
|          | 3     | .575379     | .8111556  | 0.71   | 0.478 | -1.014457            | 2.165215  |
|          | 4     | .639489     | .8111556  | 0.79   | 0.430 | -.9503466            | 2.229325  |
|          | 5     | .6042102    | .8111556  | 0.74   | 0.456 | -.9856255            | 2.194046  |
|          | 6     | .7988952    | .8111556  | 0.98   | 0.325 | -.7909405            | 2.388731  |
|          | _cons | -6.213752   | .5735736  | -10.83 | 0.000 | -7.337935            | -5.089568 |

Wald test of lnsigma2=0: chi2(5) = 1.56

```
Prob > chi2 = 0.9063
```

**(c)** *Comparar los resultados obtenidos en el inciso (b).*

Los resultados obtenidos en el inciso (b) son semejantes en cuanto a valores estimados de los parámetros y a significatividad estadística.

### **Ejercicio 3.**

Considerar la siguiente ecuación de salarios:

$$y_{jt} = \beta_0 + \beta_1 x_{jt} + u_{jt}, j = 1, 2, \dots, N; t = 1, 2 \quad (1)$$

donde  $\beta_0 = \beta_1 = 1$ ,  $u_j \sim \mathcal{N}(0, \Omega)$ ,  $\Omega = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$  y  $x_{jt} \sim U[1, 20]$ .

Generar 1.000 muestras de  $N = 5$  observaciones de corte transversal a partir del modelo (1). Para cada muestra, estimar por FGLS los parámetros del modelo y realizar un test de hipótesis para contrastar que  $H_0: \beta_1 = 1$ . Reportar tamaño del test al 1% y el poder del test cuando  $\beta_1 = 0,8$ . Luego, repetir el procedimiento con  $N = 500$ . ¿Se aprecia algún cambio en el tamaño y/o en el poder del test ante el incremento de  $N$ ?

|              | N_5  | N_500 |
|--------------|------|-------|
| tam_test_1   | 2.7  | 1     |
| poder_tes~08 | 33.2 | 100   |

Por lo tanto, se puede observar que, ante el incremento de  $N$ , el tamaño del test tiende al nivel de significación del 1% y el poder del test tiende al 100%.

---

**Datos de Panel**  
**Problem Set 2**  
**Modelos de Datos de Panel Lineales**

---

1. Utilice nuevamente la base de datos “*cornwell.dta*” provista para el Problem Set 1. Considere el siguiente modelo de regresión:

$$\ln crmrte_{it} = \beta_0 + \beta_1 \ln prbarr_{it} + \beta_2 \ln prbconv_{it} + \beta_3 \ln prbpris_{it} + \beta_4 \ln avgse_{it} \\ + \beta_5 \ln polpc_{it} + \sum_{\tau=82}^{87} \beta_{\tau} \cdot I\{t = \tau\} + \mu_i + \varepsilon_{it}$$

- a) Utilizando el comando *egen* de STATA, construya las medias individuales de las variables del modelo.
  - b) Aplique la transformación *within* al modelo. Luego, estime el modelo transformado por POLS.
  - c) Comente sobre la validez de los errores estándar del inciso previo.
  - d) Utilice el comando *xtreg* para estimar nuevamente el modelo usando efectos fijos.
  - e) Estime el modelo usando diferencias finitas de primer orden.
2. Utilice la base de datos provista “*murder.dta*”. La base de datos es una muestra longitudinal de estados de EE.UU., para los años 1987, 1990 y 1993.

- a) Estime por OLS el efecto de las ejecuciones ( $x$ ) sobre la tasa de homicidios (*murder rates*,  $m$ ) controlando por desempleo ( $u$ ) y año:

$$m_{i,t} = \alpha + \beta_x x_{i,t} + \beta_u u_{i,t} + \beta_{90} d_{90,t} + \beta_{93} d_{93,t} + \nu_{i,t}$$

Note que se omitió la dummy temporal para el año 1987. Interprete los resultados.

- b) ¿Por qué podría ser importante tener en consideración los efectos temporales agregados en el modelo?
- c) Ahora, considere la siguiente modificación en el modelo:

$$m_{i,t} = \alpha + \beta_x x_{i,t} + \beta_u u_{i,t} + \beta_{90} d_{90,t} + \beta_{93} d_{93,t} + c_i + e_{i,t}$$

donde  $c_i$  es un efecto individual por estado. Estime la ecuación usando efectos fijos.

- d) Repita la estimación del inciso previo usando diferencias finitas de primer orden.
- e) Brinde un ejemplo bajo el cual la variable de ejecuciones no sería estrictamente exógena (condicional en  $c_i$ ). **Observación.** Para obtener estimaciones consistentes, el modelo de efectos fijos asume exogeneidad estricta de las variables explicativas condicionadas en  $c_i$ .
- f) Repita la estimación del inciso c) usando el estimador de GLS para diferencias finitas de primer orden. Compruebe que los coeficientes estimados son iguales a los obtenidos por FE.
- g) Reestimar el modelo del inciso c) usando efectos aleatorios. Implementar el test de Hausman. ¿Cuál es el mejor estimador?



3. Considere el siguiente modelo:

$$y_{it} = x_{it}\beta + \mu_i + \nu_{it}, \quad i = 1, 2, \dots, N, \quad t = 1, 2, \dots, T$$

donde  $x_{it} \stackrel{iid}{\sim} \mathcal{N}(0, 1)$ ,  $\mu_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_\mu^2)$ ,  $\nu_{it} \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_\nu^2)$  y  $\mu_i \perp \nu_{it}$  para todo  $i, t$ . Suponga que  $\beta = \sigma_\mu^2 = \sigma_\nu^2 = 1$  y  $T = 10$ . La idea es realizar experimentos de Monte Carlo para evaluar la eficiencia de distintos estimadores de  $\beta$ .

- a) Caso 1:  $N = 5$ . Realice un experimento de Monte Carlo con 1000 simulaciones. Reporte media, desvío estándar y RMSE de la estimación de  $\beta$  usando: POLS, RE y FE.
  - b) Repita el punto anterior con  $N = 10, 30, 50, 100$  y 500.
  - c) Comente los resultados obtenidos y su conclusión de qué estimador debiera utilizarse en la práctica.
4. Basado en el Ejercicio 10.18 de Wooldridge (2010). Utilice la base de datos *wagepan.dta* para responder las preguntas a continuación.
- a) Utilizando *lwage* como variable dependiente, estimar un modelo que contenga un intercepto y las variables *dummy* de año *d81* a *d87*. Estime el modelo por POLS, RE, FE y FD. ¿Qué puede concluir acerca de los coeficientes de las variables *dummy*?
  - b) Añada las variables constantes en el tiempo *educ*, *black* e *hisp* al modelo, y estímelo por POLS y RE. ¿Cómo se comparan los coeficientes? ¿Qué ocurre si se estima la ecuación por FE?
  - c) ¿Son iguales los errores estándar de POLS y RE del inciso b)? ¿Cuáles son probablemente más fiables?
  - d) Obtenga los errores estándar robustos para POLS. ¿Prefiere estos o los errores estándar habituales de RE?
  - e) Obtenga los errores estándar robustos de RE. ¿Cómo se comparan con los errores estándar robustos de POLS, y por qué?

## Trabajo Práctico N° 2: Modelos de Datos de Panel Lineales.

### Ejercicio 1.

Utilizar, nuevamente, la base de datos “cornwell.dta” provista para el Problem Set 1. Considerar el siguiente modelo de regresión:

$$\ln crmrte_{it} = \beta_0 + \beta_1 \ln prbarr_{it} + \beta_2 \ln prbconv_{it} + \beta_3 \ln prbpris_{it} + \beta_4 \ln avgsen_{it} + \beta_5 \ln polpc_{it} + \sum_{\tau=1}^{87} \beta_{\tau} I\{t = \tau\} + \mu_i + \varepsilon_{it}.$$

(a) Utilizando el comando *egen* de STATA, construir las medias individuales de las variables del modelo.

**Stata.**

(b) Aplicar la transformación *within* al modelo. Luego, estimar el modelo transformado por POLS.

POLS:

|          |            |     |            |               |   |        |
|----------|------------|-----|------------|---------------|---|--------|
| Source   | SS         | df  | MS         | Number of obs | = | 630    |
| Model    | 7.81221835 | 11  | .710201668 | F(11, 619)    | = | 43.19  |
| Residual | 10.1785214 | 619 | .016443492 | Prob > F      | = | 0.0000 |
|          |            |     |            | R-squared     | = | 0.4342 |
|          |            |     |            | Adj R-squared | = | 0.4242 |
| Total    | 17.9907397 | 630 | .02855673  | Root MSE      | = | .12823 |

  

| within_lcrmrte  | Coefficient | Std. err. | t      | P> t  | [95% conf. interval] |           |
|-----------------|-------------|-----------|--------|-------|----------------------|-----------|
| within_lprbarr  | -.3597944   | .0299699  | -12.01 | 0.000 | -.4186493            | -.3009395 |
| within_lprbconv | -.2858733   | .0196143  | -14.57 | 0.000 | -.3243919            | -.2473547 |
| within_lprbpris | -.1827812   | .0300086  | -6.09  | 0.000 | -.2417122            | -.1238502 |
| within_lavgsen  | -.0044879   | .0244449  | -0.18  | 0.854 | -.0525009            | .043525   |
| within_lpolpc   | .4241142    | .0243741  | 17.40  | 0.000 | .3762483             | .4719802  |
| within_d82      | .0125802    | .0199141  | 0.63   | 0.528 | -.0265271            | .0516875  |
| within_d83      | -.0792813   | .0197277  | -4.02  | 0.000 | -.1180225            | -.04054   |
| within_d84      | -.1177281   | .0199815  | -5.89  | 0.000 | -.1569678            | -.0784884 |
| within_d85      | -.1119561   | .0201954  | -5.54  | 0.000 | -.151616             | -.0722962 |
| within_d86      | -.0818268   | .0198078  | -4.13  | 0.000 | -.1207254            | -.0429282 |
| within_d87      | -.0404704   | .0194497  | -2.08  | 0.038 | -.0786657            | -.0022751 |

(c) Comentar sobre la validez de los errores estándar del inciso previo.

Los errores estándar reportados tienden a ser pequeños comparados a los verdaderos. El problema se encuentra en que los grados de libertad de aplicar OLS al modelo transformado no coinciden con el denominador del estimador consistente para  $\sigma_{\varepsilon}^2$ . Por consiguiente, excepto que T sea lo suficientemente grande, se necesita corregir este denominador.

(d) Utilizar el comando `xtreg` para estimar, nuevamente, el modelo usando efectos fijos.

FE:

```
Fixed-effects (within) regression      Number of obs   =      630
Group variable: county                Number of groups =      90

R-squared:                            Obs per group:
    Within = 0.4342                      min =          7
    Between = 0.4066                     avg =         7.0
    Overall = 0.4042                     max =          7

                                F(11,89)      =      11.49
corr(u_i, Xb) = 0.2068                Prob > F       =      0.0000
```

(Std. err. adjusted for 90 clusters in county)

|          |         | Robust      |                                   |       |       |                      |
|----------|---------|-------------|-----------------------------------|-------|-------|----------------------|
|          | lcrmrte | Coefficient | std. err.                         | t     | P> t  | [95% conf. interval] |
| lprbarr  |         | -.3597944   | .0594678                          | -6.05 | 0.000 | -.4779557 -.2416332  |
| lprbconv |         | -.2858733   | .051522                           | -5.55 | 0.000 | -.3882464 -.1835001  |
| lprbpris |         | -.1827812   | .0452811                          | -4.04 | 0.000 | -.2727538 -.0928085  |
| lavgsen  |         | -.0044879   | .0333499                          | -0.13 | 0.893 | -.0707535 .0617777   |
| lpolpc   |         | .4241142    | .0849052                          | 5.00  | 0.000 | .2554095 .592819     |
| d82      |         | .0125802    | .0160066                          | 0.79  | 0.434 | -.0192246 .044385    |
| d83      |         | -.0792813   | .0195639                          | -4.05 | 0.000 | -.1181544 -.0404081  |
| d84      |         | -.1177281   | .0217118                          | -5.42 | 0.000 | -.160869 -.0745872   |
| d85      |         | -.1119561   | .0256583                          | -4.36 | 0.000 | -.1629386 -.0609736  |
| d86      |         | -.0818268   | .0236276                          | -3.46 | 0.001 | -.1287745 -.0348792  |
| d87      |         | -.0404704   | .0241765                          | -1.67 | 0.098 | -.0885087 .0075678   |
| _cons    |         | -1.604135   | .5102062                          | -3.14 | 0.002 | -2.617904 -.5903664  |
| sigma_u  |         | .43487416   |                                   |       |       |                      |
| sigma_e  |         | .13871215   |                                   |       |       |                      |
| rho      |         | .90765322   | (fraction of variance due to u_i) |       |       |                      |

(e) Estimar el modelo usando diferencias finitas de primer orden.

FD:

| Source   | SS         | df  | MS         | Number of obs | = | 540    |
|----------|------------|-----|------------|---------------|---|--------|
| Model    | 9.60258308 | 11  | .872962098 | F(11, 529)    | = | 36.66  |
| Residual | 12.5963755 | 529 | .023811674 | Prob > F      | = | 0.0000 |
|          |            |     |            | R-squared     | = | 0.4326 |
|          |            |     |            | Adj R-squared | = | 0.4208 |
| Total    | 22.1989586 | 540 | .041109183 | Root MSE      | = | .15431 |

  

| D.lcrmrte | Coefficient | Std. err. | t      | P> t  | [95% conf. interval] |           |
|-----------|-------------|-----------|--------|-------|----------------------|-----------|
| lprbarr   |             |           |        |       |                      |           |
| D1.       | -.3274942   | .0299801  | -10.92 | 0.000 | -.3863889            | -.2685995 |
| lprbconv  |             |           |        |       |                      |           |
| D1.       | -.2381066   | .0182341  | -13.06 | 0.000 | -.2739268            | -.2022864 |
| lprbpris  |             |           |        |       |                      |           |
| D1.       | -.1650462   | .025969   | -6.36  | 0.000 | -.2160613            | -.1140312 |
| lavgsen   |             |           |        |       |                      |           |
| D1.       | -.0217607   | .0220909  | -0.99  | 0.325 | -.0651574            | .021636   |
| lpolpc    |             |           |        |       |                      |           |
| D1.       | .3984264    | .026882   | 14.82  | 0.000 | .3456177             | .451235   |
| d82       |             |           |        |       |                      |           |
| D1.       | .0077134    | .0170579  | 0.45   | 0.651 | -.0257961            | .0412229  |
| d83       |             |           |        |       |                      |           |
| D1.       | -.0844391   | .0234564  | -3.60  | 0.000 | -.1305182            | -.03836   |
| d84       |             |           |        |       |                      |           |
| D1.       | -.1246632   | .0287464  | -4.34  | 0.000 | -.1811344            | -.068192  |
| d85       |             |           |        |       |                      |           |
| D1.       | -.121561    | .03315    | -3.67  | 0.000 | -.1866827            | -.0564392 |
| d86       |             |           |        |       |                      |           |
| D1.       | -.0863333   | .0366763  | -2.35  | 0.019 | -.1583823            | -.0142842 |
| d87       |             |           |        |       |                      |           |
| D1.       | -.0377932   | .0399728  | -0.95  | 0.345 | -.116318             | .0407316  |

**Ejercicio 2.**

Utilizar la base de datos provista “murder.dta”. La base de datos es una muestra longitudinal de estados de EE.UU., para los años 1987, 1990 y 1993.

(a) Estimar por OLS el efecto de las ejecuciones ( $x$ ) sobre la tasa de homicidios (murder rates,  $m$ ) controlando por desempleo ( $u$ ) y año:

$$m_{i,t} = \alpha + \beta_x x_{i,t} + \beta_u u_{i,t} + \beta_{90} d_{90,t} + \beta_{93} d_{93,t} + v_{i,t},$$

Notar que se omitió la dummy temporal para el año 1987. Interpretar los resultados.

POLS:

| Source   | SS         | df  | MS         | Number of obs | = | 153    |
|----------|------------|-----|------------|---------------|---|--------|
| Model    | 977.390644 | 4   | 244.347661 | F(4, 148)     | = | 3.05   |
| Residual | 11867.9475 | 148 | 80.1888343 | Prob > F      | = | 0.0190 |
| Total    | 12845.3381 | 152 | 84.5088034 | R-squared     | = | 0.0761 |
|          |            |     |            | Adj R-squared | = | 0.0511 |
|          |            |     |            | Root MSE      | = | 8.9548 |

  

| mrdrtte | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |          |
|---------|-------------|-----------|-------|-------|----------------------|----------|
| exec    | .1627547    | .1939295  | 0.84  | 0.403 | -.2204738            | .5459832 |
| unem    | 1.390786    | .4508653  | 3.08  | 0.002 | .4998207             | 2.281751 |
| d90     | 2.675335    | 1.816934  | 1.47  | 0.143 | -.91515              | 6.26582  |
| d93     | 1.607317    | 1.774768  | 0.91  | 0.367 | -1.899842            | 5.114476 |
| _cons   | -1.864393   | 3.069517  | -0.61 | 0.545 | -7.930134            | 4.201349 |

(b) ¿Por qué podría ser importante tener en consideración los efectos temporales agregados en el modelo?

Tener en consideración los efectos temporales agregados en el modelo podría ser importante si la tasa de homicidios es afectada por factores macroeconómicos externos que afectan a todos los estados de EE.UU. de la misma manera. Por lo tanto, si no se incluyen estas variables, se debe suponer que cualquier cambio en la media de la tasa de homicidios en el tiempo se debe a las ejecuciones o a la tasa de desempleo y no a factores externos. Por otra parte, controlar por estas variables hace más factible que se cumpla el supuesto de ausencia de autocorrelación serial.

(c) Ahora, considerar la siguiente modificación en el modelo:

$$m_{i,t} = \alpha + \beta_x x_{i,t} + \beta_u u_{i,t} + \beta_{90} d_{90,t} + \beta_{93} d_{93,t} + c_i + e_{i,t},$$

donde  $c_i$  es un efecto individual por estado. Estimar la ecuación usando efectos fijos.

FE:

```
Fixed-effects (within) regression      Number of obs   =      153
Group variable: id                    Number of groups =      51

R-squared:                             Obs per group:
    Within = 0.0734                      min =      3
    Between = 0.0037                     avg =     3.0
    Overall = 0.0108                     max =      3

corr(u_i, Xb) = 0.0010                  F(4,98)         =      1.94
                                         Prob > F        =     0.1098
```

| mrdрте                                   | Coefficient | Std. err.                         | t     | P> t  | [95% conf. interval] |          |
|------------------------------------------|-------------|-----------------------------------|-------|-------|----------------------|----------|
| exec                                     | -.1383231   | .1770059                          | -0.78 | 0.436 | -.4895856            | .2129395 |
| unem                                     | .2213158    | .2963756                          | 0.75  | 0.457 | -.366832             | .8094636 |
| d90                                      | 1.556215    | .7453273                          | 2.09  | 0.039 | .0771369             | 3.035293 |
| d93                                      | 1.733242    | .7004381                          | 2.47  | 0.015 | .3432454             | 3.123239 |
| _cons                                    | 5.822104    | 1.915611                          | 3.04  | 0.003 | 2.020636             | 9.623572 |
|                                          |             |                                   |       |       |                      |          |
| sigma_u                                  | 8.7527226   |                                   |       |       |                      |          |
| sigma_e                                  | 3.5214244   |                                   |       |       |                      |          |
| rho                                      | .86068589   | (fraction of variance due to u_i) |       |       |                      |          |
|                                          |             |                                   |       |       |                      |          |
| F test that all u i=0: F(50, 98) = 17.18 |             |                                   |       |       | Prob > F = 0.0000    |          |

(d) Repetir la estimación del inciso previo usando diferencias finitas de primer orden.

FD:

|  | Source   | SS         | df  | MS         | Number of obs | = | 102    |
|--|----------|------------|-----|------------|---------------|---|--------|
|  | Model    | 119.103298 | 4   | 29.7758244 | F(4, 98)      | = | 1.61   |
|  | Residual | 1812.28656 | 98  | 18.49272   | Prob > F      | = | 0.1778 |
|  | Total    | 1931.38986 | 102 | 18.9351947 | R-squared     | = | 0.0617 |
|  |          |            |     |            | Adj R-squared | = | 0.0234 |
|  |          |            |     |            | Root MSE      | = | 4.3003 |

  

|  | cmrdрте | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |          |
|--|---------|-------------|-----------|-------|-------|----------------------|----------|
|  | cexec   | -.1150682   | .1473871  | -0.78 | 0.437 | -.407553             | .1774166 |
|  | cunem   | .1630854    | .3079049  | 0.53  | 0.598 | -.4479419            | .7741126 |
|  | cd90    | 1.51099     | .6608967  | 2.29  | 0.024 | .1994623             | 2.822518 |
|  | cd93    | 1.725263    | .8533453  | 2.02  | 0.046 | .0318275             | 3.418699 |

(e) Brindar un ejemplo bajo el cual la variable de ejecuciones no sería, estrictamente, exógena (condicional en  $c_i$ ). Observación: Para obtener estimaciones consistentes, el modelo de efectos fijos asume exogeneidad estricta de las variables explicativas condicionadas en  $c_i$ .

Un ejemplo bajo el cual la variable de ejecuciones ( $x_{i,t}$ ) no sería estrictamente exógena (condicional en  $c_i$ ) podría ser si los estados aumentan las ejecuciones futuras en respuesta a los shocks positivos actuales de la tasa de homicidios. Dado el tramo de tiempo relativamente corto de la base de datos, la retroalimentación de la tasa de homicidio a las

ejecuciones futuras puede no ser muy preocupante, ya que el proceso judicial en los casos de pena capital tiende a moverse lentamente. Por supuesto, si se acelerara debido a un aumento de la tasa de homicidios, eso podría violar la exogeneidad estricta. Con una serie temporal más larga, se podría añadir  $x_{i,t+1}$  (e, incluso, valores de un futuro más lejano) y estimar la ecuación por FE, comprobando la significatividad estadística de la variable  $x_{i,t+1}$ . En el caso de que se encuentre que esta variable es estadísticamente significativa, se tendría evidencia a favor de que no se cumple el supuesto de exogeneidad estricta.

**(f)** Repetir la estimación del inciso (c) usando el estimador de GLS para diferencias finitas de primer orden. Comprobar que los coeficientes estimados son iguales a los obtenidos por FE.

```
bfdgls[4,1]
               mdrte
exec   -.13832306
unem    .22131582
d90     1.5562147
d93     1.7332421
```

**(g)** Reestimar el modelo del inciso (c) usando efectos aleatorios. Implementar el test de Hausman. ¿Cuál es el mejor estimador?

RE:

```
Random-effects GLS regression              Number of obs   =          153
Group variable: id                        Number of groups  =           51

R-squared:                                Obs per group:
    Within = 0.0680                               min =           3
    Between = 0.0731                              avg  =          3.0
    Overall = 0.0426                               max  =           3

corr(u_i, X) = 0 (assumed)                Wald chi2(4)      =           8.52
                                           Prob > chi2       =          0.0743
```

```
-----+-----
      mdrte | Coefficient  Std. err.      z    P>|z|     [95% conf. interval]
-----+-----
      exec |   -.0543375   .1595008    -0.34   0.733    - .3669533   .2582784
      unem |    .3947507   .2848133     1.39   0.166    - .1634732   .9529745
      d90  |    1.732981   .7478556     2.32   0.020     .2672106   3.19875
      d93  |    1.699913   .7065606     2.41   0.016     .3150796   3.084746
      _cons |    4.635132   2.179451     2.13   0.033     .3634863   8.906778
-----+-----
      sigma_u |  8.2056677
      sigma_e |  3.5214244
      rho    |  .84447636   (fraction of variance due to u_i)
-----+-----
```

| ---- Coefficients ---- |           |           |            |                                 |
|------------------------|-----------|-----------|------------|---------------------------------|
|                        | (b)       | (B)       | (b-B)      | $\sqrt{\text{diag}(V_b - V_B)}$ |
|                        | est_fe    | est_re    | Difference | Std. err.                       |
| exec                   | -.1383231 | -.0543375 | -.0839856  | .0767503                        |
| unem                   | .2213158  | .3947507  | -.1734349  | .0819749                        |
| d90                    | 1.556215  | 1.732981  | -.1767658  | .                               |
| d93                    | 1.733242  | 1.699913  | .0333292   | .                               |

b = Consistent under H0 and Ha; obtained from xtreg.  
 B = Inconsistent under Ha, efficient under H0; obtained from xtreg.

Test of H0: Difference in coefficients not systematic

$\chi^2(4) = (b-B)'[(V_b - V_B)^{-1}](b-B)$   
 = 5.78  
 Prob >  $\chi^2$  = 0.2165  
 (V\_b - V\_B is not positive definite)

Por lo tanto, se puede observar que, considerando un nivel de significación del 10%, el mejor estimador es el de efectos fijos, ya que se rechaza la hipótesis nula de no correlación entre los regresores y los efectos fijos, por lo que el estimador de efectos aleatorios no es consistente.



**Ejercicio 3.**

Considerar el siguiente modelo:

$$y_{it} = x_{it}\beta + \mu_i + v_{it}, i = 1, 2, \dots, N; t = 1, 2, \dots, T,$$

donde  $x_{it} \sim^{iid} \mathcal{N}(0, 1)$ ,  $\mu_i \sim^{iid} \mathcal{N}(0, \sigma_\mu^2)$ ,  $v_{it} \sim^{iid} \mathcal{N}(0, \sigma_v^2)$  y  $\mu_i \perp v_{it}$  para todo  $i, t$ . Suponer  $\beta = \sigma_\mu^2 = \sigma_v^2 = 1$  y  $T = 10$ . La idea es realizar experimentos de Monte Carlo para evaluar la eficiencia de distintos estimadores de  $\beta$ .

**(a)** Caso 1:  $N = 5$ . Realizar un experimento de Monte Carlo con 1.000 simulaciones. Reportar media, desvío estándar y RMSE de la estimación de  $\beta$  usando: POLS, RE y FE.

**(b)** Repetir el punto anterior con  $N = 10, 30, 50, 100$  y  $500$ .

|              | N_5       | N_10      | N_30      | N_50      | N_100     | N_500     |
|--------------|-----------|-----------|-----------|-----------|-----------|-----------|
| media_beta~s | .99804484 | .99234775 | 1.0019568 | 1.0039147 | 1.0005582 | .99963949 |
| de_beta_pols | .19410442 | .14170935 | .07988537 | .06148401 | .04521915 | .02023065 |
| rmse_beta~s  | .1940172  | .14184504 | .0798694  | .06157782 | .04519998 | .02022375 |
| media_beta~e | .99311721 | .99036578 | 1.0021895 | 1.0027847 | 1.0005854 | .99967618 |
| de_beta_fe   | .15215654 | .10712643 | .06006592 | .04603343 | .03388416 | .01449802 |
| rmse_beta_fe | .15223612 | .10750542 | .06007579 | .0460946  | .03387227 | .01449439 |
| media_beta~e | .99239395 | .99075022 | 1.0022435 | 1.0029077 | 1.0005371 | .99967278 |
| de_beta_re   | .15558624 | .10656719 | .05945567 | .04579737 | .0335924  | .01453039 |
| rmse_beta_re | .15569433 | .10691477 | .05946827 | .04586672 | .03357989 | .01452681 |

**(c)** Comentar los resultados obtenidos y su conclusión de qué estimador debiera utilizarse en la práctica.

En primer lugar, es importante destacar que, dados los supuestos del modelo, los tres estimadores en consideración son consistentes. Por lo tanto, se debería esperar que, a medida que el tamaño muestral aumenta, la media de las estimaciones de  $\beta$  con los diferentes estimadores estén cerca del valor poblacional ( $\beta = 1$ ). Ahora bien, para  $N < 10$ , el estimador FE es el que mejor funciona en términos de sesgo y de eficiencia. Luego, a partir de un tamaño de muestra de  $N = 30$ , ya se observa cómo el estimador RE es el más eficiente de todos, es decir, es el que presenta un menor desvío estándar, lo cual se vincula a que, dados los supuestos del modelo, es el estimador con la menor varianza asintótica. En resumen, si, en la práctica, se trabajara con un modelo donde se supone que se cumplen los supuestos del modelo del inciso, entonces, para  $N$  muy pequeño se optaría por utilizar el estimador FE, mientras que, a partir de  $N = 30$ , se optaría por el estimador RE.

**Ejercicio 4.**

Basado en el Ejercicio 10.18 de Wooldridge (2010). Utilizar la base de datos “wagepan.dta” para responder las preguntas a continuación.

(a) Utilizando *lwage* como variable dependiente, estimar un modelo que contenga un intercepto y las variables dummy de año *d81* a *d87*. Estimar el modelo por POLS, RE, FE y FD. ¿Qué se puede concluir acerca de los coeficientes de las variables dummy?

**POLS:**

| Source   | SS         | df    | MS         | Number of obs | = | 4,360  |
|----------|------------|-------|------------|---------------|---|--------|
| Model    | 92.9668229 | 7     | 13.2809747 | F(7, 4352)    | = | 50.54  |
| Residual | 1143.56282 | 4,352 | .262767192 | Prob > F      | = | 0.0000 |
|          |            |       |            | R-squared     | = | 0.0752 |
|          |            |       |            | Adj R-squared | = | 0.0737 |
| Total    | 1236.52964 | 4,359 | .283672779 | Root MSE      | = | .51261 |

  

| lwage | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |          |
|-------|-------------|-----------|-------|-------|----------------------|----------|
| d81   | .1193902    | .0310529  | 3.84  | 0.000 | .0585107             | .1802697 |
| d82   | .1781901    | .0310529  | 5.74  | 0.000 | .1173106             | .2390696 |
| d83   | .2257865    | .0310529  | 7.27  | 0.000 | .1649069             | .2866666 |
| d84   | .2968181    | .0310529  | 9.56  | 0.000 | .2359386             | .3576976 |
| d85   | .3459333    | .0310529  | 11.14 | 0.000 | .2850538             | .4068128 |
| d86   | .4062418    | .0310529  | 13.08 | 0.000 | .3453623             | .4671213 |
| d87   | .4730023    | .0310529  | 15.23 | 0.000 | .4121228             | .5338818 |
| _cons | 1.393477    | .0219577  | 63.46 | 0.000 | 1.350429             | 1.436525 |

**RE:**

|                               |                  |   |        |
|-------------------------------|------------------|---|--------|
| Random-effects GLS regression | Number of obs    | = | 4,360  |
| Group variable: nr            | Number of groups | = | 545    |
| R-squared:                    | Obs per group:   |   |        |
| Within = 0.0000               | min =            |   | 8      |
| Between = 0.0000              | avg =            |   | 8.0    |
| Overall = 0.0752              | max =            |   | 8      |
| corr(u_i, X) = 0 (assumed)    | Wald chi2(7)     | = | 738.94 |
|                               | Prob > chi2      | = | 0.0000 |

| lwage   | Coefficient | Std. err.                         | z     | P> z  | [95% conf. interval] |          |
|---------|-------------|-----------------------------------|-------|-------|----------------------|----------|
| d81     | .1193902    | .021487                           | 5.56  | 0.000 | .0772765             | .1615039 |
| d82     | .1781901    | .021487                           | 8.29  | 0.000 | .1360764             | .2203038 |
| d83     | .2257865    | .021487                           | 10.51 | 0.000 | .1836728             | .2679001 |
| d84     | .2968181    | .021487                           | 13.81 | 0.000 | .2547044             | .3389318 |
| d85     | .3459333    | .021487                           | 16.10 | 0.000 | .3038196             | .388047  |
| d86     | .4062418    | .021487                           | 18.91 | 0.000 | .3641281             | .4483555 |
| d87     | .4730023    | .021487                           | 22.01 | 0.000 | .4308886             | .515116  |
| _cons   | 1.393477    | .0219577                          | 63.46 | 0.000 | 1.350441             | 1.436513 |
| sigma_u | .37007665   |                                   |       |       |                      |          |
| sigma_e | .35469771   |                                   |       |       |                      |          |
| rho     | .52120938   | (fraction of variance due to u_i) |       |       |                      |          |

### FE:

```
Fixed-effects (within) regression      Number of obs   =      4,360
Group variable: nr                    Number of groups =       545

R-squared:                            Obs per group:
    Within = 0.1625                      min =          8
    Between = .                          avg =         8.0
    Overall = 0.0752                     max =          8

corr(u_i, Xb) = 0.0000                F(7,3808)       =      105.56
                                      Prob > F          =       0.0000
```

| lwage                                      | Coefficient | Std. err.                         | t     | P> t  | [95% conf. interval] |          |
|--------------------------------------------|-------------|-----------------------------------|-------|-------|----------------------|----------|
| d81                                        | .1193902    | .021487                           | 5.56  | 0.000 | .0772631             | .1615173 |
| d82                                        | .1781901    | .021487                           | 8.29  | 0.000 | .136063              | .2203172 |
| d83                                        | .2257865    | .021487                           | 10.51 | 0.000 | .1836594             | .2679135 |
| d84                                        | .2968181    | .021487                           | 13.81 | 0.000 | .254691              | .3389452 |
| d85                                        | .3459333    | .021487                           | 16.10 | 0.000 | .3038063             | .3880604 |
| d86                                        | .4062418    | .021487                           | 18.91 | 0.000 | .3641147             | .4483688 |
| d87                                        | .4730023    | .021487                           | 22.01 | 0.000 | .4308753             | .5151294 |
| _cons                                      | 1.393477    | .0151936                          | 91.71 | 0.000 | 1.363689             | 1.423265 |
| sigma_u                                    | .39074676   |                                   |       |       |                      |          |
| sigma_e                                    | .35469771   |                                   |       |       |                      |          |
| rho                                        | .54824631   | (fraction of variance due to u_i) |       |       |                      |          |
| F test that all u_i=0: F(544, 3808) = 9.71 |             |                                   |       |       | Prob > F = 0.0000    |          |

### FD:

| Source   | SS         | df    | MS         | Number of obs | = | 3,815  |
|----------|------------|-------|------------|---------------|---|--------|
| Model    | 19.3631642 | 7     | 2.76616631 | F(7, 3808)    | = | 14.06  |
| Residual | 749.249837 | 3,808 | .196756785 | Prob > F      | = | 0.0000 |
| Total    | 768.613001 | 3,815 | .201471298 | R-squared     | = | 0.0252 |
|          |            |       |            | Adj R-squared | = | 0.0234 |
|          |            |       |            | Root MSE      | = | .44357 |

  

| D.lwage | Coefficient | Std. err. | t    | P> t  | [95% conf. interval] |          |
|---------|-------------|-----------|------|-------|----------------------|----------|
| d81     |             |           |      |       |                      |          |
| D1.     | .1193902    | .0190006  | 6.28 | 0.000 | .0821379             | .1566425 |
| d82     |             |           |      |       |                      |          |
| D1.     | .1781901    | .0268709  | 6.63 | 0.000 | .1255074             | .2308728 |
| d83     |             |           |      |       |                      |          |
| D1.     | .2257865    | .03291    | 6.86 | 0.000 | .1612636             | .2903093 |
| d84     |             |           |      |       |                      |          |
| D1.     | .2968181    | .0380011  | 7.81 | 0.000 | .2223136             | .3713226 |
| d85     |             |           |      |       |                      |          |
| D1.     | .3459333    | .0424866  | 8.14 | 0.000 | .2626347             | .4292319 |
| d86     |             |           |      |       |                      |          |
| D1.     | .4062418    | .0465417  | 8.73 | 0.000 | .3149927             | .4974908 |
| d87     |             |           |      |       |                      |          |
| D1.     | .4730023    | .0502708  | 9.41 | 0.000 | .3744421             | .5715626 |

### Tabla comparativa:

|       | (1)<br>POLS          | (2)<br>RE            | (3)<br>FE            | (4)<br>FD            |
|-------|----------------------|----------------------|----------------------|----------------------|
| d81   | 0.119***<br>(0.0311) | 0.119***<br>(0.0215) | 0.119***<br>(0.0215) | 0.119***<br>(0.0190) |
| d82   | 0.178***<br>(0.0311) | 0.178***<br>(0.0215) | 0.178***<br>(0.0215) | 0.178***<br>(0.0269) |
| d83   | 0.226***<br>(0.0311) | 0.226***<br>(0.0215) | 0.226***<br>(0.0215) | 0.226***<br>(0.0329) |
| d84   | 0.297***<br>(0.0311) | 0.297***<br>(0.0215) | 0.297***<br>(0.0215) | 0.297***<br>(0.0380) |
| d85   | 0.346***<br>(0.0311) | 0.346***<br>(0.0215) | 0.346***<br>(0.0215) | 0.346***<br>(0.0425) |
| d86   | 0.406***<br>(0.0311) | 0.406***<br>(0.0215) | 0.406***<br>(0.0215) | 0.406***<br>(0.0465) |
| d87   | 0.473***<br>(0.0311) | 0.473***<br>(0.0215) | 0.473***<br>(0.0215) | 0.473***<br>(0.0503) |
| _cons | 1.393***<br>(0.0220) | 1.393***<br>(0.0220) | 1.393***<br>(0.0152) |                      |
| N     | 4360                 | 4360                 | 4360                 | 3815                 |
| r2    | 0.0752               |                      | 0.163                | 0.0252               |

Standard errors in parentheses  
\* p<0.10, \*\* p<0.05, \*\*\* p<0.01

Por lo tanto, lo que se puede concluir acerca de los coeficientes de las variables *dummy* es que son numéricamente idénticos.

**(b)** Añadir las variables constantes en el tiempo *educ*, *black* e *hisp* al modelo, y estimar por POLS y RE. ¿Cómo se comparan los coeficientes? ¿Qué ocurre si se estima la ecuación por FE?

POLS:

|          |            |       |            |               |   |        |
|----------|------------|-------|------------|---------------|---|--------|
| Source   | SS         | df    | MS         | Number of obs | = | 4,360  |
|          |            |       |            | F(10, 4349)   | = | 73.66  |
| Model    | 179.091659 | 10    | 17.9091659 | Prob > F      | = | 0.0000 |
| Residual | 1057.43798 | 4,349 | .243145087 | R-squared     | = | 0.1448 |
|          |            |       |            | Adj R-squared | = | 0.1429 |
| Total    | 1236.52964 | 4,359 | .283672779 | Root MSE      | = | .4931  |

  

|       |             |           |       |       |                      |           |
|-------|-------------|-----------|-------|-------|----------------------|-----------|
| lwage | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |           |
| d81   | .1193902    | .029871   | 4.00  | 0.000 | .0608279             | .1779526  |
| d82   | .1781901    | .029871   | 5.97  | 0.000 | .1196277             | .2367524  |
| d83   | .2257865    | .029871   | 7.56  | 0.000 | .1672241             | .2843488  |
| d84   | .2968181    | .029871   | 9.94  | 0.000 | .2382557             | .3553804  |
| d85   | .3459333    | .029871   | 11.58 | 0.000 | .287371              | .4044957  |
| d86   | .4062418    | .029871   | 13.60 | 0.000 | .3476794             | .4648041  |
| d87   | .4730023    | .029871   | 15.83 | 0.000 | .41444               | .5315647  |
| educ  | .0770943    | .0043766  | 17.62 | 0.000 | .0685139             | .0856747  |
| black | -.1225637   | .0237021  | -5.17 | 0.000 | -.1690319            | -.0760955 |
| hisp  | .024623     | .0213056  | 1.16  | 0.248 | -.0171468            | .0663928  |
| _cons | .4966384    | .0566686  | 8.76  | 0.000 | .3855391             | .6077377  |

RE:

|                               |                  |   |        |
|-------------------------------|------------------|---|--------|
| Random-effects GLS regression | Number of obs    | = | 4,360  |
| Group variable: nr            | Number of groups | = | 545    |
| R-squared:                    | Obs per group:   |   |        |
| Within = 0.1625               | min =            |   | 8      |
| Between = 0.1296              | avg =            |   | 8.0    |
| Overall = 0.1448              | max =            |   | 8      |
|                               | Wald chi2(10)    | = | 819.51 |
| corr(u_i, X) = 0 (assumed)    | Prob > chi2      | = | 0.0000 |

|         |             |                                   |       |       |                      |           |
|---------|-------------|-----------------------------------|-------|-------|----------------------|-----------|
| lwage   | Coefficient | Std. err.                         | z     | P> z  | [95% conf. interval] |           |
| d81     | .1193902    | .021487                           | 5.56  | 0.000 | .0772765             | .1615039  |
| d82     | .1781901    | .021487                           | 8.29  | 0.000 | .1360764             | .2203038  |
| d83     | .2257865    | .021487                           | 10.51 | 0.000 | .1836728             | .2679001  |
| d84     | .2968181    | .021487                           | 13.81 | 0.000 | .2547044             | .3389318  |
| d85     | .3459333    | .021487                           | 16.10 | 0.000 | .3038196             | .388047   |
| d86     | .4062418    | .021487                           | 18.91 | 0.000 | .3641281             | .4483555  |
| d87     | .4730023    | .021487                           | 22.01 | 0.000 | .4308886             | .515116   |
| educ    | .0770943    | .009177                           | 8.40  | 0.000 | .0591076             | .0950809  |
| black   | -.1225637   | .0496994                          | -2.47 | 0.014 | -.2199728            | -.0251546 |
| hisp    | .024623     | .0446744                          | 0.55  | 0.582 | -.0629371            | .1121831  |
| _cons   | .4966384    | .1122718                          | 4.42  | 0.000 | .2765897             | .7166871  |
| sigma_u | .34337144   |                                   |       |       |                      |           |
| sigma_e | .35469771   |                                   |       |       |                      |           |
| rho     | .48377912   | (fraction of variance due to u_i) |       |       |                      |           |

FE:

```
Fixed-effects (within) regression          Number of obs   =      4,360
Group variable: nr                        Number of groups =       545

R-squared:                                Obs per group:
    Within = 0.1625                          min =          8
    Between = .                                avg =         8.0
    Overall = 0.0752                          max =          8

corr(u_i, Xb) = 0.0000                     F(7,3808)       =      105.56
                                           Prob > F        =       0.0000
```

| lwage   | Coefficient | Std. err.                         | t     | P> t  | [95% conf. interval] |          |
|---------|-------------|-----------------------------------|-------|-------|----------------------|----------|
| d81     | .1193902    | .021487                           | 5.56  | 0.000 | .0772631             | .1615173 |
| d82     | .1781901    | .021487                           | 8.29  | 0.000 | .136063              | .2203172 |
| d83     | .2257865    | .021487                           | 10.51 | 0.000 | .1836594             | .2679135 |
| d84     | .2968181    | .021487                           | 13.81 | 0.000 | .254691              | .3389452 |
| d85     | .3459333    | .021487                           | 16.10 | 0.000 | .3038063             | .3880604 |
| d86     | .4062418    | .021487                           | 18.91 | 0.000 | .3641147             | .4483688 |
| d87     | .4730023    | .021487                           | 22.01 | 0.000 | .4308753             | .5151294 |
| educ    | 0           | (omitted)                         |       |       |                      |          |
| black   | 0           | (omitted)                         |       |       |                      |          |
| hisp    | 0           | (omitted)                         |       |       |                      |          |
| _cons   | 1.393477    | .0151936                          | 91.71 | 0.000 | 1.363689             | 1.423265 |
| sigma_u | .39074676   |                                   |       |       |                      |          |
| sigma_e | .35469771   |                                   |       |       |                      |          |
| rho     | .54824631   | (fraction of variance due to u_i) |       |       |                      |          |

F test that all u\_i=0: F(544, 3808) = 9.71 Prob > F = 0.0000

Tabla comparativa:

|       | (1)<br>POLS            | (2)<br>RE              | (3)<br>FE            |
|-------|------------------------|------------------------|----------------------|
| d81   | 0.119***<br>(0.0299)   | 0.119***<br>(0.0215)   | 0.119***<br>(0.0215) |
| d82   | 0.178***<br>(0.0299)   | 0.178***<br>(0.0215)   | 0.178***<br>(0.0215) |
| d83   | 0.226***<br>(0.0299)   | 0.226***<br>(0.0215)   | 0.226***<br>(0.0215) |
| d84   | 0.297***<br>(0.0299)   | 0.297***<br>(0.0215)   | 0.297***<br>(0.0215) |
| d85   | 0.346***<br>(0.0299)   | 0.346***<br>(0.0215)   | 0.346***<br>(0.0215) |
| d86   | 0.406***<br>(0.0299)   | 0.406***<br>(0.0215)   | 0.406***<br>(0.0215) |
| d87   | 0.473***<br>(0.0299)   | 0.473***<br>(0.0215)   | 0.473***<br>(0.0215) |
| educ  | 0.0771***<br>(0.00438) | 0.0771***<br>(0.00918) | 0<br>(.)             |
| black | -0.123***<br>(0.0237)  | -0.123**<br>(0.0497)   | 0<br>(.)             |
| hisp  | 0.0246<br>(0.0213)     | 0.0246<br>(0.0447)     | 0<br>(.)             |
| _cons | 0.497***<br>(0.0567)   | 0.497***<br>(0.112)    | 1.393***<br>(0.0152) |
| N     | 4360                   | 4360                   | 4360                 |
| r2    | 0.145                  |                        | 0.163                |

Standard errors in parentheses

\* p&lt;0.10, \*\* p&lt;0.05, \*\*\* p&lt;0.01

Por un lado, se puede observar que las estimaciones de POLS y RE son numéricamente idénticas, ya que, si el modelo incluye sólo efectos temporales agregados y covariables específicas del individuo que no tienen variación temporal, entonces, los coeficientes de POLS son iguales a los de RE.

Por otra parte, lo que ocurre si se estima la ecuación por FE es que los coeficientes asociados a las variables constantes en el tiempo no se pueden estimar y, en consecuencia, cuando se incluyen variables constantes en el tiempo, la estimación de la constante en FE no es igual a la estimación de la constante en POLS/RE.

(c) ¿Son iguales los errores estándar de POLS y RE del inciso (b)? ¿Cuáles son, probablemente, más fiables?

Los errores estándar de POLS y RE del inciso (b) no son iguales. Los errores estándar de POLS suponen, además de homocedasticidad, que no hay correlación serial en el error compuesto, es decir, que no considera la posible presencia de heterogeneidad individual no observable. Los errores estándar de RE, al menos, en su estructura estándar, permiten la presencia de correlación serial (en particular, la cual es igual para todos los pares de períodos (t, s)). Esto puede ser demasiado restrictivo, pero es menos restrictivo que los habituales errores estándar de POLS.

(d) Obtener los errores estándar robustos para POLS. ¿Son preferibles estos o los errores estándar habituales de RE?

#### POLS (con errores estándar robustos):

|                   |               |   |        |
|-------------------|---------------|---|--------|
| Linear regression | Number of obs | = | 4,360  |
|                   | F(10, 544)    | = | 49.41  |
|                   | Prob > F      | = | 0.0000 |
|                   | R-squared     | = | 0.1448 |
|                   | Root MSE      | = | .4931  |

(Std. err. adjusted for 545 clusters in nr)

|       |             | Robust    |       |       |                      |          |
|-------|-------------|-----------|-------|-------|----------------------|----------|
| lwage | Coefficient | std. err. | t     | P> t  | [95% conf. interval] |          |
| d81   | .1193902    | .0244086  | 4.89  | 0.000 | .0714435             | .1673369 |
| d82   | .1781901    | .0241987  | 7.36  | 0.000 | .1306558             | .2257243 |
| d83   | .2257865    | .0243796  | 9.26  | 0.000 | .1778968             | .2736761 |
| d84   | .2968181    | .0271485  | 10.93 | 0.000 | .2434894             | .3501468 |
| d85   | .3459333    | .0263181  | 13.14 | 0.000 | .2942358             | .3976309 |
| d86   | .4062418    | .0273064  | 14.88 | 0.000 | .3526029             | .4598807 |
| d87   | .4730023    | .025996   | 18.20 | 0.000 | .4219374             | .5240672 |
| educ  | .0770943    | .0090198  | 8.55  | 0.000 | .0593763             | .0948122 |
| black | -.1225637   | .0532662  | -2.30 | 0.022 | -.2271964            | -.017931 |
| hisp  | .024623     | .0411235  | 0.60  | 0.550 | -.0561573            | .1054033 |
| _cons | .4966384    | .1097474  | 4.53  | 0.000 | .2810579             | .7122189 |

Estos errores estándar robustos son preferibles a los errores estándar habituales de RE, ya que estos errores estándar robustos permiten cualquier tipo de correlación serial y de heterocedasticidad de los disturbios que varían en el tiempo.

(e) Obtener los errores estándar robustos de RE. ¿Cómo se comparan con los errores estándar robustos de POLS y por qué?



RE (con errores estándar robustos):

```
Random-effects GLS regression              Number of obs   =       4,360
Group variable: nr                        Number of groups =        545

R-squared:                               Obs per group:
    Within = 0.1625                        min =           8
    Between = 0.1296                      avg =          8.0
    Overall = 0.1448                      max =           8

corr(u_i, X) = 0 (assumed)                Wald chi2(10)    =       494.13
                                           Prob > chi2      =       0.0000
```

(Std. err. adjusted for 545 clusters in nr)

|         |       | Robust      |                                   |       |       |                      |
|---------|-------|-------------|-----------------------------------|-------|-------|----------------------|
|         | lwage | Coefficient | std. err.                         | z     | P> z  | [95% conf. interval] |
| d81     |       | .1193902    | .0244086                          | 4.89  | 0.000 | .0715502 .1672302    |
| d82     |       | .1781901    | .0241987                          | 7.36  | 0.000 | .1307616 .2256186    |
| d83     |       | .2257865    | .0243796                          | 9.26  | 0.000 | .1780033 .2735696    |
| d84     |       | .2968181    | .0271485                          | 10.93 | 0.000 | .2436081 .3500281    |
| d85     |       | .3459333    | .0263181                          | 13.14 | 0.000 | .2943508 .3975159    |
| d86     |       | .4062418    | .0273064                          | 14.88 | 0.000 | .3527222 .4597613    |
| d87     |       | .4730023    | .025996                           | 18.20 | 0.000 | .422051 .5239536     |
| educ    |       | .0770943    | .0090198                          | 8.55  | 0.000 | .0594157 .0947728    |
| black   |       | -.1225637   | .0532662                          | -2.30 | 0.021 | -.2269636 -.0181638  |
| hisp    |       | .024623     | .0411235                          | 0.60  | 0.549 | -.0559775 .1052236   |
| _cons   |       | .4966384    | .1097474                          | 4.53  | 0.000 | .2815375 .7117392    |
| sigma_u |       | .34337144   |                                   |       |       |                      |
| sigma_e |       | .35469771   |                                   |       |       |                      |
| rho     |       | .48377912   | (fraction of variance due to u_i) |       |       |                      |

Tabla comparativa:

|       | (1)                    | (2)                    |
|-------|------------------------|------------------------|
|       | POLS (robust)          | RE (robust)            |
| d81   | 0.119***<br>(0.0244)   | 0.119***<br>(0.0244)   |
| d82   | 0.178***<br>(0.0242)   | 0.178***<br>(0.0242)   |
| d83   | 0.226***<br>(0.0244)   | 0.226***<br>(0.0244)   |
| d84   | 0.297***<br>(0.0271)   | 0.297***<br>(0.0271)   |
| d85   | 0.346***<br>(0.0263)   | 0.346***<br>(0.0263)   |
| d86   | 0.406***<br>(0.0273)   | 0.406***<br>(0.0273)   |
| d87   | 0.473***<br>(0.0260)   | 0.473***<br>(0.0260)   |
| educ  | 0.0771***<br>(0.00902) | 0.0771***<br>(0.00902) |
| black | -0.123**<br>(0.0533)   | -0.123**<br>(0.0533)   |
| hisp  | 0.0246<br>(0.0411)     | 0.0246<br>(0.0411)     |
| _cons | 0.497***<br>(0.110)    | 0.497***<br>(0.110)    |
| N     | 4360                   | 4360                   |
| r2    | 0.145                  |                        |

Standard errors in parentheses

\* p&lt;0.10, \*\* p&lt;0.05, \*\*\* p&lt;0.01

Por lo tanto, se puede observar que estos errores estándar son numéricamente idénticos a los errores estándar robustos de POLS porque se tiene un solo estimador y, entonces, hay una sola varianza robusta.

UNIVERSIDAD TORCUATO DI TELLA  
MASTER EN ECONOMÍA Y ECONOMETRÍA  
2021

**Datos de Panel**

**Problem Set 3: Modelos de Panel Dinámicos**

1. Considere la base de datos *mod\_abdata.dta* que fue utilizada por Arellano y Bond en su famoso paper de 1991. Se trata de un panel de 140 empresas británicas encuestadas anualmente entre 1976 y 1984. El panel original no es balanceado, pero la versión para este ejercicio se trata de un panel balanceado de empresas con observaciones para exactamente 6 años entre 1977 y 1982. La variable que identifica la empresa es *id* y la variable que identifica el tiempo es *year*. La variable *n* es el empleo de la empresa. Luego, considere un modelo muy simplificado del siguiente tipo:

$$\ln n_{it} = \rho \ln n_{it-1} + \varepsilon_{it}$$

$$\varepsilon_{it} = c_i + \nu_{it}$$

$$E[c_i] = E[\nu_{it}] = E[c_i \nu_{it}] = 0$$

donde  $n_{it}$  es el empleo de la empresa  $i$  en el año  $t$ .

- a) Estime el modelo por OLS. ¿Qué sesgo esperaría encontrar y por qué?
- b) Estime el modelo usando efectos fijos (FE). ¿Permite la transformación *within* eliminar el sesgo de paneles dinámicos?
- c) Considere una transformación de diferencias finitas de primer orden del modelo. ¿Continúa siendo la variable dependiente rezagada potencialmente endógena?
- d) Implemente el estimador de Anderson-Hsiao a partir del comando *ivregress* en Stata.
- e) Ahora, obtenga la estimación GMM de  $\rho$  utilizando todos los instrumentos posibles en niveles para el modelo en primeras diferencias. Para ello utilice el comando *xtabond2*.

- f) Obtenga la estimación de GMM de  $\rho$  utilizando todos los instrumentos posibles en niveles para el modelo en primeras diferencias e  $\Delta y_{it-1}$  como instrumento para el modelo en niveles.
  - g) Repita las estimaciones de los incisos e) y f) incluyendo efectos fijos de tiempo.
2. En este ejercicio se ilustrará el hecho de que los estimadores de Arellano-Bond y de Blundell-Bond pueden extenderse en forma directa a modelos que incluyan regresores estrictamente exógenos y regresores secuencialmente exógenos.

En su paper original, Arellano y Bond modelaron el empleo de las empresas ( $n$ ) utilizando un modelo de ajuste parcial para reflejar los costos de contratación y despido, incluyendo dos rezagos de la variable empleo. Otras variables incluidas fueron el nivel salarial actual y el rezagado ( $w$ ), el stock de capital actual, rezagado una y dos veces ( $k$ ) y la producción agregada actual, rezagada una y dos veces en el sector de la empresa ( $ys$ ). Todas las variables se expresan en logaritmos. También se incluye un conjunto de variables *dummy* de tiempo.

- a) Estime el modelo por OLS. Compute los errores estándar robustos a heterocedasticidad y correlación serial.
  - b) Estime el modelo por FE. Compute los errores estándar robustos a heterocedasticidad y correlación serial.
  - c) Implemente el estimador de Anderson-Hsiao usando  $n_{it-2}$  como instrumento.
  - d) Estime la ecuación de empleo usando el estimador de Arellano-Bond. Asuma que la única endogeneidad presente es en el rezago de la variable dependiente.
  - e) Ahora, considere como hicieron Blundell y Bond (1998) que los salarios y el stock de capital no deben tomarse como estrictamente exógenos en este contexto (como se hizo en los modelos anteriores). Reestime el modelo usando el estimador de A-B y considerando a los salarios y el stock de capital como regresores secuencialmente exógenos.
  - f) Adicionalmente, Blundell y Bond (1998) eliminan de su modelo los rezagos más largos (de dos períodos) del empleo y el capital, y prescinden del nivel de producto agregado sectorial. Considerando esta cuestión, compute el estimador de Blundell-Bond.
3. Cuando hay muchos instrumentos, surgen dos problemas principales:

- Sobreestimación (*overfitting*) de la variable endógena
- Mala estimación de la matriz de pesos  $W$

En estos casos, se proponen las siguientes soluciones:

- a) Probar diferentes especificaciones de IV recortando el número de rezagos en la matriz de instrumentos  $\mathbf{Z}$ .
- b) Colapsar/combinar instrumentos. Se modifica la matriz de instrumentos para el individuo  $i$ :

$$\mathbf{Z}_i = \begin{bmatrix} y_{i1} & 0 & 0 & \cdots \\ y_{i1} & y_{i2} & 0 & \cdots \\ y_{i3} & y_{i2} & y_{i1} & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Si el modelo funciona debería dar resultados similares con distintos instrumentos.

Retome el ejercicio 2.e) para ver una aplicación de esta cuestión. Estime el modelo de empleo restringiendo el máximo rezago a 3 y 4 períodos. Por último, estime el modelo colapsando instrumentos. Analice si los resultados obtenidos son robustos.

4. Considere nuevamente el modelo del primer ejercicio. Obtenga el estimador LSDVC propuesto por Kiviet (1995) a partir del comando *xtlsdvc*. Luego, estime la matriz de varianzas y covarianzas de los coeficientes de Kiviet siguiendo el procedimiento explicado en clase.

## **Trabajo Práctico N° 3:** **Modelos de Paneles Dinámicos.**

### **Ejercicio 1.**

Considerar la base de datos “mod\_abdata.dta” que fue utilizada por Arellano y Bond en su famoso paper de 1991. Se trata de un panel de 140 empresas británicas encuestadas, anualmente, entre 1976 y 1984. El panel original no es balanceado, pero la versión para este ejercicio se trata de un panel balanceado de empresas con observaciones para, exactamente, 6 años entre 1977 y 1982. La variable que identifica la empresa es *id* y la variable que identifica el tiempo es *year*. La variable *n* es el empleo de la empresa. Luego, considerar un modelo muy simplificado del siguiente tipo:

$$\ln n_{it} = \rho \ln n_{it-1} + \varepsilon_{it},$$

$$\varepsilon_{it} = c_i + v_{it},$$

$$E(c_i) = E(v_{it}) = E(c_i v_{it}) = 0,$$

donde  $n_{it}$  es el empleo de la empresa *i* en el año *t*.

**(a)** Estimar el modelo por OLS. ¿Qué sesgo se esperaba encontrar y por qué?

**POLS:**

| Source   | SS         | df  | MS         | Number of obs | = | 770      |
|----------|------------|-----|------------|---------------|---|----------|
| Model    | 1396.09073 | 1   | 1396.09073 | F(1, 768)     | = | 76542.09 |
| Residual | 14.0079495 | 768 | .018239518 | Prob > F      | = | 0.0000   |
| Total    | 1410.09868 | 769 | 1.83367839 | R-squared     | = | 0.9901   |
|          |            |     |            | Adj R-squared | = | 0.9901   |
|          |            |     |            | Root MSE      | = | .13505   |

  

| n     | Coefficient | Std. err. | t      | P> t  | [95% conf. interval] |           |
|-------|-------------|-----------|--------|-------|----------------------|-----------|
| nL1   | .9967362    | .0036027  | 276.66 | 0.000 | .9896639             | 1.003809  |
| _cons | -.0379493   | .0063799  | -5.95  | 0.000 | -.0504734            | -.0254252 |

El sesgo que se esperaba encontrar es el sesgo de paneles dinámicos, el cual se desprende que  $\ln n_{it-1}$  está correlacionado con los efectos fijos,  $c_i$ , que se encuentran en el término de error. En general, bajo muchos supuestos, OLS sobrestima el valor real del parámetro  $\rho$ .

**(b)** Estimar el modelo usando efectos fijos (FE). ¿Permite la transformación within eliminar el sesgo de paneles dinámicos?

FE:

```
Fixed-effects (within) regression      Number of obs   =       770
Group variable: id                    Number of groups =       138

R-squared:                             Obs per group:
    Within = 0.4926                      min =          5
    Between = 0.9979                     avg =         5.6
    Overall = 0.9901                     max =          6

corr(u_i, Xb) = 0.9382                  F(1,631)         =      612.49
                                         Prob > F         =       0.0000
```

```
-----+-----
            n | Coefficient  Std. err.      t    P>|t|    [95% conf. interval]
-----+-----
      nL1 |   .869605   .0351375    24.75  0.000   .8006043   .9386056
     _cons |  .1076112   .0405095     2.66  0.008   .0280614   .1871609
-----+-----
sigma_u |   .18358137
sigma_e |   .1315487
rho     |   .66073284   (fraction of variance due to u_i)
-----+-----
F test that all u_i=0: F(137, 631) = 1.30                Prob > F = 0.0194
```

La transformación *within* no permite eliminar el sesgo de paneles dinámicos, ya que, ahora, el problema se encuentra en que  $\ln \widetilde{n_{it-1}} = \ln n_{it-1} - \overline{\ln n_{i-1}}$  está correlacionado con  $\widetilde{v_{it}} = v_{it} - \bar{v}_i$ , aun cuando  $v_{it}$  no tiene correlación serial. En particular, el término  $\ln n_{it-1}$  correlaciona negativamente con  $\frac{-1}{T-1} v_{it-1}$  que se encuentra dentro de  $\bar{v}_i$ , mientras que, simétricamente,  $\frac{-1}{T-1} \ln n_{it}$  y  $v_{it}$  también se encuentran correlacionados negativamente. Adicionalmente, hay otros pares de términos que correlacionan, pero su impacto es de segundo orden. Por último, cabe mencionar que Nickell mostró que, si  $\rho > 0$ , este sesgo es siempre negativo.

**(c)** Considerar una transformación de diferencias finitas de primer orden del modelo. ¿Continúa siendo la variable dependiente rezagada potencialmente endógena?

Considerando una transformación de diferencias finitas de primer orden del modelo, la variable dependiente rezagada continúa siendo potencialmente endógena, ya que el término  $\Delta \ln n_{it-1} = \ln n_{it-1} - \ln n_{it-2}$  está correlacionado con  $v_{it-1}$  en  $\Delta v_{it} = v_{it} - v_{it-1}$ .

**(d)** Implementar el estimador de Anderson-Hsiao a partir del comando `ivregress` en *Stata*.

#### IV (Anderson-Hsiao):

```
Instrumental variables 2SLS regression      Number of obs   =      632
                                           Wald chi2(1)    =      .
                                           Prob > chi2     =      .
                                           R-squared      =      .
                                           Root MSE      =      .25024
```

| D.n | Coefficient | Std. err. | z    | P> z  | [95% conf. interval] |          |
|-----|-------------|-----------|------|-------|----------------------|----------|
| nL1 |             |           |      |       |                      |          |
| D1. | 2.015601    | .4911953  | 4.10 | 0.000 | 1.052876             | 2.978327 |

```
Instrumented: D.nL1
Instruments: nL2
```

(e) Ahora, obtener la estimación GMM de  $p$  utilizando todos los instrumentos posibles en niveles para el modelo en primeras diferencias. Para ello, utilizar el comando `xtabond2`.

#### GMM One-Step (Arellano-Bond):

Dynamic panel-data estimation, one-step difference GMM

```
Group variable: id      Number of obs   =      632
Time variable : year    Number of groups =      138
Number of instruments = 10  Obs per group: min =      4
Wald chi2(0) = .          avg =      4.58
Prob > chi2 = .          max =      5
```

| n   | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |         |
|-----|-------------|-----------|-------|-------|----------------------|---------|
| nL1 | 1.146045    | .0865907  | 13.24 | 0.000 | .9763309             | 1.31576 |

```
Instruments for first differences equation
GMM-type (missing=0, separate instruments for each period unless collapsed)
L(1/5).L.n
```

```
Arellano-Bond test for AR(1) in first differences: z = -4.21 Pr > z = 0.000
Arellano-Bond test for AR(2) in first differences: z = -2.35 Pr > z = 0.019
```

```
Sargan test of overid. restrictions: chi2(9) = 122.88 Prob > chi2 = 0.000
(Not robust, but not weakened by many instruments.)
```



GMM Two-Step (Arellano-Bond):

Dynamic panel-data estimation, two-step difference GMM

```
-----
Group variable: id                Number of obs   =      632
Time variable : year              Number of groups =      138
Number of instruments = 10         Obs per group: min =       4
Wald chi2(0)   =                  .               avg   =      4.58
Prob > chi2    =                  .               max   =       5
-----
```

```
-----
      n | Coefficient  Std. err.      z    P>|z|    [95% conf. interval]
-----+-----
      nL1 |   1.176208   .0771686    15.24   0.000    1.024961    1.327456
-----
```

Warning: Uncorrected two-step standard errors are unreliable.

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z =  -2.97   Pr > z =  0.003
Arellano-Bond test for AR(2) in first differences: z =  -1.71   Pr > z =  0.087
-----
```

Sargan test of overid. restrictions: chi2(9) = 122.88 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(9) = 48.86 Prob > chi2 = 0.000  
(Robust, but weakened by many instruments.)

**(f)** *Obtener la estimación de GMM de  $\rho$  utilizando todos los instrumentos posibles en niveles para el modelo en primeras diferencias e  $\Delta y_{it-1}$  como instrumento para el modelo en niveles.*

### SGMM One-Step (Blundell-Bond):

Dynamic panel-data estimation, one-step system GMM

|                            |                    |   |      |
|----------------------------|--------------------|---|------|
| Group variable: id         | Number of obs      | = | 770  |
| Time variable : year       | Number of groups   | = | 138  |
| Number of instruments = 15 | Obs per group: min | = | 5    |
| Wald chi2(1) = 75831.06    | avg                | = | 5.58 |
| Prob > chi2 = 0.000        | max                | = | 6    |

|       | n | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |
|-------|---|-------------|-----------|-------|-------|----------------------|
| nL1   |   | 1.107192    | .0200965  | 55.09 | 0.000 | 1.067803 1.14658     |
| _cons |   | -.1644167   | .0233703  | -7.04 | 0.000 | -.2102216 -.1186118  |

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

Instruments for levels equation

Standard  
\_cons  
GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.L.n

Arellano-Bond test for AR(1) in first differences: z = -5.47 Pr > z = 0.000  
Arellano-Bond test for AR(2) in first differences: z = -2.27 Pr > z = 0.023

Sargan test of overid. restrictions: chi2(13) = 168.40 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Difference-in-Sargan tests of exogeneity of instrument subsets:

GMM instruments for levels  
Sargan test excluding group: chi2(9) = 127.56 Prob > chi2 = 0.000  
Difference (null H = exogenous): chi2(4) = 40.84 Prob > chi2 = 0.000

### SGMM Two-Step (Blundell-Bond):

Dynamic panel-data estimation, two-step system GMM

```
-----
Group variable: id                Number of obs   =    770
Time variable : year             Number of groups =    138
Number of instruments = 15        Obs per group: min =     5
Wald chi2(1)  = 23169.14          avg          =   5.58
Prob > chi2    =    0.000          max          =     6
-----
```

|       | n | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |
|-------|---|-------------|-----------|-------|-------|----------------------|
| nL1   |   | 1.149856    | .0316392  | 36.34 | 0.000 | 1.087845 1.211868    |
| _cons |   | -.1738829   | .0370401  | -4.69 | 0.000 | -.2464801 -.1012857  |

Warning: Uncorrected two-step standard errors are unreliable.

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

Instruments for levels equation

Standard

\_cons

GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z = -3.18 Pr > z = 0.001
Arellano-Bond test for AR(2) in first differences: z = -1.71 Pr > z = 0.087
-----
```

Sargan test of overid. restrictions: chi2(13) = 168.40 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(13) = 56.19 Prob > chi2 = 0.000  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

GMM instruments for levels

Hansen test excluding group: chi2(9) = 49.15 Prob > chi2 = 0.000

Difference (null H = exogenous): chi2(4) = 7.04 Prob > chi2 = 0.134

**(g)** Repetir las estimaciones de los incisos (e) y (f) incluyendo efectos fijos de tiempo.

### GMM One-Step (Arellano-Bond):

Dynamic panel-data estimation, one-step difference GMM

```
-----
Group variable: id                      Number of obs      =      632
Time variable : year                    Number of groups   =      138
Number of instruments = 15              Obs per group: min =        4
Wald chi2(0)      =      .              avg              =      4.58
Prob > chi2       =      .              max              =        5
-----
```

|        | n | Coefficient | Std. err. | z      | P> z  | [95% conf. interval] |
|--------|---|-------------|-----------|--------|-------|----------------------|
| nL1    |   | .2667934    | .1114731  | 2.39   | 0.017 | .0483102 .4852767    |
| yr1977 |   | .0072053    | .0133804  | 0.54   | 0.590 | -.0190198 .0334304   |
| yr1978 |   | -.000092    | .0101049  | -0.01  | 0.993 | -.0198972 .0197132   |
| yr1980 |   | -.0390927   | .010015   | -3.90  | 0.000 | -.0587218 -.0194636  |
| yr1981 |   | -.1440582   | .0107307  | -13.42 | 0.000 | -.1650901 -.1230264  |
| yr1982 |   | -.214458    | .0194763  | -11.01 | 0.000 | -.2526308 -.1762851  |

Instruments for first differences equation

Standard

D.(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)

L(1/5).L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z =    0.30  Pr > z =    0.764
Arellano-Bond test for AR(2) in first differences: z =   -0.93  Pr > z =    0.351
-----
```

```
Sargan test of overid. restrictions: chi2(9)      =   36.01  Prob > chi2 =    0.000
(Not robust, but not weakened by many instruments.)
```

### GMM Two-Step (Arellano-Bond):

Dynamic panel-data estimation, two-step difference GMM

```
-----
Group variable: id                      Number of obs      =      632
Time variable : year                    Number of groups   =      138
Number of instruments = 15              Obs per group: min =        4
Wald chi2(0)      =      .              avg              =      4.58
Prob > chi2       =      .              max              =        5
-----
```

|        | n | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |
|--------|---|-------------|-----------|-------|-------|----------------------|
| nL1    |   | .4092502    | .0923988  | 4.43  | 0.000 | .2281518 .5903486    |
| yr1977 |   | .0090912    | .0095385  | 0.95  | 0.341 | -.009604 .0277864    |
| yr1978 |   | .0020047    | .0051366  | 0.39  | 0.696 | -.0080629 .0120723   |
| yr1980 |   | -.0313017   | .0073163  | -4.28 | 0.000 | -.0456414 -.0169621  |
| yr1981 |   | -.1342723   | .0163176  | -8.23 | 0.000 | -.1662543 -.1022903  |
| yr1982 |   | -.2001323   | .0235447  | -8.50 | 0.000 | -.2462791 -.1539855  |

Warning: Uncorrected two-step standard errors are unreliable.

Instruments for first differences equation

Standard

D.(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)

L(1/5).L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z =   -0.90  Pr > z =    0.370
Arellano-Bond test for AR(2) in first differences: z =   -1.22  Pr > z =    0.222
-----
```

```
Sargan test of overid. restrictions: chi2(9)      =   36.01  Prob > chi2 =    0.000
(Not robust, but not weakened by many instruments.)
```

```
Hansen test of overid. restrictions: chi2(9)      =   11.00  Prob > chi2 =    0.276
(Robust, but weakened by many instruments.)
```

### SGMM One-Step (Blundell-Bond):

Dynamic panel-data estimation, one-step system GMM

```
-----
Group variable: id                Number of obs   =       770
Time variable : year              Number of groups =       138
Number of instruments = 20         Obs per group: min =        5
Wald chi2(6)  = 84467.08           avg          =    5.58
Prob > chi2    =      0.000         max          =        6
-----
```

|        | n | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |
|--------|---|-------------|-----------|-------|-------|----------------------|
| nL1    |   | 1.070702    | .0198077  | 54.05 | 0.000 | 1.031879 1.109524    |
| yr1977 |   | .0438478    | .0151864  | 2.89  | 0.004 | .0140831 .0736126    |
| yr1978 |   | .0518471    | .0129701  | 4.00  | 0.000 | .0264261 .0772681    |
| yr1979 |   | .0418566    | .0129664  | 3.23  | 0.001 | .0164428 .0672704    |
| yr1981 |   | -.0742759   | .0129883  | -5.72 | 0.000 | -.0997325 -.0488193  |
| yr1982 |   | -.0521052   | .0133172  | -3.91 | 0.000 | -.0782065 -.026004   |
| _cons  |   | -.1213363   | .0250374  | -4.85 | 0.000 | -.1704086 -.072264   |

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

Instruments for levels equation

Standard  
yr1977 yr1978 yr1979 yr1980 yr1981 yr1982  
\_cons

GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z = -6.30 Pr > z = 0.000
Arellano-Bond test for AR(2) in first differences: z = -2.36 Pr > z = 0.018
-----
```

Sargan test of overid. restrictions: chi2(13) = 79.17 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Difference-in-Sargan tests of exogeneity of instrument subsets:

GMM instruments for levels

Sargan test excluding group: chi2(9) = 21.45 Prob > chi2 = 0.011  
Difference (null H = exogenous): chi2(4) = 57.72 Prob > chi2 = 0.000

iv(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982, eq(level))

Sargan test excluding group: chi2(8) = 56.13 Prob > chi2 = 0.000  
Difference (null H = exogenous): chi2(5) = 23.05 Prob > chi2 = 0.000

### SGMM Two-Step (Blundell-Bond):

Dynamic panel-data estimation, two-step system GMM

```
-----
Group variable: id                      Number of obs   =      770
Time variable : year                    Number of groups =     138
Number of instruments = 20              Obs per group: min =      5
Wald chi2(6)   = 19554.89                avg =     5.58
Prob > chi2    =      0.000                max =      6
-----
```

|        | n | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |
|--------|---|-------------|-----------|-------|-------|----------------------|
| nL1    |   | 1.115279    | .0252032  | 44.25 | 0.000 | 1.065881 1.164676    |
| yr1977 |   | .042046     | .0187107  | 2.25  | 0.025 | .0053737 .0787184    |
| yr1978 |   | .0475315    | .0087333  | 5.44  | 0.000 | .0304146 .0646484    |
| yr1979 |   | .0347642    | .0075048  | 4.63  | 0.000 | .0200551 .0494734    |
| yr1981 |   | -.0766901   | .0109072  | -7.03 | 0.000 | -.0980679 -.0553123  |
| yr1982 |   | -.0535137   | .0128686  | -4.16 | 0.000 | -.0787358 -.0282917  |
| _cons  |   | -.1778026   | .0308186  | -5.77 | 0.000 | -.238206 -.1173993   |

Warning: Uncorrected two-step standard errors are unreliable.

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

Instruments for levels equation

Standard  
yr1977 yr1978 yr1979 yr1980 yr1981 yr1982  
\_cons

GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z = -3.22 Pr > z = 0.001
Arellano-Bond test for AR(2) in first differences: z = -1.56 Pr > z = 0.118
-----
```

Sargan test of overid. restrictions: chi2(13) = 79.17 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(13) = 28.91 Prob > chi2 = 0.007  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

GMM instruments for levels

Hansen test excluding group: chi2(9) = 6.67 Prob > chi2 = 0.671  
Difference (null H = exogenous): chi2(4) = 22.23 Prob > chi2 = 0.000

iv(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982, eq(level))

Hansen test excluding group: chi2(8) = 22.21 Prob > chi2 = 0.005  
Difference (null H = exogenous): chi2(5) = 6.69 Prob > chi2 = 0.244

**Ejercicio 2.**

En este ejercicio, se ilustrará el hecho de que los estimadores de Arellano-Bond y de Blundell-Bond pueden extenderse, en forma directa, a modelos que incluyan regresores estrictamente exógenos y regresores secuencialmente exógenos.

En su paper original, Arellano y Bond modelaron el empleo de las empresas ( $n$ ) utilizando un modelo de ajuste parcial para reflejar los costos de contratación y despido, incluyendo dos rezagos de la variable empleo. Otras variables incluidas fueron el nivel salarial actual y el rezagado ( $w$ ), el stock de capital actual, rezagado una y dos veces ( $k$ ), y la producción agregada actual, rezagada una y dos veces en el sector de la empresa ( $ys$ ). Todas las variables se expresan en logaritmos. También se incluye un conjunto de variables dummy de tiempo.

(a) Estimar el modelo por OLS. Computar los errores estándar robustos a heterocedasticidad y correlación serial.

**POLS:**

```
Linear regression                                Number of obs   =      632
                                                F(14, 137)      =    15042.46
                                                Prob > F         =      0.0000
                                                R-squared        =      0.9948
                                                Root MSE        =      .09885
```

(Std. err. adjusted for 138 clusters in id)

|        | n | Coefficient | Robust<br>std. err. | t     | P> t  | [95% conf. interval] |           |
|--------|---|-------------|---------------------|-------|-------|----------------------|-----------|
| nL1    |   | 1.083681    | .0479746            | 22.59 | 0.000 | .9888145             | 1.178548  |
| nL2    |   | -.1204015   | .0432502            | -2.78 | 0.006 | -.2059257            | -.0348772 |
| w      |   | -.4314672   | .1861579            | -2.32 | 0.022 | -.7995817            | -.0633527 |
| wL1    |   | .3933175    | .1806983            | 2.18  | 0.031 | .035999              | .7506359  |
| k      |   | .3214569    | .0546692            | 5.88  | 0.000 | .2133524             | .4295614  |
| kL1    |   | -.2087172   | .0674584            | -3.09 | 0.002 | -.3421117            | -.0753228 |
| kL2    |   | -.0811552   | .030786             | -2.64 | 0.009 | -.1420324            | -.020278  |
| ys     |   | .5156912    | .1862924            | 2.77  | 0.006 | .1473108             | .8840716  |
| ysL1   |   | -.7065917   | .2745098            | -2.57 | 0.011 | -1.249416            | -.1637674 |
| ysL2   |   | .2489473    | .1450994            | 1.72  | 0.088 | -.0379767            | .5358714  |
| yr1977 |   | 0           | (omitted)           |       |       |                      |           |
| yr1978 |   | 0           | (omitted)           |       |       |                      |           |
| yr1979 |   | .0161153    | .0087992            | 1.83  | 0.069 | -.0012845            | .0335151  |
| yr1980 |   | .0267825    | .0153105            | 1.75  | 0.082 | -.003493             | .057058   |
| yr1981 |   | -.0111743   | .0255106            | -0.44 | 0.662 | -.0616197            | .0392712  |
| yr1982 |   | -.0017447   | .0217911            | -0.08 | 0.936 | -.044835             | .0413456  |
| _cons  |   | -.1238146   | .2952534            | -0.42 | 0.676 | -.7076579            | .4600287  |

(b) Estimar el modelo por FE. Computar los errores estándar robustos a heterocedasticidad y correlación serial.

FE:

```
Fixed-effects (within) regression          Number of obs   =       632
Group variable: id                        Number of groups =       138

R-squared:                                Obs per group:
    Within = 0.7708                        min =           4
    Between = 0.9706                      avg =          4.6
    Overall = 0.9674                      max =           5

corr(u_i, Xb) = 0.6273                    F(14,137)       =      128.03
                                           Prob > F        =       0.0000
```

(Std. err. adjusted for 138 clusters in id)

|         | n | Coefficient | Robust<br>std. err.               | t     | P> t  | [95% conf. interval] |           |
|---------|---|-------------|-----------------------------------|-------|-------|----------------------|-----------|
| nL1     |   | .712259     | .0546499                          | 13.03 | 0.000 | .6041925             | .8203255  |
| nL2     |   | -.2216269   | .0557228                          | -3.98 | 0.000 | -.3318149            | -.1114389 |
| w       |   | -.504334    | .1902322                          | -2.65 | 0.009 | -.8805051            | -.1281629 |
| wL1     |   | .1750077    | .1374862                          | 1.27  | 0.205 | -.0968619            | .4468772  |
| k       |   | .3667223    | .0660277                          | 5.55  | 0.000 | .2361571             | .4972875  |
| kL1     |   | -.0648159   | .052492                           | -1.23 | 0.219 | -.1686152            | .0389834  |
| kL2     |   | .0287852    | .0412597                          | 0.70  | 0.487 | -.0528031            | .1103735  |
| ys      |   | .5252203    | .1803162                          | 2.91  | 0.004 | .1686574             | .8817831  |
| ysL1    |   | -.5622163   | .2111979                          | -2.66 | 0.009 | -.9798456            | -.1445871 |
| ysL2    |   | .1339081    | .1695363                          | 0.79  | 0.431 | -.2013383            | .4691544  |
| yr1977  |   | 0           | (omitted)                         |       |       |                      |           |
| yr1978  |   | .0218097    | .0273806                          | 0.80  | 0.427 | -.0323336            | .0759531  |
| yr1979  |   | .0241949    | .0257897                          | 0.94  | 0.350 | -.0268024            | .0751922  |
| yr1980  |   | .0319888    | .0201233                          | 1.59  | 0.114 | -.0078037            | .0717813  |
| yr1981  |   | -.0005961   | .0168409                          | -0.04 | 0.972 | -.0338978            | .0327056  |
| yr1982  |   | 0           | (omitted)                         |       |       |                      |           |
| _cons   |   | 1.248446    | .8176095                          | 1.53  | 0.129 | -.3683202            | 2.865213  |
| sigma_u |   | .29806935   |                                   |       |       |                      |           |
| sigma_e |   | .09040774   |                                   |       |       |                      |           |
| rho     |   | .91575291   | (fraction of variance due to u_i) |       |       |                      |           |

(c) Implementar el estimador de Anderson-Hsiao usando  $n_{it-2}$  como instrumento.



IV (Anderson-Hsiao):

|                                        |               |   |        |
|----------------------------------------|---------------|---|--------|
| Instrumental variables 2SLS regression | Number of obs | = | 494    |
|                                        | Wald chi2(13) | = | 14.10  |
|                                        | Prob > chi2   | = | 0.3669 |
|                                        | R-squared     | = | .      |
|                                        | Root MSE      | = | .53695 |

| D.n    | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |          |
|--------|-------------|-----------|-------|-------|----------------------|----------|
| nL1    |             |           |       |       |                      |          |
| D1.    | 5.823993    | 14.07042  | 0.41  | 0.679 | -21.75353            | 33.40152 |
| nL2    |             |           |       |       |                      |          |
| D1.    | -.9846567   | 2.216574  | -0.44 | 0.657 | -5.329062            | 3.359749 |
| w      |             |           |       |       |                      |          |
| D1.    | -.3323156   | .4888956  | -0.68 | 0.497 | -1.290533            | .6259022 |
| wL1    |             |           |       |       |                      |          |
| D1.    | 1.433551    | 3.563217  | 0.40  | 0.687 | -5.550226            | 8.417328 |
| k      |             |           |       |       |                      |          |
| D1.    | .0698672    | .7653782  | 0.09  | 0.927 | -1.430246            | 1.569981 |
| kL1    |             |           |       |       |                      |          |
| D1.    | -1.708326   | 4.482217  | -0.38 | 0.703 | -10.49331            | 7.076659 |
| kL2    |             |           |       |       |                      |          |
| D1.    | -.5052786   | 1.434586  | -0.35 | 0.725 | -3.317016            | 2.306459 |
| ys     |             |           |       |       |                      |          |
| D1.    | 1.344045    | 1.935232  | 0.69  | 0.487 | -2.448939            | 5.13703  |
| ysL1   |             |           |       |       |                      |          |
| D1.    | -2.722142   | 6.196766  | -0.44 | 0.660 | -14.86758            | 9.423296 |
| ysL2   |             |           |       |       |                      |          |
| D1.    | -.1505585   | .837905   | -0.18 | 0.857 | -1.792822            | 1.491705 |
| yr1977 |             |           |       |       |                      |          |
| D1.    | 0           | (omitted) |       |       |                      |          |
| yr1978 |             |           |       |       |                      |          |
| D1.    | .0677291    | .381059   | 0.18  | 0.859 | -.6791328            | .814591  |
| yr1979 |             |           |       |       |                      |          |
| D1.    | .1150868    | .3885855  | 0.30  | 0.767 | -.6465268            | .8767003 |
| yr1980 |             |           |       |       |                      |          |
| D1.    | .1093503    | .2766837  | 0.40  | 0.693 | -.4329398            | .6516404 |
| yr1981 |             |           |       |       |                      |          |
| D1.    | 0           | (omitted) |       |       |                      |          |
| yr1982 |             |           |       |       |                      |          |
| D1.    | 0           | (omitted) |       |       |                      |          |
| _cons  | .1190119    | .350733   | 0.34  | 0.734 | -.5684122            | .806436  |

Instrumented: D.nL1

Instruments: D.nL2 D.w D.wL1 D.k D.kL1 D.kL2 D.ys D.ysL1 D.ysL2 D.yr1978  
D.yr1979 D.yr1980 nL2

(d) Estimar la ecuación de empleo usando el estimador de Arellano-Bond. Asumir que la única endogeneidad presente es en el rezago de la variable dependiente.

### GMM One-Step (Arellano-Bond):

Dynamic panel-data estimation, one-step difference GMM

```
-----
Group variable: id                      Number of obs   =      414
Time variable : year                   Number of groups =      138
Number of instruments = 20              Obs per group: min =       3
Wald chi2(0) = .                        avg           =     3.00
Prob > chi2 = .                        max           =       3
-----
```

|        | n | Coefficient | Robust<br>std. err. | z     | P> z  | [95% conf. interval] |           |
|--------|---|-------------|---------------------|-------|-------|----------------------|-----------|
| -----  |   |             |                     |       |       |                      |           |
| n      |   |             |                     |       |       |                      |           |
| L1.    |   | .5325962    | .4060438            | 1.31  | 0.190 | -.2632351            | 1.328428  |
| L2.    |   | -.1678165   | .108895             | -1.54 | 0.123 | -.3812468            | .0456137  |
| -----  |   |             |                     |       |       |                      |           |
| w      |   |             |                     |       |       |                      |           |
| --.    |   | -.5435347   | .1878885            | -2.89 | 0.004 | -.9117894            | -.1752799 |
| L1.    |   | .0465042    | .2149028            | 0.22  | 0.829 | -.3746976            | .467706   |
| -----  |   |             |                     |       |       |                      |           |
| k      |   |             |                     |       |       |                      |           |
| --.    |   | .3597198    | .0798932            | 4.50  | 0.000 | .203132              | .5163076  |
| L1.    |   | -.0203542   | .1486021            | -0.14 | 0.891 | -.311609             | .2709006  |
| L2.    |   | .0531949    | .0564035            | 0.94  | 0.346 | -.0573539            | .1637438  |
| -----  |   |             |                     |       |       |                      |           |
| ys     |   |             |                     |       |       |                      |           |
| --.    |   | .6720783    | .1618321            | 4.15  | 0.000 | .3548932             | .9892634  |
| L1.    |   | -.3962257   | .2155005            | -1.84 | 0.066 | -.818599             | .0261475  |
| L2.    |   | -.061621    | .1883471            | -0.33 | 0.744 | -.4307746            | .3075325  |
| -----  |   |             |                     |       |       |                      |           |
| yr1979 |   | -.0019098   | .0289454            | -0.07 | 0.947 | -.0586417            | .0548221  |
| yr1980 |   | .0153498    | .0194               | 0.79  | 0.429 | -.0226734            | .0533731  |
| yr1982 |   | -.0047222   | .0199879            | -0.24 | 0.813 | -.0438977            | .0344534  |

Instruments for first differences equation

Standard

D.(w L.w k L.k L2.k ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981  
yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

```
-----
Arellano-Bond test for AR(1) in first differences: z = -0.93 Pr > z = 0.351
Arellano-Bond test for AR(2) in first differences: z = -1.57 Pr > z = 0.117
-----
```

Sargan test of overid. restrictions: chi2(7) = 18.99 Prob > chi2 = 0.008  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(7) = 12.33 Prob > chi2 = 0.090  
(Robust, but weakened by many instruments.)

**GMM Two-Step (Arellano-Bond):**

Dynamic panel-data estimation, two-step difference GMM

```

-----
Group variable: id                      Number of obs   =      414
Time variable : year                   Number of groups =      138
Number of instruments = 20              Obs per group: min =       3
Wald chi2(0)   =                      avg           =     3.00
Prob > chi2    =                      max           =       3
-----

```

|       | n      | Coefficient | Corrected<br>std. err. | z     | P> z  | [95% conf. interval] |           |
|-------|--------|-------------|------------------------|-------|-------|----------------------|-----------|
| ----- |        |             |                        |       |       |                      |           |
|       | n      |             |                        |       |       |                      |           |
|       | L1.    | .6080291    | .6739661               | 0.90  | 0.367 | -.7129203            | 1.928978  |
|       | L2.    | -.137942    | .1688863               | -0.82 | 0.414 | -.468953             | .1930691  |
| ----- |        |             |                        |       |       |                      |           |
|       | w      |             |                        |       |       |                      |           |
|       | --.    | -.4912924   | .2335444               | -2.10 | 0.035 | -.949031             | -.0335539 |
|       | L1.    | .1263267    | .2293468               | 0.55  | 0.582 | -.3231847            | .5758381  |
| ----- |        |             |                        |       |       |                      |           |
|       | k      |             |                        |       |       |                      |           |
|       | --.    | .2912765    | .0889614               | 3.27  | 0.001 | .1169154             | .4656376  |
|       | L1.    | -.0170639   | .219071                | -0.08 | 0.938 | -.4464351            | .4123073  |
|       | L2.    | .0263268    | .0736175               | 0.36  | 0.721 | -.1179608            | .1706145  |
| ----- |        |             |                        |       |       |                      |           |
|       | ys     |             |                        |       |       |                      |           |
|       | --.    | .5452599    | .1895989               | 2.88  | 0.004 | .1736528             | .916867   |
|       | L1.    | -.307353    | .2411337               | -1.27 | 0.202 | -.7799662            | .1652603  |
|       | L2.    | -.1253987   | .2036039               | -0.62 | 0.538 | -.524455             | .2736577  |
| ----- |        |             |                        |       |       |                      |           |
|       | yr1979 | .008789     | .0360821               | 0.24  | 0.808 | -.0619306            | .0795087  |
|       | yr1980 | .0244669    | .0224526               | 1.09  | 0.276 | -.0195394            | .0684731  |
|       | yr1982 | -.0189478   | .0283143               | -0.67 | 0.503 | -.0744428            | .0365472  |

Instruments for first differences equation

Standard

D. (w L.w k L.k L2.k ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981  
yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).L.n

```

-----
Arellano-Bond test for AR(1) in first differences: z =  -0.64  Pr > z =  0.523
Arellano-Bond test for AR(2) in first differences: z =  -1.41  Pr > z =  0.159
-----

```

Sargan test of overid. restrictions: chi2(7) = 18.99 Prob > chi2 = 0.008  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(7) = 12.33 Prob > chi2 = 0.090  
(Robust, but weakened by many instruments.)

**(e)** Ahora, considerar, como hicieron Blundell y Bond (1998), que los salarios y el stock de capital no deben tomarse como estrictamente exógenos en este contexto (como se hizo en los modelos anteriores). Reestimar el modelo usando el estimador de A-B y considerando a los salarios y al stock de capital como regresores secuencialmente exógenos.

### GMM One-Step (Arellano-Bond):

Dynamic panel-data estimation, one-step difference GMM

```
-----
Group variable: id                      Number of obs   =      414
Time variable : year                    Number of groups =      138
Number of instruments = 33              Obs per group: min =       3
Wald chi2(0)   =                      .                avg   =     3.00
Prob > chi2    =                      .                max   =       3
-----
```

|       | n      | Coefficient | Robust<br>std. err. | z     | P> z  | [95% conf. interval] |           |
|-------|--------|-------------|---------------------|-------|-------|----------------------|-----------|
| ----- |        |             |                     |       |       |                      |           |
|       | n      |             |                     |       |       |                      |           |
|       | L1.    | .8328315    | .1219725            | 6.83  | 0.000 | .5937698             | 1.071893  |
|       | L2.    | -.1640736   | .0770492            | -2.13 | 0.033 | -.3150873            | -.0130599 |
|       | w      |             |                     |       |       |                      |           |
|       | --.    | -.5056556   | .3148758            | -1.61 | 0.108 | -1.122801            | .1114896  |
|       | L1.    | .2750362    | .3347117            | 0.82  | 0.411 | -.3809867            | .931059   |
|       | k      |             |                     |       |       |                      |           |
|       | --.    | .3384097    | .1810356            | 1.87  | 0.062 | -.0164135            | .6932329  |
|       | L1.    | -.2157422   | .1197218            | -1.80 | 0.072 | -.4503925            | .0189082  |
|       | L2.    | -.0006972   | .0481602            | -0.01 | 0.988 | -.0950895            | .0936951  |
|       | ys     |             |                     |       |       |                      |           |
|       | --.    | .7245478    | .2528721            | 2.87  | 0.004 | .2289276             | 1.220168  |
|       | L1.    | -.5540143   | .4752081            | -1.17 | 0.244 | -1.485405            | .3773765  |
|       | L2.    | .0545983    | .2887007            | 0.19  | 0.850 | -.5112447            | .6204413  |
|       | yr1979 | -.0061002   | .0303218            | -0.20 | 0.841 | -.0655299            | .0533295  |
|       | yr1980 | .0188299    | .0214161            | 0.88  | 0.379 | -.0231449            | .0608046  |
|       | yr1982 | -.0067336   | .0217373            | -0.31 | 0.757 | -.049338             | .0358708  |
| ----- |        |             |                     |       |       |                      |           |

Instruments for first differences equation

Standard

D.(ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)

L(1/5).(L.n L.w L.k)

```
-----
Arellano-Bond test for AR(1) in first differences: z =  -3.83  Pr > z =  0.000
Arellano-Bond test for AR(2) in first differences: z =  -2.12  Pr > z =  0.034
-----
```

Sargan test of overid. restrictions: chi2(20) = 38.36 Prob > chi2 = 0.008  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(20) = 22.98 Prob > chi2 = 0.290  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

iv(ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

Hansen test excluding group: chi2(14) = 14.84 Prob > chi2 = 0.389

Difference (null H = exogenous): chi2(6) = 8.14 Prob > chi2 = 0.228

### GMM Two-Step (Arellano-Bond):

Dynamic panel-data estimation, two-step difference GMM

```
-----
Group variable: id                      Number of obs   =    414
Time variable : year                   Number of groups =    138
Number of instruments = 33              Obs per group: min =     3
Wald chi2(0)   =                      .                avg   =    3.00
Prob > chi2    =                      .                max   =     3
-----
```

|       | n      | Coefficient | Corrected<br>std. err. | z     | P> z  | [95% conf. interval] |          |
|-------|--------|-------------|------------------------|-------|-------|----------------------|----------|
| ----- |        |             |                        |       |       |                      |          |
|       | n      |             |                        |       |       |                      |          |
|       | L1.    | .9403457    | .1894156               | 4.96  | 0.000 | .5690979             | 1.311593 |
|       | L2.    | -.1526986   | .0928117               | -1.65 | 0.100 | -.3346062            | .029209  |
|       | w      |             |                        |       |       |                      |          |
|       | --.    | -.4490707   | .3993756               | -1.12 | 0.261 | -1.231833            | .3336911 |
|       | L1.    | .3385343    | .3136958               | 1.08  | 0.281 | -.2762982            | .9533668 |
|       | k      |             |                        |       |       |                      |          |
|       | --.    | .1701686    | .2126183               | 0.80  | 0.424 | -.2465556            | .5868928 |
|       | L1.    | -.2258957   | .1315513               | -1.72 | 0.086 | -.4837316            | .0319401 |
|       | L2.    | -.0419358   | .0564683               | -0.74 | 0.458 | -.1526117            | .0687401 |
|       | ys     |             |                        |       |       |                      |          |
|       | --.    | .689388     | .2434718               | 2.83  | 0.005 | .2121921             | 1.166584 |
|       | L1.    | -.5276126   | .4812107               | -1.10 | 0.273 | -1.470768            | .4155429 |
|       | L2.    | .1320996    | .2419835               | 0.55  | 0.585 | -.3421794            | .6063786 |
|       | yr1979 | .0193174    | .0342941               | 0.56  | 0.573 | -.0478977            | .0865326 |
|       | yr1980 | .0379698    | .0228282               | 1.66  | 0.096 | -.0067727            | .0827124 |
|       | yr1982 | -.0206929   | .0242533               | -0.85 | 0.394 | -.0682285            | .0268427 |
| ----- |        |             |                        |       |       |                      |          |

Instruments for first differences equation

Standard

D.(ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

GMM-type (missing=0, separate instruments for each period unless collapsed)

L(1/5).(L.n L.w L.k)

```
-----
Arellano-Bond test for AR(1) in first differences: z = -2.47 Pr > z = 0.014
Arellano-Bond test for AR(2) in first differences: z = -1.74 Pr > z = 0.081
-----
```

Sargan test of overid. restrictions: chi2(20) = 38.36 Prob > chi2 = 0.008  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(20) = 22.98 Prob > chi2 = 0.290  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

iv(ys L.ys L2.ys yr1977 yr1978 yr1979 yr1980 yr1981 yr1982)

Hansen test excluding group: chi2(14) = 14.84 Prob > chi2 = 0.389

Difference (null H = exogenous): chi2(6) = 8.14 Prob > chi2 = 0.228

**(f)** Adicionalmente, *Blundell y Bond (1998)* eliminan de su modelo los rezagos más largos (de dos periodos) del empleo y el capital y prescinden del nivel de producto agregado sectorial. Considerando esta cuestión, computar el estimador de *Blundell-Bond*.

### SGMM One-Step (Blundell-Bond):

Dynamic panel-data estimation, one-step system GMM

```
-----
Group variable: id                      Number of obs   =      690
Time variable : year                    Number of groups =      138
Number of instruments = 47              Obs per group: min =       5
Wald chi2(9)  =   37427.45              avg          =    5.00
Prob > chi2    =       0.000              max          =       5
-----
```

|       | n      | Coefficient | Robust<br>std. err. | z     | P> z  | [95% conf. interval] |           |
|-------|--------|-------------|---------------------|-------|-------|----------------------|-----------|
| ----- |        |             |                     |       |       |                      |           |
|       | n      |             |                     |       |       |                      |           |
|       | L1.    | .9025721    | .0412484            | 21.88 | 0.000 | .8217267             | .9834175  |
|       | w      |             |                     |       |       |                      |           |
|       | --.    | -.5397871   | .1984403            | -2.72 | 0.007 | -.928723             | -.1508513 |
|       | L1.    | .3047706    | .1800251            | 1.69  | 0.090 | -.0480722            | .6576134  |
|       | k      |             |                     |       |       |                      |           |
|       | --.    | .4734141    | .0900715            | 5.26  | 0.000 | .2968772             | .6499511  |
|       | L1.    | -.3942878   | .086912             | -4.54 | 0.000 | -.5646322            | -.2239433 |
|       | yr1978 | .0347845    | .0217776            | 1.60  | 0.110 | -.0078988            | .0774678  |
|       | yr1979 | .044848     | .0173516            | 2.58  | 0.010 | .0108395             | .0788565  |
|       | yr1980 | .0291248    | .0171671            | 1.70  | 0.090 | -.004522             | .0627716  |
|       | yr1982 | .0333513    | .0144621            | 2.31  | 0.021 | .0050062             | .0616964  |
|       | _cons  | .8194633    | .3304982            | 2.48  | 0.013 | .1716988             | 1.467228  |
| ----- |        |             |                     |       |       |                      |           |

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).(L.n L.w L.k)

Instruments for levels equation

Standard

yr1977 yr1978 yr1979 yr1980 yr1981 yr1982

\_cons

GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.(L.n L.w L.k)

Arellano-Bond test for AR(1) in first differences: z = -4.61 Pr > z = 0.000

Arellano-Bond test for AR(2) in first differences: z = -1.18 Pr > z = 0.238

Sargan test of overid. restrictions: chi2(37) = 86.05 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(37) = 52.82 Prob > chi2 = 0.044  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

GMM instruments for levels

Hansen test excluding group: chi2(25) = 35.67 Prob > chi2 = 0.077

Difference (null H = exogenous): chi2(12) = 17.15 Prob > chi2 = 0.144

iv(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982, eq(level))

Hansen test excluding group: chi2(33) = 44.68 Prob > chi2 = 0.084

Difference (null H = exogenous): chi2(4) = 8.14 Prob > chi2 = 0.087

# SGMM Two-Step (Blundell-Bond):

Dynamic panel-data estimation, two-step system GMM

```
-----
Group variable: id                      Number of obs   =      690
Time variable : year                    Number of groups =      138
Number of instruments = 47              Obs per group: min =       5
Wald chi2(9)  = 30749.14                avg          =    5.00
Prob > chi2   = 0.000                    max          =       5
-----
```

|       | n      | Coefficient | Corrected<br>std. err. | z     | P> z  | [95% conf. interval] |           |
|-------|--------|-------------|------------------------|-------|-------|----------------------|-----------|
| ----- |        |             |                        |       |       |                      |           |
|       | n      |             |                        |       |       |                      |           |
|       | L1.    | .892057     | .0524149               | 17.02 | 0.000 | .7893258             | .9947883  |
|       | w      |             |                        |       |       |                      |           |
|       | --.    | -.4138471   | .2405795               | -1.72 | 0.085 | -.8853744            | .0576801  |
|       | L1.    | .23221      | .1663529               | 1.40  | 0.163 | -.0938358            | .5582558  |
|       | k      |             |                        |       |       |                      |           |
|       | --.    | .4563271    | .1222931               | 3.73  | 0.000 | .2166371             | .6960171  |
|       | L1.    | -.3582417   | .1210988               | -2.96 | 0.003 | -.595591             | -.1208924 |
|       |        |             |                        |       |       |                      |           |
|       | yr1978 | .0405244    | .0265643               | 1.53  | 0.127 | -.0115406            | .0925895  |
|       | yr1979 | .0513874    | .0198615               | 2.59  | 0.010 | .0124596             | .0903151  |
|       | yr1980 | .0296077    | .0200915               | 1.47  | 0.141 | -.0097708            | .0689863  |
|       | yr1982 | .0290802    | .014089                | 2.06  | 0.039 | .0014662             | .0566942  |
|       | cons   | .6712912    | .3744471               | 1.79  | 0.073 | -.0626117            | 1.405194  |

Instruments for first differences equation

GMM-type (missing=0, separate instruments for each period unless collapsed)  
L(1/5).(L.n L.w L.k)

Instruments for levels equation

Standard

yr1977 yr1978 yr1979 yr1980 yr1981 yr1982

\_cons

GMM-type (missing=0, separate instruments for each period unless collapsed)  
D.(L.n L.w L.k)

Arellano-Bond test for AR(1) in first differences: z = -4.46 Pr > z = 0.000

Arellano-Bond test for AR(2) in first differences: z = -1.27 Pr > z = 0.203

Sargan test of overid. restrictions: chi2(37) = 86.05 Prob > chi2 = 0.000  
(Not robust, but not weakened by many instruments.)

Hansen test of overid. restrictions: chi2(37) = 52.82 Prob > chi2 = 0.044  
(Robust, but weakened by many instruments.)

Difference-in-Hansen tests of exogeneity of instrument subsets:

GMM instruments for levels

Hansen test excluding group: chi2(25) = 35.67 Prob > chi2 = 0.077

Difference (null H = exogenous): chi2(12) = 17.15 Prob > chi2 = 0.144

iv(yr1977 yr1978 yr1979 yr1980 yr1981 yr1982, eq(level))

Hansen test excluding group: chi2(33) = 44.68 Prob > chi2 = 0.084

Difference (null H = exogenous): chi2(4) = 8.14 Prob > chi2 = 0.087

### Ejercicio 3.

Cuando hay muchos instrumentos, surgen dos problemas principales:

- Sobreestimación (overfitting) de la variable endógena.
- Mala estimación de la matriz de pesos  $W$ .

En estos casos, se proponen las siguientes soluciones:

- Probar diferentes especificaciones de IV recortando el número de rezagos en la matriz de instrumentos  $Z$ .
- Colapsar/combinar instrumentos. Se modifica la matriz de instrumentos para el individuo  $i$ :

$$Z_i = \begin{bmatrix} y_{i1} & 0 & 0 & \dots \\ y_{i1} & y_{i2} & 0 & \dots \\ y_{i3} & y_{i2} & y_{i1} & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Si el modelo funciona, debería dar resultados similares con distintos instrumentos. Retomar el Ejercicio 2.e para ver una aplicación de esta cuestión. Estimar el modelo de empleo restringiendo el máximo rezago a 3 y 4 períodos. Por último, estimar el modelo colapsando instrumentos. Analizar si los resultados obtenidos son robustos.

#### Tabla comparativa:

|     | (1)<br>GMM (OS) 2   | (2)<br>GMM (TS) 2   | (3)<br>GMM (OS) 3   | (4)<br>GMM (TS) 3   | (5)<br>GMM (OS) 4   | (6)<br>GMM (TS) 4   | (7)<br>GMM (OS) 5   | (8)<br>GMM (TS) 5 |
|-----|---------------------|---------------------|---------------------|---------------------|---------------------|---------------------|---------------------|-------------------|
| nL1 | 0.833***<br>(0.122) | 0.940***<br>(0.189) | 0.949***<br>(0.182) | 0.900***<br>(0.226) | 0.847***<br>(0.121) | 0.930***<br>(0.174) | 1.108***<br>(0.387) | 0.877*<br>(0.455) |
| N   | 414                 | 414                 | 414                 | 414                 | 414                 | 414                 | 414                 | 414               |

Standard errors in parentheses  
\* p<0.10, \*\* p<0.05, \*\*\* p<0.01



## Ejercicio 4.

Considerar, nuevamente, el modelo del primer ejercicio. Obtener el estimador LSDVC propuesto por Kiviet (1995) a partir del comando `xtlsdvc`. Luego, estimar la matriz de varianzas y covarianzas de los coeficientes de Kiviet siguiendo el procedimiento explicado en clase.

### LSDVC (Kiviet):

LSDVC dynamic regression  
(SE not computed)

| n   | Coefficient | Std. err. | z | P> z | [95% conf. interval] |
|-----|-------------|-----------|---|------|----------------------|
| n   |             |           |   |      |                      |
| L1. | .9890308    | .         | . | .    | .                    |

### LSDVC (Kiviet):

LSDVC dynamic regression  
(SE not computed)

| n      | Coefficient | Std. err. | z | P> z | [95% conf. interval] |
|--------|-------------|-----------|---|------|----------------------|
| n      |             |           |   |      |                      |
| L1.    | .7863675    | .         | . | .    | .                    |
| yr1978 | .1430045    | .         | . | .    | .                    |
| yr1979 | .1365801    | .         | . | .    | .                    |
| yr1980 | .0957011    | .         | . | .    | .                    |
| yr1981 | .0105706    | .         | . | .    | .                    |

UNIVERSIDAD TORCUATO DI TELLA  
MAESTRÍA EN ECONOMÍA Y ECONOMETRÍA  
2022

---

**Datos de Panel**  
**Problem Set 4**  
**Modelos Lineales en Paneles Desbalanceados**

---

1. Utilice la base de datos “*keane.dta*” la cual contiene el historial de empleo y escolaridad de una muestra de hombres para los años 1981 a 1987. Luego, considere la siguiente ecuación de salarios:

$$\ln(wage_{it}) = \beta_0 + \beta_1 exper_{it} + \beta_2 educ_{it} + c_i + u_{it}, \quad t = 1, 2, \dots, T \quad (1)$$

donde  $\ln(wage_{it})$  es el logaritmo del salario por hora,  $exper_{it}$  son los años de experiencia en el mercado laboral y  $educ_{it}$  son los años de escolaridad. Responda las siguientes preguntas:

- a) Estime la ecuación usando efectos fijos. ¿Cuál es el sesgo potencial en este contexto?
  - b) Implemente el contraste de sesgo de selección propuesto por Wooldridge (1995) bajo el enfoque de Mundlak (1978).
  - c) Implemente el contraste de sesgo de selección propuesto por Wooldridge (1995) bajo el enfoque de Chamberlain (1980).
2. Considerando nuevamente la ecuación de salarios del ejercicio previo, realice los siguientes procedimientos:
  - a) Estime el modelo por Wooldridge (1995) bajo el enfoque de Chamberlain (1980).
  - b) Estime el modelo por Wooldridge (1995) bajo el enfoque de Mundlak (1978).
  - c) Comente sobre los errores estándar de las estimaciones anteriores.
  - d) Estime los errores estándar vía bootstrapping.
  - e) Estime los errores estándar analíticos (varianza asintótica).

## **Trabajo Práctico N° 4:** **Modelos Lineales en Paneles Desbalanceados.**

### **Ejercicio 1.**

Utilizar la base de datos “keane.dta”, la cual contiene el historial de empleo y escolaridad de una muestra de hombres para los años 1981 a 1987. Luego, considerar la siguiente ecuación de salarios:

$$\ln(\text{wage}_{it}) = \beta_0 + \beta_1 \text{exper}_{it} + \beta_2 \text{educ}_{it} + c_i + u_{it}, t = 1, 2, \dots, T, \quad (1)$$

donde  $\ln(\text{wage}_{it})$  es el logaritmo del salario por hora,  $\text{exper}_{it}$  son los años de experiencia en el mercado laboral y  $\text{educ}_{it}$  son los años de escolaridad. Responder las siguientes preguntas:

(a) Estimar la ecuación usando efectos fijos. ¿Cuál es el sesgo potencial en este contexto?

FE:

```
Fixed-effects (within) regression      Number of obs   =      5,837
Group variable: id                   Number of groups =      1,531

R-squared:                           Obs per group:
    Within = 0.2373                     min =          1
    Between = 0.1857                   avg =          3.8
    Overall = 0.1767                   max =          7

corr(u_i, Xb) = -0.3197                F(2,4304)       =      669.73
                                      Prob > F          =      0.0000
```

```
-----+-----
      lwage | Coefficient  Std. err.      t    P>|t|    [95% conf. interval]
-----+-----
      exper |   .0964067   .0027721    34.78  0.000   .0909721   .1018414
       educ |   .1697764   .0243797     6.96  0.000   .1219795   .2175732
       _cons |   7.270616   .295975    24.56  0.000   6.690352   7.850879
-----+-----
      sigma_u |   .45083563
      sigma_e |   .31573611
       rho    |   .67092951   (fraction of variance due to u_i)
-----+-----
F test that all u_i=0: F(1530, 4304) = 5.46                Prob > F = 0.0000
```

En este contexto de efectos fijos, la selección muestral por truncamiento incidental es un problema si la selección está relacionada con los errores idiosincráticos de la ecuación de interés. Por lo tanto, si se piensa que, efectivamente, lo anterior se cumple y que se están observando los salarios “más altos” (los mejores salarios que se ofrecieron), entonces, el truncamiento tendría como consecuencia una sobreestimación de los retornos a la educación.

(b) Implementar el contraste de sesgo de selección propuesto por Wooldridge (1995) bajo el enfoque de Mundlak (1978).

Se rechaza la hipótesis nula, por lo que existe evidencia suficiente de que hay sesgo de selección.

*(c) Implementar el contraste de sesgo de selección propuesto por Wooldridge (1995) bajo el enfoque de Chamberlain (1980).*

Se rechaza la hipótesis nula, por lo que existe evidencia suficiente de que hay sesgo de selección.

**Ejercicio 2.**

Considerando, nuevamente, la ecuación de salarios del ejercicio previo, realizar los siguientes procedimientos:

(a) Estimar el modelo por Wooldridge (1995) bajo el enfoque de Chamberlain (1980).

**POLS (Chamberlain):**

|          |            |       |            |               |   |        |
|----------|------------|-------|------------|---------------|---|--------|
| Source   | SS         | df    | MS         | Number of obs | = | 5,837  |
|          |            |       |            | F(15, 5821)   | = | 111.85 |
| Model    | 357.875358 | 15    | 23.8583572 | Prob > F      | = | 0.0000 |
| Residual | 1241.62941 | 5,821 | .213301737 | R-squared     | = | 0.2237 |
|          |            |       |            | Adj R-squared | = | 0.2217 |
| Total    | 1599.50477 | 5,836 | .274075526 | Root MSE      | = | .46185 |

  

| lwage                      | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |           |
|----------------------------|-------------|-----------|-------|-------|----------------------|-----------|
| exper                      | .0566567    | .0130844  | 4.33  | 0.000 | .0310064             | .0823071  |
| educ                       | .101945     | .0187839  | 5.43  | 0.000 | .0651215             | .1387684  |
| exper81                    | .1106423    | .0330149  | 3.35  | 0.001 | .0459208             | .1753637  |
| educ81                     | .0986618    | .0204867  | 4.82  | 0.000 | .0585003             | .1388233  |
| exper82                    | -.0102639   | .0284707  | -0.36 | 0.718 | -.0660771            | .0455492  |
| educ82                     | -.2174353   | .0366788  | -5.93 | 0.000 | -.2893393            | -.1455313 |
| exper83                    | -.0704014   | .0284495  | -2.47 | 0.013 | -.1261731            | -.0146298 |
| educ83                     | .0856036    | .0363551  | 2.35  | 0.019 | .0143341             | .1568731  |
| year#c.lambdac_chamberlain |             |           |       |       |                      |           |
| 81                         | -.2683315   | .0873923  | -3.07 | 0.002 | -.4396528            | -.0970101 |
| 82                         | -.3211014   | .0890068  | -3.61 | 0.000 | -.4955878            | -.1466151 |
| 83                         | -.3500805   | .0833289  | -4.20 | 0.000 | -.5134361            | -.1867249 |
| 84                         | -.3390861   | .0853207  | -3.97 | 0.000 | -.5063464            | -.1718258 |
| 85                         | -.3585597   | .0887959  | -4.04 | 0.000 | -.5326328            | -.1844867 |
| 86                         | -.3195615   | .09277    | -3.44 | 0.001 | -.5014252            | -.1376977 |
| 87                         | -.3590845   | .0978012  | -3.67 | 0.000 | -.5508112            | -.1673579 |
| _cons                      | 8.87783     | .1514153  | 58.63 | 0.000 | 8.580999             | 9.17466   |

(b) Estimar el modelo por Wooldridge (1995) bajo el enfoque de Mundlak (1978).

POLS (Mundlak):

|          |            |       |            |               |   |        |
|----------|------------|-------|------------|---------------|---|--------|
| Source   | SS         | df    | MS         | Number of obs | = | 5,837  |
| Model    | 354.236597 | 11    | 32.203327  | F(11, 5825)   | = | 150.64 |
| Residual | 1245.26817 | 5,825 | .213779943 | Prob > F      | = | 0.0000 |
|          |            |       |            | R-squared     | = | 0.2215 |
|          |            |       |            | Adj R-squared | = | 0.2200 |
| Total    | 1599.50477 | 5,836 | .274075526 | Root MSE      | = | .46236 |

  

| lwage                 | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |           |
|-----------------------|-------------|-----------|-------|-------|----------------------|-----------|
| exper                 | .0678465    | .007649   | 8.87  | 0.000 | .0528517             | .0828413  |
| educ                  | .0881093    | .0296264  | 2.97  | 0.003 | .0300305             | .146188   |
| mean_exper            | -.0275146   | .0156551  | -1.76 | 0.079 | -.0582044            | .0031753  |
| mean_educ             | -.0167755   | .0291599  | -0.58 | 0.565 | -.0739398            | .0403887  |
|                       |             |           |       |       |                      |           |
| year#c.lambda_mundlak |             |           |       |       |                      |           |
| 81                    | -.2756566   | .0778676  | -3.54 | 0.000 | -.4283059            | -.1230073 |
| 82                    | -.3239156   | .0765798  | -4.23 | 0.000 | -.4740404            | -.1737908 |
| 83                    | -.3637717   | .0737034  | -4.94 | 0.000 | -.5082579            | -.2192856 |
| 84                    | -.3154769   | .0727725  | -4.34 | 0.000 | -.4581381            | -.1728158 |
| 85                    | -.3101603   | .073666   | -4.21 | 0.000 | -.454573             | -.1657477 |
| 86                    | -.2515261   | .074834   | -3.36 | 0.001 | -.3982286            | -.1048236 |
| 87                    | -.2525642   | .0770484  | -3.28 | 0.001 | -.4036077            | -.1015207 |
|                       |             |           |       |       |                      |           |
| _cons                 | 8.781247    | .1284501  | 68.36 | 0.000 | 8.529437             | 9.033056  |

(c) *Comentar sobre los errores estándar de las estimaciones anteriores.*

La varianza asintótica de los estimadores de la segunda etapa necesita ser corregida por heterocedasticidad y correlación serial arbitraria, así como, además, por la estimación de la primera etapa.

(d) *Estimar los errores estándar vía bootstrapping.*

Stata.

(e) *Estimar los errores estándar analíticos (varianza asintótica).*

Stata.

**Datos de Panel**  
**Problem Set 5**  
**Modelos de Variable Dependiente Discreta**

---

1. El archivo *wagepan.dta* contiene los datos utilizados por Vella y Verbeek (1998). Estos datos contienen información para 545 hombres que trabajaron cada año de 1980 a 1987. Utilice los datos para analizar el impacto de la escolaridad ( $educ_{it}$ ) en la probabilidad de estar afiliado a un sindicato ( $union_{it}$ ). Las variables se describen en el conjunto de datos. Observe que la educación no cambia con el tiempo.

- a) Use Pooled OLS para estimar el modelo:

$$P(union_{it} = 1 | educ_{it}) = \beta_0 + \beta_1 educ_{it} \quad (1)$$

De acuerdo a los resultados obtenidos, ¿tiene impacto un año más de escolaridad sobre la probabilidad de estar afiliado a un sindicato?

- b) Use Pooled Probit para estimar el modelo:

$$P(union_{it} = 1 | educ_{it}) = \Phi(\beta_0 + \beta_1 educ_{it}) \quad (2)$$

Comente sobre el impacto de un año más de educación en la probabilidad de estar afiliado a un sindicato.

- c) Use Pooled Logit para estimar el modelo:

$$P(union_{it} = 1 | educ_{it}) = \Lambda(\beta_0 + \beta_1 educ_{it}) = \frac{e^{\beta_0 + \beta_1 educ_{it}}}{1 + e^{\beta_0 + \beta_1 educ_{it}}} \quad (3)$$

Comente sobre el impacto de un año más de educación en la probabilidad de estar afiliado a un sindicato. Compute el error estándar para esta estimación.

- d) Estime la siguiente extensión del modelo (2):

$$P(union_{it} = 1 | educ_{it}, c_i) = \Phi(\beta_0 + \beta_1 educ_{it} + c_i) \quad (4)$$

donde  $c_i$  son efectos no observables individuales. Use el modelo Probit de efectos aleatorios. ¿Cuál es el problema que surge al momento de estimar el efecto parcial de interés?

- e) Estime la siguiente extensión del modelo (3):

$$P(union_{it} = 1 | educ_{it}, c_i) = \Lambda(\beta_0 + \beta_1 educ_{it} + c_i) \quad (5)$$

donde  $c_i$  son efectos no observables individuales. Use el modelo Logit de efectos aleatorios. ¿Surge el mismo problema que en el inciso anterior al momento de estimar el efecto parcial de interés?

- f) Compute el denominado estimador Logit de efectos fijos para el modelo (5). ¿Se puede computar el efecto de un año más de educación sobre la probabilidad de estar afiliado a un sindicato? Explique.
- g) Considere la siguiente extensión del modelo (4):

$$P(\text{union}_{it} = 1 \mid \text{educ}_{it}, \text{black}_{it}, \text{married}_{it}, c_i) = \Phi(\beta_0 + \beta_1 \text{educ}_{it} + \beta_2 \text{black}_{it} + \beta_3 \text{married}_{it} + c_i) \quad (6)$$

donde  $\text{black}_{it}$  es una variable binaria que toma valor 1 si la persona es afroamericana y  $\text{married}_{it}$  es una variable binaria que toma valor 1 si la persona es casada. Asuma la siguiente versión de Mundlak (1978) del supuesto de Chamberlain (1980):

$$c_i \mid X_i \sim \text{Normal}(\psi + \xi \cdot \overline{\text{married}_i}, \sigma_a^2) \quad (7)$$

El modelo dado por (6) y (7) es un caso de lo que en la literatura se denomina modelo Probit de efectos aleatorios de Chamberlain. Al asumir solamente (6) y (7) se tiene que:

$$\begin{aligned} P(\text{union}_{it} = 1 \mid \text{educ}_{it}, \text{black}_{it}, \text{married}_{it}) &= \\ \Phi \left[ (\beta_0 + \beta_1 \text{educ}_{it} + \beta_2 \text{black}_{it} + \beta_3 \text{married}_{it} + \psi + \xi \overline{\text{married}_i}) (1 + \sigma_a^2)^{-1/2} \right] &\equiv \\ \Phi [\beta_{0,a} + \beta_{1,a} \text{educ}_{it} + \beta_{2,a} \text{black}_{it} + \beta_{3,a} \text{married}_{it} + \xi_a \overline{\text{married}_i}] & \end{aligned}$$

Use Pooled Probit para estimar el modelo. Estime el efecto de la escolaridad sobre la probabilidad de estar sindicalizado para una persona afroamericana casada.

2. Considere los datos del ejercicio previo para analizar la probabilidad de estar afiliado a un sindicato según la situación de afiliación sindical del año previo.

- a) Use Pooled Probit para estimar el modelo:

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1}) = \Phi(\psi + \rho \cdot \text{union}_{it-1}) \quad (8)$$

A continuación, obtenga una estimación para

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1} = 1)$$

y para

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1} = 0).$$

. Comente sobre el efecto marginal de estar afiliado a un sindicato en el año  $t - 1$  en la probabilidad de estar afiliado a un sindicato en el año  $t$ .

- b) Adicione al modelo el conjunto completo de variables binarias temporales. Vuelva a estimar las probabilidades solicitadas para cada año de la muestra.
- c) Estime un modelo de efectos no observables dinámico. Use el modelo Probit de efectos aleatorios incluyendo  $\text{union}_{i,80}$  como una variable explicativa adicional. Luego, promedie las probabilidades estimadas a lo largo de  $\text{union}_{i,80}$  para obtener la probabilidad promedio de estar afiliado a un sindicato en el año 1987 dado que estaba afiliado en el período anterior.



## **Trabajo Práctico N° 5:** **Modelos de Variable Dependiente Discreta.**

### **Ejercicio 1.**

El archivo “wagepan.dta” contiene los datos utilizados por Vella y Verbeek (1998). Estos datos contienen información para 545 hombres que trabajaron cada año de 1980 a 1987. Utilizar los datos para analizar el impacto de la escolaridad ( $educ_{it}$ ) en la probabilidad de estar afiliado a un sindicato ( $union_{it}$ ). Las variables se describen en el conjunto de datos. Observar que la educación no cambia con el tiempo.

(a) Usar Pooled OLS para estimar el modelo:

$$P(union_{it} = 1 | educ_{it}) = \beta_0 + \beta_1 educ_{it} \quad (1)$$

De acuerdo a los resultados obtenidos, ¿tiene impacto un año más de escolaridad sobre la probabilidad de estar afiliado a un sindicato?

POLS:

| Source   | SS         | df    | MS         | Number of obs | = | 4,360   |
|----------|------------|-------|------------|---------------|---|---------|
| Model    | .030271965 | 1     | .030271965 | F(1, 4358)    | = | 0.16    |
| Residual | 804.314682 | 4,358 | .184560505 | Prob > F      | = | 0.6855  |
| Total    | 804.344954 | 4,359 | .18452511  | R-squared     | = | 0.0000  |
|          |            |       |            | Adj R-squared | = | -0.0002 |
|          |            |       |            | Root MSE      | = | .42961  |

  

| union | Coefficient | Std. err. | t     | P> t  | [95% conf. interval] |          |
|-------|-------------|-----------|-------|-------|----------------------|----------|
| educ  | -.0015092   | .0037264  | -0.40 | 0.686 | -.0088148            | .0057964 |
| _cons | .261795     | .0443282  | 5.91  | 0.000 | .1748892             | .3487009 |

Por lo tanto, se puede observar que un año más de escolaridad no tiene impacto sobre la probabilidad de estar afiliado a un sindicato, ya que la variable *educ* no es estadísticamente significativa.

(b) Usar Pooled Probit para estimar el modelo:

$$P(union_{it} = 1 | educ_{it}) = \Phi(\beta_0 + \beta_1 educ_{it}) \quad (2)$$

Comentar sobre el impacto de un año más de educación en la probabilidad de estar afiliado a un sindicato.

### Pooled Probit:

Probit regression  
Log likelihood = -2422.7142

Number of obs = 4,360  
LR chi2(1) = 0.17  
Prob > chi2 = 0.6758  
Pseudo R2 = 0.0000

|  | union | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |           |
|--|-------|-------------|-----------|-------|-------|----------------------|-----------|
|  | educ  | -.0051242   | .0122467  | -0.42 | 0.676 | -.0291273            | .0188789  |
|  | _cons | -.6331107   | .1454783  | -4.35 | 0.000 | -.9182429            | -.3479784 |

### Efectos marginales (promedio) en Pooled Probit:

Average marginal effects  
Model VCE: OIM

Number of obs = 4,360

Expression: Pr(union), predict()  
dy/dx wrt: educ

|  |      | Delta-method |           |       |       | [95% conf. interval] |          |
|--|------|--------------|-----------|-------|-------|----------------------|----------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |          |
|  | educ | -.0016074    | .0038414  | -0.42 | 0.676 | -.0091364            | .0059216 |

### Efectos marginales (condicionales) en Pooled Probit:

Conditional marginal effects  
Model VCE: OIM

Number of obs = 4,360

Expression: Pr(union), predict()  
dy/dx wrt: educ  
At: educ = 11.76697 (mean)

|  |      | Delta-method |           |       |       | [95% conf. interval] |         |
|--|------|--------------|-----------|-------|-------|----------------------|---------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |         |
|  | educ | -.0016074    | .0038416  | -0.42 | 0.676 | -.0091369            | .005922 |

Por lo tanto, se puede observar que un año más de escolaridad no tiene impacto sobre la probabilidad de estar afiliado a un sindicato, ya que la variable *educ* no es estadísticamente significativa.

### **(c) Usar Pooled Logit para estimar el modelo:**

$$P(\text{union}_{it} = 1 \mid \text{educ}_{it}) = \Lambda(\beta_0 + \beta_1 \text{educ}_{it}) = \frac{e^{\beta_0 + \beta_1 \text{educ}_{it}}}{1 + e^{\beta_0 + \beta_1 \text{educ}_{it}}} \quad (3)$$

Comentar sobre el impacto de un año más de educación en la probabilidad de estar afiliado a un sindicato. Compute el error estándar para esta estimación.

### Pooled Logit:

Logistic regression  
Log likelihood = -2422.7197

Number of obs = 4,360  
LR chi2(1) = 0.16  
Prob > chi2 = 0.6857  
Pseudo R2 = 0.0000

|  | union | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |           |
|--|-------|-------------|-----------|-------|-------|----------------------|-----------|
|  | educ  | -.0081586   | .0201411  | -0.41 | 0.685 | -.0476344            | .0313172  |
|  | _cons | -1.034725   | .2393549  | -4.32 | 0.000 | -1.503852            | -.5655975 |

### Efectos marginales (promedio) en Pooled Logit:

Average marginal effects  
Model VCE: OIM

Number of obs = 4,360

Expression: Pr(union), predict()  
dy/dx wrt: educ

|  |      | Delta-method |           |       |       | [95% conf. interval] |          |
|--|------|--------------|-----------|-------|-------|----------------------|----------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |          |
|  | educ | -.0015051    | .0037154  | -0.41 | 0.685 | -.008787             | .0057769 |

### Efectos marginales (condicionales) en Pooled Logit:

Conditional marginal effects  
Model VCE: OIM

Number of obs = 4,360

Expression: Pr(union), predict()  
dy/dx wrt: educ  
At: educ = 11.76697 (mean)

|  |      | Delta-method |           |       |       | [95% conf. interval] |          |
|--|------|--------------|-----------|-------|-------|----------------------|----------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |          |
|  | educ | -.0015051    | .0037155  | -0.41 | 0.685 | -.0087873            | .0057771 |

Por lo tanto, se puede observar que un año más de escolaridad no tiene impacto sobre la probabilidad de estar afiliado a un sindicato, ya que la variable *educ* no es estadísticamente significativa.

(d) Estimar la siguiente extensión del modelo (2):

$$P(\text{union}_{it} = 1 \mid \text{educ}_{it}, c_i) = \Phi(\beta_0 + \beta_1 \text{educ}_{it} + c_i), \quad (4)$$

donde  $c_i$  son efectos no observables individuales. Usar el modelo Probit de efectos aleatorios. ¿Cuál es el problema que surge al momento de estimar el efecto parcial de interés?

### RE Probit:

```
Random-effects probit regression
Group variable: nr

Random effects u_i ~ Gaussian

Integration method: mvaghermite

Log likelihood = -1672.7504

Number of obs   = 4,360
Number of groups = 545

Obs per group:
    min = 8
    avg = 8.0
    max = 8

Integration pts. = 12

Wald chi2(1) = 1.04
Prob > chi2 = 0.3080
```

|  | union    | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |          |
|--|----------|-------------|-----------|-------|-------|----------------------|----------|
|  | educ     | -.0502723   | .0493148  | -1.02 | 0.308 | -.1469276            | .0463829 |
|  | _cons    | -.8013208   | .5835448  | -1.37 | 0.170 | -1.945048            | .342406  |
|  | /lnsig2u | 1.099022    | .1137102  |       |       | .8761544             | 1.32189  |
|  | sigma_u  | 1.732406    | .0984961  |       |       | 1.549725             | 1.936622 |
|  | rho      | .7500768    | .0213163  |       |       | .7060247             | .789496  |

LR test of rho=0: chibar2(01) = 1499.93      Prob >= chibar2 = 0.000

### Efectos marginales (promedio) en RE Probit:

```
Average marginal effects
Model VCE: OIM

Expression: Pr(union=1 | u_i=0), predict(pu0)
dy/dx wrt: educ

Number of obs = 4,360
```

|  |      | Delta-method |           |       |       | [95% conf. interval] |         |
|--|------|--------------|-----------|-------|-------|----------------------|---------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |         |
|  | educ | -.0076285    | .0075519  | -1.01 | 0.312 | -.02243              | .007173 |

### Efectos marginales (condicionales) en RE Probit:

```
Conditional marginal effects
Model VCE: OIM

Expression: Pr(union=1 | u_i=0), predict(pu0)
dy/dx wrt: educ
At: educ = 11.76697 (mean)

Number of obs = 4,360
```

|  |      | Delta-method |           |       |       | [95% conf. interval] |          |
|--|------|--------------|-----------|-------|-------|----------------------|----------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |          |
|  | educ | -.0076024    | .0074781  | -1.02 | 0.309 | -.0222592            | .0070543 |

El problema que surge al momento de estimar el efecto parcial de interés es que éste depende de  $c_i$ , el cual no es estimado, por lo que no es posible estimar la magnitud del efecto parcial, a menos que se imponga el valor de  $c_i$ . Este valor impuesto puede ser  $c_i =$

0, lo cual tiene sentido ya que se está asumiendo que la distribución de  $c_i$  es  $c_i | X_i \sim \text{Normal}(0, \sigma_c^2)$ .

(e) Estimar la siguiente extensión del modelo (3):

$$P(\text{union}_{it} = 1 | \text{educ}_{it}, c_i) = \Lambda(\beta_0 + \beta_1 \text{educ}_{it} + c_i), \quad (5)$$

donde  $c_i$  son efectos no observables individuales. Usar el modelo Logit de efectos aleatorios. ¿Surge el mismo problema que en el inciso anterior al momento de estimar el efecto parcial de interés?

### RE Logit:

```
Random-effects logistic regression      Number of obs   = 4,360
Group variable: nr                    Number of groups = 545

Random effects u_i ~ Gaussian          Obs per group:
                                     min = 8
                                     avg = 8.0
                                     max = 8

Integration method: mvaghermite        Integration pts. = 12

Wald chi2(1) = 0.98
Prob > chi2 = 0.3227

Log likelihood = -1670.7204
```

|  | union    | Coefficient | Std. err. | z     | P> z  | [95% conf. interval] |          |
|--|----------|-------------|-----------|-------|-------|----------------------|----------|
|  | educ     | -.0831898   | .0841158  | -0.99 | 0.323 | -.2480538            | .0816742 |
|  | _cons    | -1.497913   | .9974077  | -1.50 | 0.133 | -3.452797            | .4569698 |
|  | /lnsig2u | 2.248281    | .1156237  |       |       | 2.021663             | 2.4749   |
|  | sigma_u  | 3.077571    | .17792    |       |       | 2.747885             | 3.446812 |
|  | rho      | .7421998    | .0221233  |       |       | .6965274             | .7831387 |

LR test of rho=0: chibar2(01) = 1504.00      Prob >= chibar2 = 0.000

### Efectos marginales (promedio) en RE Logit:

```
Average marginal effects      Number of obs = 4,360
Model VCE: OIM

Expression: Pr(union=1 | u_i=0), predict(pu0)
dy/dx wrt: educ
```

|  |      | Delta-method |           |       |       | [95% conf. interval] |          |
|--|------|--------------|-----------|-------|-------|----------------------|----------|
|  |      | dy/dx        | std. err. | z     | P> z  |                      |          |
|  | educ | -.0059833    | .0061477  | -0.97 | 0.330 | -.0180325            | .0060659 |

### Efectos marginales (condicionales) en RE Logit:

Conditional marginal effects  
Model VCE: OIM

Number of obs = 4,360

Expression:  $\Pr(\text{union}=1 \mid u_i=0)$ , predict(pu0)  
dy/dx wrt: educ  
At: educ = 11.76697 (mean)

|      |           | Delta-method |       |       |                      |         |
|------|-----------|--------------|-------|-------|----------------------|---------|
|      | dy/dx     | std. err.    | z     | P> z  | [95% conf. interval] |         |
| educ | -.0059476 | .0060407     | -0.98 | 0.325 | -.0177872            | .005892 |

Sí, surge el mismo problema que en el inciso anterior a la hora de estimar el efecto parcial de interés.

**(f)** *Computar el denominado estimador Logit de efectos fijos para el modelo (5). ¿Se puede computar el efecto de un año más de educación sobre la probabilidad de estar afiliado a un sindicato? Explicar.*

El efecto de un año más de educación sobre la probabilidad de estar afiliado a un sindicato no se puede computar, ya que, en este método no se identifican los coeficientes de los regresores que no varían en el tiempo, como es el caso de la variable *educ* en este ejercicio. Sin embargo, incluso si el coeficiente estuviera identificado (en el caso de que la variable varíe en el tiempo), sucedería lo de los incisos anteriores de que se debería imponer el valor de  $c_i$  sumado a que, en este caso, es difícil saber qué valor imponer, ya que no se está asumiendo que se conoce la distribución de  $c_i$ .

**(g)** *Considerar la siguiente extensión del modelo (4):*

$$P(\text{union}_{it} = 1 \mid \text{educ}_{it}, \text{black}_{it}, \text{married}_{it}, c_i) = \Phi(\beta_0 + \beta_1 \text{educ}_{it} + \beta_2 \text{black}_{it} + \beta_3 \text{married}_{it} + c_i), \quad (6)$$

donde  $\text{black}_{it}$  es una variable binaria que toma valor 1 si la persona es afroamericana y  $\text{married}_{it}$  es una variable binaria que toma valor 1 si la persona es casada. Asumir la siguiente versión de Mundlak (1978) del supuesto de Chamberlain (1980):

$$c_i \mid X_i \sim \text{Normal}(\psi + \xi \overline{\text{married}_i}, \sigma_a^2) \quad (7)$$

El modelo dado por (6) y (7) es un caso de lo que, en la literatura, se denomina modelo Probit de efectos aleatorios de Chamberlain. Al asumir sólo (6) y (7), se tiene que:

$$\begin{aligned} P(\text{union}_{it} = 1 \mid \text{educ}_{it}, \text{black}_{it}, \text{married}_{it}, c_i) &= \\ \Phi[(\beta_0 + \beta_1 \text{educ}_{it} + \beta_2 \text{black}_{it} + \beta_3 \text{married}_{it} + \psi + \xi \overline{\text{married}_i}) (1 + \sigma_a^2)^{-\frac{1}{2}}] &= \\ \Phi(\beta_{0,a} + \beta_{1,a} \text{educ}_{it} + \beta_{2,a} \text{black}_{it} + \beta_{3,a} \text{married}_{it} + \xi_a \overline{\text{married}_i}). \end{aligned}$$

*Usar Pooled Probit para estimar el modelo. Estimar el efecto de la escolaridad sobre la probabilidad de estar sindicalizado para una persona afroamericana casada.*

### Pooled Probit:

```
Probit regression                                Number of obs = 4,360
                                                Wald chi2(4) = 15.55
                                                Prob > chi2 = 0.0037
Log pseudolikelihood = -2389.9119              Pseudo R2 = 0.0136
```

(Std. err. adjusted for 545 clusters in nr)

|              |         |             | Robust    |       |       |                      |
|--------------|---------|-------------|-----------|-------|-------|----------------------|
|              | union   | Coefficient | std. err. | z     | P> z  | [95% conf. interval] |
|              | educ    | -.0031662   | .0219937  | -0.14 | 0.886 | -.0462731 .0399408   |
|              | black   | .4707704    | .1297179  | 3.63  | 0.000 | .216528 .7250127     |
|              | married | .0425222    | .0532229  | 0.80  | 0.424 | -.0617927 .1468371   |
| mean_married |         | .2052462    | .1316841  | 1.56  | 0.119 | -.0528499 .4633423   |
| _cons        |         | -.8279919   | .2671794  | -3.10 | 0.002 | -1.351654 -.3043298  |

### Efectos marginales (condicionales) en Pooled Probit:

```
Conditional marginal effects                    Number of obs = 4,360
Model VCE: Robust
```

```
Expression: Pr(union), predict()
dy/dx wrt: educ
At: educ = 11.47692
      black = 1
      married = 1
      mean_married = .6923077
```

|  |      |           | Delta-method |       |       |                      |
|--|------|-----------|--------------|-------|-------|----------------------|
|  |      | dy/dx     | std. err.    | z     | P> z  | [95% conf. interval] |
|  | educ | -.0012358 | .0085842     | -0.14 | 0.886 | -.0180605 .0155888   |

**Ejercicio 2.**

Considerar los datos del ejercicio previo para analizar la probabilidad de estar afiliado a un sindicato según la situación de afiliación sindical del año previo.

(a) Usar Pooled Probit para estimar el modelo:

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1}) = \Phi(\psi + \rho \text{union}_{it-1}) \quad (8)$$

A continuación, obtener una estimación para

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1} = 1)$$

y para

$$P(\text{union}_{it} = 1 \mid \text{union}_{it-1} = 0).$$

Comentar sobre el efecto marginal de estar afiliado a un sindicato en el año t-1 en la probabilidad de estar afiliado a un sindicato en el año t.

**Pooled Probit:**

Probit regression

Number of obs = 3,815

LR chi2(1) = 1416.84

Prob > chi2 = 0.0000

Log likelihood = -1406.9979

Pseudo R2 = 0.3349

| union | Coefficient | Std. err. | z      | P> z  | [95% conf. interval] |           |
|-------|-------------|-----------|--------|-------|----------------------|-----------|
| union |             |           |        |       |                      |           |
| L1.   | 1.953334    | .055067   | 35.47  | 0.000 | 1.845404             | 2.061263  |
|       |             |           |        |       |                      |           |
| _cons | -1.348154   | .0328877  | -40.99 | 0.000 | -1.412613            | -1.283695 |

El efecto marginal de estar afiliado a un sindicato en el año t-1 en la probabilidad de estar afiliado a un sindicato en el año t es 0,639.

(b) Adicionar al modelo el conjunto completo de variables binarias temporales. Volver a estimar las probabilidades solicitadas para cada año de la muestra.



Pooled Probit (con variables binarias temporales):

|                             |                       |
|-----------------------------|-----------------------|
| Probit regression           | Number of obs = 3,815 |
|                             | LR chi2(7) = 1432.42  |
|                             | Prob > chi2 = 0.0000  |
| Log likelihood = -1399.2079 | Pseudo R2 = 0.3386    |

|       | union | Coefficient | Std. err. | z      | P> z  | [95% conf. interval] |           |
|-------|-------|-------------|-----------|--------|-------|----------------------|-----------|
| union |       |             |           |        |       |                      |           |
| l1.   |       | 1.967931    | .0554571  | 35.49  | 0.000 | 1.859237             | 2.076625  |
| d82   |       | .0412915    | .0960685  | 0.43   | 0.667 | -.1469994            | .2295824  |
| d83   |       | -.0513702   | .0981709  | -0.52  | 0.601 | -.2437816            | .1410412  |
| d84   |       | .0046824    | .0980729  | 0.05   | 0.962 | -.1875369            | .1969016  |
| d85   |       | -.1584597   | .1003127  | -1.58  | 0.114 | -.3550689            | .0381495  |
| d86   |       | -.1384916   | .1007772  | -1.37  | 0.169 | -.3360114            | .0590282  |
| d87   |       | .1744346    | .0957908  | 1.82   | 0.069 | -.013312             | .3621812  |
| _cons |       | -1.339921   | .0712489  | -18.81 | 0.000 | -1.479566            | -1.200275 |

- El efecto marginal de estar afiliado a un sindicato en el año 1981 en la probabilidad de estar afiliado a un sindicato en el año 1982 es 0,651.
- El efecto marginal de estar afiliado a un sindicato en el año 1982 en la probabilidad de estar afiliado a un sindicato en el año 1983 es 0,636.
- El efecto marginal de estar afiliado a un sindicato en el año 1983 en la probabilidad de estar afiliado a un sindicato en el año 1984 es 0,646.
- El efecto marginal de estar afiliado a un sindicato en el año 1984 en la probabilidad de estar afiliado a un sindicato en el año 1985 es 0,614.
- El efecto marginal de estar afiliado a un sindicato en el año 1985 en la probabilidad de estar afiliado a un sindicato en el año 1986 es 0,618.
- El efecto marginal de estar afiliado a un sindicato en el año 1986 en la probabilidad de estar afiliado a un sindicato en el año 1987 es 0,667.

(c) *Estimar un modelo de efectos no observables dinámico. Usar el modelo Probit de efectos aleatorios incluyendo  $union_{i,80}$  como una variable explicativa adicional. Luego, promediar las probabilidades estimadas a lo largo de  $union_{i,80}$  para obtener la probabilidad promedio de estar afiliado a un sindicato en el año 1987 dado que estaba afiliado en el período anterior.*

### RE Probit:

```
Random-effects probit regression          Number of obs   = 3,815
Group variable: nr                      Number of groups = 545

Random effects u_i ~ Gaussian           Obs per group:
                                         min = 7
                                         avg = 7.0
                                         max = 7

Integration method: mvaghermite         Integration pts. = 12

Log likelihood = -1293.5235              Wald chi2(8)     = 335.28
                                         Prob > chi2      = 0.0000
```

|          | union   | Coefficient | Std. err. | z      | P> z  | [95% conf. interval] |           |
|----------|---------|-------------|-----------|--------|-------|----------------------|-----------|
| union    | L1.     | .8886017    | .0923747  | 9.62   | 0.000 | .7075507             | 1.069653  |
|          | d82     | .0398224    | .1134088  | 0.35   | 0.725 | -.1824547            | .2620995  |
|          | d83     | -.0636919   | .1163085  | -0.55  | 0.584 | -.2916524            | .1642686  |
|          | d84     | -.0119455   | .116519   | -0.10  | 0.918 | -.2403185            | .2164276  |
|          | d85     | -.224562    | .1192335  | -1.88  | 0.060 | -.4582554            | .0091315  |
|          | d86     | -.2661777   | .1199779  | -2.22  | 0.027 | -.5013301            | -.0310253 |
|          | d87     | .1277544    | .1136075  | 1.12   | 0.261 | -.0949122            | .3504211  |
|          | union80 | 1.479094    | .1659071  | 8.92   | 0.000 | 1.153922             | 1.804266  |
|          | _cons   | -1.791908   | .1172376  | -15.28 | 0.000 | -2.02169             | -1.562127 |
| /lnsig2u |         | .2114328    | .1648497  |        |       | -.1116665            | .5345322  |
| sigma_u  |         | 1.111507    | .0916157  |        |       | .9456968             | 1.306388  |
| rho      |         | .5526622    | .0407552  |        |       | .4721123             | .6305396  |

LR test of rho=0: chibar2(01) = 160.37      Prob >= chibar2 = 0.000

La probabilidad promedio de estar afiliado a un sindicato en el año 1987 dado que estaba afiliado en el período anterior es 0,397.