

Trabajo Práctico N° 2: **Matching.**

Ejercicio 1: Exact Matching.

(Basado en Cunningham) Este ejercicio propone utilizar el procedimiento de matching sobre una variable para pensar en términos simples de dónde provienen los estimadores de Matching. Hoy en día, es conocimiento común que fumar aumenta la tasa de mortalidad. Sin embargo, esta afirmación no proviene de datos experimentales.

Table 5.1: Death rates per 1,000 person-years (Cochran 1968)

Smoking group	Canada	UK	US
Non-smokers	20,2	11,3	13,5
Cigarettes	20,5	14,1	13,5
Cigars/pipes	35,5	20,7	17,4

Table 5.2: Mean ages, years (Cochran 1968).

Smoking group	Canada	UK	US
Non-smokers	54,9	49,1	57,0
Cigarettes	50,5	49,8	53,2
Cigars/pipes	65,9	55,7	59,7

(a) Considerar los datos de mortalidad y condición de fumador de la Tabla 1. ¿Qué resultado da la diferencia de medias entre grupos de fumadores en términos de tasa de mortalidad? ¿Qué pide el supuesto de independencia? En particular, comentar qué espera que pase con otras variables observables.

El resultado que da la diferencia de medias entre grupos de fumadores en términos de tasa de mortalidad es 15, 6,6 y 3,9 para Canadá, UK, US, respectivamente. El supuesto de independencia pide que la media de la tasa de mortalidad entre grupos sea igual. En particular, se espera que las variables observables entre fumadores no deberían ser, en promedio, diferentes, es decir, los grupos deberían ser balanceados.

(b) Considerar la edad de las personas. ¿Qué se puede decir sobre el supuesto de independencia?

Considerando la edad de las personas, lo que se puede decir sobre el supuesto de independencia es que no se cumpliría, ya que esta característica no es independiente del resultado potencial.

(c) Estimar el efecto correcto.

Ejercicio 2: Teorema de Rosenbaum y Rubin.

*Demostrar el siguiente teorema. Sean $Y(0)$, $Y(1)$ resultados potenciales, X un tratamiento binario, W un vector de características observables. Suponiendo que vale el supuesto de *unconfoundedness*, se define $e(W)$ como la probabilidad de recibir el tratamiento en función de variables observables. Luego $(Y(0), Y(1) \perp X \mid e(W))$. Como corolario:*

$$ATE = E[E[Y^{obs} \mid X=1, e(W)] - E[Y^{obs} \mid X=0, e(W)]]$$

$$P(X=1 \mid Y(0), Y(1), e(W)) = E(X \mid Y(0), Y(1), e(W))$$

$$P(X=1 \mid Y(0), Y(1), e(W)) = E(E(X \mid Y(0), Y(1), e(W), W) \mid Y(0), Y(1), e(W))$$

$$P(X=1 \mid Y(0), Y(1), e(W)) = E(E(X \mid W) \mid Y(0), Y(1), e(W))$$

$$P(X=1 \mid Y(0), Y(1), e(W)) = E(e(W) \mid Y(0), Y(1), e(W))$$

$$P(X=1 \mid Y(0), Y(1), e(W)) = e(W)$$

El resultado implica que los resultados potenciales son independientes del tratamiento habiendo condicionado en la probabilidad de recibir el tratamiento, $e(W)$ (el llamado *propensity score*). Como se tiene el resultado demostrado al nivel de la probabilidad, esto implica el resultado deseado para las esperanzas y se puede calcular el ATE habiendo condicionado en el *propensity score* en vez de en todas las características W .

El teorema de Rosenbaum y Rubin sugiere un procedimiento aplicado para estimar los efectos promedios de tratamiento: calcular la probabilidad $e(W)$ de recibir el tratamiento en función de las características W y hacer un *matching* en esta variable que resume las anteriores. Esto, además, simplifica el problema de dimensionalidad de emparejar muchas variables con algunas, potencialmente, continuas. El supuesto de *unconfoundedness* es necesario para el teorema de Rosenbaum y Rubin. No se puede reemplazar fallas en este supuesto y esperar que se solucione haciendo *Propensity Score Matching*.

Ejercicio 3: Propensity Score Matching.

Para solucionar el problema de la dimensionalidad utilizando matching sobre múltiples variables, se puede reducir el conjunto de variables en una sola, la llamada propensity score, puntaje de propensión o probabilidad de recibir el tratamiento. En este ejercicio, se propone realizar una evaluación del impacto de fumar durante el embarazo sobre el peso de los bebés en base a datos observacionales. Utilizando la base de datos “cattaneo2.dta” que utiliza Cattaneo (XX), responder las siguientes preguntas.

(a) *Comprobar si los grupos de control y de tratamiento están balanceados.*

Stata.

(b) *¿Cuál es la diferencia de medias simple?*

Stata.

(c) *Estimar la probabilidad de recibir el tratamiento con un modelo Logit. Utilizar como variables explicativas mmarried, deadkids, nprenatal, monthslb, prenatal, fbaby y alcohol. Definir una sección de soporte común.*

Stata.

(d) *Estimar el efecto promedio de tratamiento sobre los tratados utilizando Propensity Score Matching implementando nearest-neighbor matching, radius matching, kernel matching y stratification matching.*

Nearest-Neighbor Matching:

ATT estimation with Nearest Neighbor Matching method
(random draw version)
Bootstrapped standard errors

n. treat.	n. contr.	ATT	Std. Err.	t

864	659	-235.279	37.700	-6.241

Note: the numbers of treated and controls refer to actual
nearest neighbour matches

Radius Matching:

ATT estimation with the Radius Matching method

Bootstrapped standard errors

n. treat.	n. contr.	ATT	Std. Err.	t
863	864	-246.371	34.574	-7.126

Note: the numbers of treated and controls refer to actual matches within radius

Kernel Matching:

ATT estimation with the Kernel Matching method

Bootstrapped standard errors

n. treat.	n. contr.	ATT	Std. Err.	t
864	864	-229.593	31.817	-7.216

Stratification Matching:

ATT estimation with the Stratification method

Bootstrapped standard errors

n. treat.	n. contr.	ATT	Std. Err.	t
864	864	-227.836	25.709	-8.862

(e) Estimar el efecto promedio de tratamiento utilizando nearest-neighbour matching.

Matching estimator: Average Treatment Effect

Number of obs = 1728
Number of matches (m) = 1

bweight	Coefficient	Std. err.	z	P> z	[95% conf. interval]	
SATE	-209.5832	28.82159	-7.27	0.000	-266.0725	-153.0939

Matching variables: e_x

Bias-adj variables: mmarried alcohol deadkids nprenatal monthslb prenatal fbaby

(f) Estimar el efecto promedio de tratamiento utilizando ajuste por regresión.

Treatment-effects estimation
Estimator : regression adjustment
Outcome model : linear
Treatment model: none

Number of obs = 1,728

	bweight	Coefficient	Robust std. err.	z	P> z	[95% conf. interval]	
ATE							
	mbsmoke						
(smoker vs nonsmoker)		-203.0403	26.27955	-7.73	0.000	-254.5473	-151.5334
POmean							
	mbsmoke						
	nonsmoker	3343.881	19.0128	175.88	0.000	3306.616	3381.145

(g) Estimar el efecto promedio de tratamiento utilizando inverse probability weighting.

Treatment-effects estimation
Estimator : inverse-probability weights
Outcome model : weighted mean
Treatment model: logit

Number of obs = 1,728

	bweight	Coefficient	Robust std. err.	z	P> z	[95% conf. interval]	
ATE							
	mmarried						
(married vs notmarried)		103.099	28.54709	3.61	0.000	47.14773	159.0503
POmean							
	mmarried						
	notmarried	3191.532	20.32589	157.02	0.000	3151.694	3231.37

(h) Estimar el efecto promedio de tratamiento utilizando el estimador doblemente robusto.

		Coefficient	Robust std. err.	z	P> z	[95% conf. interval]	
ATE							
	mbsmoke						
	(smoker vs nonsmoker)	-203.1215	26.27575	-7.73	0.000	-254.621	-151.622
POmean							
	mbsmoke						
	nonsmoker	3343.847	19.01012	175.90	0.000	3306.588	3381.107

Ejercicio 4: Estimador de Matching sin Características Observables.

Suponer que vale el supuesto de unconfoundedness. En este ejercicio, se propone computar la expresión analítica del estimador de PSM cuando la probabilidad de recibir el tratamiento no depende de características observables. Utilizar el corolario del Ejercicio 2.

$$ATE = E [E [Y^{obs} | X = 1, e(W)] - E [Y^{obs} | X = 0, e(W)]].$$

$$\widehat{ATE} = E (\hat{\mu}_1 - \hat{\mu}_0)$$

$$\widehat{ATE} = E \left[\frac{n^{-1} \sum_{i=1}^n Y_i^{obs}(X_i=1)}{n^{-1} \sum_{i=1}^n I(X_i=1)} - \frac{n^{-1} \sum_{i=1}^n Y_i^{obs}(X_i=0)}{n^{-1} \sum_{i=1}^n I(X_i=0)} \right]$$

$$\widehat{ATE} = E \left[\frac{n^{-1} \sum_{i=1}^n Y_i^{obs} x_i}{n^{-1} \sum_{i=1}^n x_i} - \frac{n^{-1} \sum_{i=1}^n Y_i^{obs} (1-x_i)}{n^{-1} \sum_{i=1}^n (1-x_i)} \right]$$

$$\widehat{ATE} = E \left[\frac{n^{-1} \sum_{i=1}^n Y_i^{obs} x_i}{\bar{x}} - \frac{n^{-1} \sum_{i=1}^n Y_i^{obs} (1-x_i)}{1-\bar{x}} \right]$$

$$\widehat{ATE} = E \left[n^{-1} \sum_{i=1}^n Y_i^{obs} \left(\frac{x_i}{\bar{x}} - \frac{1-x_i}{1-\bar{x}} \right) \right]$$

$$\widehat{ATE} = E \left[n^{-1} \sum_{i=1}^n Y_i^{obs} \frac{x_i - \bar{x}}{\bar{x}(1-\bar{x})} \right]$$

$$\widehat{ATE} = E \left[\frac{\sum_{i=1}^n Y_i^{obs} \frac{x_i - \bar{x}}{\bar{x}(1-\bar{x})}}{n} \right]$$

$$\widehat{ATE} = E \left(\frac{\sum_{i=1}^n Y_i^{obs} \omega_i}{n} \right),$$

donde:

$$\omega_i = \frac{x_i - \bar{x}}{\bar{x}(1-\bar{x})}$$

$$\omega_i = \frac{x_i - p}{p(1-p)}.$$