

# Aprendizaje Supervisado con Series Temporales



## Singular Spectrum Analysis

Gabriel Martos Venturini  
*[gmartos@utdt.edu](mailto:gmartos@utdt.edu)*



UNIVERSIDAD  
TORCUATO DI TELLA

## Bibliografía recomendada



- *Principal Component Analysis*. Jolliffe (§ 12).

# Agenda

## Singular Spectrum Analysis

- Introducción

- El modelo univariante

- Implementación en R

## Forecasting y selección de modelos con SSA

## Apéndice

# Agenda

## Singular Spectrum Analysis

- Introducción

- El modelo univariante

- Implementación en R

Forecasting y selección de modelos con SSA

Apéndice

# Agenda

## Singular Spectrum Analysis

### Introducción

El modelo univariante

Implementación en R

Forecasting y selección de modelos con SSA

Apéndice

# Motivación

- ▶ Las técnicas convencionales de análisis de series temporales (modelos ARIMA y extensiones) requieren de supuestos fuertes (estacionareidad) en los mecanismos de generación de datos.
- ▶ Singular Spectrum Analysis (SSA):
  - ▶ No necesitamos asumir **estacionareidad**.
  - ▶ Descomponemos la serie en diferentes componentes que pueden ser interpretadas como elementos de la tendencia, los ciclos y el ruido.

$$Y(t) = \underbrace{f_1(t) + \cdots + f_m(t)}_{\text{Señal}} + \underbrace{\varepsilon(t)}_{\text{Ruido}}$$

- ▶ Forecasting: Relación de recurrencia lineal.
- ▶ Extensible al contexto multivariante.
- ▶ Drawback: Escasos elementos para construir herramientas de inferencia en torno a las estimaciones que hacemos con el modelo.

## Algunas referencias

- ▶ de Carvalho, Martos (2021): *Modeling Interval Trendlines: Symbolic Singular Spectrum Analysis for Interval Time Series*. JF.
- ▶ de Carvalho, Martos (2020): *Brexit: Tracking and disentangling the sentiment towards leaving the EU*. IJF
  - ▶ ASSA: *Applied Singular Spectrum Analysis*.
- ▶ Hassani, Soofi, Zhigljavsky (2013): *Predicting inflation dynamics with singular spectrum analysis*. JRSS.
- ▶ Hassani, Soofi, Zhigljavsky (2010): *Predicting daily exchange rate with singular spectrum analysis*. NonLinAnalysis.
- ▶ de Carvalho, Rodriguez, Rua (2012): *Tracking the US business cycle with a singular spectrum analysis*. Economics Letters.
- ▶ Hassani, Heravi, Zhigljavsky. (2009): *Forecasting European industrial production with singular spectrum analysis*. IJF.

# Agenda

## Singular Spectrum Analysis

Introducción

El modelo univariante

Implementación en R

Forecasting y selección de modelos con SSA

Apéndice



# Etapas de SSA y outputs del modelo

Dado el conjunto train  $\{y_1, \dots, y_n\}$  el *algoritmo* SSA tiene dos etapas:

## A Decomposition.

A.1 Embedding (parámetro sensible  $l$ ).

A.2 Singular value decomposition.

## B Reconstruction.

B.1 Grouping (parámetro sensible  $m$ ).

B.2 Diagonal averaging (“Hankelización”).

## ► Outputs del modelo:

- Conjunto de “componentes principales” que nos permiten construir una versión *filtrada* de la serie (nowcasting:  $\tilde{\mathbf{y}} = (\tilde{y}_1, \dots, \tilde{y}_n)$ ).
- Los elementos necesarios para extrapolar las componentes asociadas a la tendencia y el ciclo hacia el futuro (forecasting).

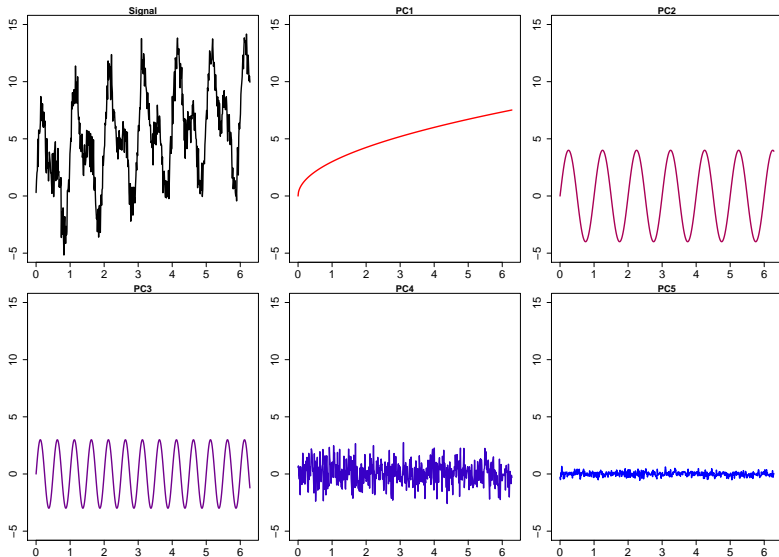


Figure: "l" impacta en la forma en que construimos estas 'componentes principales'. "m" indica cuantas componentes utilizamos para extrapolar.

## A.1 Embedding

- ▶ Reorganizamos  $\{y_1, \dots, y_n\}$  en una matriz de **trayectorias**:

$$\mathbf{X}_{l \times k} = \begin{bmatrix} y_1 & y_2 & \cdots & y_k \\ y_2 & y_3 & \cdots & y_{k+1} \\ \vdots & \vdots & \ddots & \vdots \\ y_l & y_{l+1} & \cdots & y_n \end{bmatrix}.$$

- ▶  $l$  es un parámetro de localidad ( $k \equiv n - l + 1$ ).
  - ▶ Algunos resultados teóricos sugieren que  $l \approx n/2$ .
- ▶ Elegir  $l$  por “VC” si el objetivo es hacer predicciones.
- ▶ Notar que  $\mathbf{X}$  es una matriz **Hankel**.
  - ▶ A toda matriz de trayectorias le corresponde una serie temporal y viceversa (hay una relación biunívoca entre  $\{y_1, \dots, y_n\}$  y  $\mathbf{X}$ ).

## A.2 SVD

- ▶ Sean  $\sigma_1 \geq \dots \geq \sigma_l$  las raíces de los autovalores de  $\mathbf{X}\mathbf{X}^T$
- ▶  $\mathbf{u}_1, \dots, \mathbf{u}_l$  los correspondientes autovectores de  $\mathbf{X}\mathbf{X}^T$ .

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \equiv \sum_{i=1}^d \mathbf{Z}_i, \quad \text{▶ (Ver detalles en Apénice)}$$

- ▶ donde  $\mathbf{Z}_i = \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ ,  $\mathbf{v}_i = \mathbf{X}^T \mathbf{u}_i / \sigma_i$ , y

$$d = \max\{i \in \{1, \dots, l\} : \sigma_i > 0\} = \text{rank}(\mathbf{X}).$$

- ▶  $\mathbf{X}$  se descompone como una suma de  $d$  matrices de rango 1.
- ▶ Cada matriz  $\mathbf{Z}_i$  para  $i = 1, \dots, d$  esta asociada a una 'componente principal' de la serie original  $\{y_1, \dots, y_n\}$ .

## (BackUp slide)

- ¿Qué representa la matriz  $\mathbf{XX}^T$ ?

$$\mathbf{XX}^T = \begin{bmatrix} \sum_{j=1}^k y_j^2 & \sum_{j=1}^k y_j y_{j+1} & \cdots & \sum_{j=1}^k y_j y_{j+l-1} \\ \sum_{j=1}^k y_{j+1} y_j & \sum_{j=1}^k y_{j+1}^2 & \cdots & \sum_{j=1}^k y_{j+1} y_{j+l-1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{j=1}^k y_{j+l-1} y_j & \sum_{j=1}^k y_{j+l-1} y_{j+1} & \cdots & \sum_{j=1}^k y_{j+l-1}^2 \end{bmatrix}.$$

- $\mathbf{XX}^T$  es una estimación “local” de la función de autocovarianza.
- La descomposición en valores y vectores propios de  $\mathbf{XX}^T$  nos permite descomponer la serie como una suma de componentes que pueden interpretarse como tendencia, ciclos y ruido.
  - PCA para series temporales.

## B.1 Agrupamiento

- ▶ Objetivo: Separar la señal del ruido.
- ▶ Para  $\mathcal{I} \subset \{1, \dots, d\}$  computamos

$$\mathbf{X}_{\mathcal{I}} = \sum_{i \in \mathcal{I}} \mathbf{z}_i.$$

- ▶ Generalmente ocurre que  $\mathcal{I} = \{1, \dots, m\}$  con  $m \ll d$ .
- ▶ Criterios prácticos para elegir  $m$ :
  - ▶  $m_c = \min\{q : \sum_{i=1}^q \sigma_i / \sum_{j=1}^d \sigma_j \geq c\}$ , con  $c \in [0.7, 0.9]$ .
  - ▶ Scree plot:  $\{(i, \sigma_i)\}_{i=1}^d$  para definir el corte (criterio del “codo”).
  - ▶ Criterio estadístico para automatizar la selección de componentes.
  - ▶ VC: Minimizamos el error de predicción fuera de la muestra.
- ▶ En general  $\mathbf{X}_{\mathcal{I}}$  no será una matriz Hankel.

## B.2 Hankelización

Promediamos sobre las antidiagonales de  $\mathbf{X}_{\mathcal{I}}$  (Hankelizamos, ver BackUp) para construir la versión filtrada de la serie  $\tilde{\mathbf{y}} = (\tilde{y}_1, \dots, \tilde{y}_n)$ :

$$\tilde{\mathbf{y}} = \overline{\mathbb{D}}(\mathbf{X}_{\mathcal{I}}) = \left( \frac{1}{|\mathcal{A}_1|} \sum_{(i,j) \in \mathcal{A}_1} x_{ij}^l, \dots, \frac{1}{|\mathcal{A}_n|} \sum_{(i,j) \in \mathcal{A}_n} x_{ij}^l \right),$$

$|A|$  denota la cardinalidad del conjunto  $A$ , y la secuencia de conjuntos:

$$\mathcal{A}_c = \{(i, j) : i + j = c + 1, i \in \{1, \dots, l\}, j \in \{1, \dots, k\}\}, \quad c = 1, \dots, n,$$

definen los elementos pertenecientes a las  $n$  antidiagonales de  $\mathbf{X}_{\mathcal{I}}$ .

- ▶ El output del modelo  $\tilde{\mathbf{y}}$  es una versión *filtrada* de la serie original.
- ▶ Con  $\tilde{\mathbf{y}}$ , los elementos de la descomposición, y el supuesto de recurrencia lineal construimos las predicciones (a continuación).

## (BackUp)

Hankelizar = hacer promedios antidiagonales. Si

$$\mathbf{X}_{\mathcal{I}} = \begin{bmatrix} a_{11} & \textcolor{blue}{a}_{12} & \textcolor{red}{a}_{13} & \cdots & a_{1k} \\ \textcolor{blue}{a}_{21} & \textcolor{red}{a}_{22} & a_{23} & \cdots & a_{2k} \\ \textcolor{red}{a}_{31} & a_{32} & a_{33} & \cdots & a_{3k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{l1} & a_{l2} & a_{l3} & \cdots & a_{lk} \end{bmatrix}.$$

entonces:

$$\tilde{y}_1 = a_{11}, \quad \tilde{y}_2 = \frac{\textcolor{blue}{a}_{12} + \textcolor{blue}{a}_{21}}{2}, \quad \tilde{y}_3 = \frac{\textcolor{red}{a}_{13} + \textcolor{red}{a}_{22} + \textcolor{red}{a}_{31}}{3}, \dots, \quad \tilde{y}_n = a_{lk}.$$



## Criterio estadístico para determinar $\mathcal{I}$ (BackUp)

El *periodograma* asociado a  $\mathbf{y} = (y_1, \dots, y_n)$  se corresponde con  $\{(\omega_j, \mathbb{I}(\omega_j))\}_{j=1}^J$ , donde  $\omega_j = 2\pi j/n$  para  $j = 1, \dots, J = \lfloor n/2 \rfloor$ .

$$\mathbb{I}(\omega_j) = \frac{1}{n} \left| \sum_{t=1}^n y_t \exp^{-it\omega_j} \right|^2.$$

### Targeted grouping based on the Kolmogorov–Smirnov statistic

Set  $i = 1$  and execute the steps:

- Step 1. Compute residuals  $\varepsilon = \mathbf{y} - \tilde{\mathbf{y}}$ , yield from SSA on  $\mathcal{I} = \{1, \dots, i\}$ .
- Step 2. Compute the periodogram of  $\varepsilon$  to test the null hypothesis of white noise using the Kolmogorov–Smirnov test based on the statistic:

$$\sqrt{J} \max\{|C(\omega_j) - j/J|\}_{j=1}^J, \quad C(\omega_j) = \frac{\sum_{i=1}^j \mathbb{I}(\omega_i)}{\sum_{i=1}^J \mathbb{I}(\omega_i)}.$$

If the null is rejected then make  $i = i + 1$  and repeat Steps 1 and 2. Otherwise stop.

# Agenda

## Singular Spectrum Analysis

Introducción

El modelo univariante

Implementación en R

Forecasting y selección de modelos con SSA

Apéndice

## Nowcasting: Brexit poll tracker data

Datos composicionales:  $\{(p_t, s_t, u_t)\}_{t=1}^n$  (leave–stay–undecided).

**Table:** Summary statistics for the 16 houses included in the poll tracker.

Poll-house	Mean Nmb Resp	n-pools
BMG Research	1464	8
ComRes	2258	16
Greenberg QR Research	2327	2
Harris	2114	1
ICM	1883	47
Ipsos MORI	909	12
Lord Ashcroft Polls	20058	1
Opinium	1970	13
ORB	1294	19
Panelbase	1547	2
Pew Research Center	1006	2
Populus	3368	2
Survation	1879	22
TNS	1414	12
YouGov	1882	113

<https://ig.ft.com/sites/brexit-polling/>

## Paquete ASSA 2.0 en R

```
y = tsframe(dates, y)
sst(y, l = "automatic", m = "automatic")
```

Arguments:

y: tsframe format data.

l: window length; "automatic" sets the default option  
 $l = \text{ceiling}(y\$n + 1) / 2$ .

m: number of leading eigentriples. An automatic criterion based on the cumulative periodogram of the residuals is provided by default.

- ▶ ASSA (2.0 en adelante) tiene implementados varios modelos de SSA (uni y multi variantes); los métodos automáticos de selección de modelos y las rutinas necesarias para hacer forecasting (next).
- ▶ Competencia: Rssa (Golyandina et al).

## Nowcasting: SSA vs MSSA

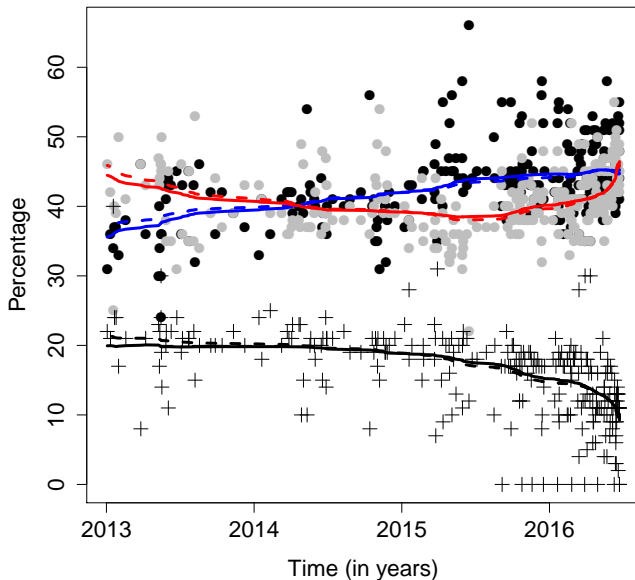


Figure: SSA vs MSSA (automatic) trendline estimations.

# Agenda

Singular Spectrum Analysis

Forecasting y selección de modelos con SSA

Apéndice

# Recurrencia lineal y predicciones

- ▶ RL:  $y_{n+1} = s_{n+1} + \varepsilon_{n+1}$ , con  $s_{n+1} = \phi_1 s_n + \cdots + \phi_{l-1} s_{n+1-l}$ .
  - ▶ Golyandina and Zhigljavsky, 2013, Sect 3.8.

- ▶ Elegimos  $(l, m)$  y estimamos:  $\{\tilde{y}_n, \dots, \tilde{y}_1\}$  para forecastear:

$$\hat{y}_{n+1} = a_1 \tilde{y}_n + \cdots + a_{l-1} \tilde{y}_{n+1-l}.$$

- ▶ El vector  $\mathbf{a} = (a_1, \dots, a_{l-1})$  (estimaciones de  $\phi$ ) se obtiene

$$\mathbf{a} = \frac{1}{1 - \nu^2} \sum_{i=1}^m \mathbf{u}_i[l] \mathbf{u}_i[-l] \in \mathbb{R}^{l-1}, \quad \nu^2 = \sum_{i=1}^m \mathbf{u}_i[l]^2.$$

- ▶ Implementado en la versión 2.0 de ASSA.
  - ▶ En algunas versiones de Windows, R necesita que instales Rtools antes de descargar e instalar ASSA 2.0 (necesitas compilar código en C y Fortran para poder correr las rutinas internas del paquete).

# Forecasting con ASSA (versión 2.0 en adelante)

```
predict(modelo, p)
```

## Arguments

modelo: modelo estimado (sst, msst, msstc, isst, misst).

p: horizonte temporal del forecast.

- ▶ El comando predict toma todos los hiperparámetros ( $l, m$ ) seteados en el modelo estimado como inputs para la predicción.
- ▶ Competencia: Rssa (desarrollado por Golyandina et al).



# Selección de modelos: Hold-out set


- ▶ División de la data:



- ▶ Construimos una grilla de posibles valores para  $(l, m)$ .
- ▶ Aprendemos las componentes sobre Train.
- ▶ Forcasteamos sobre Test y computamos MSE o MAE.
- ▶ Elegimos  $(l^*, m^*)$  minimizando las cantidades anteriores.
- ▶ Métrica alternativa: Errores escalados.
  - ▶  $ECE_t = [(y_t - \tilde{y}_t)/y_t]^2$ .
  - ▶  $EAE_t = |(y_t - \tilde{y}_t)/y_t|$ .
- ▶ Aconsejable considerar horizonte de forecast reducidos.


# Selección de modelos: Rolling forecasting origin

- ▶ Ventana creciente para train:



- ▶ Promediamos los errores de predicción a 1 período.
- ▶ Método de validación adecuado cuando vas a utilizar el modelo para hacer predicciones (de corto plazo) de manera dinámica.

- Si queremos considerar horizontes predictivos más largos:



- Puede resultar conveniente utilizar diferentes modelos ( $l$ 's y  $m$ 's distintos) para hacer predicciones a corto, mediano y largo plazo.
- A estos procedimientos NO los deberíamos llamar de “Validación Cruzada”, sino más de bien de validación por fuera de la muestra.

# Caso estudio




Figure: Índice de producción industrial, datos mensuales (período 1919–2019).



*"That's all Folks!"*

# Agenda

Singular Spectrum Analysis

Forecasting y selección de modelos con SSA


Apéndice

## Descomposición en valores singulares (BackUp)

- Descomponemos  $\mathbf{X} \in \mathbb{R}^{l \times k}$  como suma de matrices de rango 1:

$$\mathbf{X} = \mathbf{U}_{l \times d} \mathbf{\Sigma}_{d \times d} \mathbf{V}_{d \times k}^T.$$

Ejemplo para el caso en donde  $\text{rank}(\mathbf{X}) = 2$ .



- $\mathbf{\Sigma}$  contiene las raíces de los autovalores no nulos de  $\mathbf{X}\mathbf{X}^T$  o  $\mathbf{X}^T\mathbf{X}$ .
- $\mathbf{U}$  y  $\mathbf{V}$  contienen los autovectores de  $\mathbf{X}\mathbf{X}^T \in \mathbb{R}^{l \times l}$  y  $\mathbf{X}^T\mathbf{X} \in \mathbb{R}^{k \times k}$ .

## Aproximaciones de rango pequeño (BackUp)

- ▶ Consideremos que  $\Sigma$  tiene ordenados los elementos en su diagonal principal de la siguiente manera:  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_d$ .
- ▶ Para  $r \leq d = \text{rank}(\mathbf{X})$ ,  $\mathbf{X}_r \equiv \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$  es la mejor aproximación de  $\mathbf{X}$  con una matriz de rango  $r$  en el sentido:

$$\mathbf{X}_r = \arg \left\{ \min_{\mathbf{A}} \|\mathbf{X} - \mathbf{A}\|_F, \text{ s.a. } \text{rank}(\mathbf{A}) = r \right\}$$

- ▶ El resultado también vale para otras normas matriciales.
- ▶ Esta es la idea que subyace al hacer SVD y descomponer la matriz de trayectorias en SSA en una suma de matrices de rango 1.
- ▶ [Volver a la slide §-12](#)