



UNIVERSIDAD
TORCUATO DI TELLA

UNIVERSIDAD TORCUATO DI TELLA
DEPARTAMENTO DE ECONOMÍA
MAESTRÍA EN ECONOMETRÍA

**Detección temprana de burbujas especulativas en criptomonedas
mediante *machine learning*: Integrando datos de mercado y métricas
on-chine.**

Alumno: Juan Ignacio Menduiña

Tutor: Gabriel Martos Venturini

Fecha: /10/2026

Resumen

.

Clasificación JEL: .

Palabras clave: .

Abstract

.

JEL classification: .

Keywords: .

Índice

1. Introducción.....	4
2. Revisión de la literatura.....	
3. Datos y estadísticas descriptivas.....	
	3.1.
	3.2.
	3.3.
4. Metodología.....	
	4.1.
	4.2.
5. Resultados.....	
	5.1.
	5.2.
6. Conclusiones.....	
Referencias.....	
Apéndice.....	

1. Introducción

Las burbujas especulativas constituyen episodios recurrentes en los mercados financieros, caracterizados por aumentos abruptos en los precios de activos seguidos de colapsos repentinos, con consecuencias significativas para inversores, instituciones financieras y la estabilidad económica agregada. Desde la burbuja de los tulipanes en Holanda en el siglo XVII hasta la crisis de las puntocom en 2000 y la crisis financiera global de 2008, estos fenómenos han suscitado un interés sostenido en la teoría económica y financiera. La detección temprana de burbujas especulativas es fundamental para la gestión de riesgo y la formulación de políticas regulatorias orientadas a prevenir crisis sistémicas.

El mercado de criptomonedas ha experimentado una evolución particularmente volátil en la última década, marcada por múltiples episodios de burbujas especulativas y colapsos abruptos. Bitcoin, la criptomoneda pionera, alcanzó su primer gran pico histórico en diciembre de 2017 (\$19.798), seguido de un *crash* que eliminó más del 80% de su valor en 2018. Posteriormente, un nuevo ciclo alcista culminó en noviembre de 2021 con precios superiores a \$69.000, antes de un colapso que borró, aproximadamente, 2 billones de dólares en capitalización de mercado crypto durante 2022. A diferencia de los activos tradicionales, las criptomonedas generan métricas *on-chain* únicas derivadas de su infraestructura *blockchain* (NVT, MVRV, variación de direcciones activas, volumen de transacciones en cadena, flujos netos hacia *exchanges*), que no existen en mercados convencionales y que podrían contener señales anticipatorias de episodios de burbuja. Esta característica distintiva, sumada a la alta volatilidad, a la ausencia de fundamentales contables tradicionales y al comportamiento *herding* intensificado por redes sociales, plantea desafíos metodológicos particulares para la detección y la predicción de burbujas en cryptoactivos.

El objetivo de este trabajo es desarrollar y evaluar modelos de *machine learning* para detectar episodios de burbuja en criptomonedas, integrando datos de mercado tradicionales con métricas *on-chain* de la *blockchain*, y evaluar su precisión *out-of-sample* y su capacidad de generalización *cross-asset*, haciendo uso del test econométrico GSADF (*Generalized Supremum Augmented Dickey-Fuller*) de Phillips *et al.* (2015), método estándar para identificar comportamiento explosivo en series de precios. Específicamente, se construye un panel de datos de 25-30 criptomonedas estratificadas por capitalización y liquidez, abarcando Bitcoin (desde 2016) y Ethereum (desde 2017), las principales *altcoins* por capitalización de mercado y una muestra de criptomonedas de capitalización media, para entrenar modelos de *ensemble* (*Random Forest* y *XGBoost*) que clasifiquen períodos de burbuja utilizando, como *ground truth*, los episodios identificados por el test GSADF. Adicionalmente, se evalúa la robustez de los resultados ante definiciones alternativas de burbuja

mediante el diagnóstico de Wheatley *et al.* (2019), que combina sobrevaluación respecto a fundamentales de red estimados por Ley de Metcalfe generalizada y presencia de trayectorias superexponenciales según el modelo LPPLS (*Log-Periodic Power Law Singularity*).

A modo introductorio, [PÁRRAFO QUE MUESTRE UNA SERIE DE PRECIOS EXPLOSIVA DE BTC Y ETH].

Como principales resultados del trabajo, [PÁRRAFO CON PRINCIPALES RESULTADOS].

En este contexto, el trabajo brinda evidencia empírica sobre [PÁRRAFO SOBRE PRINCIPALES APORTES].

El resto del trabajo está estructurado de la siguiente manera. En la sección 2, se presenta la revisión de la literatura sobre detección de burbujas en mercados financieros, con énfasis en métodos econométricos (GSADF, LPPLS) y aplicaciones recientes de *machine learning* en criptomonedas. En la sección 3, se presentan las fuentes de datos, la construcción del panel de criptomonedas y las métricas *on-chain* incorporadas, y estadísticas descriptivas de los episodios de burbuja identificados por GSADF y Wheatley *et al.* (2019). En la sección 4, se describe la metodología, incluyendo la especificación de los modelos de *ensemble* (*Random Forest*, *XGBoost*), la estrategia de ingeniería de *features*, los procedimientos de optimización de hiperparámetros y las estrategias de validación temporal y *cross-asset*. En la sección 5, se analizan los resultados obtenidos. Finalmente, en la sección 6, se concluye.

2. Revisión de la literatura

3. Datos y estadísticas descriptivas

3.1.

3.2.

3.3.

4. Metodología

4.1.

4.2.

5. Resultados

5.1.

5.2.

6. Conclusiones

Referencias

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T. y Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Cheung, A., Roca, E. y Su, J. J. (2015). Crypto-Currency Bubbles: An Application of the Phillips–Shi–Yu (2013) Methodology on Mt. Gox Bitcoin Prices. *Applied Economics*, 47(23), 2348-2358. <http://dx.doi.org/10.1080/00036846.2015.1005827>
- Diebold, F. X. y Mariano, R. S. (1995). Comparing Predictive Accuracy. *Journal of Business & Economic Statistics*, 13(3), 253-263. <https://doi.org/10.2307/1392185>
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). The Elements of Statistical Learning. Springer.
- Li, Y., Wang, Z., Wang, H., Wu, M. y Xie, L. (2021). Identifying Price Bubble Periods in the Bitcoin Market-Based on GSADF Model. *Quality & Quantity*, 55(5), 1829-1844. <https://doi.org/10.1007/s11135-020-01077-4>
- Lundberg, S. M. y Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30. <https://doi.org/10.48550/arXiv.1705.07874>
- Park, S. y Yang, J. S. (2024). Machine Learning Models Based on Bubble Analysis for Bitcoin Market Crash Prediction. *Engineering Applications of Artificial Intelligence*, 133, 108497. <https://doi.org/10.1016/j.engappai.2024.108857>
- Phillips, P. C. B., Shi, S. y Yu, J. (2015). Testing for Multiple Bubbles: Historical Episodes of Exuberance and Collapse in the S&P 500. *International Economic Review*, 56(4), 1043-1078. <https://doi.org/10.1111/iere.12132>
- Tashman, L. J. (2000). Out-of-Sample Tests of Forecasting Accuracy: An Analysis and Review. *International Journal of Forecasting*, 16(4), 437-450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)
- Wheatley, S., Sornette, D., Huber, T., Reppen, M. y Gantner, R. N. (2019). Are Bitcoin Bubbles Predictable? Combining a Generalized Metcalfe's Law and the Log-Periodic Power Law Singularity Model. *Royal Society Open Science*, 6(6), 180538. <https://doi.org/10.1098/rsos.180538>

Apéndice